

8-RL Value Learning

强化学习 RL

假设两台老虎机，一台100%获得1元；另一台75%获得2元，25%获得0元

这当然可以当作一个MDP来解决，简单计算就知道另一台更优，到了实际游戏时，只需要一直拉另一台

但是不知道如果第二台的概率，就需要在实际游戏里测试，得到数据再反过来解决MDP
这就不是一个规划Planning，而是一个学习Learning过程，具体的说，是强化学习

依旧假设问题是一个MDP [6-MDP 价值迭代](#)、[7-MDP 策略迭代](#)：

- 状态state 动作action
- 转移函数 $T(s,a,s')$
- 奖励函数 $R(s,a,s')$
- 目标是找到策略 $\pi(s)$

只不过，**T和R是未知的**，需要通过实际测试才能得到一定数据样本


基于模型的学习 Model-Based Learning

针对MDP，模型指的就是T和R函数。但是在RL中，T和R是未知的

但是能通过一定的探索获得信息，比如：

- 计数 (s,a,s') 统计得到 $T(s,a,s')$
- 根据到达状态 (s,a,s') 后的反馈 统计得到 $R(s,a,s')$ （注意这里的反馈是人类预先设定好的，agent并不知道具体的函数）

得到T和R，就可以转换为之前所说的MDP问题，通过价值迭代等方法来求策略 π
可以根据这个策略继续进行探索，反复进行



无模型学习 Model-Free Learning

区别

假设要求一个班级中学生年龄的期望

两种学习方法都需要采样 $a_1, a_2, \dots, a_n$ (a 是年龄, 下标为一种索引)

基于模型的学习:

根据采样估计出某个年龄的概率 $P(a) = \text{nums}(a) / n$ 然后对各个年龄 a 加权求和 $E(a) = \sum_a P(a) a$

无模型学习:

直接根据采样计算 $E(a) = \frac{1}{n} \sum_i a_i$

这里的概率 P 就相当于之前的 T, R

两种方法:

- Value-Learning
- Q-Learning

价值学习 Value Learning/被动强化学习


在**固定的策略**下, 不断进行游戏, 统计(state, value), 目标是得到**状态的价值**, 而非求出 T, R 然后再求解MDP (基于模型)

但是单通过价值得不到最优策略 (结尾部分会解释)

这不是规划, 因为agent实际上进行了游戏

根据统计到的状态, 有两种计算价值的办法

Example: Direct Evaluation



以状态C为例，总共有4个样本，价值总计为三个 $[-1, 10]=9$ 一个 $[-1, -10]=-11$ ，取平均得到 $V_c = 4$

注意，价值是从一个状态开始未来的预期效用值，也就是把后续所有reward相加

这里因为样本少出现一个问题：if B and E both go to C under this policy, how can their values be different?

这样做的缺点是：

- 只用到了state和对应的reward，浪费了状态转移的信息
- 需要很长的时间，但是只要样本足够，最后可以给出正确的结果

时间差分学习 Temporal Difference Learning/间接评估

既然有固定的策略，为什么不用策略评估来计算状态的价值？

$$V_{k+1}^{\pi}(s) = \sum_{s'} T(s, \pi(s), s') [R(s, \pi(s), s') + \gamma V_k^{\pi}(s')]$$

因为不知道具体的 $T()$ $R()$

时间差分学习是一种可以在不知道 T R 的情况下，用类似价值评估得到价值的方法
核心想法是每次行动后就更新 $V(s)$ ，使用一种动态求平均值的方法

首先初始化所有的 $V^{\pi}(s) = 0$

每次行动获得一个样本(state, action, state', R)，比如(B, east, C, -2)，计算

$$am(()) = R(s, \pi(s), s') + \gamma V^{\pi}(s')$$

(一开始 $V^{\pi}(s')$ 为0，直接带入；之后发生了更新就带入更新后的值) 这个样本代表 $V(s)$ 的一种可能，我们想要的 $V^{\pi}(s) \leftarrow (1-\alpha)V^{\pi}(s) + \alpha \cdot \text{sample}$

或者写成

$$V^{\pi}(s) \leftarrow V^{\pi}(s) + (\alpha \cdot V^{\pi}(s))$$

也就是部分保留了原先的值，也进行了部分的更新，随着 α 的下调，最后 $V^{\pi}(s')$ 可以得到一个收敛的值

这里的 α 叫学习率

(1) 1，越早得到的 sample 占最后 $V^{\pi}(s')$ 的权重逐渐缩小，越后面获得的样本越重要

这也是说得通的，因为越后面获得的样本，带入计算的 $V^{\pi}(s')$ 也是多次更新的结果，也就更接近正确结果

Example: Temporal Difference Learning

States

	A	
B	C	D
	E	

Assume: $\gamma = 1, \alpha = 1/2$

Observed Transitions

B, east, C, -2 C, east, D, -2

	0	
0	0	8
	0	

	0	
-1	0	8
	0	

	0	
-1	3	8
	0	

$V^{\pi}(s) \leftarrow (1 - \alpha)V^{\pi}(s) + \alpha [R(s, \pi(s), s') + \gamma V^{\pi}(s')]$

Handwritten notes:
 $V^{\pi}(C) \leftarrow (1-\alpha)V^{\pi}(C) + \alpha(6)$
 $\leftarrow (1-\frac{1}{2}) \cdot 0 + \frac{1}{2} \cdot 6 = 3$
 $r + \gamma \cdot V(D) = -2 + 1 \cdot 8 = 6$

这个例子里，假设 $\gamma=1$, $\alpha=0.5$

一开始 $V^{\pi}(D)$ 有初始值

(B, east, C, -2) 计算略，这里展示 (C, east, D, -2) 的计算过程

sample = $-2 + 1 * 8 = 6$

更新 $V^{\pi}(C) = (1-0.5) * V^{\pi}(C) + 0.5 * \text{sample} = 3$

可以看到，尽管这一步得到的 $R=-2 < 0$ ，但是更新的 $V(C)$ 变大了

这依旧是价值的定义：从一个状态开始未来的预期效用值，而这里 D 有较大的价值

得不到策略

然而，有了价值，我们还是无法进行策略提取

$$\pi^*(s) = \arg \max_a \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V^*(s')]$$

依旧是因为T未知

所以这个方法是不完整的，只能得到价值而得不到策略

（作为对比，策略迭代算法同时进行了策略评估和提取）

这时候就需要学习Q-Value，因为知道了所有的Q-Value也就知道了最优策略。又因为不同Q-Value需要在同一个状态下做不同的行动（Q-State），不能按照固定的策略进行，所以这是一个主动学习