

10-贝叶斯网络BN D分离

贝叶斯网络 Bayes'nets/BN

也被称作graphical models

一些数学概念

后续需要用到的数学概念

- Observed variables (evidence) 观测过的变量
- Unobserved variables 未观测变量
- Model 已知变量与未知变量之间关联方式

随机变量

用一个大写字母表示，也有定义域

为了简写， $R \in \{\text{true}, \text{false}\} \rightarrow \{-r, +r\}$

概率分布

为随机变量的每个可能取值赋予一个概率值

写成 $P(R)$ ， R 是随机变量

如果写成 $P(r)$ ，其实就是 $P(R=r)$ 这一项的取值

联合分布

同时考虑所有随机变量的概率分布

如果有 n 个定义域为 d 的变量，联合分布的大小就是 d^n ，非常庞大，类似搜索空间或者真值表

$P(R=.., W=.., T=..)=..$ 或者简写 $P(.., .., ..)=..$

边际分布

对联合分布中部分变量求和或积分得到的边缘概率分布，是联合分布的一部分

条件概率 条件分布

链式法则 $P(a, b, c, \dots) = P(a)P(b|a)P(c|a, b)\dots$

计算条件分布时的归一化

概率推理

利用已知概率分布计算查询变量的后验概率或边缘概率

条件独立

A 和 B 在 C 的条件下相互独立 $A \perp\!\!\!\perp B \mid C$ $P(a, b \mid c) = P(a|c) P(b|c)$ 或者写成 $P(a \mid c, b) = P(a|c)$

举个例子， $P(\text{traffic, umbrella} \mid \text{rain}) = P(\text{traffic} \mid \text{rain})$ ，但是traffic和umbrella之间并不独立，只是在rain的条件下独立

如果条件独立成立，链式法则可以被简化为 $P(a, b, c, \dots) = P(a)P(b|a)P(c|b)\dots$
这样子就可以把巨大的联合分布化简为多个简单的条件分布

贝叶斯网络

我们可以先得到整个联合分布，再根据需要进行查找和计算，但是整个联合分布太大了，无法储存和学习

贝叶斯网络是一个有向无环图，包括：

- 节点：表示变量，可能已观测/未观测；每一个变量都有一个条件概率表，和它的所有父节点构成一个条件分布
- 弧：表示变量间潜在的直接影响或依赖关系。节点之间如果没有弧相连，就隐含了条件独立性假设；无路径连通的节点是绝对独立的
(实际上是没有被任何活跃路径连通，会在后续D-分离部分解释)

Example: Alarm Network

B	P(B)
+b	0.001
-b	0.999



E	P(E)
+e	0.002
-e	0.998



A	J	P(J A)
+a	+j	0.9
+a	-j	0.1
-a	+j	0.05
-a	-j	0.95

A	M	P(M A)
+a	+m	0.7
+a	-m	0.3
-a	+m	0.01
-a	-m	0.99

B	E	A	P(A B,E)
+b	+e	+a	0.95
+b	+e	-a	0.05
+b	-e	+a	0.94
+b	-e	-a	0.06
-b	+e	+a	0.29
-b	+e	-a	0.71
-b	-e	+a	0.001
-b	-e	-a	0.999

BN的核心是局部**马尔可夫性**假设，**给定**一个节点的所有父节点，该节点与它的所有非后代节点条件独立。由此可以推导出：

- 条件概率仅依赖于**直接相连**的父节点

$$P(x_i | x_1, \dots, x_{i-1}) = P(x_i | \text{parens}(X_i))$$

链式法则由此化简为，多个只和父节点有关的条件分布的积

$$P(x_1, x_2, x, \dots, x_n) = \prod_{i=1}^n P(x_i | \text{parents}(X_i))$$

这使得原本需要指数级参数的联合分布，可以用少量局部条件概率表来表示

2. 节点在其父节点给定后，便与图中其他特定部分“阻断”。这种局部阻断是判断任意变量间条件独立性的基础，可由后续介绍的D-分离算法实现

一个简单但不严谨的应用，例如计算图中的概率

$$P(+b, +e, +a, +j, +m) = P(+b)P(+e)P(+a | +b, +e)P(+j | +a)P(+m | +a)$$

其中B和E是绝对独立的，故概率直接相乘；

A发生在B和E条件下；

给定了A，J和M是条件独立的，故等效于两个概率直接相乘（局部马尔可夫性）；

而且条件是直接相连的父节点A，而不包含B和E（推论1）

之后通过D分离能更严谨的解释为什么B和E绝对独立，以及更复杂的情况该怎么判断独立性

包含所有变量的概率都可以这样计算，于是原本需要有 2^5 个条目的联合分布就被拆解成了这些条件分布

一般的，一个n个布尔变量的联合分布大小是 2^n ；如果用n个节点，每个节点最多k个父节点的BN表示，大小是 $(n2^{k+1})$

D-Septeration 有向分离/D-分离

贝叶斯网络的结构暗含着独立性的假设，在利用BN建模的时候，要选取与实际情况相符的图。刚刚的马尔可夫性给出了一个简单的判断图中独立性的方法，下面介绍D-分离算法，可以更方便的判断

为了方便理解，下面的BN图里，可以把->理解成因果关系

基本三元组

Chain

A -> B -> C

如果B还没有被观测，A和C之间不是独立的

如果B被观测（或者说给定B的值），A和C在B下条件独立，可以证明如下

$$P(c|a, b) = P(a, b, c)P(a, b) = P(a)P(b|a)P(c|b)P(a)P(b|a) = P(c|b)$$

说明链中一个节点的证据会阻断影响的传递

eg: fire -> smoke -> alarm

不知道smoke的时候，fire发生与否会间接影响到alarm的概率分布

但是一旦知道smoke的取值，fire发生与否就和alarm无关了

Fork/Common Cause

$A \leftarrow B \rightarrow C$

如果B还没有被观测，A和C之间不是独立的（AC倾向于有类似的概率）

如果B被观测（或者说给定B的值），A和C在B下条件独立，可以证明如下

$$P(c|a, b) = P(a, b, c)P(a, b) = P(b)P(a|b)P(c|b)P(b)P(a|b) = P(c|b)$$

共同的原因已知，结果之间独立

eg: DDL $\rightarrow$ Lab Full

|

V

Forum Busy

不知道DDL的情况时，两个结果不是独立的，观察到Lab Full，很可能Forum Busy也发生；观察到一个结果影响另一个的概率，不独立

但是如果给定DDL，观察到Lab Full也不影响Forum Busy的概率，因为这只依赖DDL的情况

Collider/V-Structure/Common Effect

$A \rightarrow B \leftarrow C$

如果B还没有被观测，A和C之间**独立**，证明如下：

$$P(a, c) = \sum_b P(a, c, b) = \sum_b P(a)P(c)P(b|a, c) = P(a)P(c) \cdot 1$$

如果B被观测（或者说给定B的值），A和C不独立

eg: Rain $\rightarrow$ Traffic $\leftarrow$ Concert

如果知道Traffic发生，但是Rain没发生，那么Concert就很可能发生

Rain的发生影响了Concert的概率，不独立

独立性的具体分析

所有情况都可以被归类成上面的三元组，只要是不独立的，就说明影响可以传递，路径是活跃的active；独立则说明路径被阻断，是不活跃的

(下图还多一个情况，可以类比Collider)

Active / Inactive Paths

Question: Are X and Y conditionally independent given evidence variables {Z}?

- Yes, if X and Y “d-separated” by Z
- Consider all (undirected) paths from X to Y
- No active paths = independence!



A path is active if each triple is active:

- Causal chain $A \rightarrow B \rightarrow C$ where B is unobserved (either direction)
- Common cause $A \leftarrow B \rightarrow C$ where B is unobserved
- Common effect (aka v-structure)
 $A \rightarrow B \leftarrow C$ where B or one of its descendants is observed

All it takes to block a path is a single inactive segment

Active Triples

Inactive Triples



$X_i X_j | X_a, \dots, X$ 是否成立，只要看从 X_i 到 X_j 的所有**无向路径**（找路径的时候是无向的，拆分**三元组**分析时要看方向），在给定证据 $X_a, \dots, X$ 下，有没有活跃的路径。只要有一个活跃的路径，就不确保独立

对于一个路径，只要路径中有一个三元组是不活跃的，整个路径就被截断，该路径就不活跃；所有三元组都是活跃的，影响可以传递，该路径就活跃

一个例子如下：


$L \perp\!\!\!\perp T' | T$ Yes

$L \perp\!\!\!\perp B$ Yes

$L \perp\!\!\!\perp B | T$

$L \perp\!\!\!\perp B | T'$

$L \perp\!\!\!\perp B | T, R$ Yes



第二条判断，从L到B之间的无向路径是L-R-T-B，有两个三元组

第一个是L→R→T，没有被观测节点，活跃；

第二个是R→T←B，没有被观测节点，不活跃；

有一个不活跃的，整个路径被截断，L和B独立

第五条判断，还是两个三元组，其中L→R→T中R已知，不活跃，路径被截断

这个例子都只有一条有向路径，如果有多条就逐一分析，只要有一个路径活跃，就不保证独立；换句话说，只有所有路径都不活跃才条件独立，比如：

■ Variables:


- R: Raining
- T: Traffic
- D: Roof drips
- S: I'm sad

■ Questions:

$$T \perp\!\!\!\perp D$$

$$T \perp\!\!\!\perp D | R \quad \text{Yes}$$

$$T \perp\!\!\!\perp D | R, S$$



第一条判断，T到R有两条路径，T-R-D和T-S-D

其中T←R→D是活跃的，故有一条路径活跃，不保证独立

注：上面突然说“不保证独立”而不是“不独立”，是因为D-分离实际上不能发现图中所有的独立性

比如在特定的概率分布下（比如所有概率都为1/2），数学上可能可以使得独立性被满足，但是一般不会出现，所以一开始都写的是“不独立”（而且我们一般假设相消性成立）

用途

Topology Limits Distributions

Given some graph topology G , only certain joint distributions can be encoded



The graph structure guarantees certain (conditional) independences

(There might be more independence)



Adding arcs increases the set of distributions, but has several costs

Full conditioning can encode any distribution

$$\{X \perp\!\!\!\perp Y, X \perp\!\!\!\perp Z, Y \perp\!\!\!\perp Z, \\ X \perp\!\!\!\perp Z \mid Y, X \perp\!\!\!\perp Y \mid Z, Y \perp\!\!\!\perp Z \mid X\}$$



$$\{X \perp\!\!\!\perp Z \mid Y\}$$



不同结构的贝叶斯网络暗含不同的条件独立性假设，可以根据D分离来判断。一旦两个网络的假设完全一致（同一个马尔可夫等价类），那么就可以用一个替换另一个。但是选择和实际情况最贴合的网络，节点的概率表会更简单，更具备可解释性（比如基本三元组里common cause和chain是等价的，理论上可以替换，但是如果变量之间实际上就是common cause关系，选这个会更简单）

- 弧越少的模型，暗含的假设就越多，有更多的节点满足条件独立性，计算最简单。但如果实际情况不符合这些独立性，会发生欠拟合
- 弧越多，假设越少。如果完全联通，就没有任何一个独立性假设，那所有的情况都可以这样建模，但BN也就退化为联合分布

之前提到BN的基本假设是马尔可夫性，这实际上是一种既局部又全局的性质，而D-分离是推导独立性的方法

BN完全联通，上面说“没有任何一个独立性假设”，但是马尔可夫性也成立：

$$P(X_i | X_1, \dots, X_{i-1}) = P(X_i | \text{arens}(X_i))$$

但由于此时 $\text{arens}(X_i)$ 正是所有编号小于 i 的变量的集合 $X_1, \dots, X_{i-1}$ ，所以这个等式实际上退化为：

$$P(X_i | X_1, \dots, X_{i-1}) = P(X_i | X_1, \dots, X_{i-1})$$

这是一个恒等式，没有对联合分布施加任何实质性的约束，也就是所谓的“没有任何一个独立性假设”。

下面的内容由DeepSeek-V4生成，仅供概念辨析：

贝叶斯网络的独立性声明有三个层次

- 局部马尔可夫性 (Local Markov Property): 这是BN的定义性公理，也是我们介绍的公式。每个节点在给定父节点后，独立于其非后代节点。
- 全局马尔可夫性 (Global Markov Property): 这是由D分离算法判定的所有独立性集合。
- 相消性 (Faithfulness): 指分布的独立性是否完全且恰好是D分离判定的那些。我们通常假设此性质成立。

核心定理是：局部马尔可夫性 $\Leftrightarrow$ 全局马尔可夫性。这意味着，局部公理一旦确立，由D分离得出的所有全局独立性，就自动被蕴含在分布之中了。