

12-贝叶斯网络BN 采样

采样 Sampling in BN

之前在强化学习[9-RL Q-Learning](#)中已经接触过采样sampling的方法，但是当时的目的是学习Learning

在贝叶斯网络中，节点的概率信息是已知的，采样的目的是比直接计算更快地得到概率推理的结果，虽然这个结果不一定准确

假设一个节点A，有60%概率得到+a，40%概率得到-a


我们可以用一个0-1之间的随机数模拟这个节点，当随机数在0-0.6之间，视为采样得到+a；0.6-1之间视为-a

如果一个采样方法是一致的consistent，意味着当采样次数足够大，频率能趋近于正确的概率

先验采样 Prior Sampling

沿着BN从上到下进行抽取样本，根据每个节点的概率分布来模拟抽取的概率

Prior Sampling



下图中，从C节点开始，按照0.5/0.5的概率抽取，得到+c
向下遍历，S节点，按照 $P(S|+c)$ 的模拟..
依此类推，最后得到一个完整的样本

然后根据样本的频率，就可以推理概率，例如

$$P(+c) = N(+c)/N$$

$$P(+c | -s) = N(+c, -s)/N(-s)$$

伪代码：

```
#generate one sample
def PriorSampling():
    for i in (1,2,...,n):
        sample x_i from P(X_i | Parents(X_i))
    return (x_1,x_2,...,x_n)
```

拒绝采样 Rejection Sampling

和先验采样的流程基本一致

唯一的区别是，对于带有条件概率的推理，不保留所有样本最后再计算，而是直接丢弃不符合条件evidence的样本


伪代码：

```
def RejectionSampling():
    for i in (1,2,...,n):
        sample x_i from P(X_i | Parents(X_i))
        if x_i not consistent with evidence:
            return
        #reject - no sample is generated in this try
    return (x_1,x_2,...,x_n)
```

抽取到符合条件的样本的可能性就是 $P(\text{condition})$ ，所以很多样本都被抛弃了，没有得到有效利用

似然加权 Likelihood Weight

Prior Sampling



在拒绝采样中，会抛弃很多不符合证据的样本；而似然加权对于包含证据的节点，不按照概率去生成，而是直接固定，概率用来调整样本的权重

比如计算 $P(+s, +w)$ ，一开始权重为1

抽取C和R节点的过程和之前相同，假设抽取到了+c +r

在S节点，不按照 $P(S|+c)$ 去生成样本，而是直接固定为证据+s，权重乘以 $P(+s|+c) = 0.1$

在W节点，直接固定+w，然后权重乘以 $P(+w|+s, +r) = 0.99$

最后该样本的权重为0.099

推理概率的时候，按照加权的频率计算

伪代码：

```
def LikelihoodWeight():
    weight = 1
    for i in (1, 2, ..., n):
        if X_i is an evidence variable:
            x_i = evidence x_i for X_i
            weight *= P(x_i | Parents(X_i))
```

else:

```
    sample x_i from P(X_i | Parents(X_i))  
    return (x_1, x_2, ..., x_n), weight
```

当证据概率极低，而且还在BN的下游时，似然加权就没有很有效了

比如 **Fire** $\rightarrow$ **Alarm**，推理概率 $P(+a)$

按照现实情况设定概率，**+f**概率很低，警报也非常准确


那么首先对**F**节点，绝大多数样本都抽取到**-f**，然后固定**+a**，但是权重 $P(+a|-f)$ 也将非常小
极少数**+f**样本，才有较大的权重

虽然通过似然加权，样本都满足证据不会被抛弃，但是这种情况下多数样本的权重趋近于零，大权重的有效样本数量极少，采样的效率很低

Gibbs Sampling


Step 1: Fix evidence

- $R = +r$




Step 2: Initialize other variables

- Randomly



Steps 3: Repeat

- Choose a non-evidence variable X
- Resample X from $P(X | \text{all other variables})$



- 先固定所有证据，其他变量随机赋值
- 然后进行迭代：每一次选择一个变量，重新赋值，赋值的概率依据是 $P(X_i | \text{其余全部确定的变量})$
- 大量重复这个过程，得到一条样本链

最后进行概率推理：丢弃开头的一部分样本（烧入期，让链稳定），然后每隔几步取一个样本（减少相关性），这些样本就近似服从目标概率

如何得到概率 $P(X_i | \text{其余全部确定的变量})$

根据BN的特性进行计算，与 X_i 无关的项都会抵消掉

比如在上图中：

$$P(+c, +r, -w) = \frac{P(+c, +r, -w)}{P(+c, +r, -w)} = \frac{P(+c, +r, -w)}{\sum_s P(s, +c, +r, -w)} = \frac{P(+c)P(+c)P(+r|+c)P(-w|+c, +r)}{\sum_s P(+c)P(s|+c)P(+r|+c)P(-w|+c, +r)}$$

相关性

样本链中相邻的样本高度相似，具有相关性