


14-HMM 前向算法

隐马尔可夫模型 Hidden Markov Model/HMM

马尔可夫模型 MM

引入时间维度



$$P(X_1)$$

$$P(X_t | X_{t-1})$$

和MDP的比较: [6-MDP 价值迭代](#)

- 每个节点是 X_t 这样和时间有关的状态，类似数列
- 转移概率是 $P(X_{t+1} | X_t)$
- 需要提供初始概率 $P(X_1)$
- 暂时不考虑行动action
- **稳定性假设**Stationary Assumption: 在任意时间，转移函数总是相同的


和BN的比较: [10-贝叶斯网络BN D分离](#)

- 条件独立性: 假设 $\text{Past} \perp\!\!\!\perp \text{Future} \mid \text{Present}$
(或者说当前状态只和上一状态有关。称为一阶马尔可夫性，和D分离有类似之处)
- 实际上就是一个可以无限扩展的BN


Example Markov Chain: Weather

- States: $X = \{\text{rain}, \text{sun}\}$
- Initial distribution: 1.0 sun
- CPT $P(X_t | X_{t-1})$:

X_{t-1}	X_t	$P(X_t X_{t-1})$
sun	sun	0.9
sun	rain	0.1
rain	sun	0.3
rain	rain	0.7



Two new ways of representing the same CPT



递推公式

$$P(X_t) = \sum_{X_{t-1}} P(X_t | X_{t-1}) P(X_{t-1})$$

这里的转移概率是已知的，所以可以通过数学方法写出通项

这其实也是合并两个节点的BN的变量消元法。 [11-贝叶斯网络BN 推理](#)

稳态分布 Stationary Distribution

对于大多数的链状MM，随着时间无限推移，最后的概率会趋于稳定，而且这个收敛的值和初始状态概率无关，只和转移概率有关
这种情况可以通过求解（不动点法）

$$\begin{cases} P(X_t) = P(X_{t+1}) \\ \sum P(X_t) = 1 \end{cases}$$


得到最后收敛情况的概率分布

这和MDP中的策略迭代算法[7-MDP 策略迭代](#)类似，策略迭代因为有确定的策略，贝尔曼方程里没有max项，变成了线性方程组，求解最后收敛的结果即可

BN采样中提到的Gibbs Sampling也是类似的方法。 [12-贝叶斯网络BN 采样](#)

Google推出的PageRank算法实际上就是构建了个马尔可夫模型，根据网页之间超链接的情况作为转移概率，计算出稳态分布的情况，作为网页排名的依据。

隐马尔可夫模型 HMM



对比MM:

- 没法直接观察到 X_t ，只能观测与 X_t 有关的证据 E_t
- 因此多了一个概率分布 $P(E_t | X_t)$ ，这个分布也是稳定的，在任意时间都相同
- 条件独立性增加：当前观测的结果只取决于当前的状态
- 条件独立性注意：证据之间无法保证独立，可以由D分离common cause+chain推理得到

总的来说，HMM的属性是：

- 无法确定 X_t ，只能得到 E_t
- 已知的概率信息：
 - 初始概率 $P(X_0)$
 - 转移概率 $P(X_{t+1} | X_t)$
 - 观测概率 $P(E_t | X_t)$
- 稳定性假设：在任意时间，
 - 转移概率总是相同的
 - 观测概率总是相同的
- 条件独立性：
 - 当前状态只取决于上一状态
 - 当前观测的结果只取决于当前的状态

下面先介绍两个基本的计算过程，HMM的前向算法和粒子滤波都是建立在这两个基本过程上的

时间流逝更新 Time Elapse Update

先考虑一个简单的MM，不包含证据

假设我们知道当前状态的概率分布 $P(X_t)$ ，想要知道下一状态的，只需要

$$P(x_{t+1}) = \sum_{x_t} P(x_{t+1}, x_t) = \sum_{x_t} P(x_{t+1} | x_t) P(x_t)$$

这个结果很符合直觉，到达下一个状态 X_{t+1} ，需要先经历所有可能的 x_t

下面考虑HMM，方法其实也类似，只是多了个证据 e_t 作为条件

假设我们根据当前所有的证据（用 $e_{1:t}$ 表示），有一个关于当前隐藏状态的推测/信念

$$B(X_t) = P(X_t | e_{1:t})$$

推进一个时间步，则下一个根据当前所有证据，下一个状态的概率是

$$P(X_{t+1} | e_{1:t}) = \sum_{x_t} P(X_{t+1}, x_t | e_{1:t}) = \sum_{x_t} P(X_{t+1} | x_t e_{1:t}) P(x_t | e_{1:t}) \quad (\text{条件概率公式}) = \sum_{x_t} P(x_t | e_{1:t}) P(X_{t+1} | x_t e_{1:t})$$

这个结果很符合直觉，到达下一个状态 X_{t+1} ，需要先经历所有可能的 x_t ，再通过转移概率移动

如果按照信念概率，写成

$$B'(X_{t+1}) = \sum_{x_t} P(X' | x_t) B(x_t)$$

这个结果就像信念也跟着转移在传递，由 $B(X_t)$ 推测下一个时间步的 $B'(X_{t+1})$

观测更新 Observation Update

当获得下一个时间步的观测结果 e_{t+1} ，可以更新推测的信念 $B'(X_{t+1})$


$$P(X_{t+1} | e_{1:t+1}) = \frac{P(X_{t+1}, e_{t+1} | e_{1:t})}{P(e_{t+1} | e_{1:t})} P(X_{t+1} | e_{1:t}) = P(e_{t+1} | X_{t+1}, e_{1:t}) P(X_{t+1} | e_{1:t})$$

也就是

$$B(X_{t+1}) \propto P(e_{t+1} | X_{t+1}) B'(X_{t+1})$$

这里是成比例，因为所有的 x_{t+1} 都有一项相同的因子 $P(e_{t+1} | e_{1:t})$ ，最后可以归一化消掉所以成比例不影响结果

结合：前向算法



先根据已有的证据推测下一步隐藏变量的情况；然后进行新的观测，更新之前的推测。结合两个更新，就是前向算法