

多智能体系统与强化学习

主讲人：高阳、杨林、杨天培

<https://reinforcement-learning-2025.github.io/>

课程信息

任课老师



高阳，教授、博导，
中国人工智能学会会士、中国计算机学会会士。主要研究强化学习、多智能体系统、大模型、具身智能。




**杨林，助理教授，
特聘研究员，博导。**
主要研究计算机系
统建模与优化。



**杨天培，助理教授，
特聘研究员，博导。**
主要研究AI Agent，强
化学习理论和应用。

参考教材

Reinforcement Learning, second edition: An Introduction (可参考中文版)



– Richard S. Sutton, Andrew G. Barto


<https://web.stanford.edu/class/psych209/Readings/SuttonBartoIPRLBook2ndEd.pdf>

学者信息

Richard S. Sutton: 阿尔伯塔大学计算科学系教授、强化学习和人工智能实验室首席研究员

Andrew G. Barto: 马萨诸塞大学阿默斯特分校信息与计算机科学学院教授

Multi-Agent Reinforcement Learning: Foundations and Modern Approaches



– Stefano V. Albrecht, Filippos, Christianos, Lukas Schäfer

<https://www.marl-book.com/download/marl-book.pdf>

学者信息

Stefano V. Albrecht: 爱丁堡大学信息学学院副教授

Filippos, Christianos: 爱丁堡大学和自主代理研究小组的多代理强化学习博士

Lukas Schäfer: 微软研究院，人工智能研究员

Multiagent Systems: Algorithmic, Game-Theoretic, and Logical Foundations


– Yoav Shoham, Kevin Leyton-Brown

<https://www.masfoundations.org/mas.pdf>

学者信息

Yoav Shoham: 斯坦福大学计算机科学系，人工智能教授

Kevin Leyton-Brown: 不列颠哥伦比亚大学计算机科学学院教授，加拿大皇家学会院士



课程内容

部分一：强化学习基础（4个主题）

- 基础理论与基本概念、蒙特卡洛与时序差分学习、函数逼近、策略梯度与深度强化学习、在线与离线强化学习

部分二：多智能体系统基础（3个主题）

- 多智能体系统简介、博弈论与纳什均衡、经典多智能体算法

部分三：多智能体强化学习（3~4个主题）

- 中心化训练与分散执行、合作多智能体算法、竞争与混合场景算法

部分四：高级主题与应用（2个主题）

- 大语言模型中的强化学习、多智能体强化学习前沿(邀请报告)

每个主题大约2-4小时的课堂授课

课程评估

课程考评方式

- 考勤：10分。每学期2次点名。
- 课程作业：20分。10次课后的小实验练习。
- 课程实践：20分。共2题(全选)，小组大作业，每组3人。
- 课程项目：50分。4题中选1题，每组5人。评价标准为系统和论文、专利等。

提交网址：采用课程自主代码训练平台(DODO)，
实现代码提交、验证。

课程资源

上交张伟楠

课程网页：<https://wnzhang.net/teaching/sjtu-rl-2024/index.html>

课件下载：<https://wnzhang.net/teaching/sjtu-rl-2024/slides/12-13-marl.pdf>

视频网站：[https://www.bilibili.com/video/BV1Qopze2E1M/?spm_id_from=333.337.
search-card.all.click&vd_source=de2e9219f23447529ee6fd993443a984](https://www.bilibili.com/video/BV1Qopze2E1M/?spm_id_from=333.337.search-card.all.click&vd_source=de2e9219f23447529ee6fd993443a984)

西湖大学WindyLab

课件下载：<https://github.com/MathFoundationRL/Book-Mathematical-Foundation-of-Reinforcement-Learning>

视频网站：[https://space.bilibili.com/2044042934?spm_id_from=333.1369.opus.
module_author_name.click](https://space.bilibili.com/2044042934?spm_id_from=333.1369.opus.module_author_name.click)

斯坦福大学

视频网站：<https://web.stanford.edu/class/cs234/>

王树森(Meta)

视频网站：<https://www.youtube.com/watch?v=vmkRMvhCW5c>

第一讲：强化学习基础

强化学习问题和范式

高 阳

大 纲

起源

MDP模型

动态规划

大 纲

起源

MDP模型

动态规划

起 源



口什么是学习

- ✓ 获取新的知识、 行为和认知能力
- ✓ 将所获得的知识和技能嵌入到系统中
- ✓ 随系统自身的运行， 导致系统性能的不断提升

- ✓ 不同于统计机器学习(概念学习)




最早的人机大战




评估函数

Alpha-beta剪枝



启发式搜索



当存在相同启发式估值时如何选择




$g(n) = f(n) + h(n)$ A*算法的产生

P. E. Hart, N. J. Nilsson, and B. Raphael. A formal basis for the heuristic determination of minimum cost paths in graphs. IEEE Trans. Syst. Sci. and Cybernetics, SSC-4(2):100-107, 1968




JOHN R. ANDERSON@CMU

从认知的角度



强化学习问题




强化学习的本质：奖惩和试错(Trial and Error)


三类机器学习的方法

machine learning


unsupervised
learning



supervised
learning



reinforcement
learning



三类机器学习的方法

监督学习（supervised learning）	无监督学习（unsupervised learning）
输入数据为带标签数据	输入数据为不带标签数据
需要训练数据集进行模型训练	只需要输入数据
通常用作预测	通常用于分析
分类和回归等任务	聚类等

强化学习不依赖于静态数据集，而是在动态环境中运行，并从收集的经验中学习。数据点或经验是在训练过程中通过环境与智能体之间的试错交互收集的。

概念学习 VS 交互学习

□ 概念学习

- ✓ 给定正例/反例，学习目标概念

□ 交互学习

- ✓ 通过交互的方式学习一个任务

- ✓ 系统(或外部环境)存在若干个”状态”

- ✓ 学习算法/动作会影响”状态”的分布

- ✓ 潜在的Exploration和Exploitation折衷



挑 战


□ 不确定性

- ✓ 环境、动作、反馈、模型


□ 学习的目标

- ✓ 概念 \rightarrow 决策

- ✓ 最大化长期奖赏



✓ **Markov Decision Process**



大 纲

起源

MDP模型

动态规划


一个例子

Local perception

0	1	0
0	1	0
0	1	0

Current situation

[10001000]




Action

10001000


Condition	Action	Payoff	Best classifier
Classifier list	[0010#010]	[nw]	0.7
	[1##0100#]	[w]	0.5
	[000#0101]	[nw]	0.8
	[0#000#01]	[ew]	0.5
	[0#100001]	[n]	0.9
	[0010#0#0]	[sw]	0.3
	[#1#01###]	[w]	0.9

强化学学习要素

强化学习过程抽象



强化学习要素



基于模型的智能体决策方法

通过模型对未来的状态和收益进行
预测和规划

数学模型 - MDP


Markov Decision Process

S- set of states, 状态集合

A- set of actions, 动作集合


δ - transition probability, 状态转移概率

R – immediate reward function, 即时奖赏函数



MDP模型 – 状态和动作


环境 = 状态集合



状态之间的转移 $\delta(s, a, s')$


MDP模型 – 奖赏

$R(s,a)$ = 在状态s, 采用a动作获得的奖赏




举例:


$R(s,a) =$ -1 with probability 0.5
+10 with probability 0.35
+20 with probability 0.15



MDP模型 – 轨迹



在一次 Episode 中， 所获得
的经验或轨迹(trjectory)



MDP模型 – 动作选择


□ 目标

- ✓ 最大化期望奖赏(单状态下)

单状态学习问题

□ 策略


- ✓ 状态到动作的映射($\pi: S \rightarrow A$)



例：N-臂老虎机机



单状态学习问题



目标：最大化期望即时奖赏

给定模型：采用贪心动作
(Greedy action)



困难：模型未知

MDP模型 – 返回函数

□ 返回函数(面向多状态学习问题)

- ✓ 将所有的即时奖赏组合成一个单一值

□ Modeling Issues

- ✓ 轨迹中早期的奖赏和晚期的奖赏相比，谁更重要？
- ✓ 系统是持续的？还是有终止状态的？

通常返回函数是即时奖赏值的线性组合

MDP模型 – 返回函数

□ 有限窗口(Finite Horizon)

$$\text{return} = \sum_{1 \leq i \leq H} R(s_i, a_i)$$

□ 无穷窗口(Infinite Horizon)

✓ 有折扣 $\text{return} = \sum_{i=0}^{\infty} \gamma^i R(s_i, a_i)$

✓ 无折扣 $\text{return} = \frac{1}{N} \sum_{i=0}^{N-1} R(s_i, a_i) \quad N \rightarrow \infty$

通常返回函数是即时奖赏值的线性组合

MDP模型 – 动作选择

□ 目标

- ✓ 最大化期望返回(Return)

□ 策略

- ✓ 状态到动作的映射($\pi: S \rightarrow A$)

□ 最优策略

- ✓ 如果 π 是最优策略，则其从任一状态出发，均是最优的策略

定理：必然存在着一个确定性的最优策略

监督学习 VS 强化学习

□ 监督学习

- ✓ (正/反例)在样本上的分布是确定的*。

□ 强化学习

- ✓ (状态/奖赏)的分布是策略依赖的(Policy Dependent!!!)
- ✓ 策略上**小**的变化都会导致返回值的**巨大**改变.

*目前有迁移学习在考虑非独立同分布的学习任务

MDP模型 – 小结

状态集合, $|S|=n$. $s \in S$


动作集合, $|A|=k$. $a \in A$

转移函数 $\delta(s_1, a, s_2)$

即时奖赏函数 $R(s, a)$

策略 $\pi: S \rightarrow A$

折扣累计返回 $\sum_{i=0}^{\infty} \gamma^i r_i$



大 纲

起源

MDP模型

动态规划

动态规划

给定一个完全已知的MDP模型

- 策略评估(Policy Evaluation)

- ✓ 给定一个策略 π , 评估其返回值

- 最优控制(Optimal Control)

- ✓ 寻找一个最优策略 π^* (从任一状态出发, 其返回值都为最大)

动态规划 – 值函数

- $V^\pi(s)$: 从 s 状态出发，采用 π 策略，所获得的期望返回值
- $Q^\pi(s,a)$: 从 s 状态出发，采用 a 动作，继而采用 π 策略，所获得的期望返回值
- 最优值函数 $V^*(s)$ and $Q^*(s,a)$: 采用最优策略 π^* 所获得的期望返回值

定理：策略 π 为最优策略当且仅当，在每一个状态 s

$$V^*(s) = \max_{\pi} V^{\pi}(s)$$

$$V^{\pi}(s) = \max_a Q^{\pi}(s,a)$$

动态规划 – 策略评估


□ Bellman等式(有折扣无限窗口)

$$\checkmark V^\pi(s) = E_{s' \sim \pi(s)} [R(s, \pi(s)) + \gamma V^\pi(s')]$$

□ 重写

$$\checkmark V^\pi(s) = E[R(s, \pi(s))] + \gamma \sum_{s'} \delta(s, \pi(s), s') V^\pi(s')$$

从时间步的角度看轨迹



系统中所有值函数是以上公式

构成的公式组，需要进行线性规划求解

例 - 策略评估


$$A = \{+1, -1\}$$

$$\gamma = 1/2$$

$$\delta(s_i, a) = s_{i+a}$$

π : 随机(一半概率选择+1或者-1动作)

$$\forall a: R(s_i, a) = i$$



$$V^\pi(s_0) = 0 + \gamma [\pi(s_0, +1)V^\pi(s_1) + \pi(s_0, -1)V^\pi(s_3)]$$

$$V^\pi(s_1) = 1 + \gamma [\pi(s_1, +1)V^\pi(s_2) + \pi(s_1, -1)V^\pi(s_0)]$$

$$V^\pi(s_2) = 2 + \gamma [\pi(s_2, +1)V^\pi(s_3) + \pi(s_2, -1)V^\pi(s_1)]$$

$$V^\pi(s_3) = 3 + \gamma [\pi(s_3, +1)V^\pi(s_0) + \pi(s_3, -1)V^\pi(s_2)]$$

例 - 策略评估


$$A = \{+1, -1\}$$

$$\gamma = 1/2$$

$$\delta(s_i, a) = s_{i+a}$$

π : 随机

$$\forall a: R(s_i, a) = i$$



$$V^\pi(s_0) = 0 + (V^\pi(s_1) + V^\pi(s_3))/4$$

$$V^\pi(s_1) = 1 + (V^\pi(s_0) + V^\pi(s_2))/4$$

$$V^\pi(s_2) = 2 + (V^\pi(s_1) + V^\pi(s_3))/4$$

$$V^\pi(s_3) = 3 + (V^\pi(s_2) + V^\pi(s_0))/4$$

求解线性方程组

$$V^\pi(s_0) = 5/3$$

$$V^\pi(s_1) = 7/3$$

$$V^\pi(s_2) = 11/3$$

$$V^\pi(s_3) = 13/3$$

动态规划 – 最优控制

□ Bellman等式(有折扣无限窗口)

$$\checkmark V^\pi(s) = E_{s' \sim \pi(s)} [R(s, \pi(s)) + \gamma V^\pi(s')]$$

□ 重写

$$\checkmark V^\pi(s) = E[R(s, \pi(s))] + \gamma \sum_{s'} \delta(s, \pi(s), s') V^\pi(s')$$

□ 状态-动作对值函数(对任意确定策略 π)

$$\checkmark Q^\pi(s, a) = E[R(s, a)] + \gamma \sum_{s'} \delta(s, a, s') V^\pi(s')$$

$$\checkmark \text{其中, } V^\pi(s) = Q^\pi(s, \pi(s, a))$$

例 - 最优控制


$$A = \{+1, -1\}$$

$$\gamma = 1/2$$

$$\delta(s_i, a) = s_{i+a}$$

π : 随机

$$\forall a: R(s_i, a) = i$$



$$Q^\pi(s_0, +1) = 0 + \gamma V^\pi(s_1)$$

请大家写出其他Q值函数的表达，以及
更新后的策略.....

$$Q^\pi(s_0, +1) = 7/6$$

$$Q^\pi(s_0, -1) = 13/6$$

$$V^\pi(s_1) = 7/3$$

$$V^\pi(s_2) = 11/3$$

$$V^\pi(s_3) = 13/3$$


例 - 最优控制

$$A = \{+1, -1\}$$

$$\gamma = 1/2$$

$$\delta(s_i, a) = s_{i+a}$$

$$R(s_i, a) = i$$



π : 根据状态-动作值函数进行修改

请大家根据新的策略重新写出Bellman等式，并求解

动态规划 - 最优控制

□ 贪心策略

- ✓ $\pi(s) = \operatorname{argmax}_a Q^\pi(s, a)$

□ ε -贪心策略

- ✓ 以 $1 - \varepsilon$ 概率选择, $\pi(s) = \operatorname{argmax}_a Q^\pi(s, a)$
- ✓ 以 ε 概率选择其他动作

动态规划 - 计算最优策略


1. 线性规划

2. 策略评估

$$V^{i+1}(s) \leftarrow \max_a \{ R(s, a) + \gamma \sum_{s'} \delta(s, a, s') V^i(s') \}$$

3. 最优控制

$$\pi_i(s) = \arg \max_a \{ Q^{\pi_{i-1}}(s, a) \}$$



思考和讨论

1. 理解强化学习范式和概念学习的不同
2. 理解离散型MDP模型中各个要素
3. 掌握动态规划方法

谢 谢 !