

多智能体系统与强化学习

主讲人：高阳、杨林、杨天培

<https://reinforcement-learning-2025.github.io/>

第七讲：离线强化学习

从实际环境到虚拟环境

杨 林

大 纲

离线强化学习

批量限制Q学习 (BCQ)

保守Q学习 (CQL)

大 纲

离线强化学习


批量限制Q学习 (BCQ)

保守Q学习 (CQL)


离线强化学习概念

□ 动机: 在真实环境中从零开始训练一个强化学습智能体往往不可取

- ✓ 风险较高，例如无人驾驶归控、智能医疗等
- ✓ 十分昂贵，例如机器人控制、推荐系统等




□ 离线强化学习: 在一个给定的离线数据集上直接训练出智能体策略，训练的过程中，智能体不得和环境做交互




□ 离线强化学习有潜力大大扩宽强化学习落地的范围

离线强化学习范式


(a) On-policy



(b) off-policy



(c) 离线强化学习



□ 训练的过程中与环境交互：


- ✓ 在线策略学习与离线策略学习的智能体可以和环境交互
- ✓ 离线强化学习的智能体不和环境做交互

□ 训练数据是否来自别的策略交互经验：

- ✓ Yes - 离线强化学习和离线策略学习
- ✓ No - 在线强化学习

离线强化学习与模仿学习

□ 离线强化学习让强化学习更像有监督学习



均依赖静态数据、避免在线学习的风险

□ 不同点

- ✓ 奖励信号需求
- ✓ 数据需求（离线强化学习数据包含次优或随机行为）


离线强化学习的主要问题和挑战

- 离线强化学习面临的最重要的挑战是分布偏移（Distribution Shift）
- 数据集分布和当前策略的分布不一致导致外推误差（Extrapolation Error）
 - ✓ 智能体如果涉足到了从没有见过的、远离数据集的状态动作对，怎么办？

$$Q(s, a) \leftarrow (1 - \alpha)Q(s, a) + \alpha(r + \gamma \max_a Q(s', a'))$$


- ✓ 外推误差：策略尝试数据中未见的动作，Q函数的预测会严重脱离真实值

如果 a' 是一个分布外的动作，怎么处理？




Q学习中的分布偏移

□ 策略与数据分布偏离



Q学习中的外推误差

- OOD 区域无法正确推断奖励，为了追求虚假的高奖励而选择危险动作



大 纲

离线强化学习

批量限制Q学习 (BCQ)

保守Q学习 (CQL)

BCQ原理



- 对于经典表格型强化学习，BCQ的基本思路是仅仅使用在数据集支撑上的目标Q值做时序差分的计算

$$Q(s, a) \leftarrow (1 - \alpha)Q(s, a) + \alpha(r + \gamma \max_{a' \text{ s.t. } (s', a') \in \mathcal{B}} Q(s', a'))$$

仅仅考虑在数据集支撑上的 (s', a')

原本会被使用的OOD数据

在BCQ中不再考虑使用



BCQ：批量限制Q学习

□ 对于更广泛的连续动作强化学习设置，BCQ的基本思路是“**仅仅使用在数据集支撑上的目标Q值做时序差分的计算**”可以如下实现：

- ✓ 使用一个生成模型，如变分自动编码器VAE，来生成距离数据集较近的状态动作对

$$\pi(s) = \arg \max_{a_i + \xi_\phi(s, a_i, \Phi)} Q_\theta(s, a_i + \xi_\phi(s, a_i, \Phi))$$

在 $[-\Phi, +\Phi]$ 的扰动

其中 $\{a_i \sim G_\omega(s)\}_{i=1}^n$ ，生成模型，如变分自动编码器VAE

□ 对于 n 和 Φ 的选择，形成模仿学习和强化学习之间的一个权衡

- ✓ n 和 Φ 越小，越接近模仿学习，策略性能可能不好
- ✓ n 和 Φ 越大，越接近强化学习，但容易出OOD问题

BCQ伪代码

Algorithm 1 基于批量约束的 Q 学习 (Batch-Constrained Q-learning, BCQ)

- 1: 输入: 经验批量数据 \mathcal{B} , 训练轮数 T , 目标网络更新率 τ , 小批量大小 N ,
最大扰动量 Φ , 采样动作数 n , 最小加权系数 λ
- 2: 初始化 Q 网络 $Q_{\theta_1}, Q_{\theta_2}$, 扰动网络 ξ_ϕ , 以及 VAE $G_\omega = \{E_{\omega_1}, D_{\omega_2}\}$, 参
数随机初始化为 $\theta_1, \theta_2, \phi, \omega$, 目标网络 $Q_{\theta'_1}, Q_{\theta'_2}, \xi_{\phi'}$ 设为 $\theta'_1 \leftarrow \theta_1, \theta'_2 \leftarrow$
 $\theta_2, \phi' \leftarrow \phi$
- 3: **for** $t = 1$ to T **do**
- 4: 从批量数据 \mathcal{B} 中随机采样 N 个转换样本 (s, a, r, s')
- 5: 计算 VAE 编码:
$$\mu, \sigma = E_{\omega_1}(s, a), \quad \tilde{a} = D_{\omega_2}(s, z), \quad z \sim \mathcal{N}(\mu, \sigma)$$
- 6: 更新 VAE 参数:
$$\omega \leftarrow \operatorname{argmin}_\omega \sum (a - \tilde{a})^2 + D_{\text{KL}}(\mathcal{N}(\mu, \sigma) \parallel \mathcal{N}(0, 1))$$
- 7: 采样 n 个候选动作:
$$\{a_i \sim G_\omega(s')\}_{i=1}^n$$

VAE做模仿学习

BCQ伪代码

8: 对每个采样动作进行扰动:

$$\{a_i = a_i + \xi_\phi(s', a_i, \Phi)\}_{i=1}^n$$

9: 计算值目标 y :

$$y = r + \gamma \max_{a_i} \left[\lambda \min_{j=1,2} Q_{\theta'_j}(s', a_i) + (1 - \lambda) \max_{j=1,2} Q_{\theta'_j}(s', a_i) \right]$$

乐观与保守估
计之间的平衡

10: 更新 Q 网络:

$$\theta \leftarrow \operatorname{argmin}_\theta \sum (y - Q_\theta(s, a))^2$$

11: 更新扰动网络:

$$\phi \leftarrow \operatorname{argmax}_\phi \sum Q_{\theta_1}(s, a + \xi_\phi(s, a, \Phi)), \quad a \sim G_\omega(s)$$

扰动函数 ξ 像
是 actor

12: 更新目标网络:

$$\theta'_i \leftarrow \tau \theta + (1 - \tau) \theta'_i, \quad \phi' \leftarrow \tau \phi + (1 - \tau) \phi'$$

13: end for

大 纲

离线强化学习

批量限制Q学习 (BCQ)

保守Q学习 (CQL)

CQL原理

- 学习一个保守的、可作为价值下界的 Q 函数，以避免在OOD 数据上的过高估计

✓ 对于一个新的学习策略 μ ，增加一个其遇见数据上的 Q 函数的惩罚

$$\widehat{Q}^{k+1} \leftarrow \arg \min_Q \alpha(\mathbb{E}_{s \sim \mathcal{D}, a \sim \mu(a|s)}[Q(s, a)] - \mathbb{E}_{s \sim \mathcal{D}, a \sim \widehat{\pi}(a|s)}[Q(s, a)]) + \frac{1}{2} \mathbb{E}_{s, a, s' \sim \mathcal{D}}[(Q(s, a) - \widehat{B}^\pi \widehat{Q}^k(s, a))^2]$$

↑
最小化分布外
动作的估值
↑
最大化分布内动作的
估值
↑
最小化MSE

CQL：保守Q学习

- 使用 $\max \mu$ 操作来估计当前的学习策略 π , 为了增加覆盖度, 加上正则

$$\begin{aligned} \min_Q \max_{\mu} \alpha (\mathbb{E}_{s \sim \mathcal{D}, a \sim \mu(a|s)} [Q(s, a)] - \mathbb{E}_{s \sim \mathcal{D}, a \sim \hat{\pi}(a|s)} [Q(s, a)]) \\ + \frac{1}{2} \mathbb{E}_{s, a, s' \sim \mathcal{D}} [(Q(s, a) - \widehat{\mathcal{B}}^\pi \widehat{Q}^k(s, a))^2] + \mathcal{R}(\mu) \quad (\text{CQL}(\mathcal{R})) \end{aligned}$$

$$\begin{aligned} \min_Q \alpha \mathbb{E}_{s \sim \mathcal{D}} [\log \sum_a \exp(Q(s, a)) - \mathbb{E}_{a \sim \hat{\pi}(a|s)} [Q(s, a)]] \\ + \frac{1}{2} \mathbb{E}_{s, a, s' \sim \mathcal{D}} [(Q(s, a) - \widehat{\mathcal{B}}^\pi \widehat{Q}^k(s, a))^2] \quad (\text{CQL}(\mathcal{H})) \end{aligned}$$

最大值逼近

- 经验上使用 μ 和均匀分布的KL散度作为正则项的实现

$$\mathcal{R}(\mu) = - D_{\text{KL}}(\mu, \text{Unif}(a))$$

CQL伪代码

Algorithm 1 保守 Q 学习 (两种变体)

```
1: 初始化 Q 函数  $Q_\theta$ , 可选初始化策略  $\pi_\phi$ 
2: for 步骤  $t$  从 1 到  $N$  do
3:   使用函数 CQL( $\mathcal{H}$ ), 通过  $G_Q$  次梯度步训练 Q 函数 (Q 学习用  $\mathcal{B}^*$ ,
   行动者-评论家用  $\mathcal{B}^{\pi_{\phi_t}}$ ) :<span style="border: 1px solid red; padding: 2px;">使用策略 $\pi$ 采样
4:    $\theta_t := \theta_{t-1} - \eta_Q \nabla_\theta \text{CQL}(\mathcal{R})(\theta)$ 
5:   if 使用行动者-评论家架构 then
6:     通过  $G_\pi$  次梯度步改进策略  $\pi_\phi$ , 采用 SAC 风格的熵正则化:
7:      $\phi_t := \phi_{t-1} + \eta_\pi \nabla_\phi \mathbb{E}_{s \sim \mathcal{D}, a \sim \pi_\phi(\cdot | s)} [Q_\theta(s, a) - \log \pi_\phi(a | s)]$ 
8:   end if
9: end for
```

熵项: 控制动作的收敛性

↑
求期望得到价值函数

- CQL 可以直接做基于价值函数的训练
- 如果需要做策略训练, 则在训练价值函数 Q 的同时, 使用 Soft AC 算法训练出策略 π

CQL：保守Q学习的实验

- 在多个 Gym 环境和不同的数据集采样设置下，CQL 几乎都能取得最好的策略性能

Task Name	SAC	BC	BEAR	BRAC-p	BRAC-v	CQL(\mathcal{H})
halfcheetah-random	30.5	2.1	25.5	23.5	28.1	35.4
hopper-random	11.3	9.8	9.5	11.1	12.0	10.8
walker2d-random	4.1	1.6	6.7	0.8	0.5	7.0
halfcheetah-medium	-4.3	36.1	38.6	44.0	45.5	44.4
walker2d-medium	0.9	6.6	33.2	72.7	81.3	79.2
hopper-medium	0.8	29.0	47.6	31.2	32.3	58.0
halfcheetah-expert	-1.9	107.0	108.2	3.8	-1.1	104.8
hopper-expert	0.7	109.0	110.3	6.6	3.7	109.9
walker2d-expert	-0.3	125.7	106.1	-0.2	-0.0	153.9
halfcheetah-medium-expert	1.8	35.8	51.7	43.8	45.3	62.4
walker2d-medium-expert	1.9	11.3	10.8	-0.3	0.9	98.7
hopper-medium-expert	1.6	111.9	4.0	1.1	0.8	111.0
halfcheetah-random-expert	53.0	1.3	24.6	30.2	2.2	92.5
walker2d-random-expert	0.8	0.7	1.9	0.2	2.7	91.1
hopper-random-expert	5.6	10.1	10.1	5.8	11.1	110.5
halfcheetah-mixed	-2.4	38.4	36.2	45.6	45.9	46.2
hopper-mixed	3.5	11.8	25.3	0.7	0.8	48.6
walker2d-mixed	1.9	11.3	10.8	-0.3	0.9	26.7

谢 谢 !