

2024-2025学年 第1学期(秋)




数据挖掘

模型的评价

2024 年 12 月

基本思路

分类问题：数据预处理→模型训练→模型调整→对新数据分类→模型评价



评价目的

- 对于解决同一问题的**不同模型**，通过**比较模型指标**来**比较模型之间的优劣**，
选取最优模型
- 对于**同一模型**，通过**比较模型指标**来**调整模型参数**



目录

- 01 评价指标
- 02 不平衡分类
- 03 过拟合和欠拟合

准确率评价

混淆矩阵

		PREDICTED CLASS	
		Class=Yes	Class>No
ACTUAL CLASS	Class=Yes	a (TP)	b (FN)
	Class>No	c (FP)	d (TN)

$$\text{准确率 (Accuracy)} = \frac{a + d}{a + b + c + d} = \frac{TP + TN}{TP + TN + FP + FN}$$

例子

- 考虑一个二分类问题
 - 0类的实例数 = 9990
 - 1类的实例数 = 10
- 如果模型预测每个实例为0类, 则准确率为 **99.9%**
 - 准确率是误导
 - 模型不能正确预测任何1类实例
 - 而在**疾病检测、地震预报**等问题中, 1类更需要被关心

其它度量

		PREDICTED CLASS	
ACTUAL CLASS		Class=Yes	Class=No
	Class=Yes	a (TP)	b (FN)
	Class=No	c (FP)	d (TN)

- 真阳率TP，真阳性 (True positive rate, TPR) 或 灵敏度 (sensitivity) 、查全率 (recall)
 - $TPR = TP/(TP + FN)$
- 真阴率TN，真阴性 (True negative rate, TNR) 或 特指度 (specificity)
 - $TNR = TN/(TN + FP)$
- 假阳率FP，假阳性 (False positive rate, FPR) 或 误报率
 - $FPR = FP/(TN + FP)$
- 假阴率FN，假阴性 (False negative rate, FNR) 漏报率 (与查全率此消彼长)
 - $FNR = FN/(TP + FN)$

其它度量

- 两个广泛使用的度量
 - 召回率（查全率，recall）和精确率（查准率，precision）

$$recall = \frac{TP}{TP + FN}$$

$$precision = \frac{TP}{TP + FP}$$

		PREDICTED CLASS	
ACTUAL CLASS		Class=Yes	Class>No
	Class=Yes	a (TP)	b (FN)
	Class>No	c (FP)	d (TN)

例子

- 假设我们手上有60个正样本，40个负样本，我们要找出所有的正样本，系统查找出50个，其中只有40个是真正的正样本，计算上述各指标。
 - TP: 将正类预测为正类数: 40
 - FN: 将正类预测为负类数: 20 (60-40, 剩余没正确分类的正样本)
 - FP: 将负类预测为正类数: 10
 - TN: 将负类预测为负类数: 30
- 准确率(accuracy) = 预测对的/所有 = $(TP+TN)/(TP+FN+FP+TN)$ = 70%
- 精确率(precision) = $TP/(TP+FP)$ = 80%
- 召回率(recall) = $TP/(TP+FN)$ = 66.7%

查全率vs.查准率

下面是两个场景：

- **地震的预测:** 对于地震的预测，我们希望的是recall非常高，也就是说每次地震我们都希望预测出来。这个时候我们可以牺牲precision。情愿发出1000次警报，把10次地震都预测正确了，也不要预测100次，对了8次，漏了2次。
- **嫌疑人定罪:** 基于不错怪一个好人的原则（无罪推定原则，presumption of innocence），对于嫌疑人的定罪我们希望是非常准确的（precision高），及时有时候放过了一些罪犯（recall低），但也是值得的。

$$F_1 = \frac{2rp}{r + p} = \frac{2 \times TP}{2 \times TP + FP + FN}$$

ROC曲线

- 前面分类器性能评价的局限性：分类器预测结果为离散的1或者0
- 朴素贝叶斯输出？ $p(x|y)=?$
- 其他分类器输出？ Softmax,...

A\P	C	$\neg C$	
C	TP	FN	P
$\neg C$	FP	TN	N
	P'	N'	All

ROC曲线

- 前面分类器性能评价的局限性：分类器预测结果为离散的1或者0
- 朴素贝叶斯输出？ $p(y|x)=?$
- 其他分类器输出？ Softmax,...

输出是一个连续的概率值

A\P	C	$\neg C$	
C	TP	FN	P
$\neg C$	FP	TN	N
	P'	N'	All

Instance	P(+ A)
1	0.95
2	0.93
3	0.87
4	0.85
5	0.85
6	0.85
7	0.76
8	0.53
9	0.43
10	0.25

ROC曲线

- 前面分类器性能评价的局限性：分类器预测结果为离散的1或者0
- 朴素贝叶斯输出？ $p(x|y)=?$
- 其他分类器输出？ Softmax,...
- 解决方法：连续的值离散化
- 导致的问题：离散阈值难以确定

输出是一个连续的概率值

A\P	C	$\neg C$	
C	TP	FN	P
$\neg C$	FP	TN	N
	P'	N'	All

Instance	P(+ A)
1	0.95
2	0.93
3	0.87
4	0.85
5	0.85
6	0.85
7	0.76
8	0.53
9	0.43
10	0.25

ROC曲线

- 接收者操作特征曲线 (Receiver Operating Characteristic Curve, 或者叫ROC曲线) 是一种坐标图式的分析工具，用于
 - 选择最佳的分类模型、舍弃次佳的模型。
 - 在同一模型中设定最佳阈值。
- 给定一个二元分类模型和它的阈值，就能从所有样本的(阳性 / 阴性)真实值和预测值计算出一个 ($X=FPR$, $Y=TPR$) 坐标点。

A\P	C	$\neg C$	
C	TP	FN	P
$\neg C$	FP	TN	N
	P'	N'	All

$$TPR = TP/(TP + FN)$$

$$FPR = FP/(TN + FP)$$

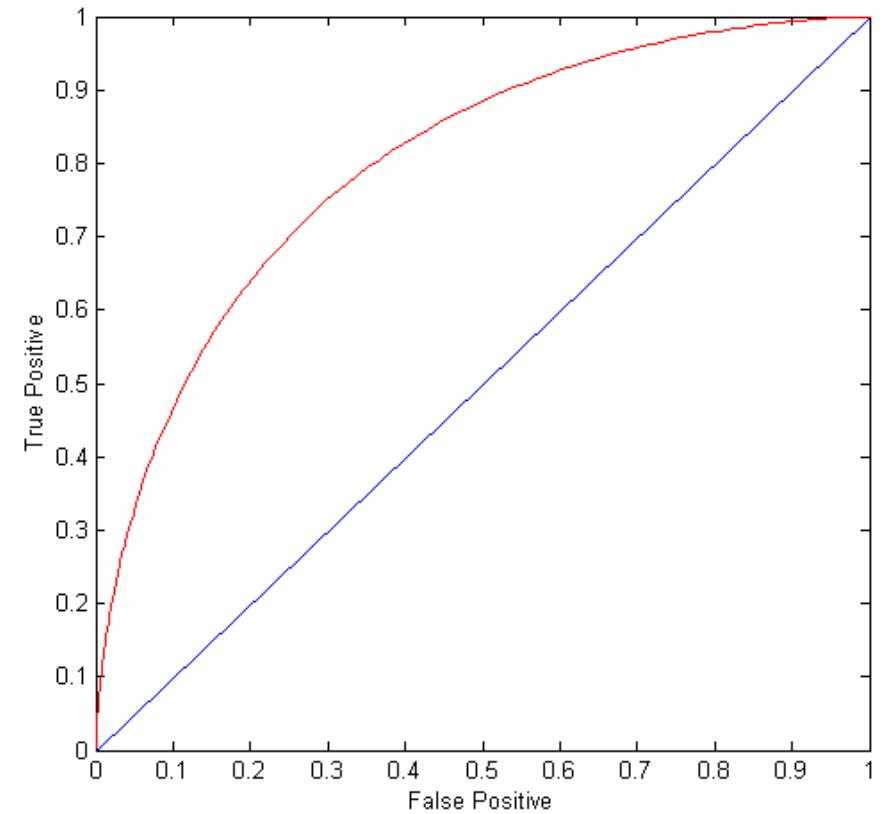
$$TNR = TN/(TN + FP)$$

$$FNR = FN/(TP + FN)$$

ROC曲线属性

(FPR, TPR):

- (0,0): 任何分类都是**阴性**
- (1,1): 任何分类都是**阳性**
- (0,1): **理想分类**
- 对角线:
 - 随机猜测结果
 - 对角线以下: 预测结果与真实结果相反



ROC曲线下方面积: AUC


- ROC曲线下方的区域称为AUC， Area Under the ROC curve

- Ideal:

- Area = 1

- Random guess:

- Area = 0.5



$$TPR = TP/(TP + FN)$$

$$FPR = FP/(TN + FP)$$


如何构建ROC曲线

- 首先利用分类器计算每个数据记录的后验概率 $P(+|A)$
- 将这些数据记录对应的 $P(+|A)$ 从高到低排列 (如右表)：
 - 由低到高, 对于每个 $P(+|A)$ 值 (threshold, 阈值), 把对应的记录以及那些值 **高于或等于阈值** 指派为阳性类 **positive**, 把那些值 **低于阈值** 指派为阴性类 **negative**
 - 统计 TP, FP, TN, FN
 - 计算 $TPR = TP/(TP+FN)$ 和 $FPR = FP/(FP + TN)$
- 绘出诸点(FPR, TPR)并连接它们

Instance	$P(+ A)$	True Class
1	0.95	+
2	0.93	+
3	0.87	-
4	0.85	-
5	0.85	-
6	0.85	+
7	0.76	-
8	0.53	+
9	0.43	-
10	0.25	+

例子


Class	+	-	+	-	-	-	+	-	+	+	
Threshold \geq	0.25	0.43	0.53	0.76	0.85	0.85	0.85	0.87	0.93	0.95	0.95
TP	5	4	4	3	3	3	3	2	2	1	0
FP	5	5	4	4	3	2	1	1	0	0	0
TN	0	0	1	1	2	3	4	4	5	5	5
FN	0	1	1	2	2	2	2	3	3	4	5
→ TPR	1	0.8	0.8	0.6	0.6	0.6	0.6	0.4	0.4	0.2	0
→ FPR	1	1	0.8	0.8	0.6	0.4	0.2	0.2	0	0	0



Instance	P(+ A)	True Class
1	0.95	+
2	0.93	+
3	0.87	-
4	0.85	-
5	0.85	-
6	0.85	+
7	0.76	-
8	0.53	+
9	0.43	-
10	0.25	+

例子

Class	+	-	+	-	-	-	+	-	+	+	
Threshold \geq	0.25	0.43	0.53	0.76	0.85	0.85	0.85	0.87	0.93	0.95	0.95
TP	5	4	4	3	3	3	3	2	2	1	0
FP	5	5	4	4	3	2	1	1	0	0	0
TN	0	0	1	1	2	3	4	4	5	5	5
FN	0	1	1	2	2	2	2	3	3	4	5
→ TPR	1	0.8	0.8	0.6	0.6	0.6	0.6	0.4	0.4	0.2	0
→ FPR	1	1	0.8	0.8	0.6	0.4	0.2	0.2	0	0	0




Instance	P(+ A)	True Class
1	0.95	+
2	0.93	+
3	0.87	-
4	0.85	-
5	0.85	-
6	0.85	+
7	0.76	-
8	0.53	+
9	0.43	-
10	0.25	+

例子

Class	+	-	+	-	-	-	+	-	+	+	
Threshold >=	0.25	0.43	0.53	0.76	0.85	0.85	0.85	0.87	0.93	0.95	0.95
TP	5	4	4	3	3	3	3	2	2	1	0
FP	5	5	4	4	3	2	1	1	0	0	0
TN	0	0	1	1	2	3	4	4	5	5	5
FN	0	1	1	2	2	2	2	3	3	4	5
→ TPR	1	0.8	0.8	0.6	0.6	0.6	0.6	0.4	0.4	0.2	0
→ FPR	1	1	0.8	0.8	0.6	0.4	0.2	0.2	0	0	0

A= [填空1]


B= [填空2]



Instance	P(+ A)	True Class
1	0.95	+
2	0.93	+
3	0.87	-
4	0.85	-
5	0.85	-
6	0.85	+
7	0.76	-
8	0.53	+
9	0.43	-
10	0.25	+

如何构建ROC曲线

Class	+	-	+	-	-	-	+	-	+	+	
Threshold \geq	0.25	0.43	0.53	0.76	0.85	0.85	0.85	0.87	0.93	0.95	0.95
TP	5	4	4	3	3	3	3	2	2	1	0
FP	5	5	4	4	3	2	1	1	0	0	0
TN	0	0	1	1	2	3	4	4	5	5	5
FN	0	1	1	2	2	2	2	3	3	4	5
→ TPR	1	0.8	0.8	0.6	0.6	0.6	0.6	0.4	0.4	0.2	0
→ FPR	1	1	0.8	0.8	0.6	0.4	0.2	0.2	0	0	0




Instance	P(+ A)	True Class
1	0.95	+
2	0.93	+
3	0.87	-
4	0.85	-
5	0.85	-
6	0.85	+
7	0.76	-
8	0.53	+
9	0.43	-
10	0.25	+



目录

- 01 评价指标
- 02 不平衡分类
- 03 过拟合和欠拟合

数据不平衡问题




基于抽样的方法

- 基于抽样的方法
 - 考虑一个包含100个正样本和1000个负样本的数据集
 - **Oversampling** 过采样
 - 复制正样本, 直到训练集中正样本和负样本一样多
 - 可能导致模型过分拟合, 因为一些噪声样本也可能被复制多次
 - **Undersampling**欠采样
 - 随机抽取100个负样本, 与所有的正样本一起形成训练集
 - 问题: 一些有用的负样本可能没有选出来用于训练, 因此导致一个不太优的模型
 - 解决问题的方法: 多次执行不充分抽样, 并归纳类似于集成学习方法的多分类器
 - **Oversampling + Undersampling**

基于抽样的方法

- 基于抽样的方法
 - **Oversampling** 过采样
 - 复制正样本, 直到训练集中正样本和负样本一样多
 - 可能导致模型过分拟合, 因为一些噪声样本也可能被复制多次




基于抽样的方法

- 基于抽样的方法

- Undersampling欠采样

- 随机抽取100个负样本, 与所有的正样本一起形成训练集
 - 问题: 一些有用的负样本可能没有选出来用于训练, 因此导致一个不太优的模型
 - 解决问题的方法: 多次执行不充分抽样, 并归纳类似于组合学习方法的多分类器





有用的负样本可能没有选出来用于训练

基于抽样的方法

- 基于抽样的方法
 - 考虑一个包含100个正样本和1000个负样本的数据集
 - **Oversampling** 过采样
 - 复制正样本, 直到训练集中正样本和负样本一样多
 - 可能导致模型过分拟合, 因为一些噪声样本也可能被复制多次
 - **Undersampling**欠采样
 - 随机抽取100个负样本, 与所有的正样本一起形成训练集
 - 问题: 一些有用的负样本可能没有选出来用于训练, 因此导致一个不太优的模型
 - 解决问题的方法: 多次执行不充分抽样, 并归纳类似于组合学习方法的多分类器
 - **Oversampling + Undersampling**


两阶段学习

- 两阶段学习：PN-Rules
 - 是基于规则的分类
 - 学习分两个阶段，每个阶段学习一组规则
- 训练
 - 阶段I：学习一组规则，尽可能覆盖正类（少的那一类）
 - 阶段II：使用阶段I覆盖的正类和负类样本+部分其它负类样本，学习一组规则



两阶段学习

- 分类
 - 用第一组规则对 x 分类，如果分到负类，则 x 属于负类
 - 否则，用第二组规则确定 x 所属的类
- R. Agarwal, and M. V. Joshi. PNrule: A New Framework for Learning Classifier Models in Data Mining (A Case-Study in Network Intrusion Detection). In Proc. of the First SIAM Conference on Data Mining. Chicago, USA, April 2001



Rakesh Agrawal 

Computer scientist

Rakesh Agrawal is a computer scientist who until recently was a Technical Fellow at the Microsoft Search Labs. [Wikipedia](#)

Education: Indian Institute of Technology Roorkee

Books: 23 European Symposium on Computer Aided Process Engineering; GWh Level Renewable Energy; Liquid CO₂; MORE

Awards: SIGMOD Edgar F. Codd Innovation Award

Notable student: Ramakrishnan Srikant



目录

- 01 评价指标
- 02 不平衡分类
- 03 过拟合和欠拟合


模型过分拟合和拟合不足

- 分类模型的误差大致分为两种：
 - **训练误差**：是在训练记录上误分类样本比例
 - **泛化误差**：是模型在未知记录上的期望误差
- 一个好的分类模型不仅要能够很好的拟合训练数据，而且对未知样本也要能准确分类。
- 换句话说，一个好的分类模型必须具有低训练误差和低泛化误差。
- 当训练数据拟合太好的模型（**较低训练误差**），其**泛化误差可能比具有较高训练误差**的模型高，这种情况成为模型**过分拟合**。


数据预处理→模型训练→模型调整→对新数据分类→模型评价

模型过分拟合和拟合不足

- 以决策树算法为例
 - 当决策树很小时，训练和检验误差都很大，这种情况称为模型拟合不足。出现拟合不足的原因是模型尚未学习到数据的真实结构。
 - 随着决策树中结点数的增加，模型的训练误差和泛化误差都会随之下降。
 - 当树的规模变得太大时，即使训练误差还在继续降低，但泛化误差开始增大，导致模型过分拟合。



模型过分拟合和拟合不足




例子

表 4-3 哺乳类动物分类的训练数据集样本。打星号的类标号代表错误标记的记录

名称	体温	胎生	4 条腿	冬眠	类标号
豪猪	恒温	是	是	是	是
猫	恒温	是	是	否	是
蝙蝠	恒温	是	否	是	否*
鲸	恒温	是	否	否	否*
蝾螈	冷血	否	是	是	
科莫多巨蜥	冷血	否	是	否	
蟒蛇	冷血	否	否	是	
鲑鱼	冷血	否	否	否	
鹰	恒温	否	否	否	
虹鱥	冷血	是	否	否	

表 4-4 哺乳类动物分类的检验数据集样本

名称	体温	胎生	4 条腿	冬眠	类标号
人	恒温	是	否	否	是
鸽子	恒温	否	否	否	否
象	恒温	是	是	否	是
豹纹鲨	冷血	是	否	否	否
海龟	冷血	否	是	否	否
企鹅	冷血	否	否	否	否
鳗	冷血	否	否	否	否
海豚	恒温	是	否	否	是
针鼹	恒温	否	是	是	是
希拉毒蜥	冷血	否	是	是	否



决策树 M_1 的训练误差为 0,
但它在检验数据上的误差达 30%


例子

表 4-3 哺乳类动物分类的训练数据集样本。打星号的类标号代表错误标记的记录

名称	体温	胎生	4 条腿	冬眠	类标号
豪猪	恒温	是	是	是	是
猫	恒温	是	是	否	是
蝙蝠	恒温	是	否	是	否*
鲸	恒温	是	否	否	否*
蝾螈	冷血	否	是	是	
科莫多巨蜥	冷血	否	是	否	
蟒蛇	冷血	否	否	是	
鲑鱼	冷血	否	否	否	
鹰	恒温	否	否	否	
虹鱥	冷血	是	否	否	


表 4-4 哺乳类动物分类的检验数据集样本

名称	体温	胎生	4 条腿	冬眠	类标号
人	恒温	是	否	否	是
鸽子	恒温	否	否	否	否
象	恒温	是	是	否	是
豹纹鲨	冷血	是	否	否	否
海龟	冷血	否	是	否	否
企鹅	冷血	否	否	否	否
鳗	冷血	否	否	否	否
海豚	恒温	是	否	否	是
针鼹	恒温	否	是	是	是
希拉毒蜥	冷血	否	是	是	否



决策树 M_2 的训练误差为 20%，
但它在检验数据上的误差达 10%

噪声导致的过分拟合




噪声导致决策边界的改变

缺乏代表性样本导致的过分拟合

- 根据少量训练记录做出分类决策的模型也容易受过分拟合的影响。
- 由于训练数据缺乏具有代表性的样本，在没有多少训练记录的情况下，学习算法仍然细化模型就会产生过分拟合。

表 4-5 哺乳动物分类的训练集样本

名称	体温	胎生	4 条腿	冬眠	类标号
蝾螈	冷血	否	是	是	否
虹鱥	冷血	是	否	否	否
鹰	恒温	否	否	否	否
弱夜鹰	恒温	否	否	是	否
鸭嘴兽	恒温	否	是	是	是




训练集太少
模型太复杂

图 4-26 根据表 4-5 中的数据集建立的决策树

减少泛化误差

- 过分拟合的主要原因一直是个争辩的话题，但数据挖掘研究界普遍认为**模型的复杂度**对模型的过分拟合有影响。
- 如何确定正确的模型复杂度？理想的复杂度是能产生最低泛化误差的模型的复杂度。
- 奥卡姆剃刀定律




奥卡姆剃刀(Occam's Razor)

- 奥卡姆剃刀 (Occam's Razor) , 拉丁文为lex parsimoniae, 意思是简约之法则。
- 是由14世纪逻辑学家、圣方济各会修士威廉奥卡姆William of Occam (约1287年至1347年) 提出的一个解决问题的法则。
- 他在《箴言书注》第2卷15章说“**切勿浪费较多东西，去做：用较少的东西，同样可以做好的事情**”。
- 奥卡姆剃刀定律被广泛运用在多个学科的逻辑定律，它的简单表述：
 - 如无必要，勿增实体
 - Entities should not be multiplied unnecessarily




减少泛化误差

- 根据奥卡姆剃刀原则
 - 引入惩罚项，使较简单的模型比复杂的模型更可取
 - 引入正则项
 - 神经网络中，引入dropout机制



(a) Standard Neural Net



(b) After applying dropout.

减少泛化误差

- 使用验证集

- 该方法中，不是用训练集估计泛化误差，而是把原始的训练数据集分为两个较小的子集，一个子集用于训练，而另一个称为验证集，用于估计泛化误差。
- 该方法为评估模型在未知样本上的性能提供了较好办法。

