

2025-2026学年 第1学期(秋)



# 数据挖掘

## 神经网络分类器

2025 年 11 月

# 生物神经元

---

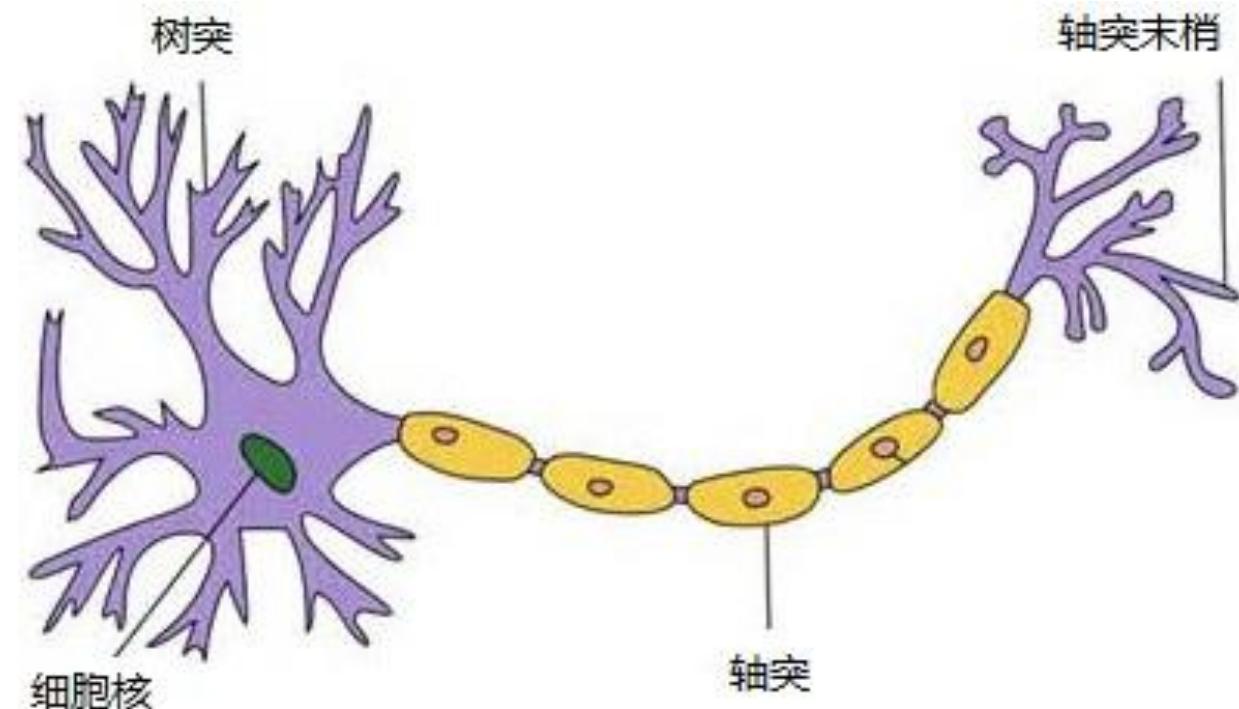
- **大脑是如何学习的?**

- 树突接收信息
- 轴突传递信息

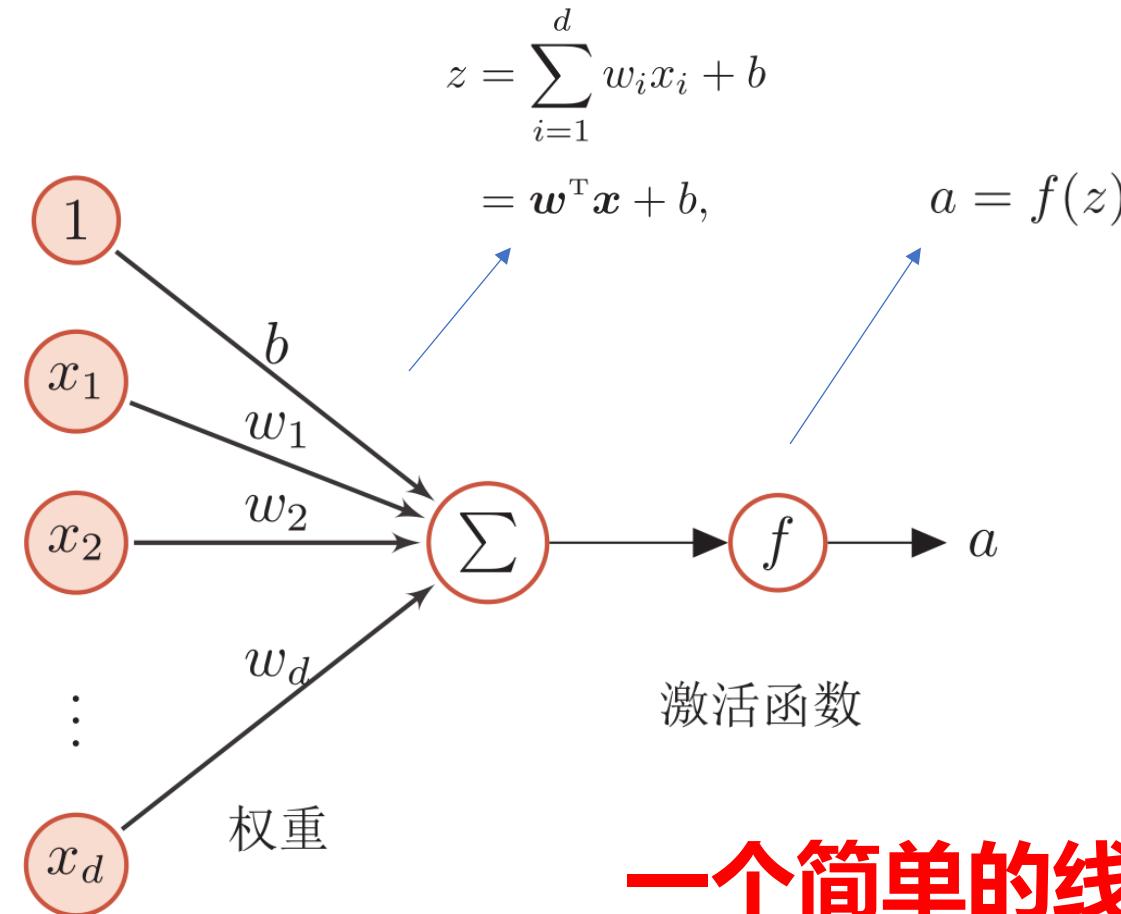
- **为什么要模拟人脑?**

- 快速、智能
- 稳定

- **我们如何模拟人脑的生物神经元?**



# 神经元模型



# 人工神经网络

- 人工神经网络主要由大量的神经元以及它们之间的有向连接构成。包含三个方面：

- 神经元的激活规则

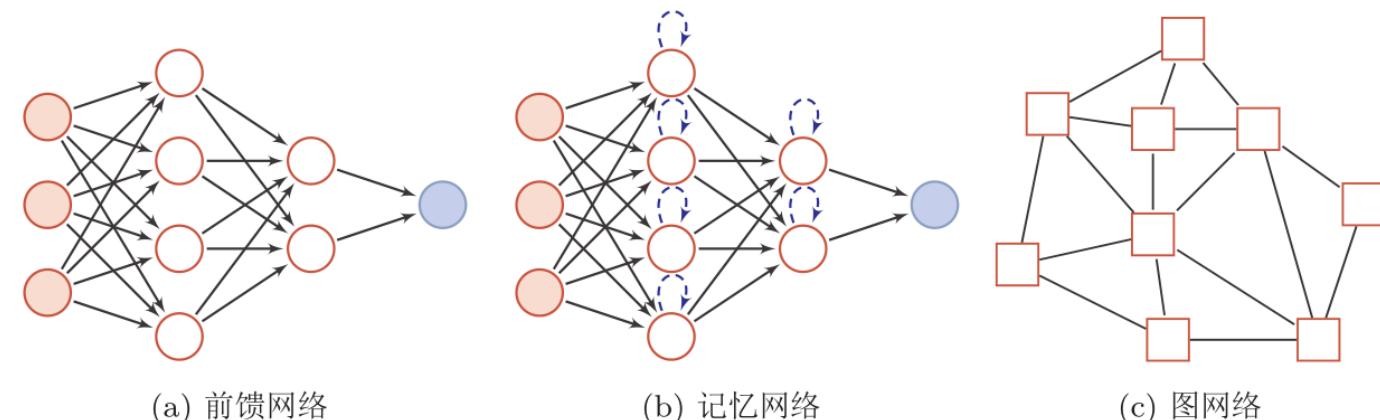
- 主要是指神经元输入到输出之间的映射关系，一般为非线性函数

- 网络的拓扑结构

- 不同神经元之间的连接关系。

- 学习算法

- 通过训练数据来学习神经网络的参数。



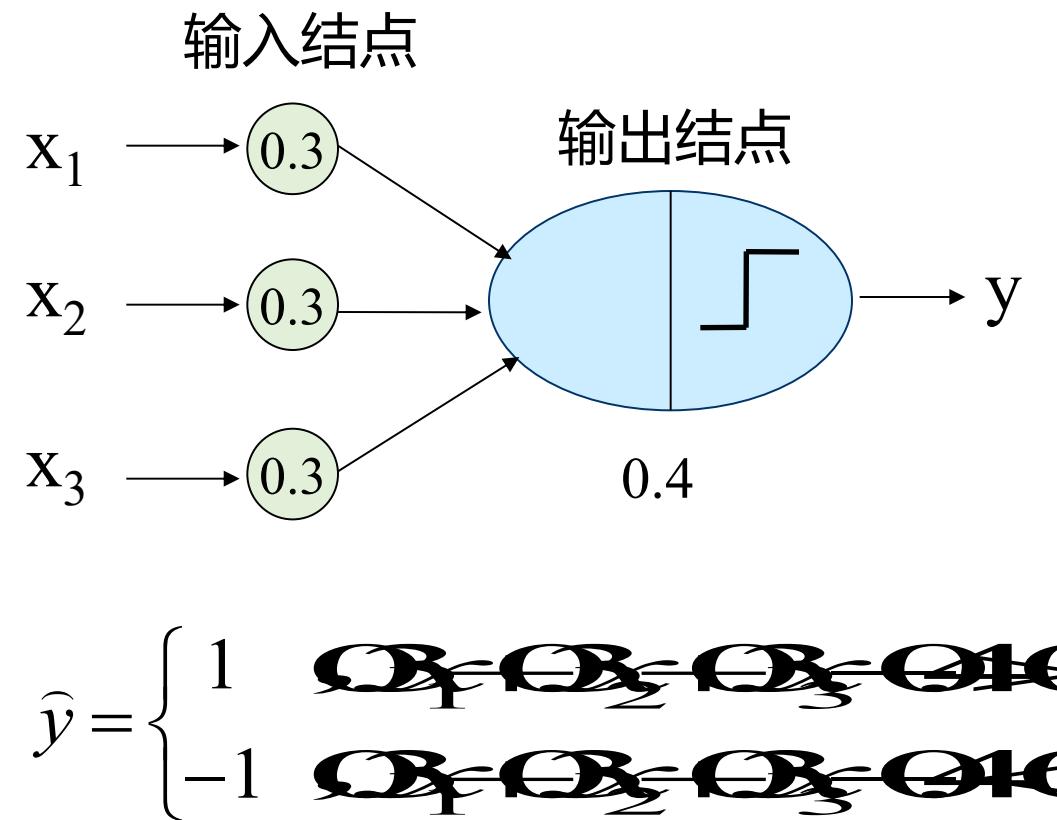


# 目 录

- 01 感知机
- 02 多层人工神经网络
- 03 多层感知机
- 04 误差反向传播网络
- 05 后向传播算法

# 感知机

$x_1$	$x_2$	$x_3$	$y$
1	0	0	-1
1	0	1	1
1	1	0	1
1	1	1	1
0	0	1	-1
0	1	0	-1
0	1	1	1
0	0	0	-1



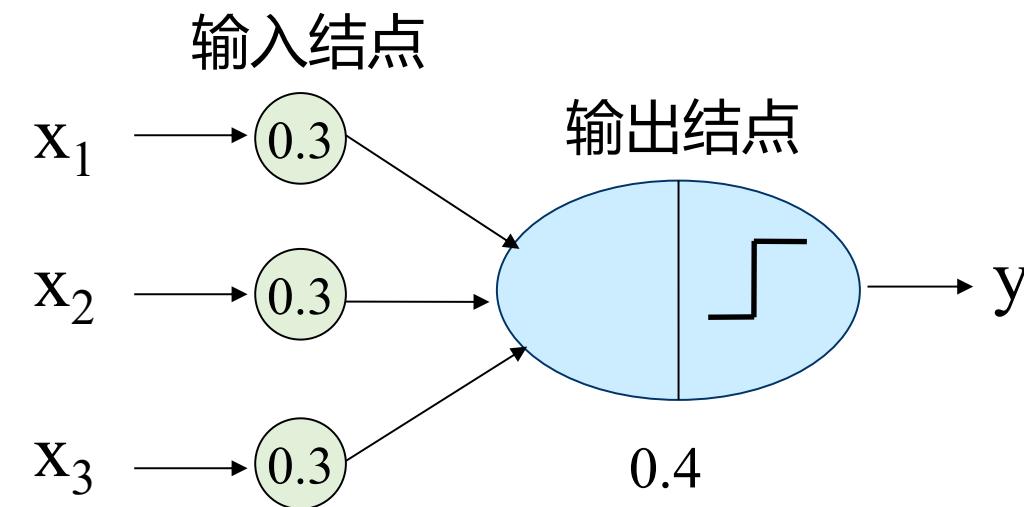
# 感知机

上一个例子的模型：

$$\hat{y} = \begin{cases} 1 & \text{if } x_1 + x_2 + x_3 > 0 \\ -1 & \text{otherwise} \end{cases}$$

化为一般的形式：

~~Y = 0.3x\_1 + 0.3x\_2 + 0.3x\_3 + 0.4~~



# 感知机

---

初始：用随机值初始化权值向量 $w^{(0)}$

循环：直到输出和实例一致

{

对每个训练样例 $(x_i, y_i)$ , 按照 $w^{(k)}$ 计算输出值 $y_i^{(k)}$ ;

for每个权值 $w^{(k)}$

更新权值 $w^{(k+1)} = w^{(k)} + \lambda(y_i - y_i^{(k)})x_i$ ;

}

# 感知机

---

$$\text{更新权值: } w^{(k+1)} = w^{(k)} + \lambda(y_i - y_i^{(k)})x_i$$

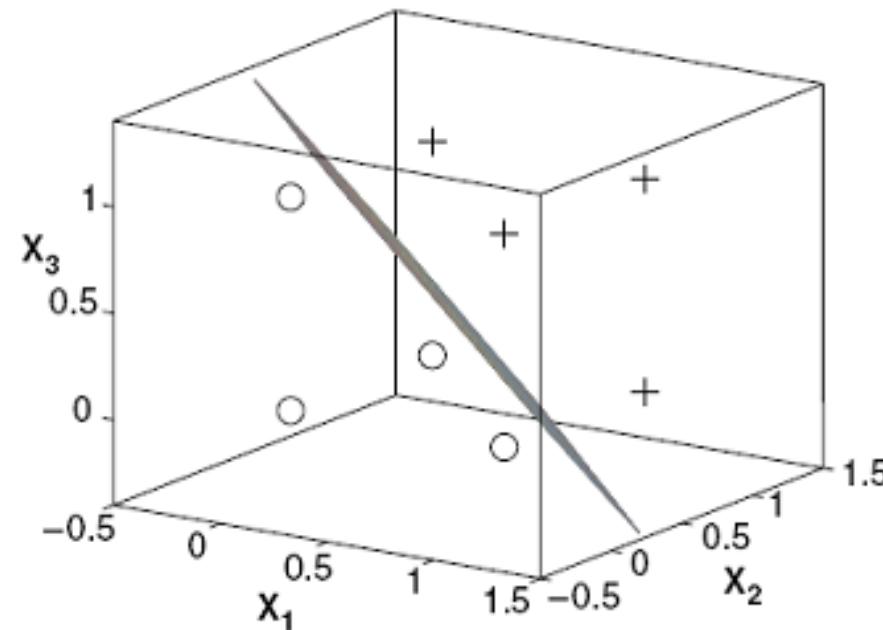
- 如果  $y_i = y_i^{(k)}$ , 权值w不变;
- 如果  $y_i = 1$ (实际类),  $y_i^{(k)} = -1$ , 预测误差为2;
- 为了补偿这个误差, 需要提高正输入链的权值, 降低负输入链的;
- 如果  $y_i = -1$ (实际类),  $y_i^{(k)} = 1$ , 预测误差为-2;
- 为了补偿这个误差, 需要降低正输入链的权值, 提高负输入链的;

# 感知机

- F. Rosenblatt 证明了对“线性可分”的问题

感知机通过有限次训练就能学会正确的行为

$x_1$	$x_2$	$x_3$	$y$
1	0	0	-1
1	0	1	1
1	1	0	1
1	1	1	1
0	0	1	-1
0	1	0	-1
0	1	1	1
0	0	0	-1

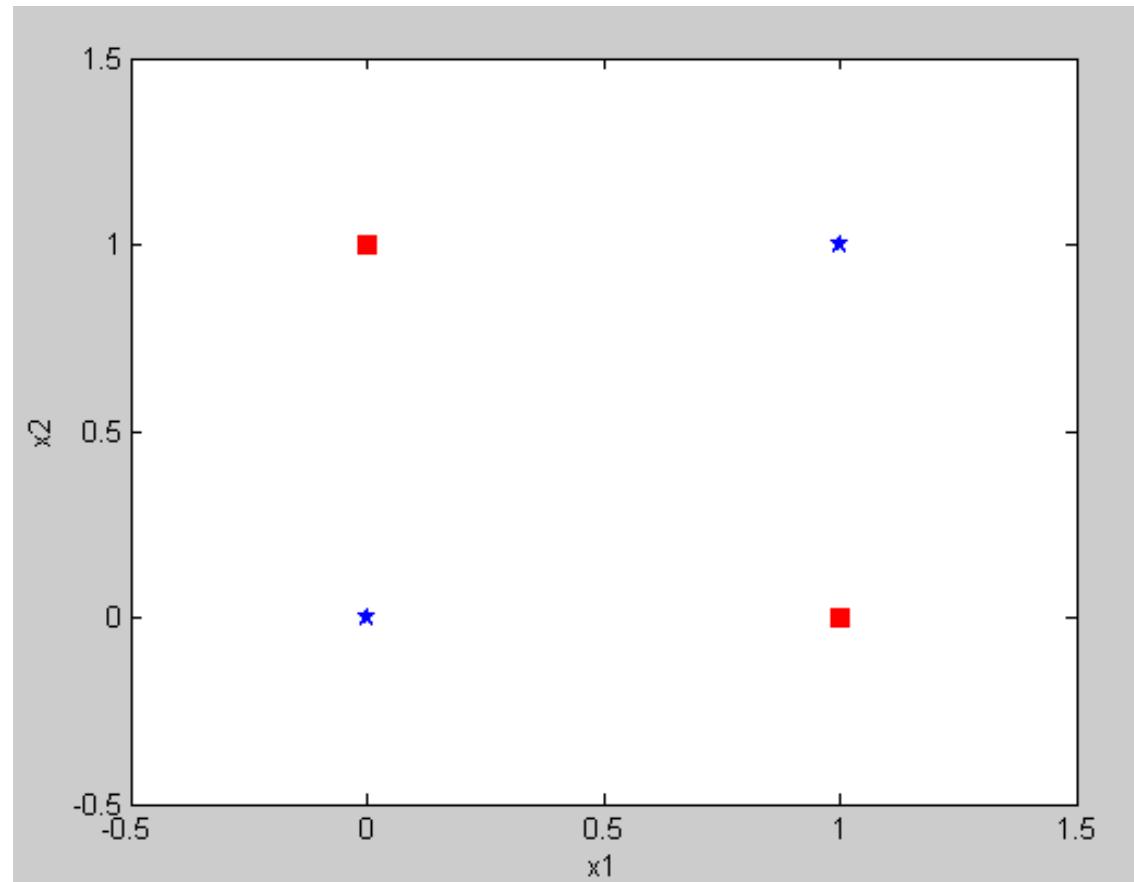


# 感知机

- Marvin Minsky, *Perceptrons*

证明了感知器无法执行“异或问题”

$x_1$	$x_2$	$Y$
0	0	-1
1	0	1
0	1	1
1	1	-1



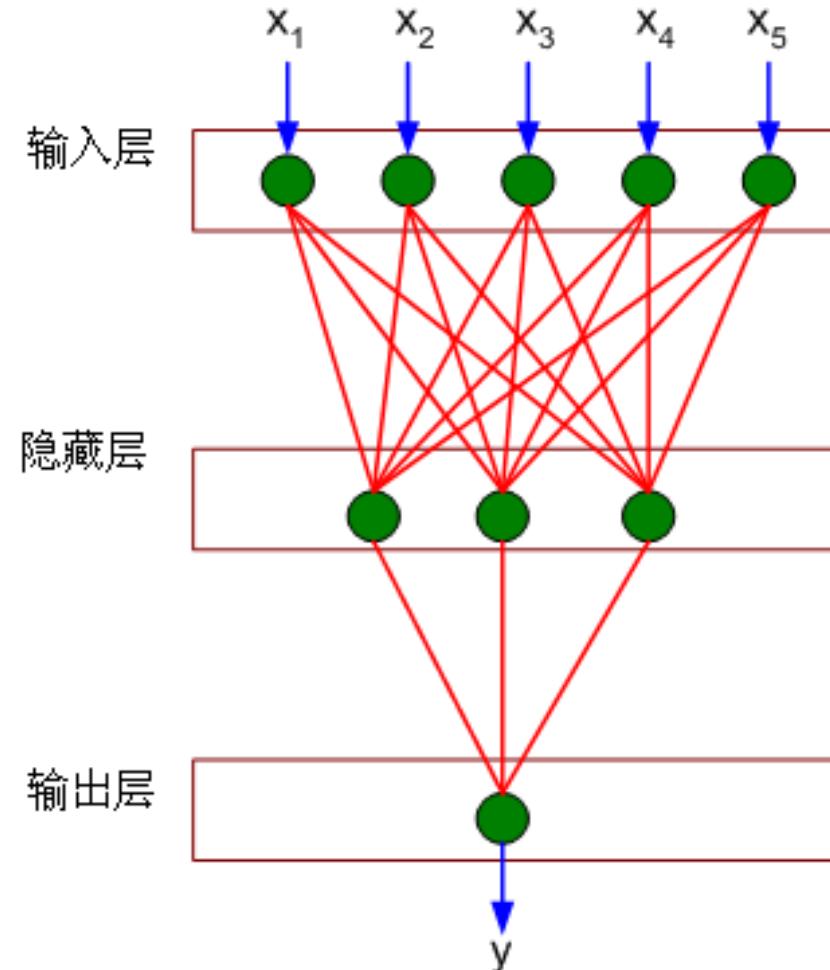


# 目 录

- 01 感知机
- 02 多层人工神经网络
- 03 多层感知机
- 04 误差反向传播网络
- 05 后向传播算法

# 多层人工神经网络

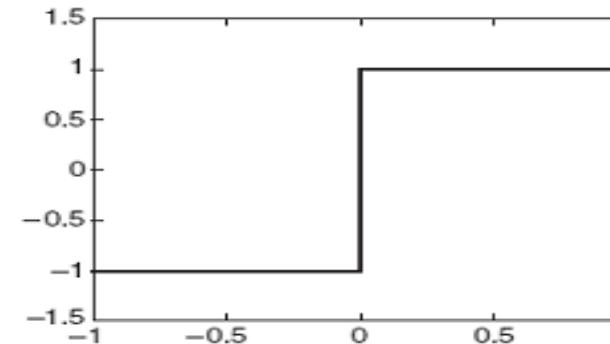
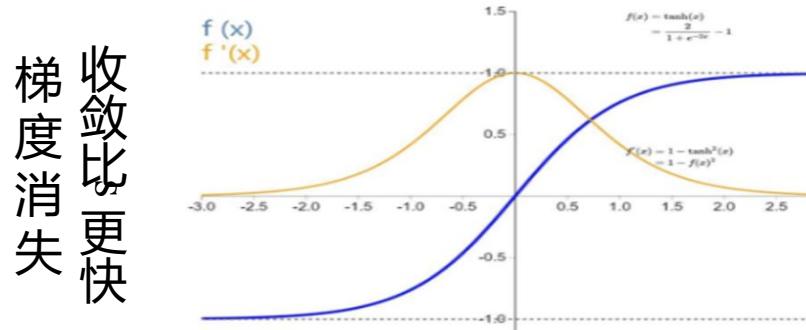
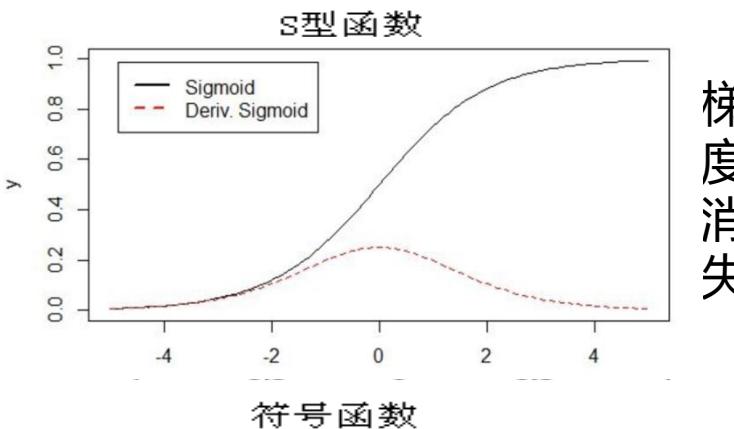
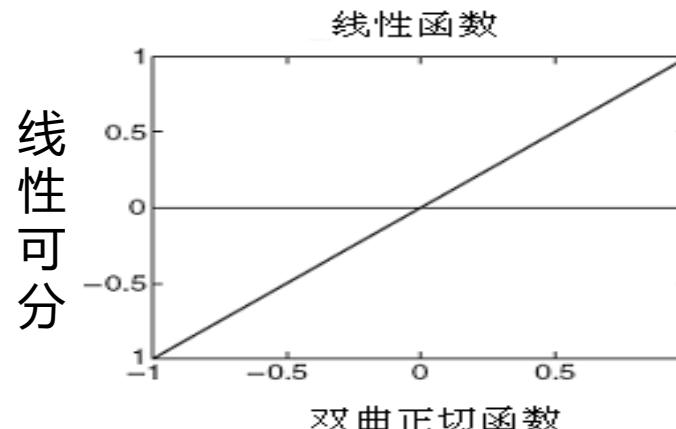
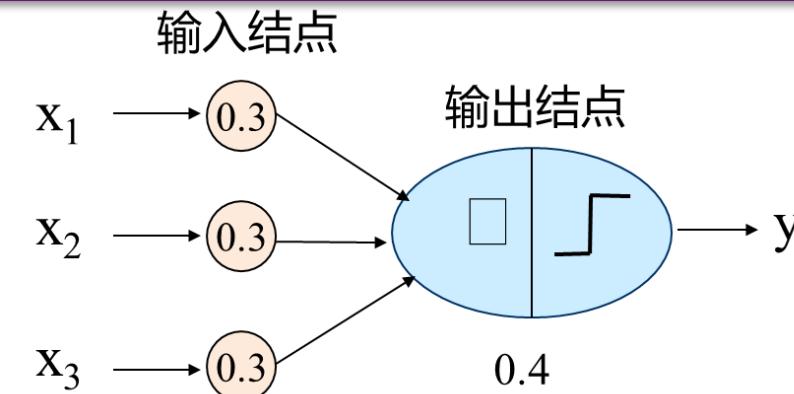
- 人工神经网络比感知机模型复杂
  - 输入层和输出层之间包含隐藏层



# 多层人工神经网络

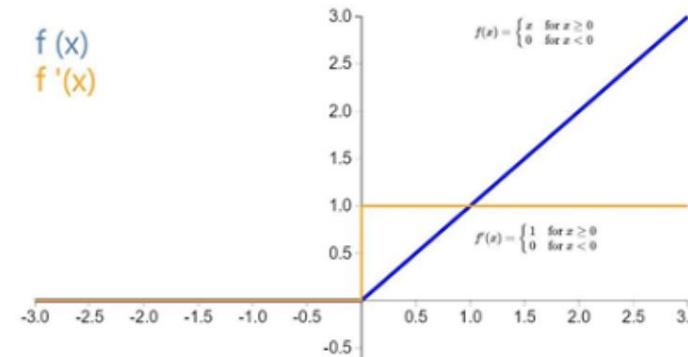
- 人工神经网络比感知机模型复杂
  - 激活函数可以是多种函数

$$\theta_0 \leftarrow \theta_0 - \eta \frac{\partial f}{\partial \theta_0}$$



# 多层人工神经网络

- 人工神经网络比感知机模型复杂
  - 激活函数可以是多种函数



解决了部分梯度消失问题

激活函数	函数	导数
Logistic 函数	$f(x) = \frac{1}{1+\exp(-x)}$	$f'(x) = f(x)(1-f(x))$
Tanh 函数	$f(x) = \frac{\exp(x)-\exp(-x)}{\exp(x)+\exp(-x)}$	$f'(x) = 1-f(x)^2$
ReLU	$f(x) = \max(0, x)$	$f'(x) = I(x > 0)$
ELU	$f(x) = \max(0, x) + \min(0, \gamma(\exp(x) - 1))$	$f'(x) = I(x > 0) + I(x \leq 0) \cdot \gamma \exp(x)$
SoftPlus 函数	$f(x) = \log(1 + \exp(x))$	$f'(x) = \frac{1}{1+\exp(-x)}$

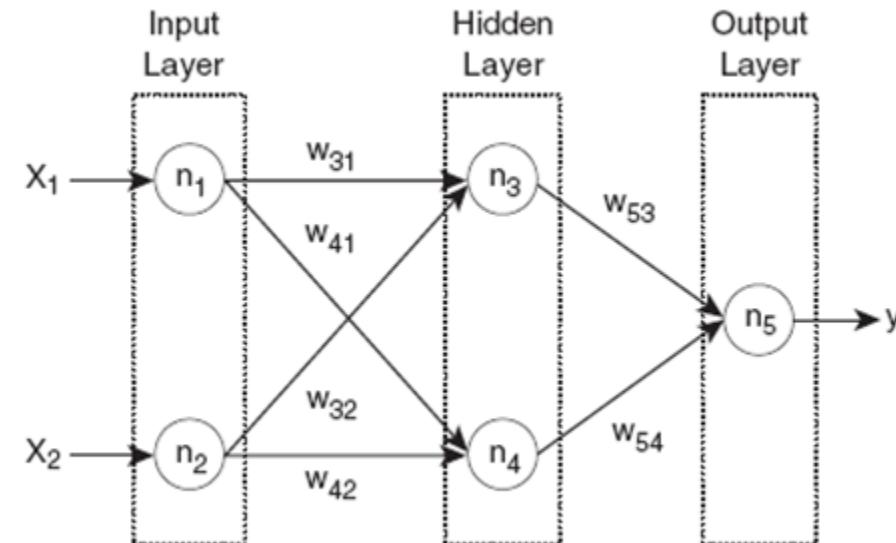
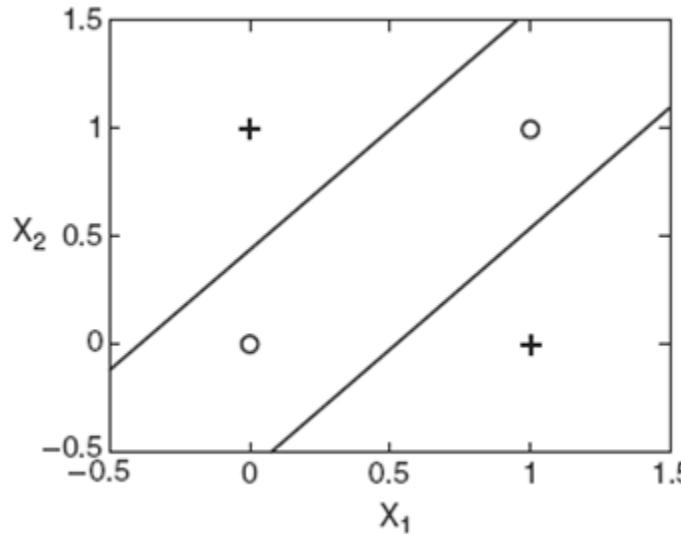
收敛速度比双面正切更快

导致神经元懒惰

设置较小的学习率

# 多层人工神经网络

- 例：用两层前馈神经网络解决异或问题



决策边界

神经网络拓扑结构



# 目 录

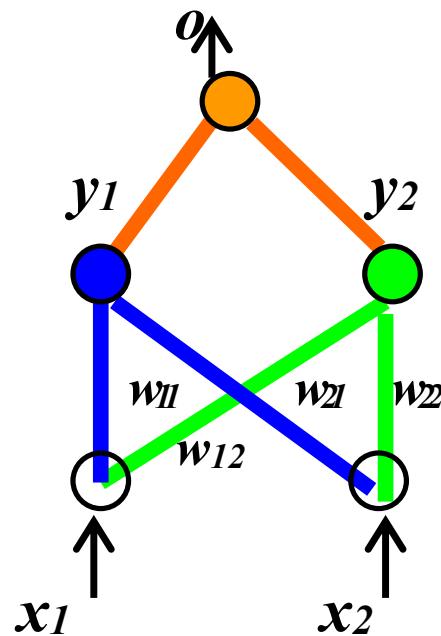
- 01 感知机
- 02 多层人工神经网络
- 03 多层感知机
- 04 误差反向传播网络
- 05 后向传播算法

# 多层感知机

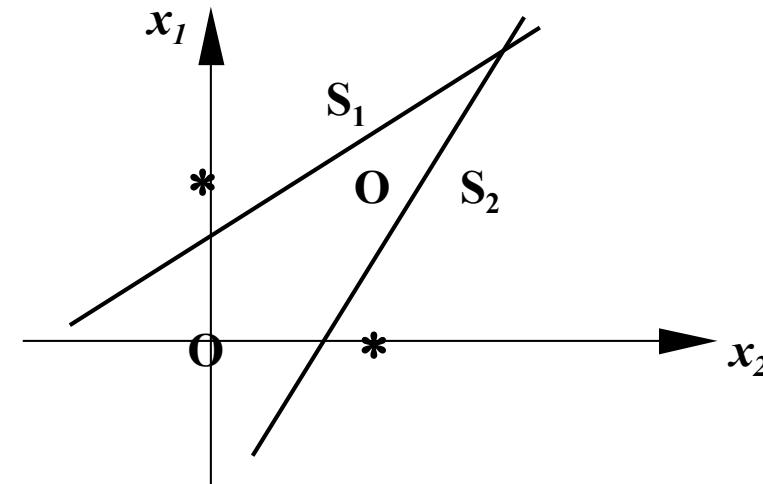
用两计算层感知器解决“异或”问题。

“异或”的真值表

x1	x2	y1	y2	o
0	0	1		
0	1	1		
1	0	0		
1	1	1		



双层感知器



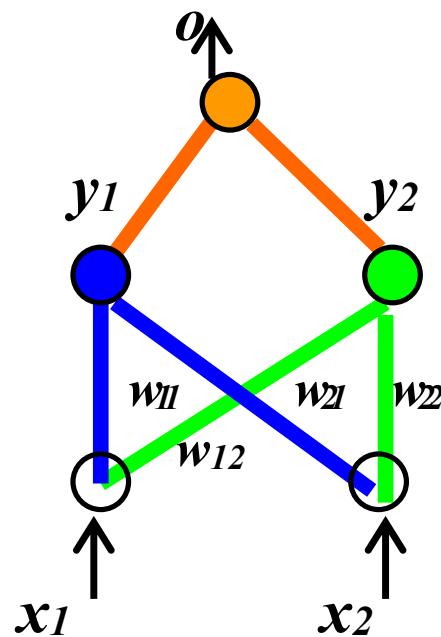
“异或”问题分类

# 多层感知机

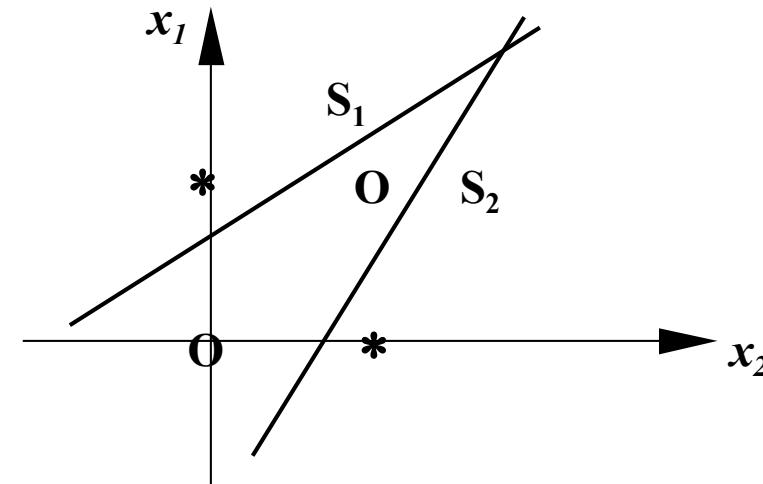
用两计算层感知器解决“异或”问题。

“异或”的真值表

x1	x2	y1	y2	o
0	0		1	
0	1		0	
1	0		1	
1	1		1	



双层感知器



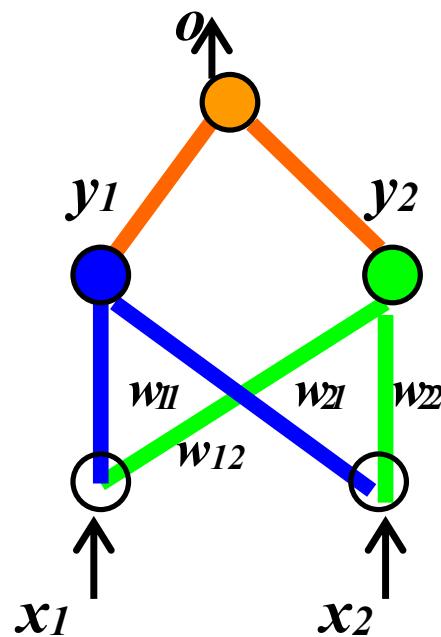
“异或”问题分类

# 多层感知机

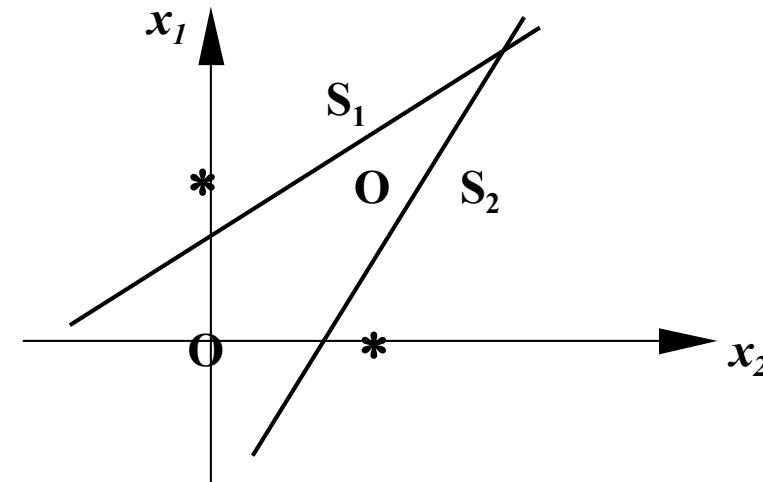
用两计算层感知器解决“异或”问题。

“异或”的真值表

x1	x2	y1	y2	o
0	0	1	1	
0	1	1	0	
1	0	0	1	
1	1	1	1	



双层感知器



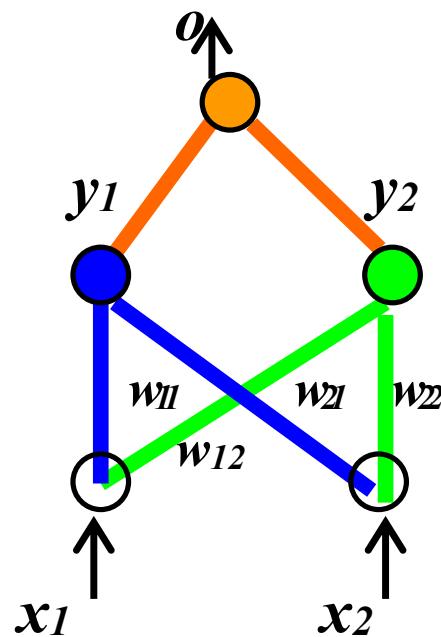
“异或”问题分类

# 多层感知机

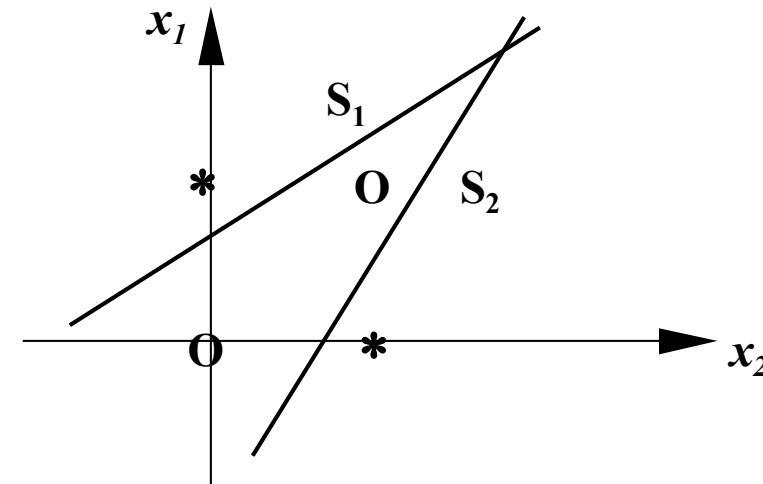
用两计算层感知器解决“异或”问题。

“异或”的真值表

x1	x2	y1	y2	o
0	0	1	1	0
0	1	1	0	1
1	0	0	1	1
1	1	1	1	0



双层感知器



“异或”问题分类

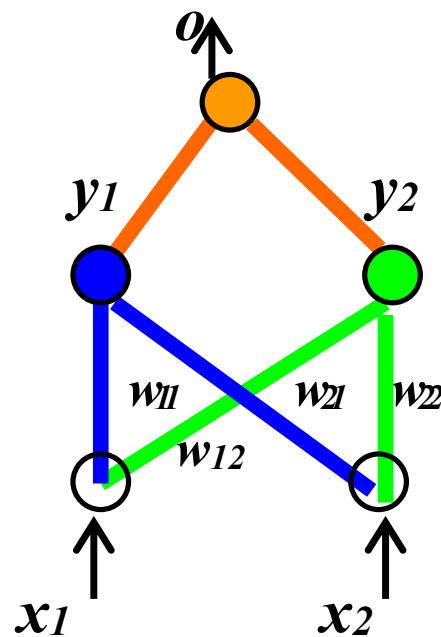
# 多层感知机

用两计算层感知器解决“异或”问题。

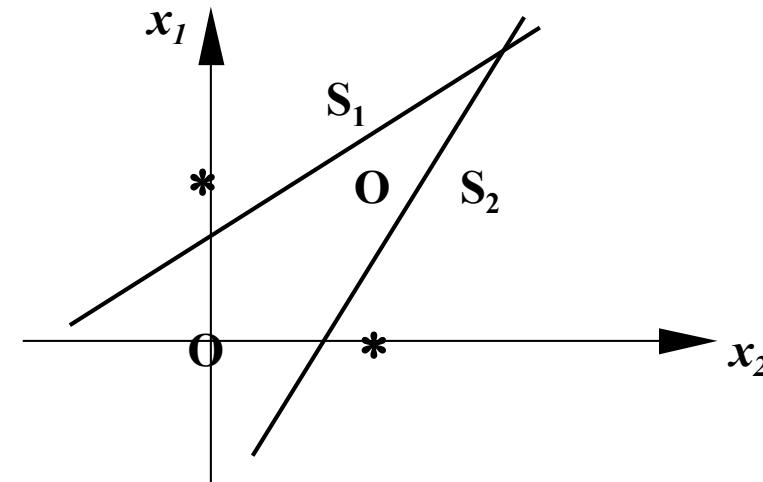
“异或”的真值表

x1	x2	
0	0	0
0	1	1
1	0	1
1	1	0

0
0
1
1
0



双层感知器



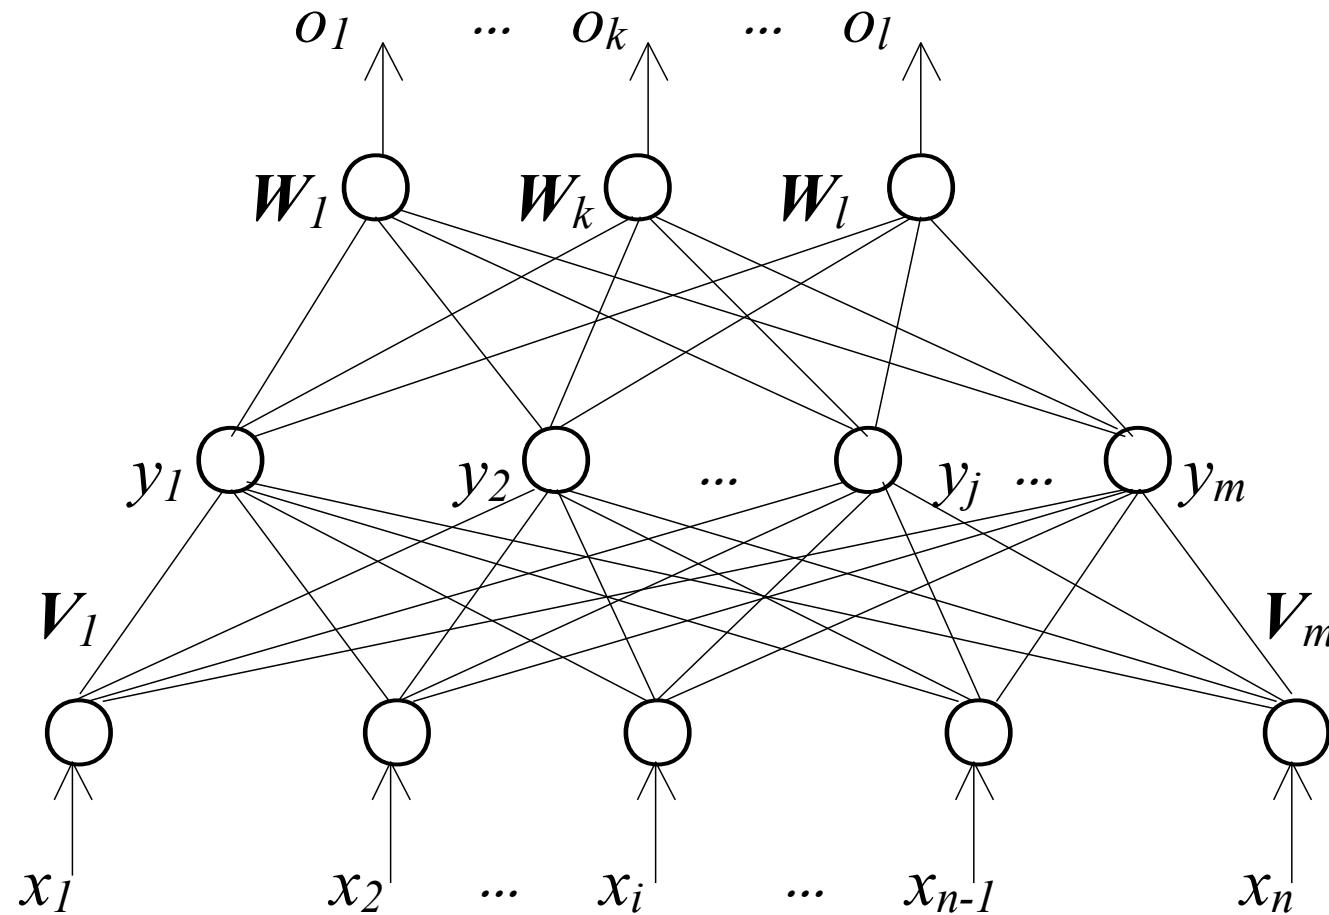
“异或”问题分类



# 目 录

- 01 感知机
- 02 多层人工神经网络
- 03 多层感知机
- 04 误差反向传播网络
- 05 后向传播算法

# 误差反向传播 (BP) 网络



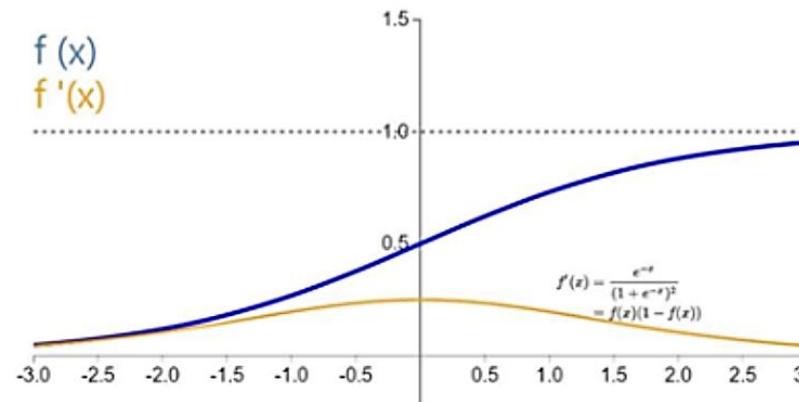
基于BP算法的多层前馈网络模型

# 误差反向传播 (BP) 网络

- 激活函数

- 必须处处可导

- 一般都使用S型函数



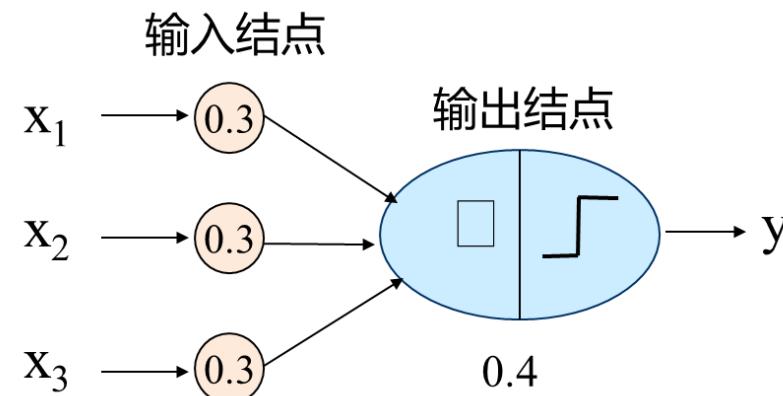
- 使用S型激活函数时BP网络输入与输出关系

- 输入

$$net = x_1 w_1 + x_2 w_2 + \dots + x_n w_n$$

- 输出

$$y = f(net) = \frac{1}{1 + e^{-net}}$$



# 误差反向传播 (BP) 网络

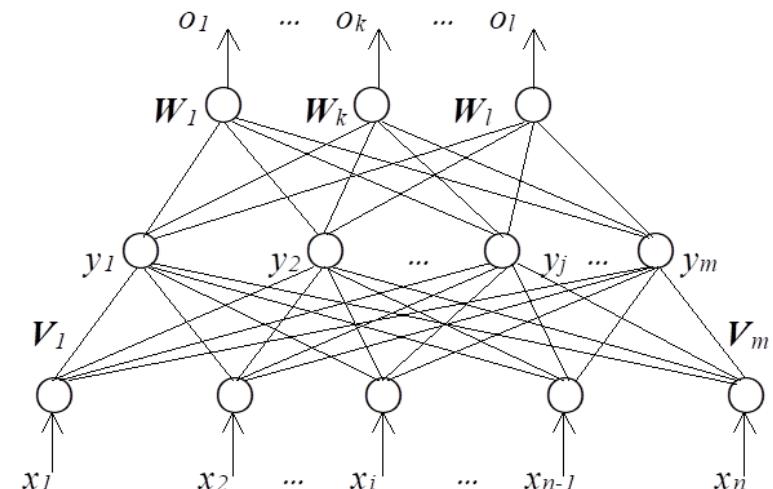
- 学习的类型: 监督式学习
- 核心思想:
  - 将输出误差以某种形式通过隐层向输入层逐层反传

将误差分摊给各层的所有单元  
——各层单元的误差信号

修正各单元权值

- 学习的过程:

- 信号的正向传播 → 误差的反向传播



# 误差反向传播 (BP) 网络



- 正向传播:

- 输入样本 — 输入层 — 各隐层 — 输出层

- 判断是否转入反向传播阶段:

- 若输出层的实际输出与期望的输出（教师信号）不符

- 误差反传

- 误差以某种形式在各层表示 —— 修正各层单元的权值



- 网络输出的误差减少到可接受的程度

- 进行到预先设定的学习次数为止



# 目 录

- 01 感知机
- 02 多层人工神经网络
- 03 多层感知机
- 04 误差反向传播网络
- 05 后向传播算法

# 后向传播算法

## 1、初始化权重

- 循环以下两步，直到满足条件

## 2、向前传播输入

- 在每个节点加权求和，再代入激活函数



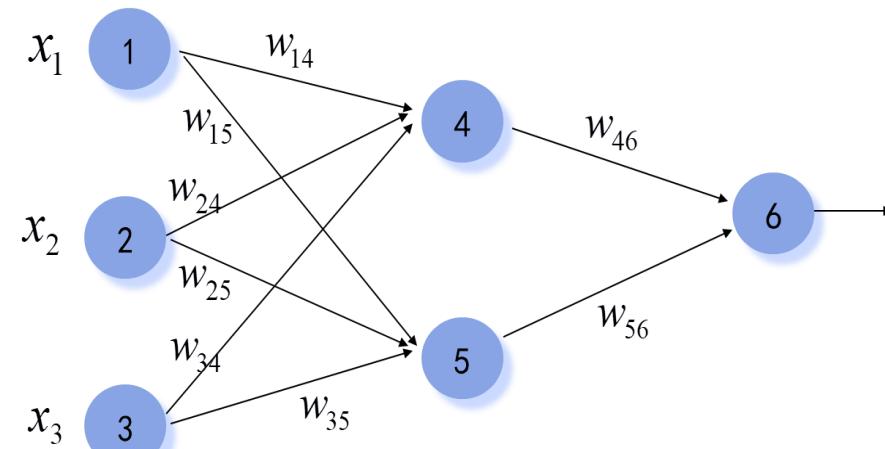
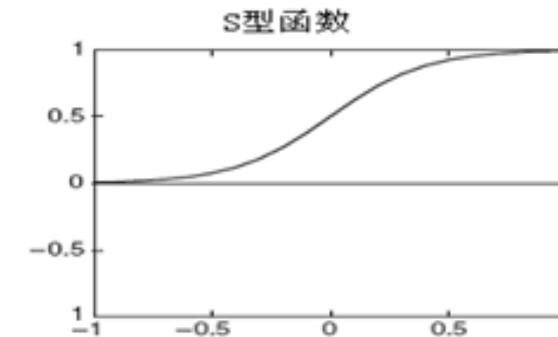
## 3、向后传播误差

$$E_j = \frac{1}{2} \sum_{k=1}^K (y_k - t_k)^2$$

$$E_j = \frac{1}{2} \sum_{k=1}^K (y_k - t_k)^2$$

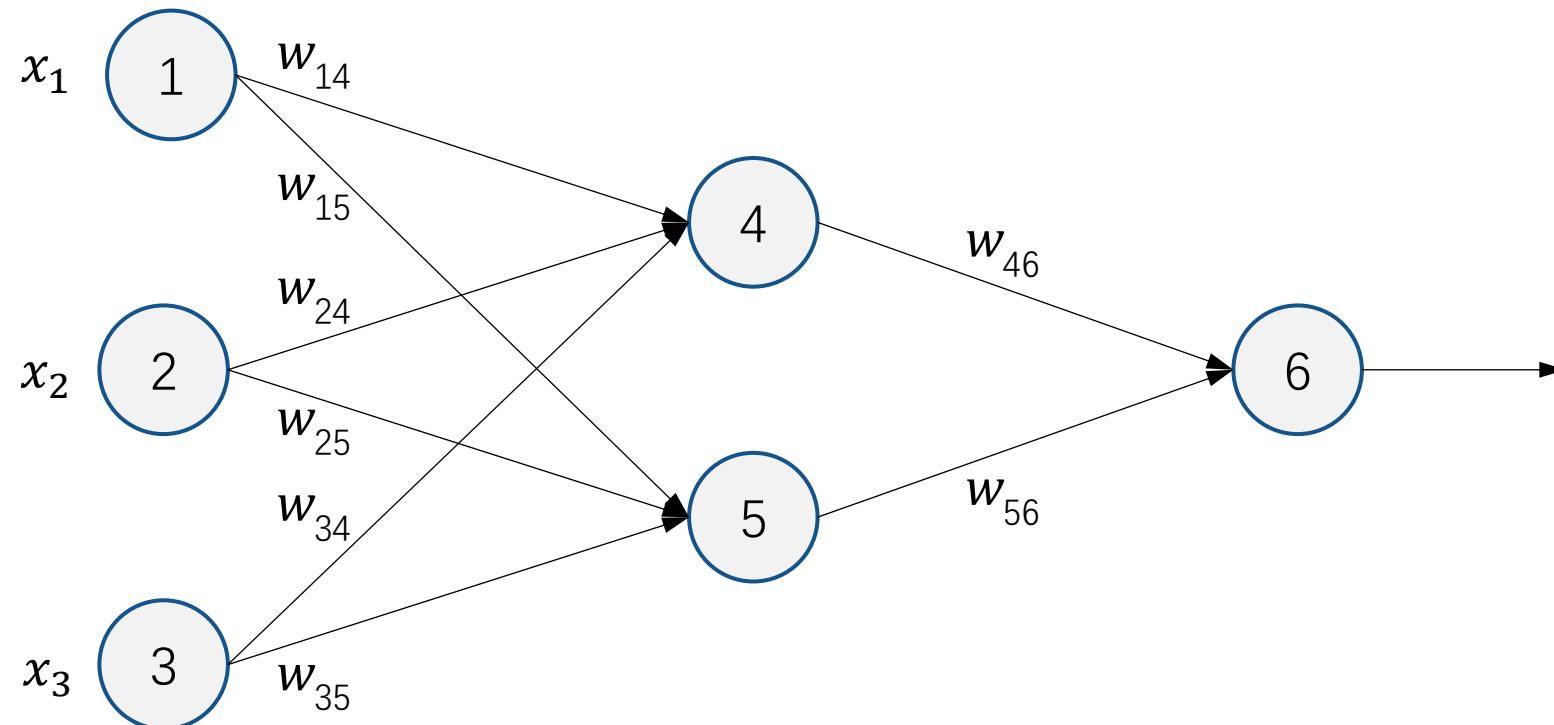
$$\nabla_j = \nabla_j + \delta E_j$$

$$t_j = t_j + \delta E_j$$



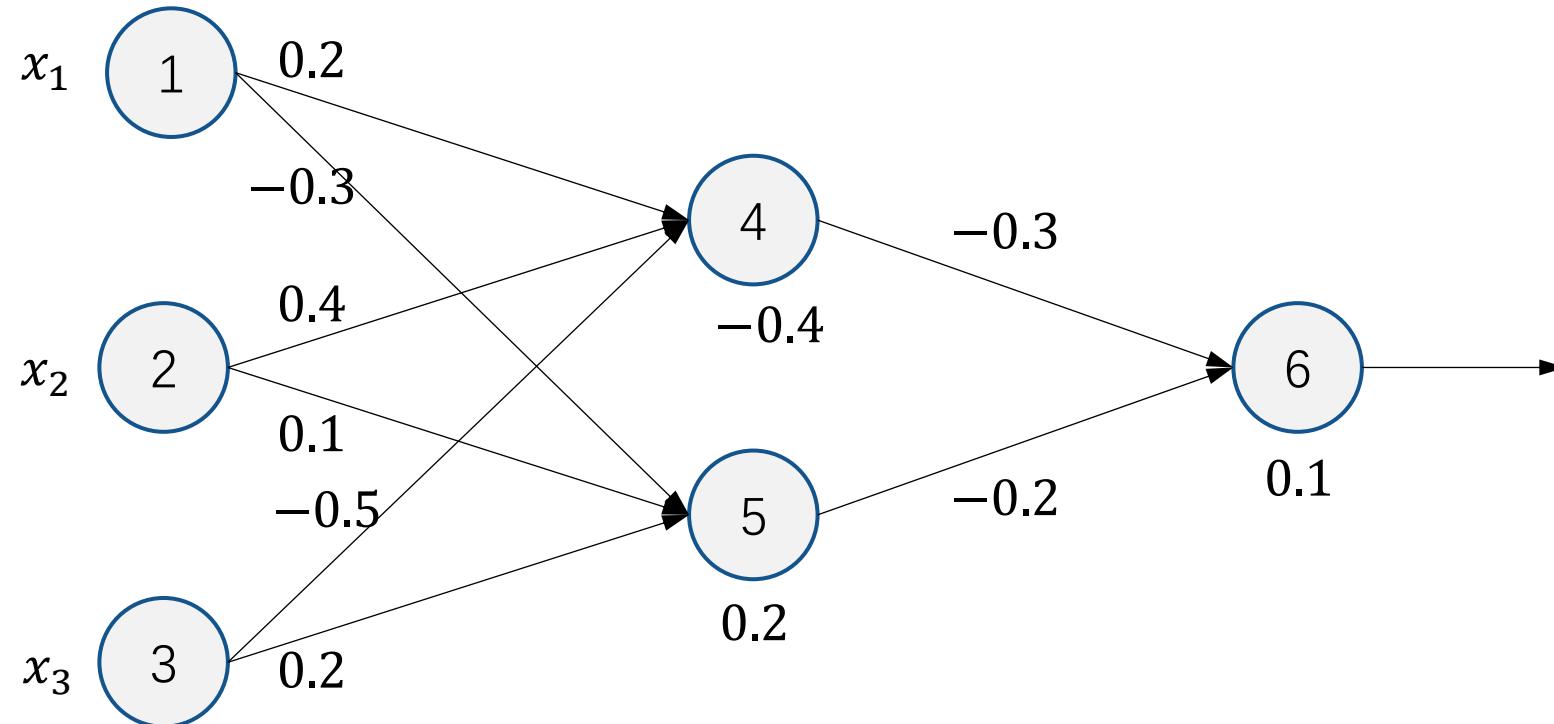
# 后向传播算法

## 1、初始化权重和偏置

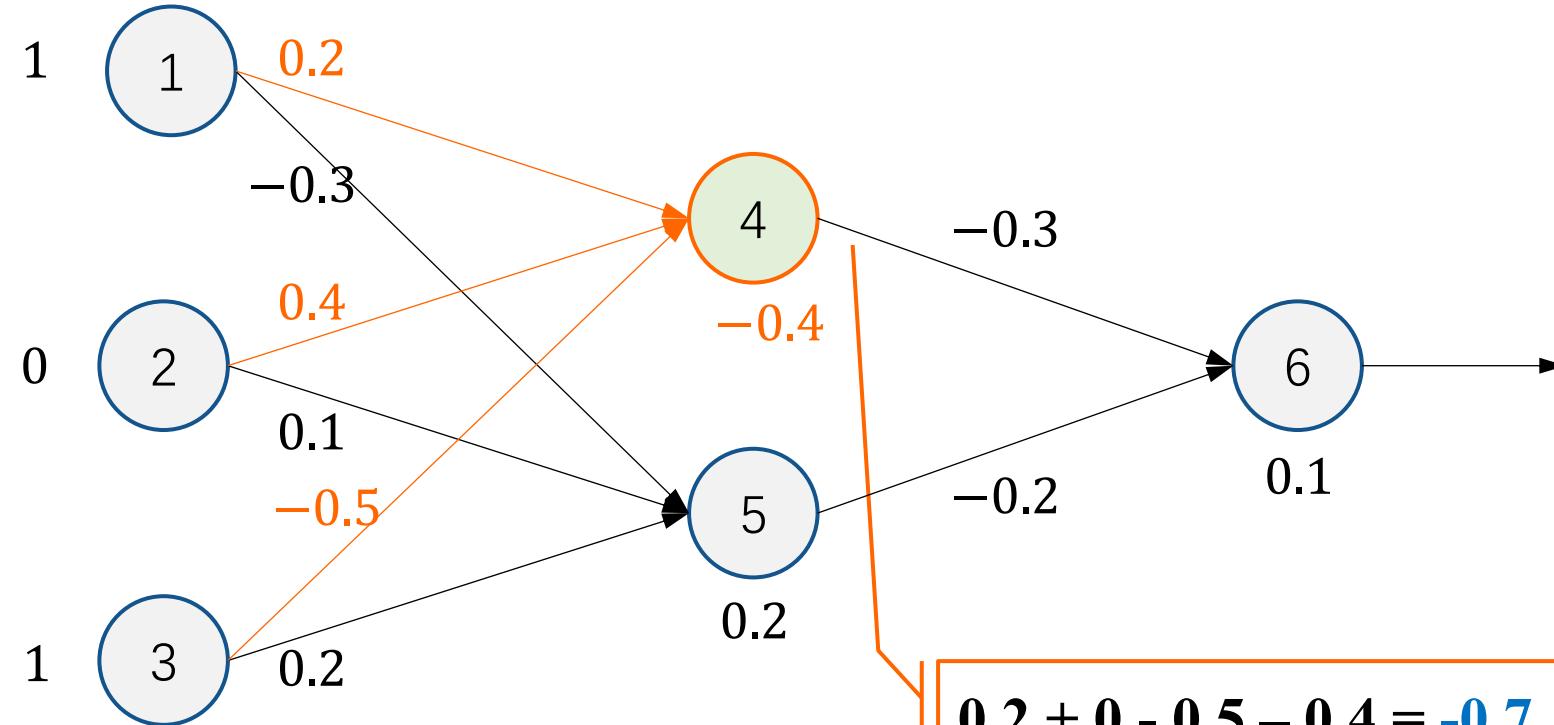


# 后向传播算法

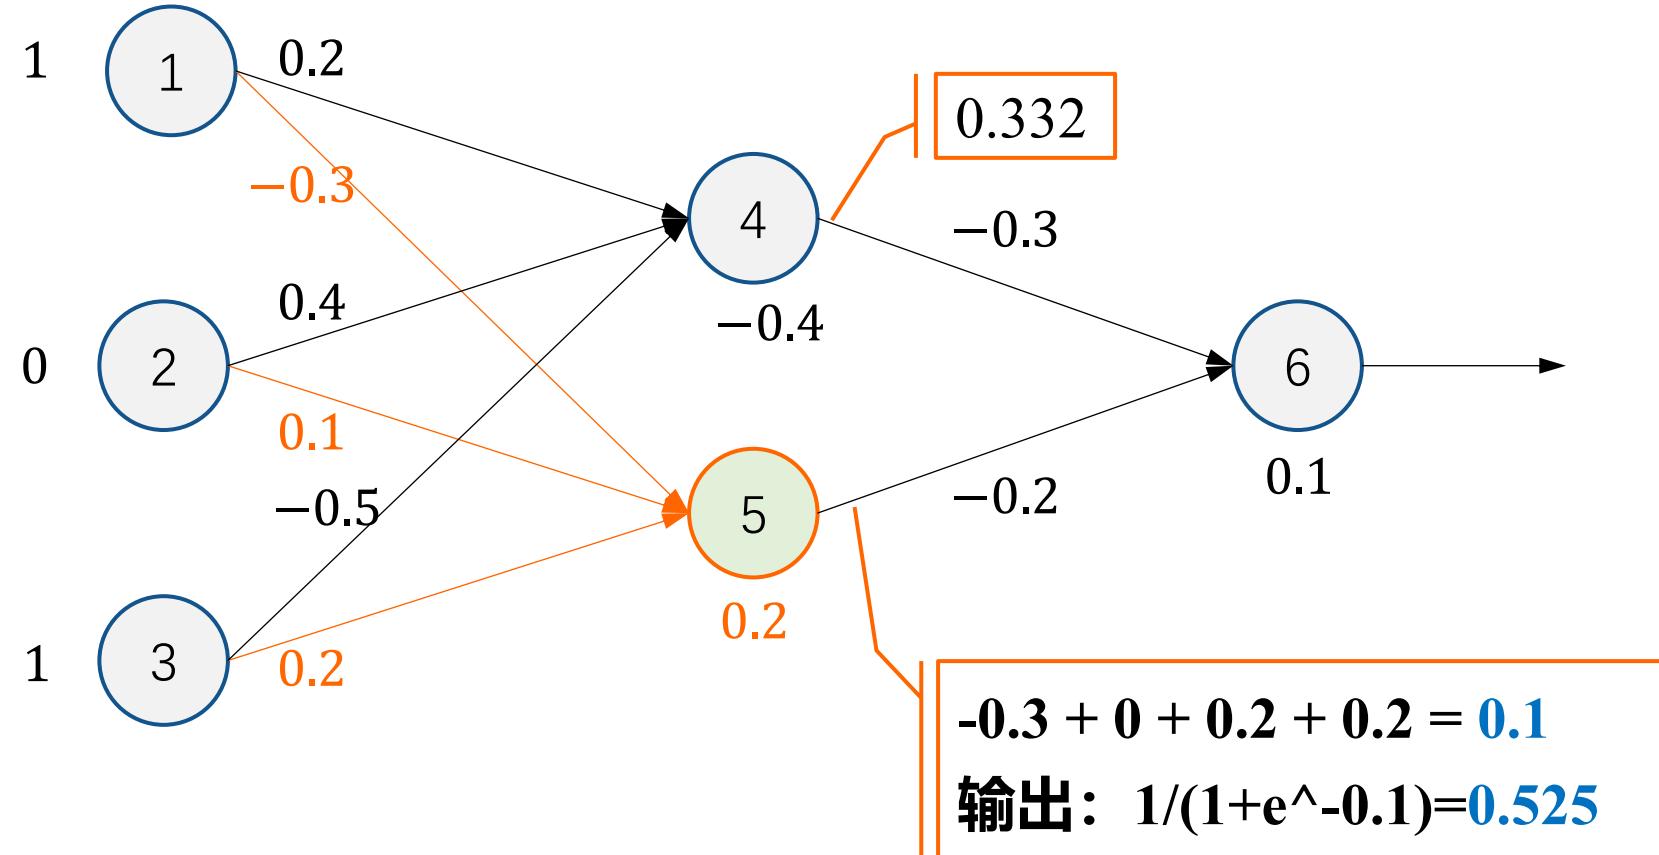
## 2、向前传播输入



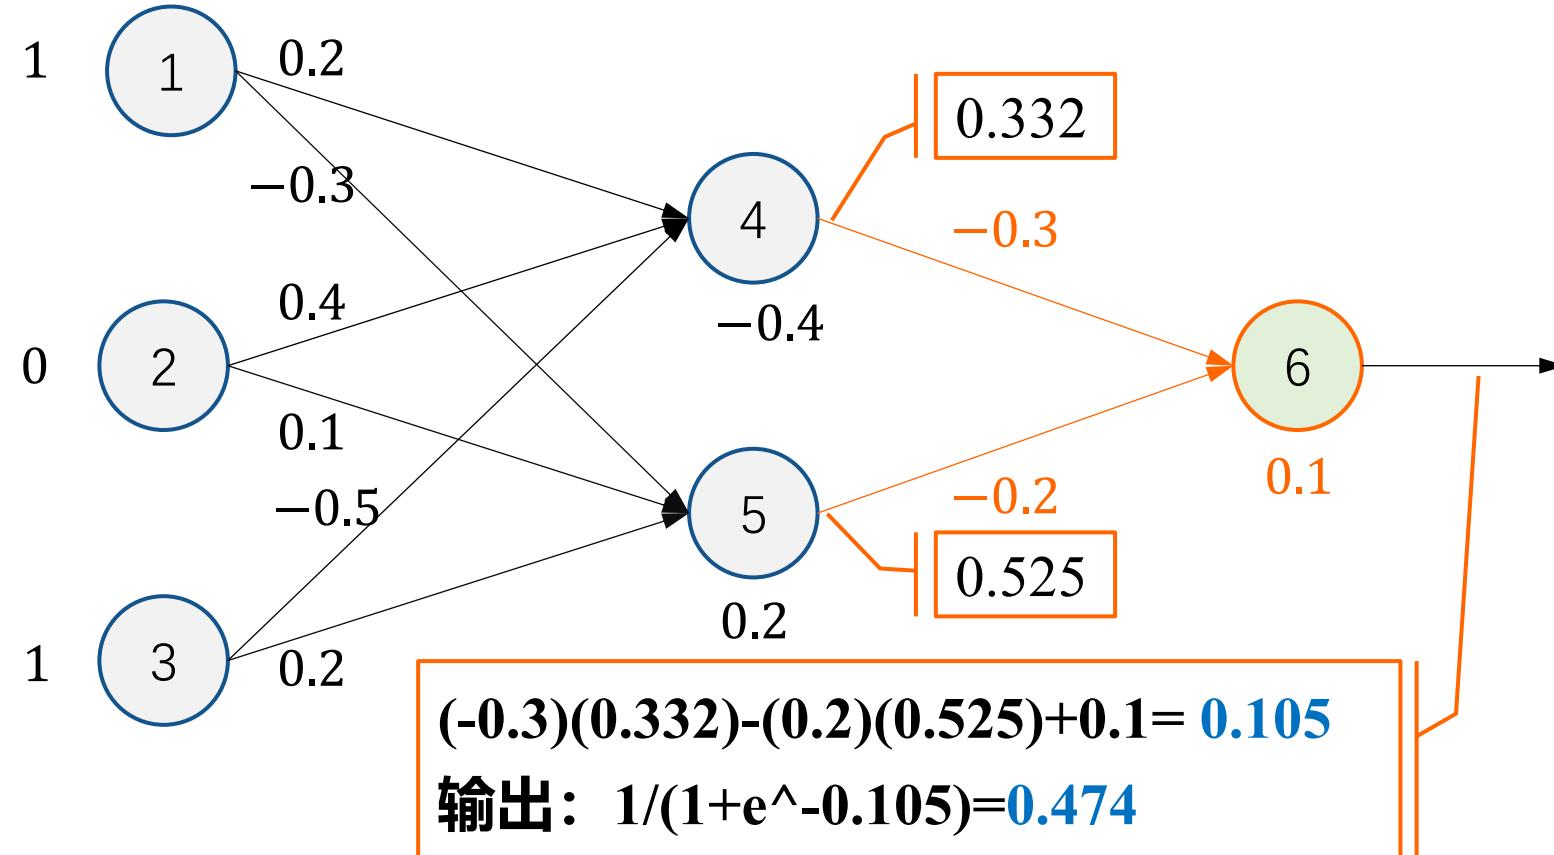
# 前向转播



# 前向转播

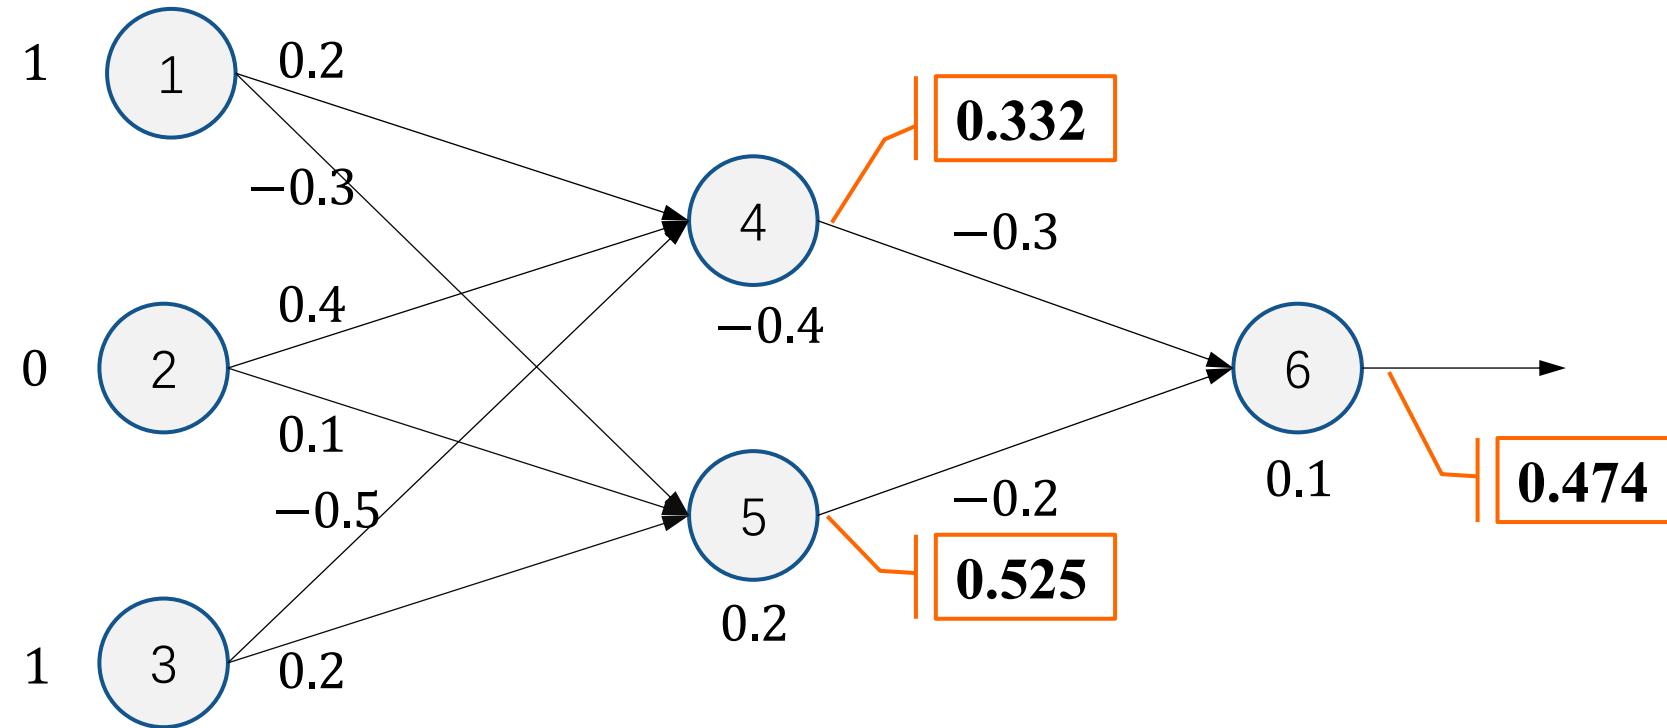


# 前向转播



# 前向转播

---



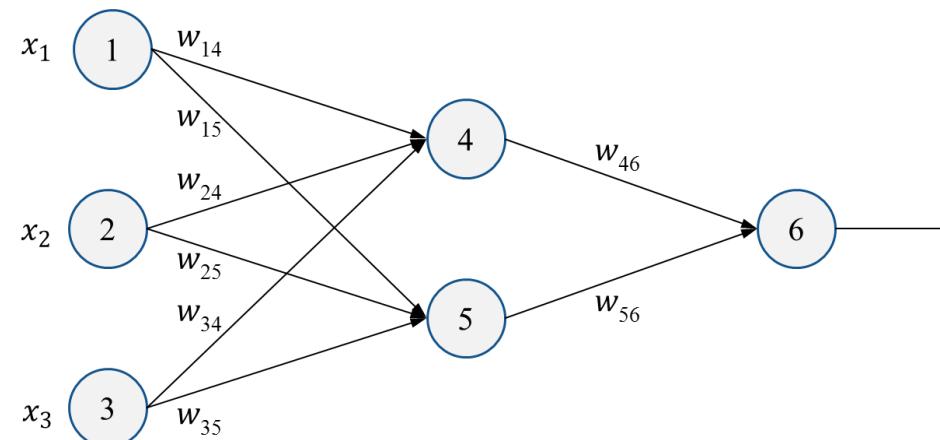
# 前向转播

- 初始随机设置参数

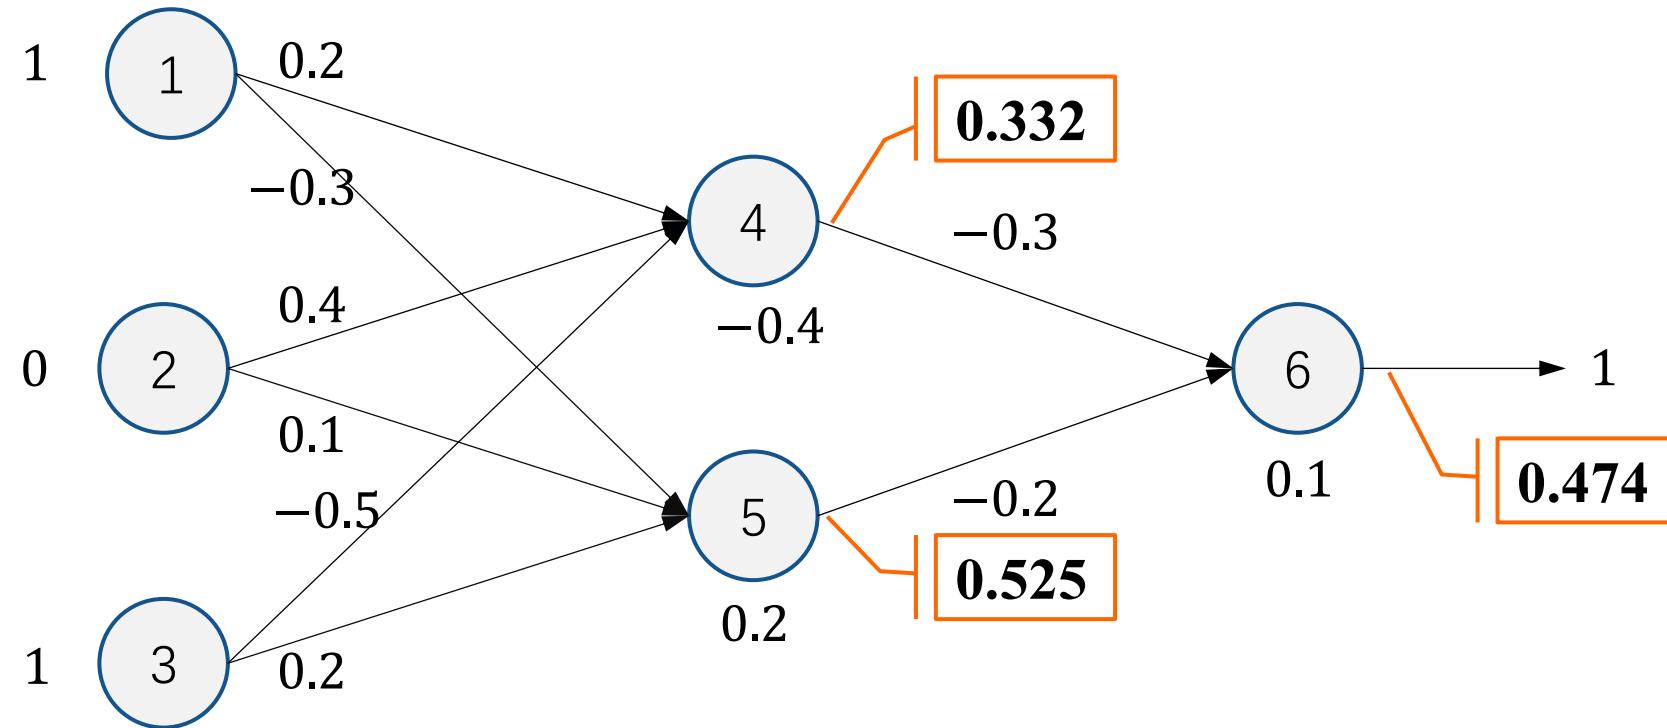
$x_1$	$x_2$	$x_3$	$w_{14}$	$w_{15}$	$w_{24}$	$w_{25}$	$w_{34}$	$w_{35}$	$w_{46}$	$w_{56}$	$\theta_4$	$\theta_5$	$\theta_6$
1	0	1	0.2	-0.3	0.4	0.1	-0.5	0.2	-0.3	-0.2	-0.4	0.2	0.1

- 输入和输出的表格

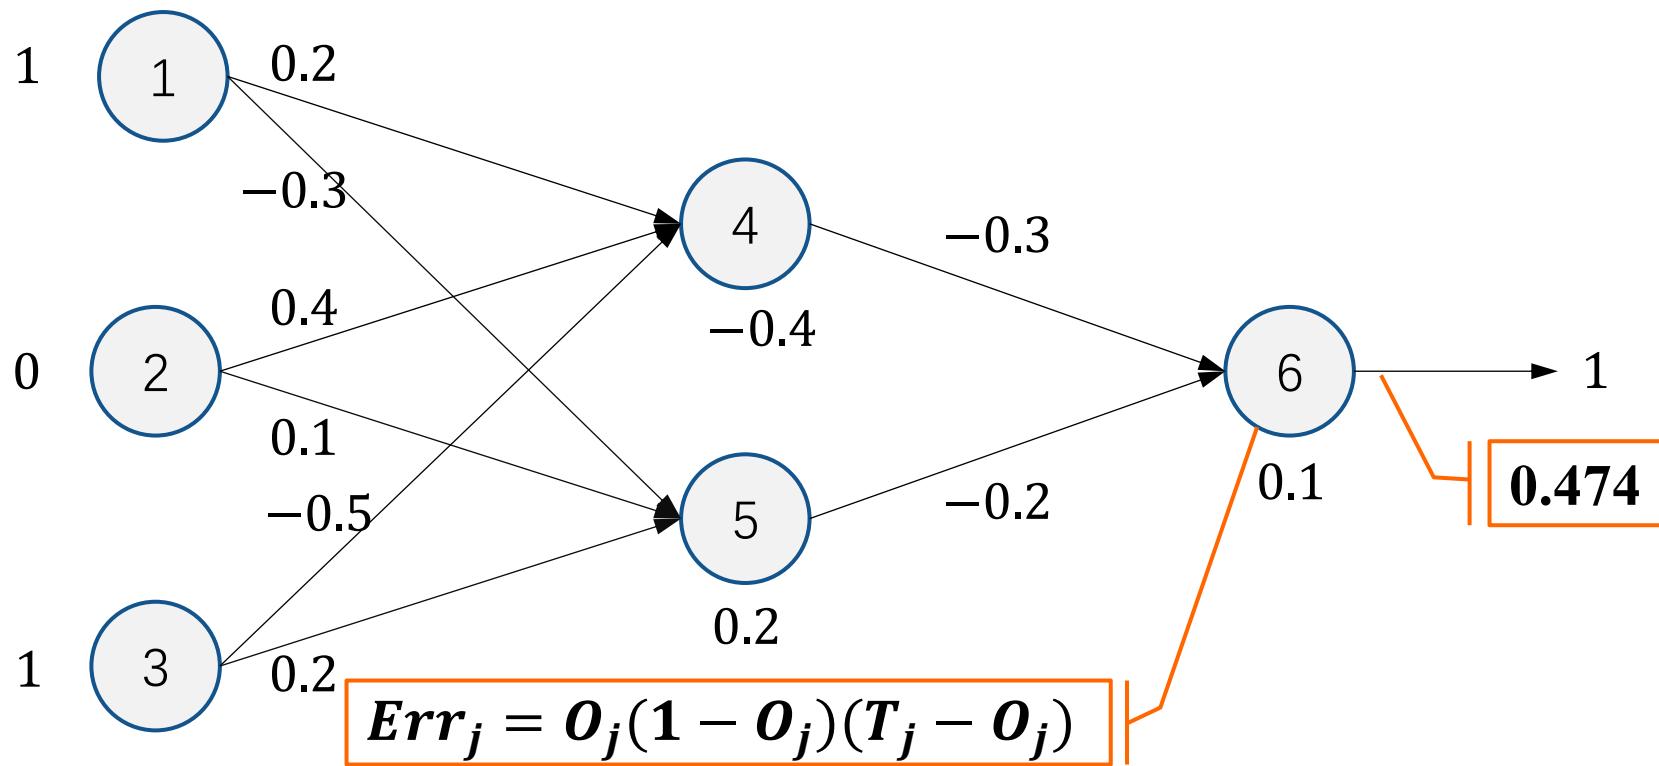
<i>Unit j</i>	<i>Net input, <math>I_j</math></i>	<i>Output, <math>O_j</math></i>
4	$0.2 + 0 - 0.5 - 0.4 = -0.7$	$1/(1 + e^{0.7}) = 0.332$
5	$-0.3 + 0 + 0.2 + 0.2 = 0.1$	$1/(1 + e^{-0.1}) = 0.525$
6	$(-0.3)(0.332) - (0.2)(0.525) + 0.1 = -0.105$	$1/(1 + e^{0.105}) = 0.474$



# 前向转播



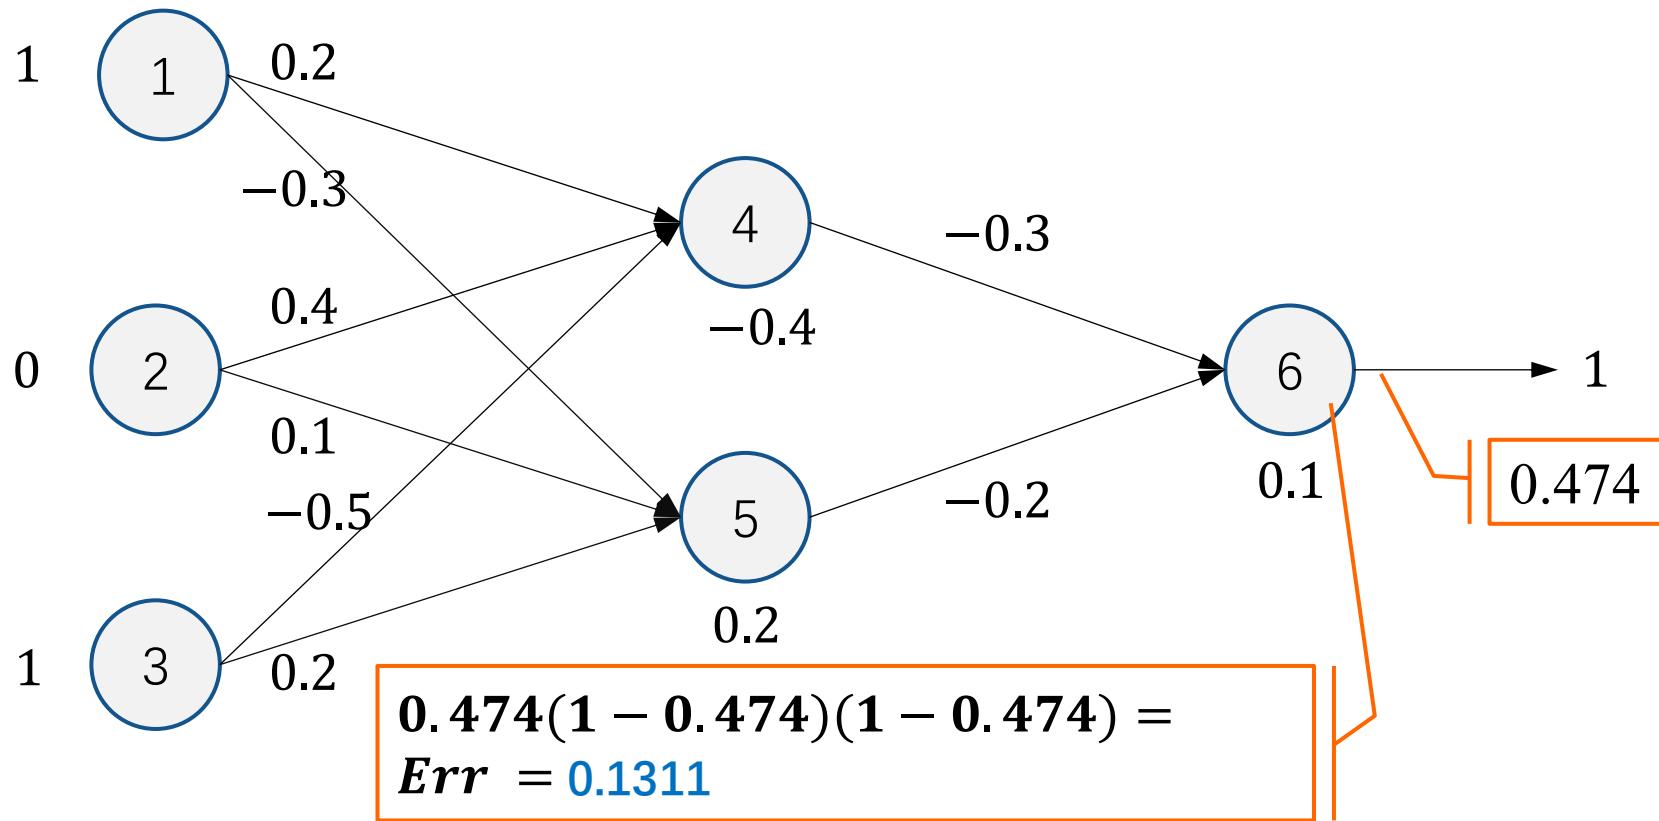
# 后向传播



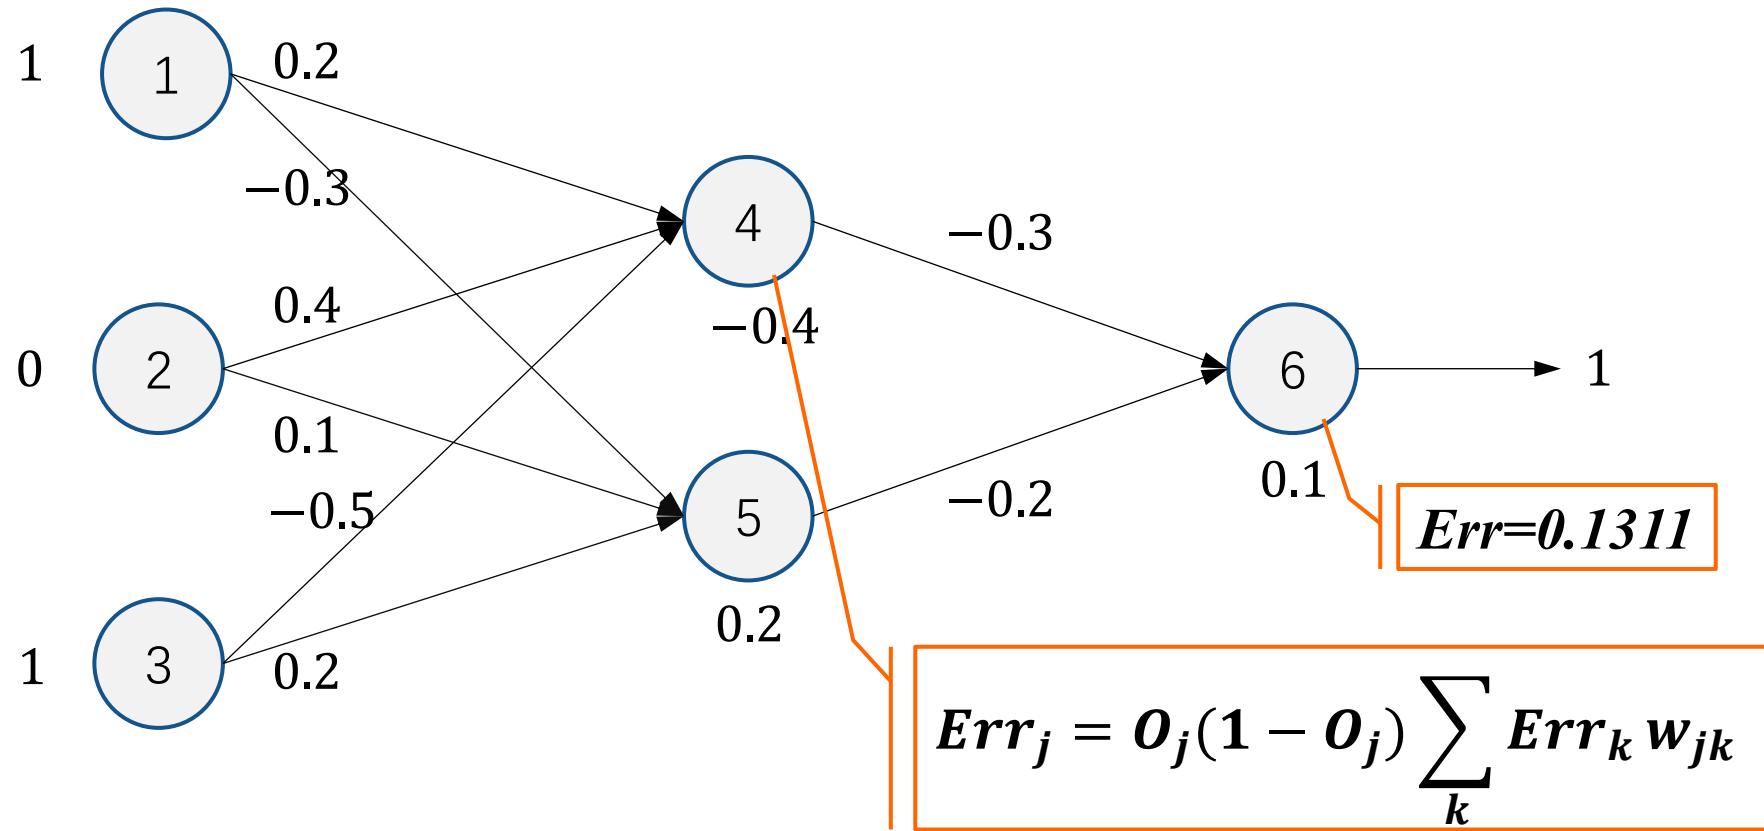
$$Err_j = o_j(1 - o_j)(T_j - o_j)$$

0.474

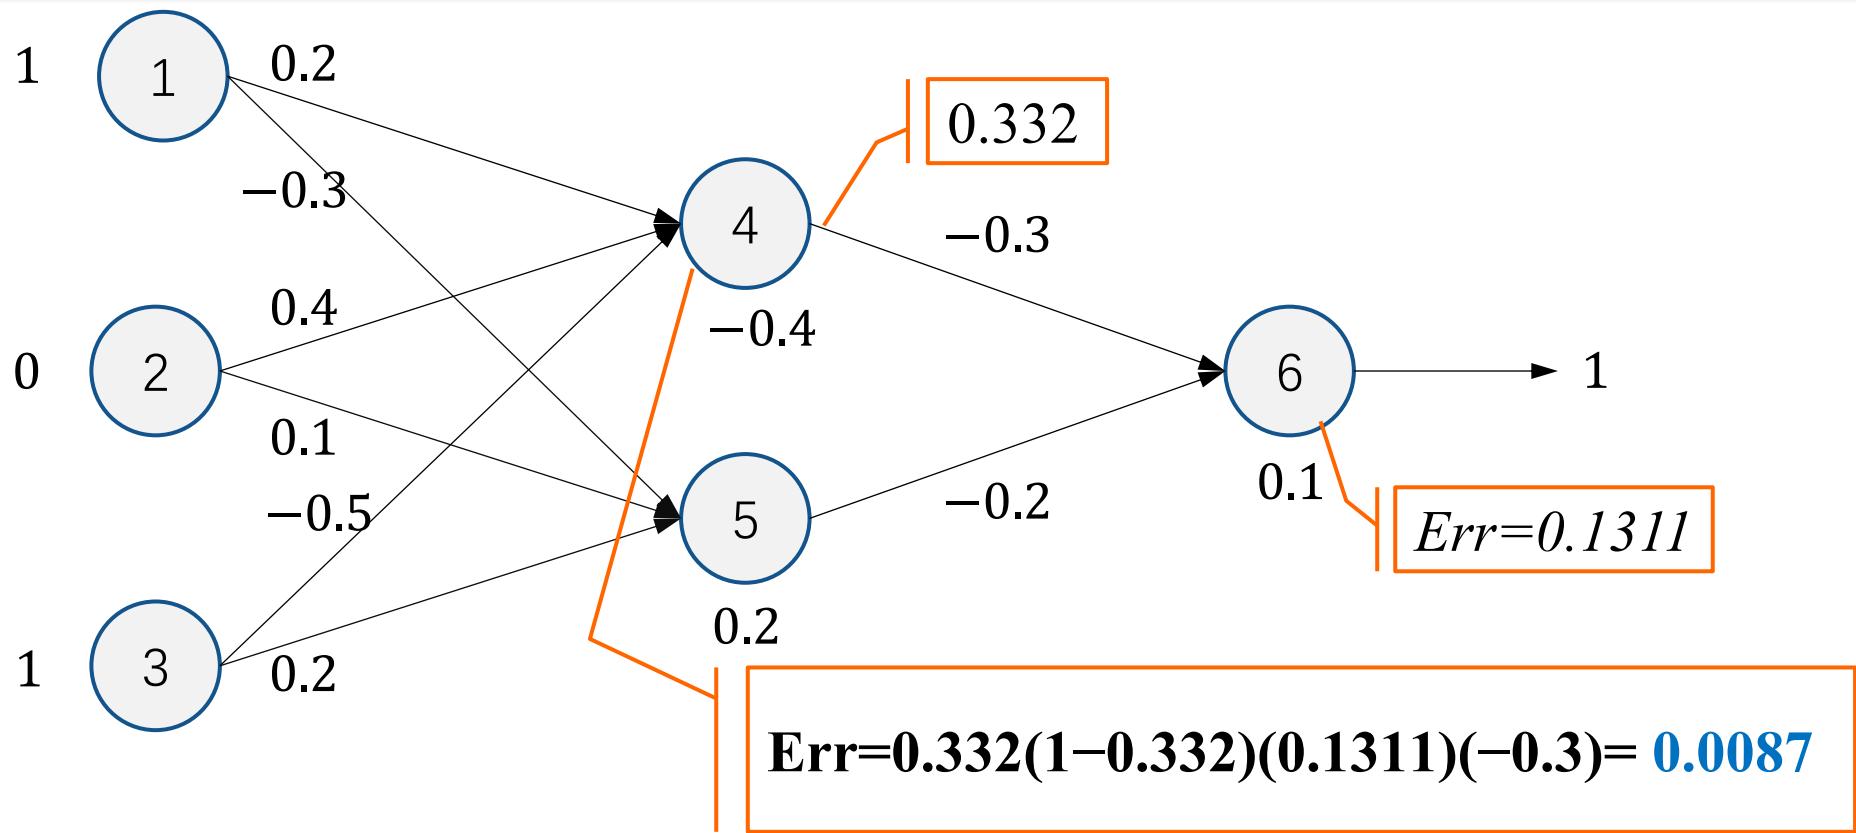
# 后向传播



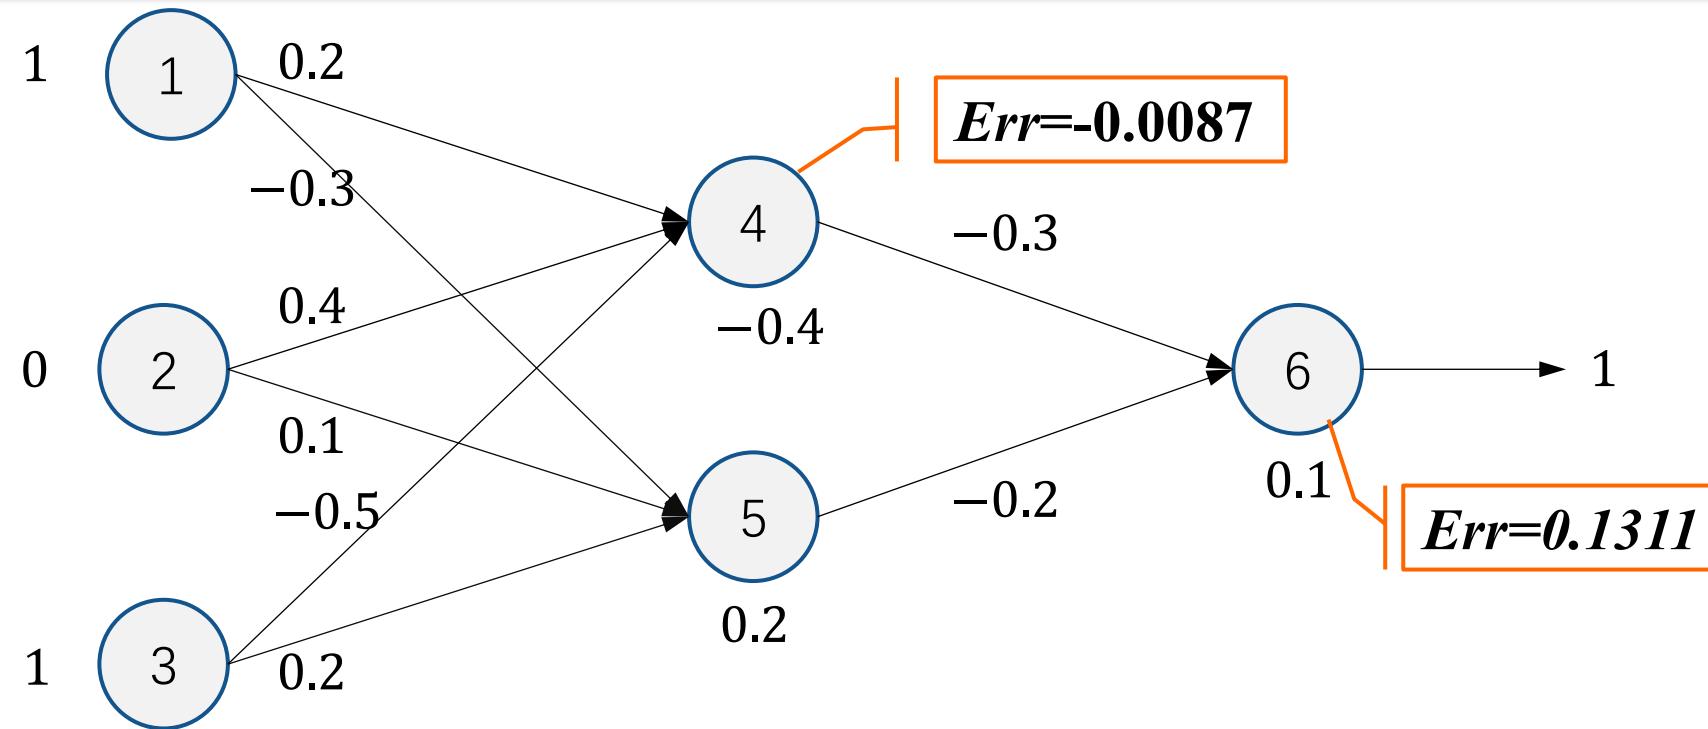
# 后向传播



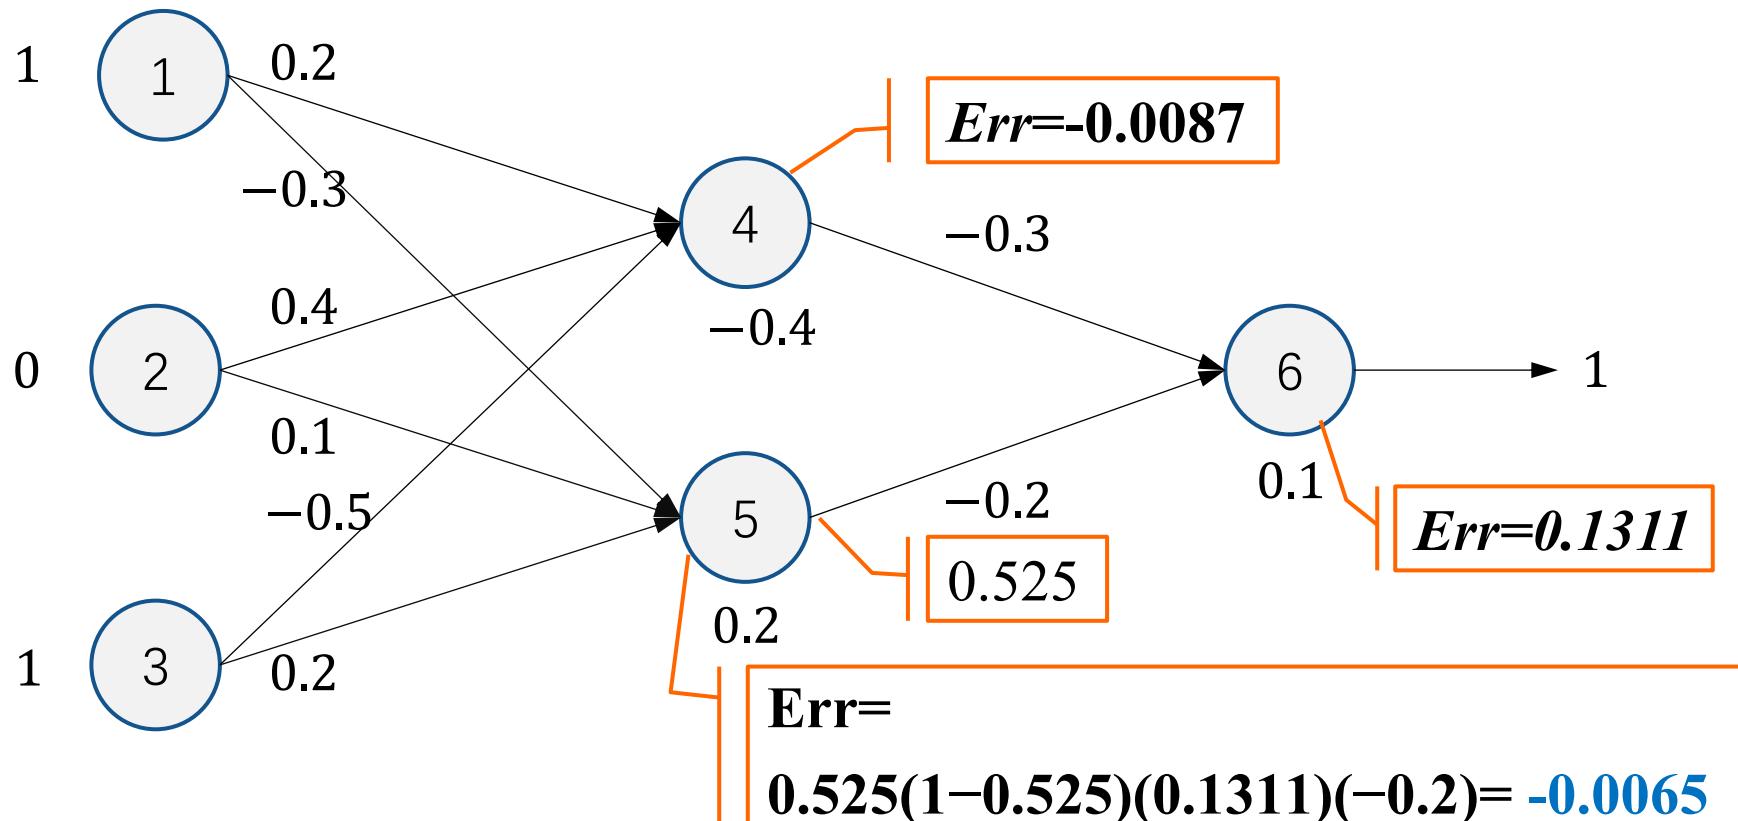
# 后向传播



# 后向传播

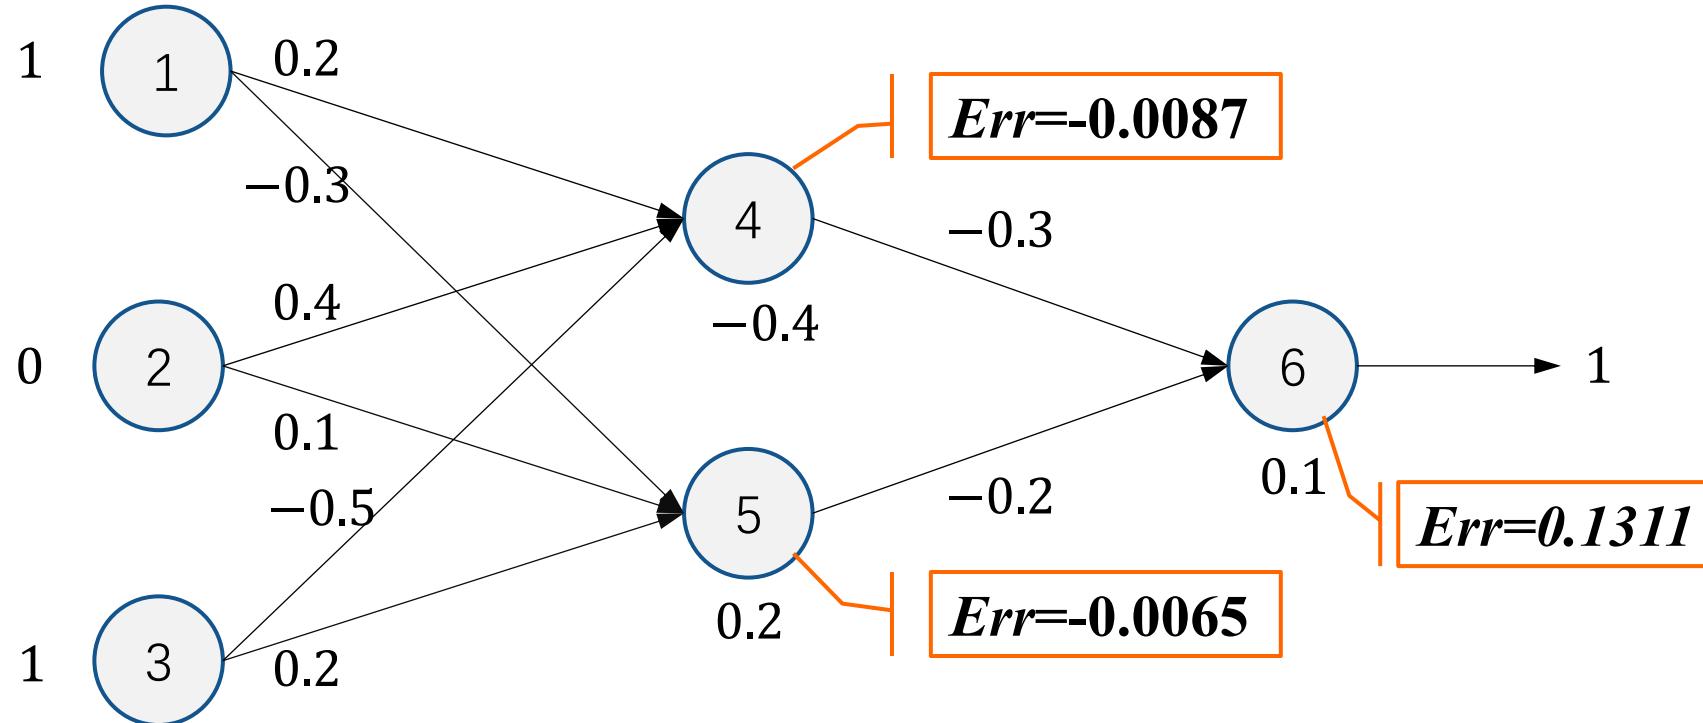


# 后向传播



$$Err_j = O_j(1 - O_j) \sum_k Err_k w_{jk}$$

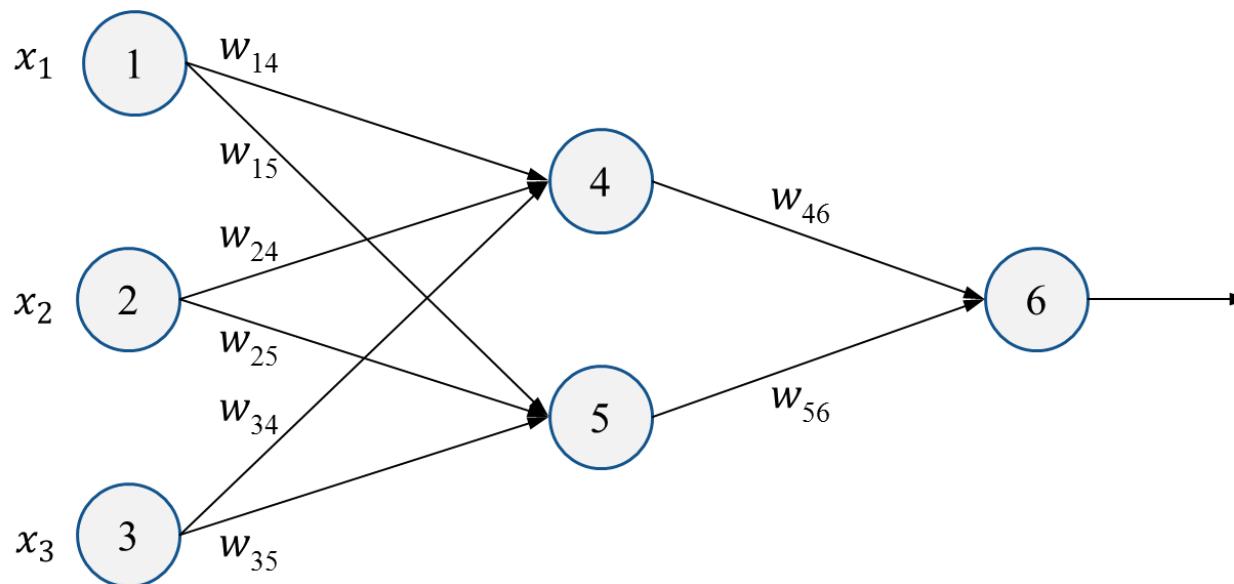
# 后向传播



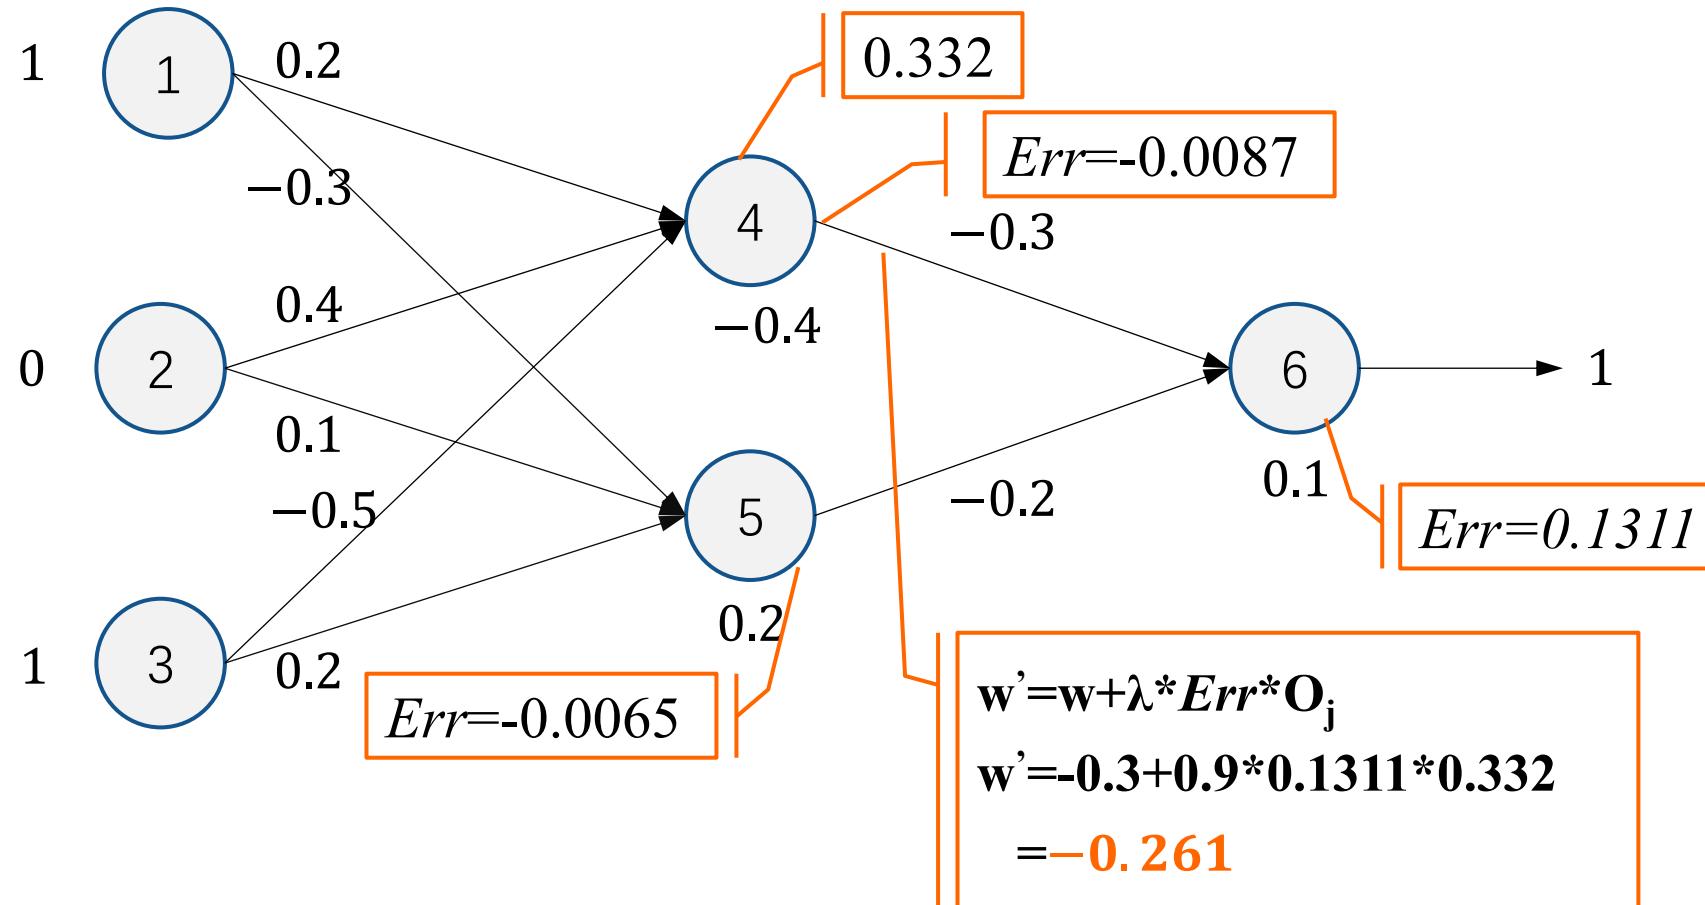
# 后向传播

- 计算各结点的误差

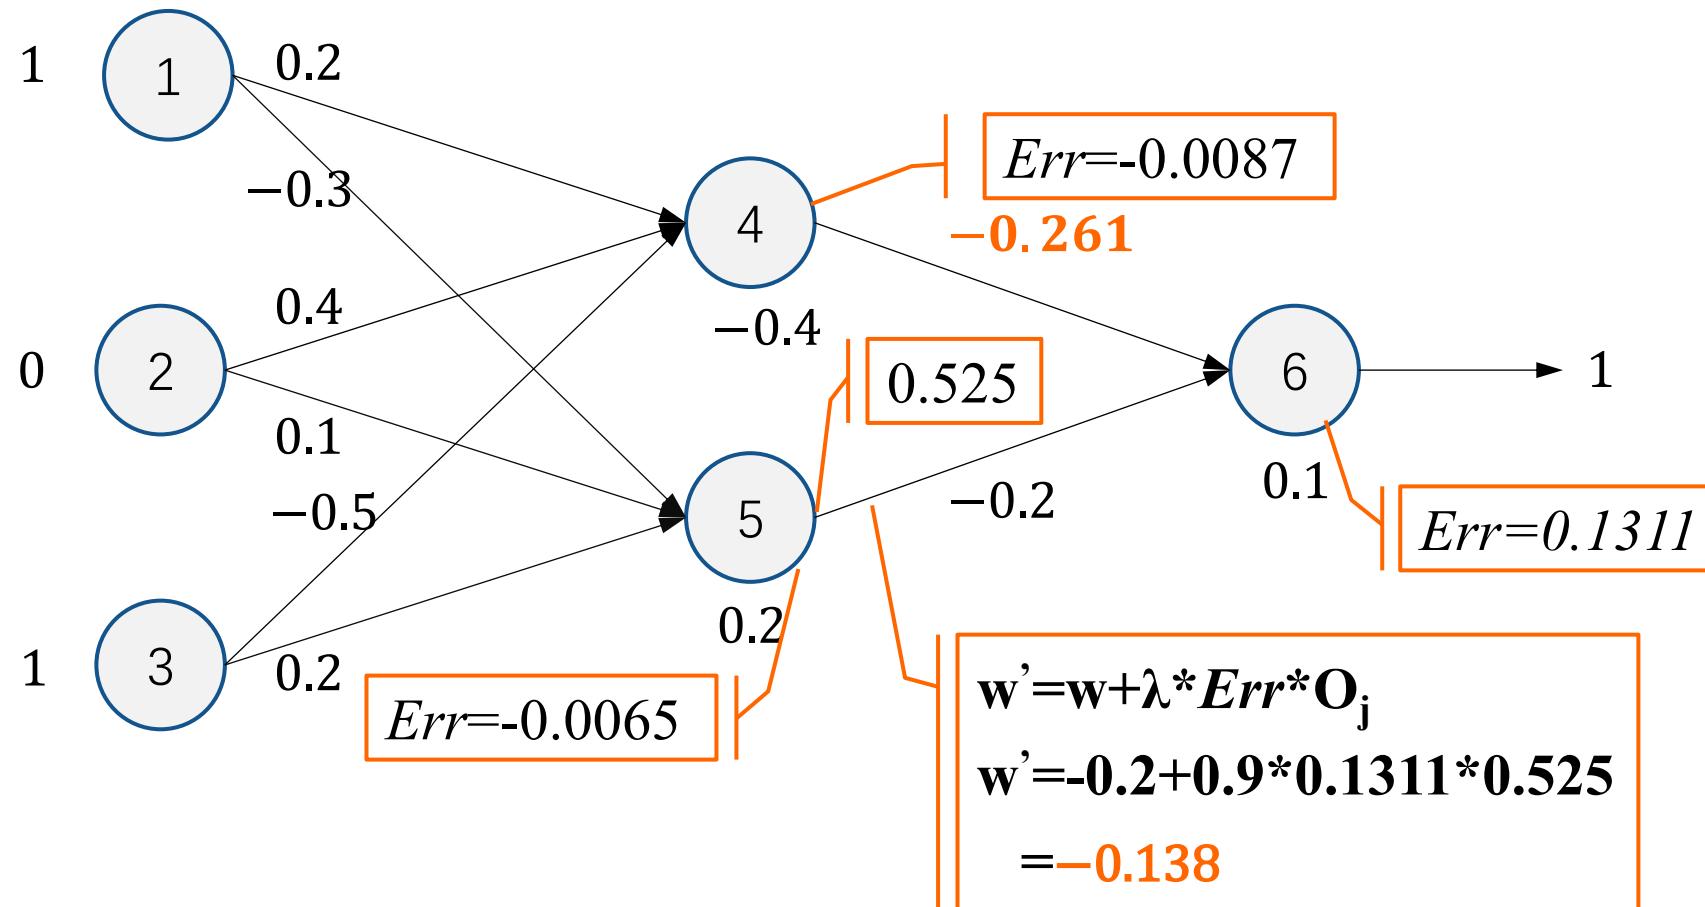
<i>Unit j</i>	<i>Err<sub>j</sub></i>
6	$(0.474)(1 - 0.474)(1 - 0.474) = 0.1311$
5	$(0.525)(1 - 0.525)(0.1311)(-0.2) = -0.0065$
4	$(0.332)(1 - 0.332)(0.1311)(-0.3) = -0.0087$



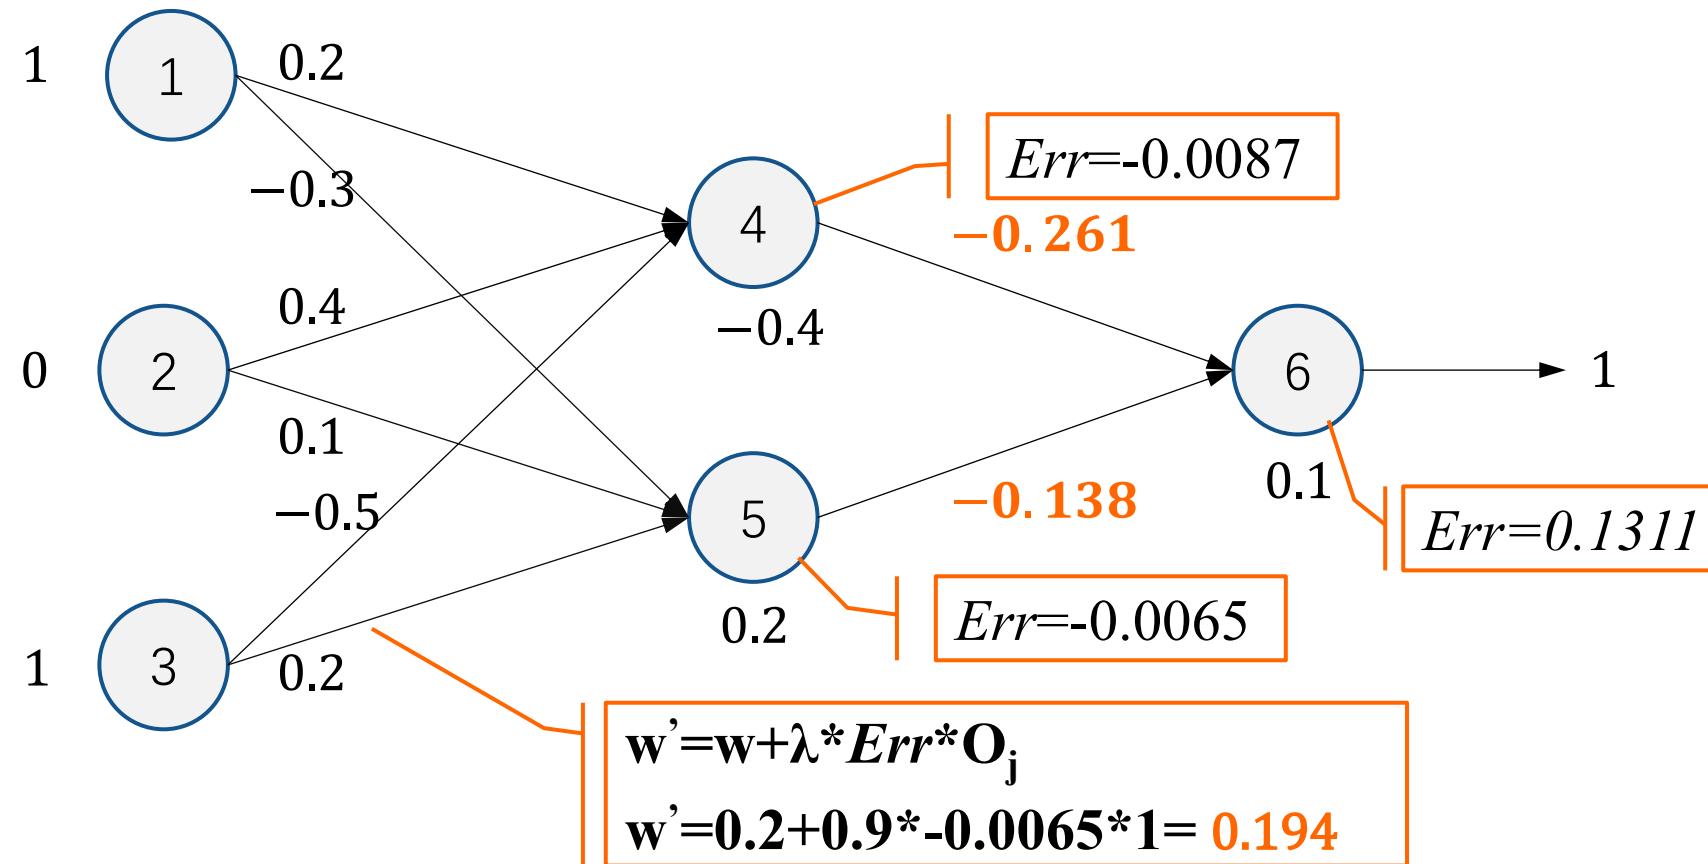
# 权重更新



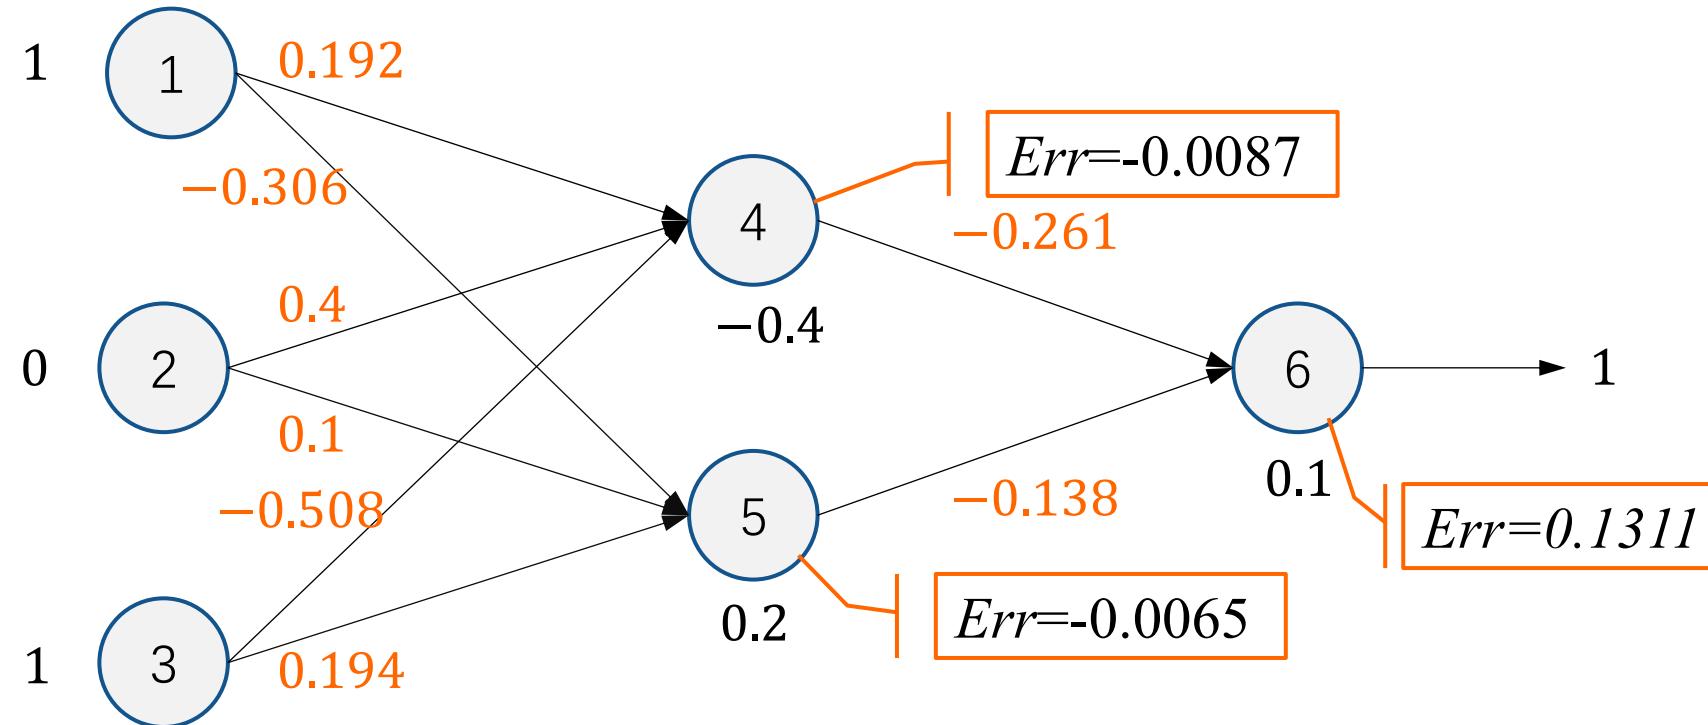
# 权重更新



# 权重更新



# 后向传播算法



# 后向传播算法

- 根据误差调整新的权重和偏置

$$Err_j = O_j(1 - O_j)(T_j - O_j)$$

$$Err_j = O_j(1 - O_j) \sum_k Err_k w_{jk}$$

$$w_{ij} = w_{ij} + \lambda Err_j y_i$$

$$t_j = t_j + \lambda Err_j$$

Weight or bias	New value
$w_{46}$	$-0.3 + (0.9)(0.1311)(0.332) = -0.261$
$w_{56}$	$-0.2 + (0.9)(0.1311)(0.525) = -0.138$
$w_{14}$	$0.2 + (0.9)(-0.0087)(1) = 0.192$
$w_{15}$	$-0.3 + (0.9)(-0.0065)(1) = -0.306$
$w_{24}$	$0.4 + (0.9)(-0.0087)(0) = 0.4$
$w_{25}$	$0.1 + (0.9)(-0.0065)(0) = 0.1$
$w_{34}$	$-0.5 + (0.9)(-0.0087)(1) = -0.508$
$w_{35}$	$0.2 + (0.9)(-0.0065)(1) = 0.194$
$\theta_6$	$0.1 + (0.9)(0.1311) = 0.218$
$\theta_5$	$0.2 + (0.9)(-0.0065) = 0.194$
$\theta_4$	$-0.4 + (0.9)(-0.0087) = -0.408$

# 后向传播算法

## 1、初始化权重

- 循环以下两步，直到满足条件

## 2、向前传播输入

- 在每个节点加权求和，再代入激活函数

$$f = \sum_i w_i x_i$$
$$y = \frac{1}{1 + e^{-z}}$$

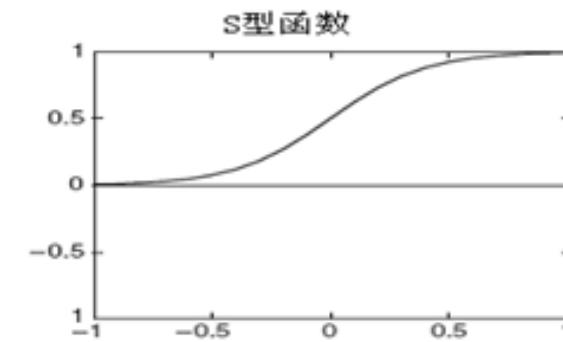
## 3、向后传播误差

$$E_j = Q - Q_j$$

$$E_j = Q - Q \sum_k E_k y_k$$

$$w_j = w_j + \alpha E_j y_j$$

$$t_j = t_j + \alpha E_j r_j$$



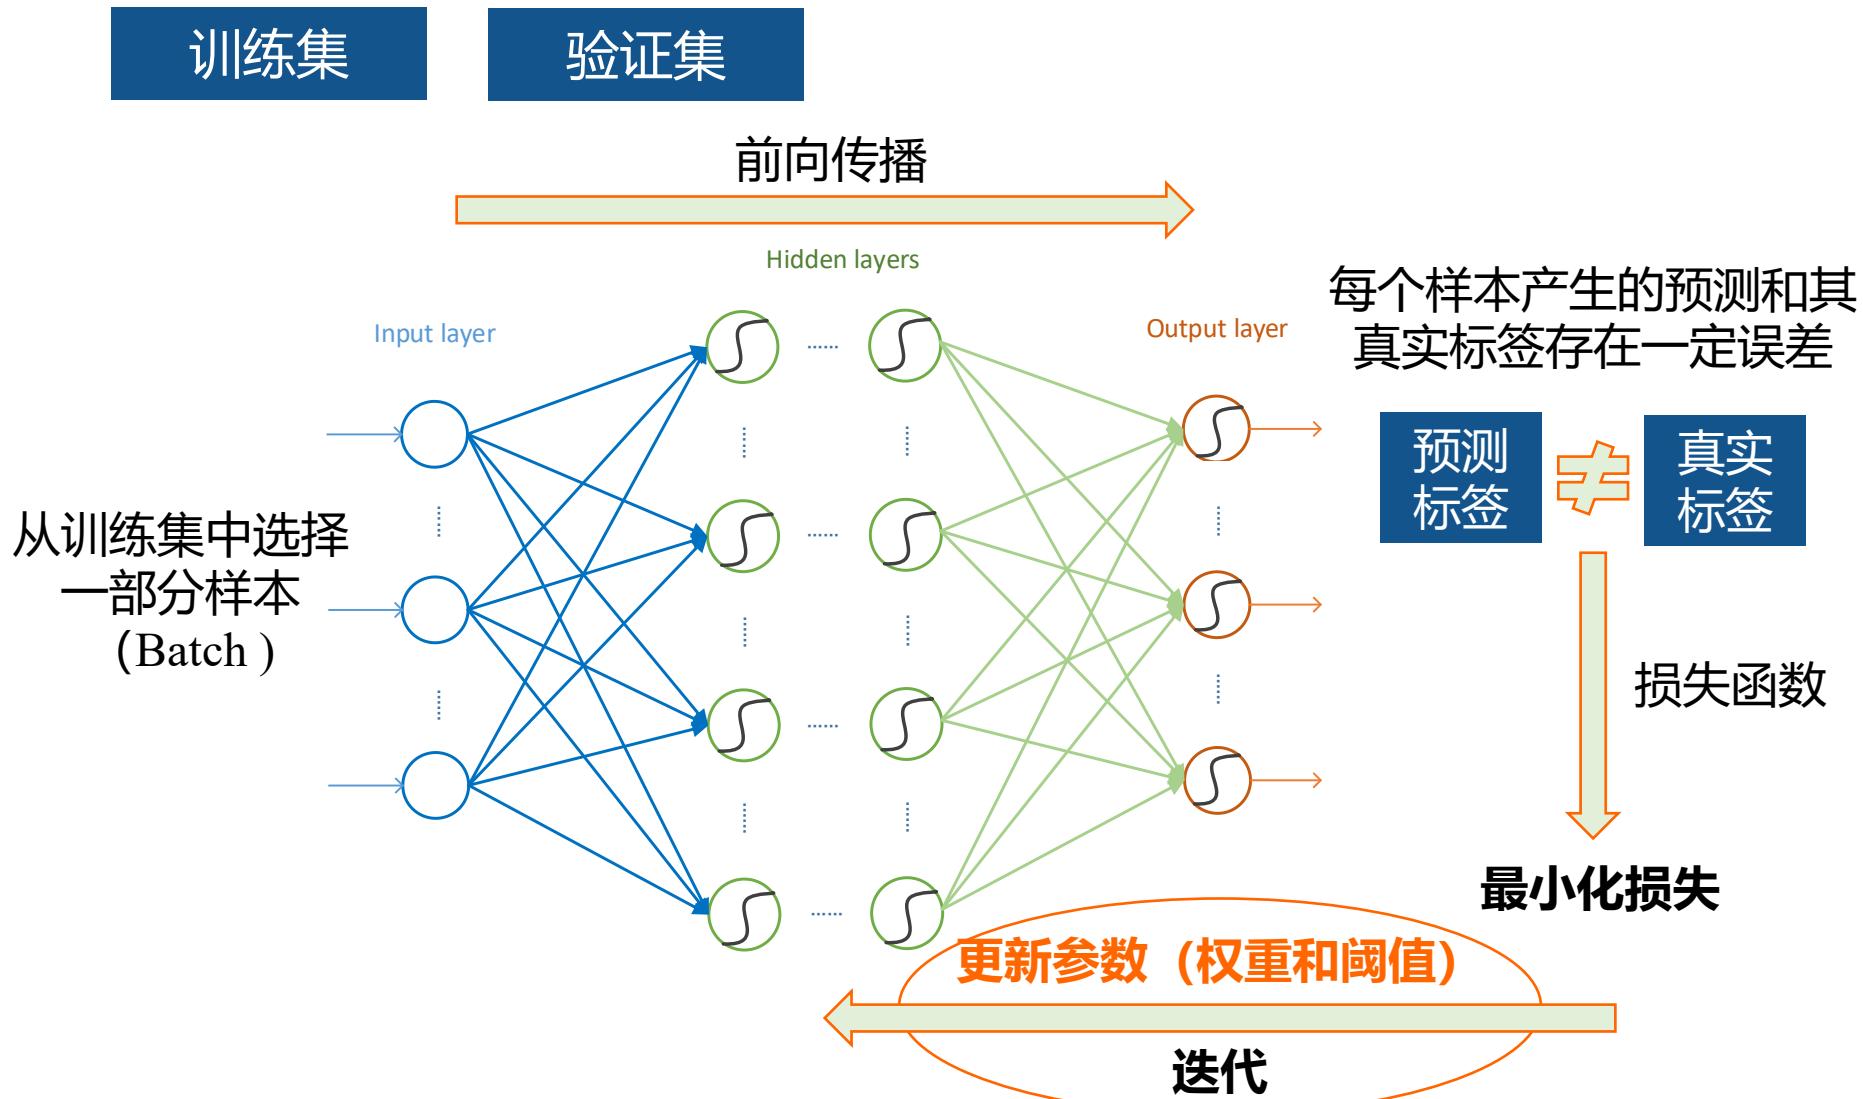
均方误差

$$J(w, b) = \frac{1}{n} \sum \frac{1}{2} (Y - Y^{hat})^2$$

权值迭代，梯度下降法

# 后向传播算法推导

$$D = \{(\vec{x}_1, \vec{y}_1), (\vec{x}_2, \vec{y}_2), \dots, (\vec{x}_m, \vec{y}_m)\}, \vec{x}_i \in R^d, \vec{y}_i \in R^l$$



# 后向传播算法推导

- 什么是梯度?

For example:  $f(\theta_0, \theta_1) \xrightarrow{\nabla} \left( \frac{\partial f}{\partial \theta_0}, \frac{\partial f}{\partial \theta_1} \right)^T$

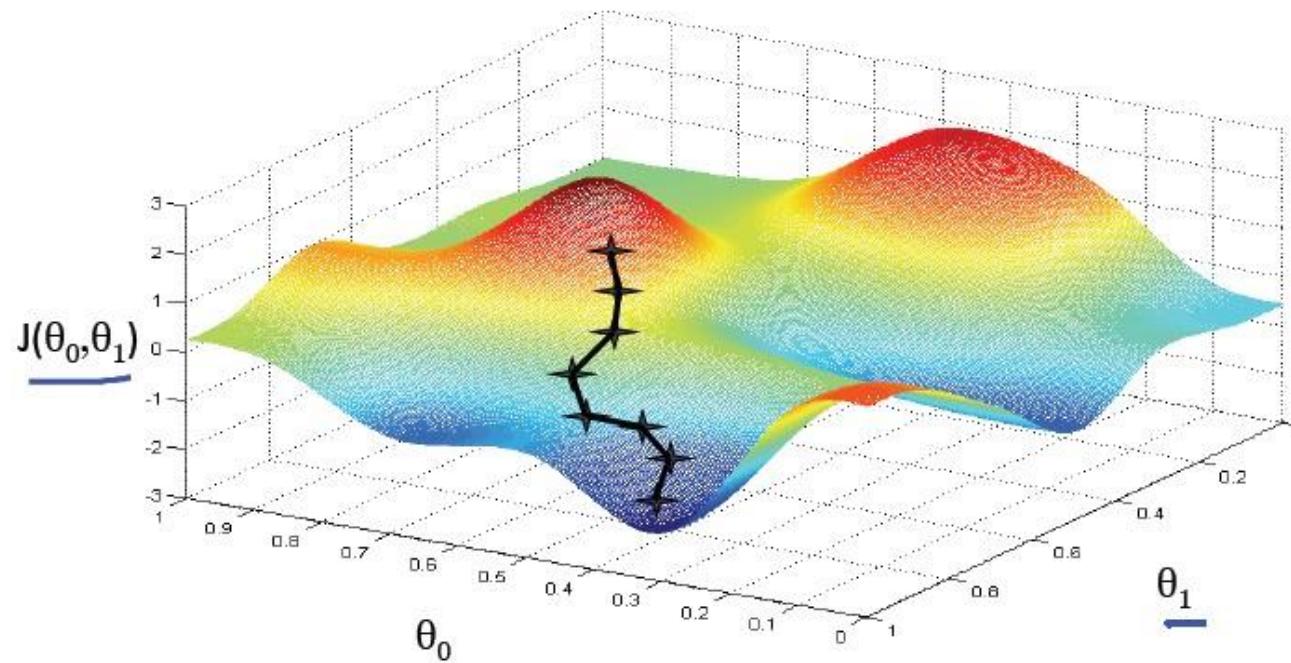
- 梯度  $\nabla f$  指向函数增长最快的方向
- $-\nabla f$  指向函数下降最快的方向

最小化  $f(\theta_0, \theta_1)$   $\rightarrow$   $\vec{\theta} \leftarrow \vec{\theta} - \eta \nabla f(\vec{\theta})$   $\rightarrow$

$$\theta_0 \leftarrow \theta_0 - \eta \frac{\partial f}{\partial \theta_0}$$
$$\theta_1 \leftarrow \theta_1 - \eta \frac{\partial f}{\partial \theta_1}$$

# 后向传播算法推导

梯度下降是求一个函数最小值的一阶迭代优化算法



Update:

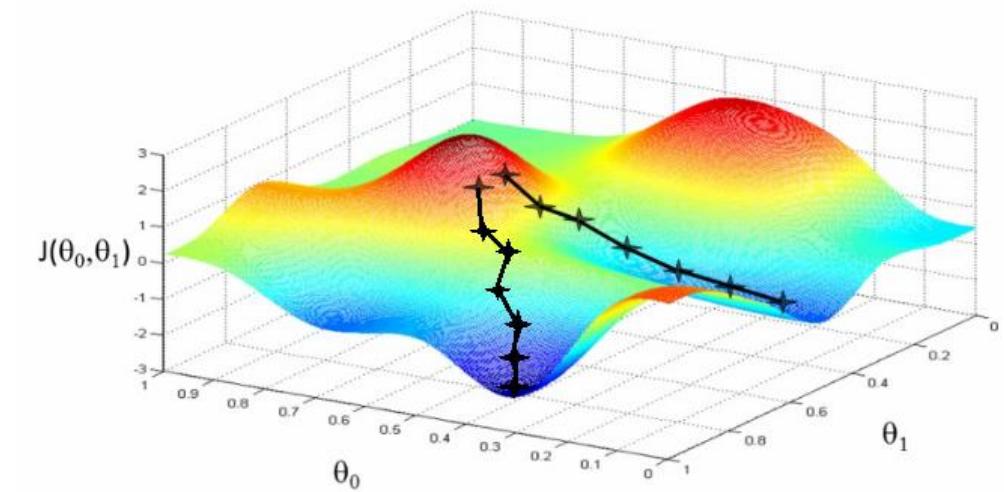
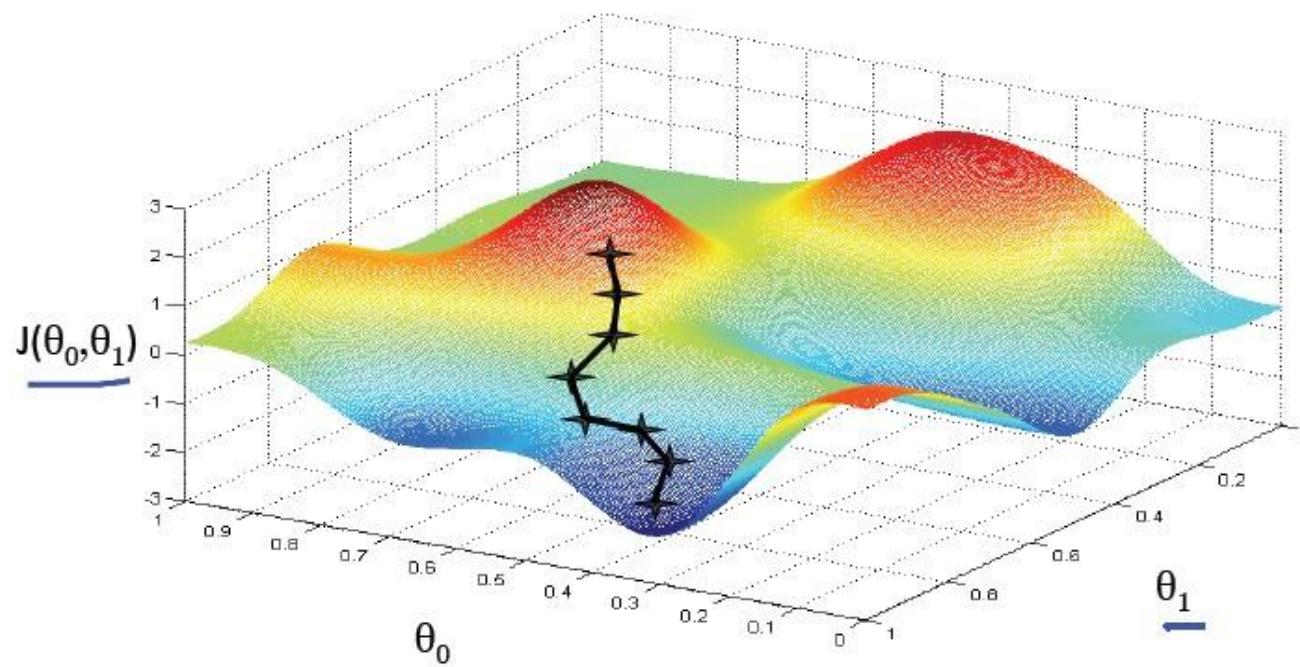
$$\vec{\theta} \leftarrow \vec{\theta} - \eta \nabla f(\vec{\theta})$$

$$\theta_0 \leftarrow \theta_0 - \eta \frac{\partial f}{\partial \theta_0}$$

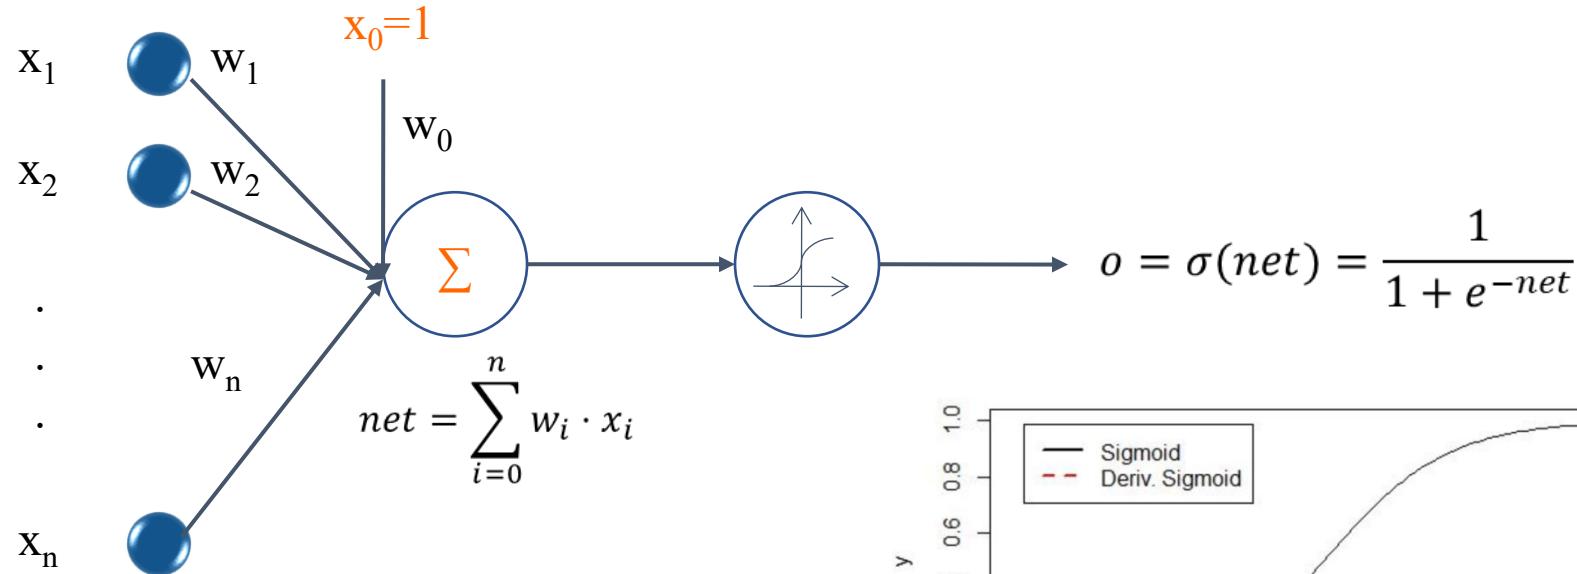
$$\theta_1 \leftarrow \theta_1 - \eta \frac{\partial f}{\partial \theta_1}$$

# 后向传播算法推导

梯度下降是求一个函数最小值的一阶迭代优化算法



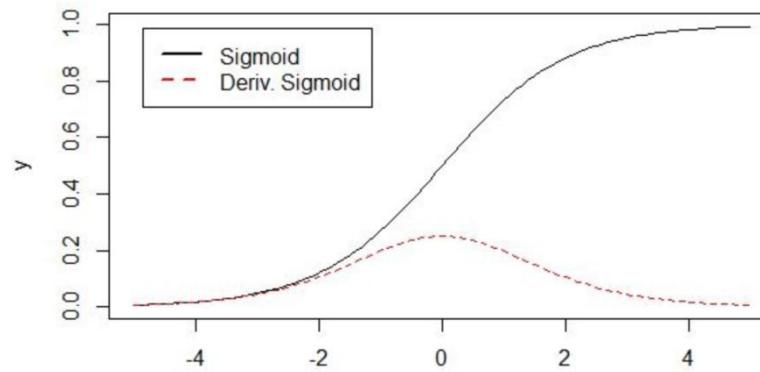
# 后向传播算法推导



logistic函数 (sigmoid函数)

$$\sigma(y) = \frac{1}{1 + e^{-y}}$$

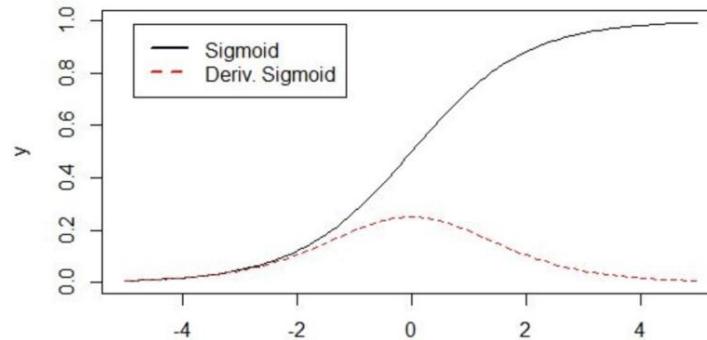
$$\frac{d\sigma(y)}{dy} = \sigma(y) \cdot (1 - \sigma(y))$$



# 后向传播算法推导

Logistic函数求导

$$y = \frac{1}{1+e^{-x}}$$



$$y'_x = \frac{e^{-x}}{(1 + e^{-x})^2} \tag{1}$$

$$= \frac{1 + e^{-x} - 1}{(1 + e^{-x})^2} \tag{2}$$

$$= \frac{1}{1 + e^{-x}} - \frac{1}{(1 + e^{-x})^2} \tag{3}$$

$$= \frac{1}{1 + e^{-x}} \left(1 - \frac{1}{1 + e^{-x}}\right) \tag{4}$$

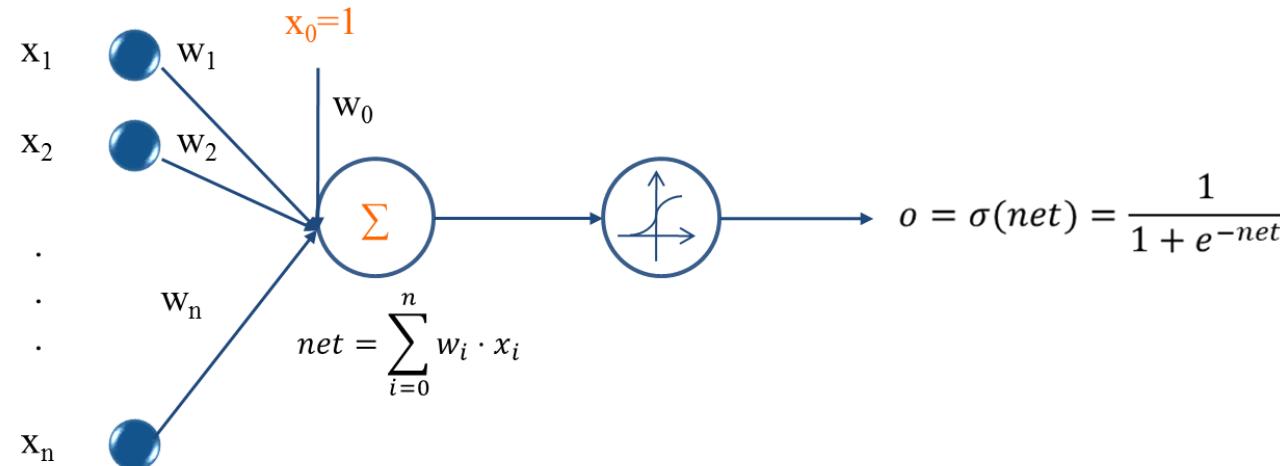
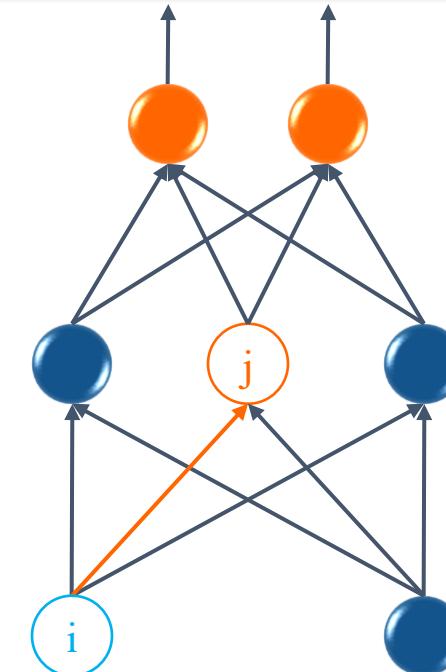
$$= y(1 - y) \tag{5}$$

# 后向传播算法推导

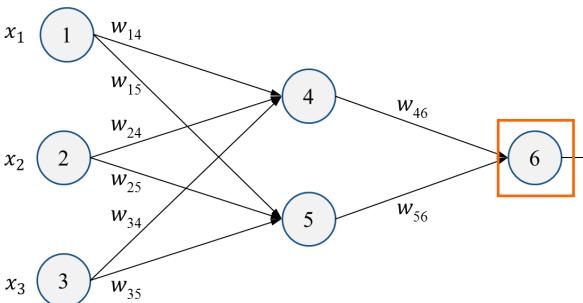
$$E_d(\bar{w}) \equiv \frac{1}{2} \sum_{k \in outputs} (t_k - o_k)^2 \quad \Delta w_{ij} = -\eta \frac{\partial E_d}{\partial w_{ij}}$$

$$\frac{\partial E_d}{\partial w_{ij}} = \frac{\partial E_d}{\partial net_j} \cdot \frac{\partial net_j}{\partial w_{ij}} = \frac{\partial E_d}{\partial net_j} x_{ij}$$

- $net_j = \sum w_{ij}x_{ij}$  ( j神经元输入的加权和)
- 激活函数, the sigmoid function
- $outputs$  = 网络最后一层中的神经元
- $Downstream(j)$  = 将j神经元的输出作为输入的神经元集合



# Output Units 输出神经元的训练



$$\frac{\partial E_d}{\partial net_j} = \frac{\partial E_d}{\partial o_j} \cdot \frac{\partial o_j}{\partial net_j}$$

Sigmoid Function

$$\sigma(y) = \frac{1}{1 + e^{-y}}$$

$$\frac{d\sigma(y)}{dy} = \sigma(y) \cdot (1 - \sigma(y))$$

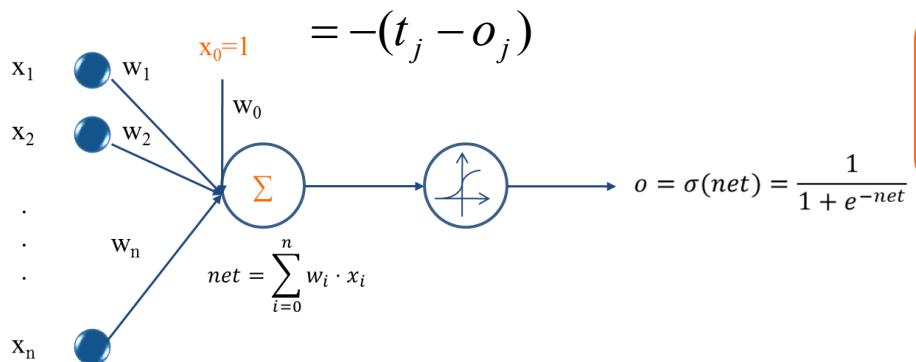
$$\frac{\partial E_d}{\partial o_j} = \frac{\partial}{\partial o_j} \frac{1}{2} \sum_{k \in outputs} (t_k - o_k)^2$$

$$\frac{\partial o_j}{\partial net_j} = \frac{\partial \sigma(net_j)}{\partial net_j} = o_j(1 - o_j)$$

$$\begin{aligned} \frac{\partial E_d}{\partial o_j} &= \frac{\partial}{\partial o_j} \frac{1}{2} (t_j - o_j)^2 \\ &= \frac{1}{2} 2(t_j - o_j) \frac{\partial(t_j - o_j)}{\partial o_j} \end{aligned}$$



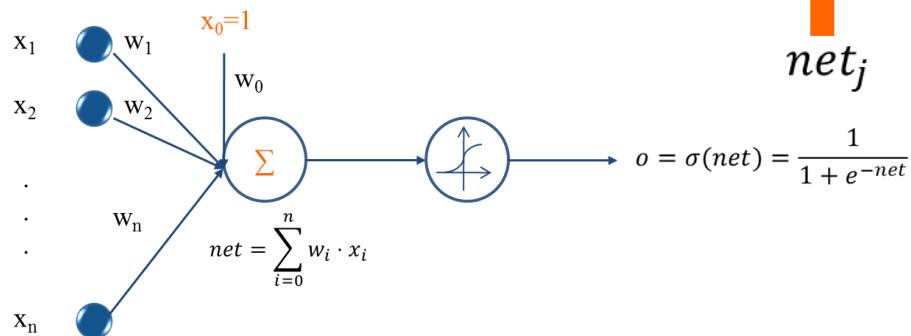
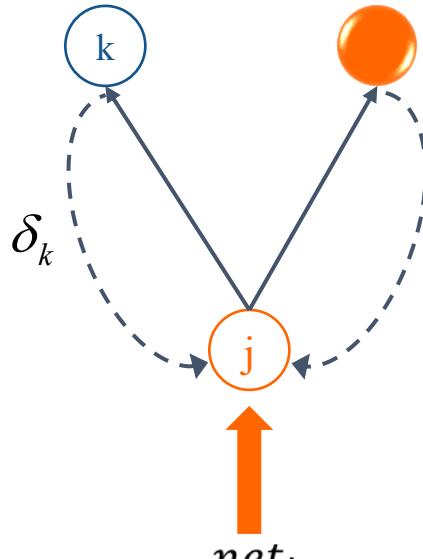
$$\frac{\partial E_d}{\partial net_j} = -(t_j - o_j)o_j(1 - o_j)$$



$$\Delta w_{ij} = -\eta \frac{\partial E_d}{\partial w_{ij}} = \eta(t_j - o_j)o_j(1 - o_j)x_{ij}$$

# Hidden Units 隐藏层神经元的训练

$$\begin{aligned}\frac{\partial E_d}{\partial net_j} &= \sum_{k \in Downstream(j)} \frac{\partial E_d}{\partial net_k} \frac{\partial net_k}{\partial net_j} = \sum_{k \in Downstream(j)} -\delta_k \frac{\partial net_k}{\partial o_j} \frac{\partial o_j}{\partial net_j} \\ &= \sum_{k \in Downstream(j)} -\delta_k w_{jk} \frac{\partial o_j}{\partial net_j} = \sum_{k \in Downstream(j)} -\delta_k w_{jk} o_j (1 - o_j)\end{aligned}$$



$$\delta_k = -\frac{\partial E_d}{\partial net_k}$$

$$\delta_j = o_j(1 - o_j) \sum_{k \in Downstream(j)} \delta_k w_{jk}$$

$$\Delta w_{jk} = \eta \delta_j x_{jk}$$

# 后向传播算法推导

## 1、初始化权重

- 循环以下两步，直到满足条件

## 2、向前传播输入

- 在每个节点加权求和，再代入激活函数

$$f = \sum_i w_i x_i$$
$$y = \frac{1}{1 + e^{-f}}$$

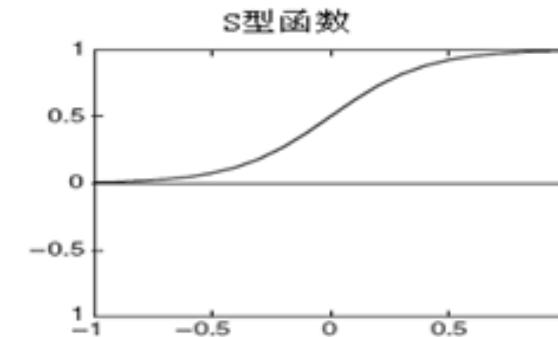
## 3、向后传播误差

$$E_j = y - y^*$$

$$E_j = y - y^* \sum_k E_k$$

$$w_j = w_j + \lambda E_j$$

$$t_j = t_j + \lambda E_j$$

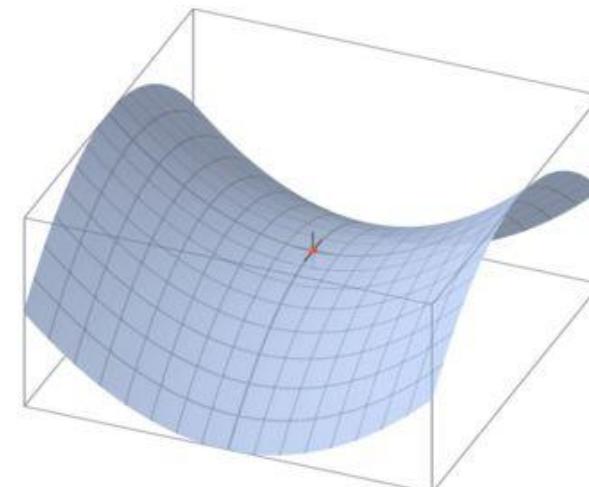


均方误差

$$J(w, b) = \frac{1}{n} \sum \frac{1}{2} (Y - Y^{hat})^2$$

# 后向传播BP网络注意事项

- 初始值选择
  - 权值向量以及阀值的初始值应设定在一均匀分布的小范围内
  - 初始值不能为零，否则性能曲面会趋向于鞍点
  - 初始值不能太大，否则远离优化点，导致性能曲面平坦，学习率很慢
- 训练样本输入次序
  - 不同，也会造成不一样的学习结果
  - 在每一次的学习循环中，输入向量输入网络的次序应使其不同
- BP算法的学习过程的终止条件
  - 权值向量的梯度 < 给定值
  - 均方误差值 < 给定误差容限值
  - 若其推广能力达到目标则予终止
  - 可以结合上述各种方式



# 总结

---

- 普适近似，精度较高
- 噪声敏感
- 训练非常耗时，但对目标分类较快

# 作业：泰坦尼克号幸存者预测

---

- RMS泰坦尼克号的沉没是历史上最著名的沉船之一。 1912年4月15日，在首航期间，泰坦尼克号撞上冰山后沉没，2224名乘客和机组人员中有1502人遇难。这一耸人听闻的悲剧震撼了国际社会，也催生了更完备的船舶安全条例。
- 没有足够的救生艇是泰坦尼克号存活率低的重要原因，虽然幸存下来的运气有一些因素，但有些人比其他人更有可能生存，比如妇女，儿童和上层阶级。
- 在这个作业中，我们要求你完成对什么样的人可能生存的分析。

# 作业：泰坦尼克号幸存者预测

- 尽可能从不同的方面来认识数据。有一些规律和性质能被很容易地发现，而一些隐藏的关系却不能被一眼看出，需要从某些特殊的角度才能观察到。
- 数据集介绍及下载：<https://www.kaggle.com/competitions/titanic/data>
- 数据形式

	A	B	C	D	E	F	G	H	I	J	K	L
1	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
2	1	0	3	Braund, Mr. Owen Harris	male	22	1	0	A/5 21171	7.25		S
3	2	1	1	Cumings, Mrs. John Bradley Wicks	female	38	1	0	PC 17599	71.2833	C85	C
4	3	1	3	Heikkinen, Kai Elof	female	26	0	0	STON/O2 310128	7.925		S
5	4	1	1	Futrelle, Mrs. Jacques Heath	female	35	1	0	113803	53.1	C123	S
6	5	0	3	Allan, Mr. William Henry	male	35	0	0	373450	8.05		S
7	6	0	3	Moran, Mr. James	male		0	0	330877	8.4583		Q
8	7	0	1	McCarthy, Mrs. Elizabeth	male	54	0	0	17463	51.8625	E46	S
9	8	0	3	Palsson, Master Gustaf Dalén	male	2	3	1	349909	21.075		S
10	9	1	3	Johnson, Mrs. Oscar Evarist	female	27	0	2	347742	11.1333		S
11	10	1	2	Nasser, Mrs. Jacob	female	14	1	0	237736	30.0708		C
12	11	1	3	Sandström, Mrs. Oscar Evarist	female	4	1	1	PP 9549	16.7	G6	S
13	12	1	1	Bonnell, Mrs. Charles Francis	female	58	0	0	113783	26.55	C103	S

# 作业：泰坦尼克号幸存者预测

---

## 具体要求：

- 进行数据探索，包括但不限于统计描述、缺失值检查、异常值检测等，分析各个变量与生存率之间的关系。
- 数据集使用Kaggle网站提供的数据集（train.csv、test.csv，**不要修改文件名**），文件路径设置为当前代码文件路径（如“./test.csv”）。
- 构建神经网络模型预测泰坦尼克号上的乘客是幸存还是遇难。
- 计算模型的准确率（需不低于**90%**）等评价指标。

# 作业：泰坦尼克号幸存者预测

---

## 上交形式

- 提交完整的代码文件（使用Jupyter Notebook格式）。
- 文件命名为“**学号-姓名-准确率.ipynb**”（如**602024710021-张三-97.8.ipynb**）。
- **不需要提交数据集，只提交Jupyter文件。**

## 注意事项

- 确保代码具有良好的可读性，适当添加注释说明。
- 遵守学术诚信原则，严禁抄袭他人作品。