

无约束优化的算法描述

1. 选定优化方向  
2. 选定优化步长 (这一步也叫**直线搜索**)  
3. 修改 $\alpha$ 的值

$f^{(k+1)} = f^{(k)} + \alpha^T \Delta x^{(k)}$  with  $f^{(k+1)} < f^{(k)}$   
1. other notation:  $x^* = x + \Delta x$ ,  $x = x + \Delta x$   
2.  $\Delta x$  is the step, or search direction;  $t$  is the step size, or step length  
3. from convexity  $f(x^*) < f(x)$  implies  $\nabla f(x)^T \Delta x < 0$  (i.e.,  $\Delta x$  is a descent direction)

精确直线搜索: 找 $\alpha$ 方向上使得函数值最小的 $\alpha$ 的值, 称为步长

$t = \arg \min_{t>0} f(x + t\Delta x)$

跟踪直线搜索: 从单位步长开始, 按比例逐渐减小, 直到满足停止条件.

给 $x$  a starting point  $x \in \text{dom } f$ .  
repeat  
1.  $\Delta x := -\nabla f(x)$ .  
2. Line search: Choose step size  $t$  via exact or backtracking line search.  
3. Update  $x := x + \Delta x$ .  
until stopping criterion is satisfied.

上方梯度下降算法描述

1. 停止条件通常称为精度足够小  
2. 微扰, 包括微扰, 实际工作中不太用它  
3. 收敛较快

$R^n$ 空间的二次问题

$f(x) = (1/2)(x_1^2 + \gamma x_2^2)$  ( $\gamma > 0$ )  
with exact line search, starting at  $x^{(0)} = (\gamma, 1)$ :  
 $d_1^{(0)} = \gamma \left( \frac{\gamma}{\gamma+1} \right)$ ,  $d_2^{(0)} = \left( \frac{\gamma}{\gamma+1} \right)^{1/2}$   
very slow if  $\gamma \gg 1$  or  $\gamma \ll 1$   
example for  $\gamma = 10$

例子

$R^n$ 空间的非二次问题

nonquadratic example  
 $f(x_1, x_2) = x_1^4 + 3x_1x_2 + x_2^4 - 3x_1 - 1 + e^{-x_1 - x_2}$   
backtracking line search  
exact line search

$R^n$  100维的一个问题

a problem in  $R^{100}$   
 $f(x) = e^T x - \sum_{i=1}^{100} \log(x_i - a_i^T x)$   
"linear" convergence, i.e., a straight line on a smiling plot

最速下降方法

规范化最速下降方法  
normalized steepest descent direction (at  $x$ , for norm  $\|\cdot\|$ ):  
 $\Delta_{nsd} = \arg \min_{\|\nabla f(x)^T v\|_1 = 1} \|v\|$   
Interpretation: for small  $v$ ,  $f(x+v) \approx f(x) + \nabla f(x)^T v$   
direction  $\Delta_{nsd}$  is unit-norm step with most negative directional derivative

非规范化最速下降方法  
(unnormalized) steepest descent direction  
 $\Delta_{sd} = \|\nabla f(x)\|^{-1} \Delta_{nsd}$   
satisfies  $\nabla f(x)^T \Delta_{sd} = -\|\nabla f(x)\|_2^2$

最速下降模型

steepest descent method  
1. general descent method with  $\Delta x = \Delta_{nsd}$   
2. convergence properties similar to gradient descent

例子

Examples  
1. Euclidean norm:  $\Delta_{nsd} = -\nabla f(x)$   
2. Quadratic norm  $\|x\|_P = (x^T P x)^{1/2}$  ( $P \in S_{++}^n$ ):  $\Delta_{nsd} = -P^{-1} \nabla f(x)$   
3.  $l_1$ -norm:  $\Delta_{nsd} = -(\partial f(x)/\partial x_i)_{i=1}^n$ , where  $|\partial f(x)/\partial x_i| = \|\nabla f(x)\|_\infty$   
unit balls and normalized steepest descent directions for a quadratic norm and the  $l_1$ -norm:  
 $\Delta_{nsd}$  is steepest descent direction at  $x$  local Hessian norm  
 $\|\nabla f(x)\|_{H(x)} = (x^T \nabla^2 f(x) x)^{1/2}$   
dashed lines are contour lines of  $f$ , ellipse is  $\{x + v | \nabla f(x)^T v = 1\}$   
arrow shows  $-\nabla f(x)$

3.2 Newton step  
 $\Delta_{nsd} = -\nabla^2 f(x)^{-1} \nabla f(x)$   
Interpretations  
1.  $x + \Delta_{nsd}$  minimizes second order approximation  
 $f(x+v) \approx f(x) + \nabla f(x)^T v + \frac{1}{2} v^T \nabla^2 f(x) v$   
2.  $x + \Delta_{nsd}$  solves linearized optimality condition  
 $\nabla f(x+v) \approx \nabla f(x+v) = \nabla f(x) + \nabla^2 f(x) v = 0$

3. 算法: 无约束优化问题

Chapter6\_应用与算法

1. 近似

1.1 范数近似

1.1 Norm Approximation

$\minimize \quad \|Ax - b\|$   
( $A \in R^{m \times n}$  with  $m \geq n$ )

解释

总解释: 回归问题  
几何解释: 投影  
估计的解释: 测量误差 (最小最好)  
最佳设计的解释

最小二乘问题 ( $>$  误差的平方)

正规方程  
 $Least-squares approximation (\| \cdot \|_2)$ : solution satisfies normal equations  
 $A^T A x = A^T b$   
 $(x^* = (A^T A)^{-1} A^T b$  if  $\text{rank } A = n$ )

Chebyshev逼近 ( $\infty$ -范数)

描述为LP  
 $\minimize \quad t$   
subject to  $-tI \preceq Ax - b \preceq tI$

残差绝对值之和逼近 ( $1$ -范数)

描述为LP  
Sum of absolute residuals approximation ( $\| \cdot \|_1$ ): can be solved as an LP  
 $\minimize \quad 1^T y$   
subject to  $-y \preceq Ax - b \preceq y$

1.2 罚函数近似

1.2 Penalty function approximation.

基本形式  
 $\minimize \quad \phi(r_1) + \dots + \phi(r_m)$   
subject to  $r = Ax - b$   
( $A \in R^{m \times n}$ ,  $\phi: R \rightarrow R$  is a convex penalty function)

解释: 选定 $\phi$ 之后, 我们得到了的一个函数 $\Delta_\phi$ , 它得到了相应的梯度信息, 但函数值函数每一个子问题的解, 函数值函数每个子问题的最优化和和, 在罚函数逼近问题中, 我们最小化函数带来的各种惩罚。

常见罚函数

Examples  
1. quadratic:  $\phi(u) = u^2$   
2. double-line with width  $a$ :  $\phi(u) = \max\{0, |u| - a\}$   
3. log-barrier with limit  $a$ :  
 $\phi(u) = \begin{cases} -a^2 \log(1 - (u/a)^2) & |u| < a \\ \infty & \text{otherwise} \end{cases}$

例子

1.  $p$ -范数罚函数,  $q$ -范数逼近问题的等价形式, 没有量纲限制  
2. 带有约束的线性函数, 对于小于 $a$ 的残差不进行惩罚  
3. 对称峰形罚函数, 对于大于 $a$ 的残差给予无惩罚的惩罚  
(1)-范数罚函数, (2)-范数罚函数, 范数线性罚函数和对数峰形罚函数的最优残差分布

Huber罚函数 (with parameter  $M$ )  
 $\phi_{Huber}(u) = \begin{cases} u^2 & |u| \leq M \\ M^2(u - M) & |u| > M \end{cases}$   
Huber罚函数相对于 $l_2$ -范数罚函数的效果: 前者为尖峰, 后者为圆滑, 可以限制对异常值的影响, 对异常值更加敏感, 给予的惩罚更大, 因此拟合的曲线更好。

1.3 正则化近似

1.3 Regularized approximation

解释: 选定 $\phi$ 之后, 我们得到了的一个函数 $\Delta_\phi$ , 它得到了相应的梯度信息, 但函数值函数每一个子问题的解, 函数值函数每个子问题的最优化和和, 在罚函数逼近问题中, 我们最小化函数带来的各种惩罚。

基本形式 (两种方法: 引入问题参数或者最小化二次范数平方和)

$\minimize \quad \|Ax - b\| + \delta \|x\|$   
Solution for  $\delta > 0$  traces out optimal trade-off curve  
other common method:  $\minimize \quad \|Ax - b\|_2^2 + \delta \|x\|_2^2$  with  $\delta > 0$   
Interpretation: find good approximation  $Ax \approx b$  with small  $x$

Tikhonov正则化: 基于最小化加权范数平方和方法, 采用 $l_2$ -范数, 这得到一个 (凸的) 二次优化问题, 且这个问题有解。

Tikhonov regularization  
 $\minimize \quad \|Ax - b\|_2^2 + \delta \|x\|_2^2$   
can be solved as a least-squares problem  
 $\minimize \quad \left\| \begin{bmatrix} A \\ \sqrt{\delta} I \end{bmatrix} x - \begin{bmatrix} b \\ 0 \end{bmatrix} \right\|_2^2$   
solution  $x^* = (A^T A + \delta I)^{-1} A^T b$

2. 应用实例: 最优输入设计

2. 应用实例: 最优输入设计

考虑一个动态系统,  $u(t)$ 是输入标量序列,  $y(t)$ 是输出标量序列, 它们通过差分方程 (第一个式子)  
差分方程称为输入输出模型或者系统的静态响应。  
目标: 1.跟踪输出 (输出/需要逼近给定目标或者参考信号 $y_{ideal}$ , 用 $y_{track}$ 表示)  
2.输入能量最小 (用 $J_{input}$ 表示)  
3.输入变化率最小 (用 $J_{smooth}$ 表示)  
通过最小化加权相加可以在目标间进行权衡

linear dynamical system with impulse response  $h$

$y(t) = \sum_{\tau=0}^t h(\tau)u(t-\tau)$ ,  $t = 0, 1, \dots, N$

Input design problem: multiteriter problem with 3 objectives  
1. tracking error with desired output  $y_{des}$ :  $J_{track} = \sum_{t=0}^N (y(t) - y_{des}(t))^2$   
2. input magnitude:  $J_{input} = \sum_{t=0}^N u(t)^2$   
3. input variation:  $J_{smooth} = \sum_{t=0}^N (u(t+1) - u(t))^2$   
track desired output using a small and slowly varying input signal

regularized least-squares formulation

$\minimize \quad J_{track} + \delta J_{input} + \eta J_{smooth}$   
for fixed  $\delta, \eta$ , a least-squares problem in  $p(0), \dots, p(N)$

2.1 正则化近似

2. 信号重建

1.3.3 Signal reconstruction

基本形式 (其中 $x_{cor}$ 为关于 $x$ 的: 原始信号 $x$ 在未知, 小值目标快速变化的噪声干扰之后, 得到的信号 $x_{cor}$ ), 目标是重建原始信号 $x$ ,  $x_{cor}$ 的情况下, 重建原始信号 $x$ 的估计量 $\hat{x}$ 。  
重建问题的一个简单方式是如下面所示的误差问题, 其中第二项称为正则化函数或光滑目标, 用来评价 $x_{cor}$ 的平滑程度。

$\minimize \quad (\|x - x_{cor}\|_2 + \phi(x))$   
 $x \in R^n$  is unknown signal  
 $x_{cor} = x + v$  is (known) corrupted version of  $x$ , with additive noise  $v$   
variable  $\hat{x}$  (reconstructed signal) is estimate of  $x$   
 $\phi: R^n \rightarrow R$  is regularization function or smoothing objective

构建重建问题的方法:  
1. 二次光滑  
2. 改变平滑度  
二次光滑  
最平滑的解的方法是使二次光滑函数  
 $\phi_{quad}(x) = \sum_{i=1}^n (x_{i+1} - x_i)^2 = \|Dx\|_2^2$   
其中,  $D \in R^{(n-1) \times n}$  为反对角矩阵  
 $D = \begin{bmatrix} -1 & 1 & 0 & \dots & 0 & 0 & 0 \\ 0 & -1 & 1 & \dots & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & \dots & -1 & 1 & 0 \\ 0 & 0 & 0 & \dots & 0 & -1 & 1 \end{bmatrix}$   
我们可以构造光滑化  
 $\hat{x} = (I + \lambda D^T D)^{-1} x_{cor}$   
参数  $\lambda = \lambda_{min} I_2$  和  $\lambda_{max} I_2$  之间的平滑度, 其中  $\lambda > 0$  参数化了最佳平滑度, 这个二次问题的解  
可以非常有效地求解, 因为  $I + \lambda D^T D$  是三对角的, 参见附录 C。  
examples: quadratic smoothing, total variation smoothing:  
 $\phi_{quad}(x) = \sum_{i=1}^{n-1} (x_{i+1} - x_i)^2$ ,  $\phi_{tv}(x) = \sum_{i=1}^{n-1} |x_{i+1} - x_i|$

2.2 最大似然估计

2.2 Statistical Estimation

1. Gaussian noise  $N(0, \sigma^2)$ :  $p(x) = (2\pi\sigma^2)^{-1/2} e^{-x^2/(2\sigma^2)}$   
 $\hat{x} = \frac{1}{n} \sum_{i=1}^n x_i$   
ML estimate is LS solution  
2. Laplacian noise  $p(x) = (1/(2a)) e^{-|x|/a}$   
 $\hat{x} = -a \log(2a) - \frac{1}{n} \sum_{i=1}^n |x_i - \hat{x}|$   
ML estimate is 1-norm solution  
3. uniform noise on  $[-a, a]$   
 $\hat{x} = \frac{1}{n} \sum_{i=1}^n x_i$   
ML estimate is any  $\hat{x}$  with  $|\hat{x}_i - x_i| \leq a$

Logistic回归

Logistic regression  
Random variable  $y \in \{0, 1\}$  with distribution  
 $p = \text{prob}(y = 1) = \frac{\exp(a^T x + b)}{1 + \exp(a^T x + b)}$   
1.  $a, b$  are parameters;  $x \in R^n$  are (observable) explanatory variables  
2. Estimation problem: estimate  $a, b$  from  $m$  observations  $(u_i, y_i)$   
log-likelihood function (for  $y_1, \dots, y_m = y_1, y_2, \dots, y_m = y_i$ )  
 $\ell(a, b) = \log \left( \prod_{i=1}^m \frac{\exp(a^T u_i + b)}{1 + \exp(a^T u_i + b)} \right) = \sum_{i=1}^m \log \left( \frac{\exp(a^T u_i + b)}{1 + \exp(a^T u_i + b)} \right)$   
concave in  $a, b$

2.3 最优检测器设计

2.3 最优检测器设计

基本形式: 在矩阵 $A$ 和 $b$ 的情况下优化目标函数 $\|Ax - b\|$

随机鲁棒最小二乘  
图片给出了问题的目标函数, 问题的解以及其与Tikhonov问题的等价性证明  
Stochastic robust LS with  $A = A + U$ ,  $U$  random,  $EU = 0$ ,  $E U^T U = P$   
 $\minimize \quad E[\|A + U)x - b\|_2^2]$   
1. explicit expression for objective:  
 $E[\|Ax - b\|_2^2] = E[\|Ax - b + Ux\|_2^2]$   
 $= \|Ax - b\|_2^2 + E[U^T U] x^T x$   
 $= \|Ax - b\|_2^2 + x^T P x$   
2. hence, robust LS problem is equivalent to LS problem  
 $\minimize \quad \|Ax - b\|_2^2 + \|P^{1/2} x\|_2^2$   
3. for  $P = \delta I$ , get Tikhonov regularized problem  
 $\minimize \quad \|Ax - b\|_2^2 + \delta \|x\|_2^2$

随机鲁棒最小二乘  
图片给出了问题的目标函数, 问题的解以及其与Tikhonov问题的等价性证明  
Stochastic robust LS with  $A = A + U$ ,  $U$  random,  $EU = 0$ ,  $E U^T U = P$   
 $\minimize \quad E[\|A + U)x - b\|_2^2]$   
1. explicit expression for objective:  
 $E[\|Ax - b\|_2^2] = E[\|Ax - b + Ux\|_2^2]$   
 $= \|Ax - b\|_2^2 + E[U^T U] x^T x$   
 $= \|Ax - b\|_2^2 + x^T P x$   
2. hence, robust LS problem is equivalent to LS problem  
 $\minimize \quad \|Ax - b\|_2^2 + \|P^{1/2} x\|_2^2$   
3. for  $P = \delta I$ , get Tikhonov regularized problem  
 $\minimize \quad \|Ax - b\|_2^2 + \delta \|x\|_2^2$

随机鲁棒最小二乘  
图片给出了问题的目标函数, 问题的解以及其与Tikhonov问题的等价性证明  
Stochastic robust LS with  $A = A + U$ ,  $U$  random,  $EU = 0$ ,  $E U^T U = P$   
 $\minimize \quad E[\|A + U)x - b\|_2^2]$   
1. explicit expression for objective:  
 $E[\|Ax - b\|_2^2] = E[\|Ax - b + Ux\|_2^2]$   
 $= \|Ax - b\|_2^2 + E[U^T U] x^T x$   
 $= \|Ax - b\|_2^2 + x^T P x$   
2. hence, robust LS problem is equivalent to LS problem  
 $\minimize \quad \|Ax - b\|_2^2 + \|P^{1/2} x\|_2^2$   
3. for  $P = \delta I$ , get Tikhonov regularized problem  
 $\minimize \quad \|Ax - b\|_2^2 + \delta \|x\|_2^2$

随机鲁棒最小二乘  
图片给出了问题的目标函数, 问题的解以及其与Tikhonov问题的等价性证明  
Stochastic robust LS with  $A = A + U$ ,  $U$  random,  $EU = 0$ ,  $E U^T U = P$   
 $\minimize \quad E[\|A + U)x - b\|_2^2]$   
1. explicit expression for objective:  
 $E[\|Ax - b\|_2^2] = E[\|Ax - b + Ux\|_2^2]$   
 $= \|Ax - b\|_2^2 + E[U^T U] x^T x$   
 $= \|Ax - b\|_2^2 + x^T P x$   
2. hence, robust LS problem is equivalent to LS problem  
 $\minimize \quad \|Ax - b\|_2^2 + \|P^{1/2} x\|_2^2$   
3. for  $P = \delta I$ , get Tikhonov regularized problem  
 $\minimize \quad \|Ax - b\|_2^2 + \delta \|x\|_2^2$

随机鲁棒最小二乘  
图片给出了问题的目标函数, 问题的解以及其与Tikhonov问题的等价性证明  
Stochastic robust LS with  $A = A + U$ ,  $U$  random,  $EU = 0$ ,  $E U^T U = P$   
 $\minimize \quad E[\|A + U)x - b\|_2^2]$   
1. explicit expression for objective:  
 $E[\|Ax - b\|_2^2] = E[\|Ax - b + Ux\|_2^2]$   
 $= \|Ax - b\|_2^2 + E[U^T U] x^T x$   
 $= \|Ax - b\|_2^2 + x^T P x$   
2. hence, robust LS problem is equivalent to LS problem  
 $\minimize \quad \|Ax - b\|_2^2 + \|P^{1/2} x\|_2^2$   
3. for  $P = \delta I$ , get Tikhonov regularized problem  
 $\minimize \quad \|Ax - b\|_2^2 + \delta \|x\|_2^2$

随机鲁棒最小二乘  
图片给出了问题的目标函数, 问题的解以及其与Tikhonov问题的等价性证明  
Stochastic robust LS with  $A = A + U$ ,  $U$  random,  $EU = 0$ ,  $E U^T U = P$   
 $\minimize \quad E[\|A + U)x - b\|_2^2]$   
1. explicit expression for objective:  
 $E[\|Ax - b\|_2^2] = E[\|Ax - b + Ux\|_2^2]$   
 $= \|Ax - b\|_2^2 + E[U^T U] x^T x$   
 $= \|Ax - b\|_2^2 + x^T P x$   
2. hence, robust LS problem is equivalent to LS problem  
 $\minimize \quad \|Ax - b\|_2^2 + \|P^{1/2} x\|_2^2$   
3. for  $P = \delta I$ , get Tikhonov regularized problem  
 $\minimize \quad \|Ax - b\|_2^2 + \delta \|x\|_2^2$

随机鲁棒最小二乘  
图片给出了问题的目标函数, 问题的解以及其与Tikhonov问题的等价性证明  
Stochastic robust LS with  $A = A + U$ ,  $U$  random,  $EU = 0$ ,  $E U^T U = P$   
 $\minimize \quad E[\|A + U)x - b\|_2^2]$   
1. explicit expression for objective:  
 $E[\|Ax - b\|_2^2] = E[\|Ax - b + Ux\|_2^2]$   
 $= \|Ax - b\|_2^2 + E[U^T U] x^T x$   
 $= \|Ax - b\|_2^2 + x^T P x$   
2. hence, robust LS problem is equivalent to LS problem  
 $\minimize \quad \|Ax - b\|_2^2 + \|P^{1/2} x\|_2^2$   
3. for  $P = \delta I$ , get Tikhonov regularized problem  
 $\minimize \quad \|Ax - b\|_2^2 + \delta \|x\|_2^2$

随机鲁棒最小二乘  
图片给出了问题的目标函数, 问题的解以及其与Tikhonov问题的等价性证明  
Stochastic robust LS with  $A = A + U$ ,  $U$  random,  $EU = 0$ ,  $E U^T U = P$   
 $\minimize \quad E[\|A + U)x - b\|_2^2]$   
1. explicit expression for objective:  
 $E[\|Ax - b\|_2^2] = E[\|Ax - b + Ux\|_2^2]$   
 $= \|Ax - b\|_2^2 + E[U^T U] x^T x$   
 $= \|Ax - b\|_2^2 + x^T P x$   
2. hence, robust LS problem is equivalent to LS problem  
 $\minimize \quad \|Ax - b\|_2^2 + \|P^{1/2} x\|_2^2$   
3. for  $P = \delta I$ , get Tikhonov regularized problem  
 $\minimize \quad \|Ax - b\|_2^2 + \delta \|x\|_2^2$

随机鲁棒最小二乘  
图片给出了问题的目标函数, 问题的解以及其与Tikhonov问题的等价性证明  
Stochastic robust LS with  $A = A + U$ ,  $U$  random,  $EU = 0$ ,  $E U^T U = P$   
 $\minimize \quad E[\|A + U)x - b\|_2^2]$   
1. explicit expression for objective:  
 $E[\|Ax - b\|_2^2] = E[\|Ax - b + Ux\|_2^2]$   
 $= \|Ax - b\|_2^2 + E[U^T U] x^T x$   
 $= \|Ax - b\|_2^2 + x^T P x$   
2. hence, robust LS problem is equivalent to LS problem  
 $\minimize \quad \|Ax - b\|_2^2 + \|P^{1/2} x\|_2^2$   
3. for  $P = \delta I$ , get Tikhonov regularized problem  
 $\minimize \quad \|Ax - b\|_2^2 + \delta \|x\|_2^2$

随机鲁棒最小二乘  
图片给出了问题的目标函数, 问题的解以及其与Tikhonov问题的等价性证明  
Stochastic robust LS with  $A = A + U$ ,  $U$  random,  $EU = 0$ ,  $E U^T U = P$   
 $\minimize \quad E[\|A + U)x - b\|_2^2]$   
1. explicit expression for objective:  
 $E[\|Ax - b\|_2^2] = E[\|Ax - b + Ux\|_2^2]$   
 $= \|Ax - b\|_2^2 + E[U^T U] x^T x$   
 $= \|Ax - b\|_2^2 + x^T P x$   
2. hence, robust LS problem is equivalent to LS problem  
 $\minimize \quad \|Ax - b\|_2^2 + \|P^{1/2} x\|_2^2$   
3. for  $P = \delta I$ , get Tikhonov regularized problem  
 $\minimize \quad \|Ax - b\|_2^2 + \delta \|x\|_2^2$

随机鲁棒最小二乘  
图片给出了问题的目标函数, 问题的解以及其与Tikhonov问题的等价性证明  
Stochastic robust LS with  $A = A + U$ ,  $U$  random,  $EU = 0$ ,  $E U^T U = P$   
 $\minimize \quad E[\|A + U)x - b\|_2^2]$   
1. explicit expression for objective:  
 $E[\|Ax - b\|_2^2] = E[\|Ax - b + Ux\|_2^2]$   
 $= \|Ax - b\|_2^2 + E[U^T U] x^T x$   
 $= \|Ax - b\|_2^2 + x^T P x$   
2. hence, robust LS problem is equivalent to LS problem  
 $\minimize \quad \|Ax - b\|_2^2 + \|P^{1/2} x\|_2^2$   
3. for  $P = \delta I$ , get Tikhonov regularized problem  
 $\minimize \quad \|Ax - b\|_2^2 + \delta \|x\|_2^2$

随机鲁棒最小二乘  
图片给出了问题的目标函数, 问题的解以及其与Tikhonov问题的等价性证明  
Stochastic robust LS with  $A = A + U$ ,  $U$  random,  $EU = 0$ ,  $E U^T U = P$   
 $\minimize \quad E[\|A + U)x - b\|_2^2]$   
1. explicit expression for objective:  
 $E[\|Ax - b\|_2^2] = E[\|Ax - b + Ux\|_2^2]$   
 $= \|Ax - b\|_2^2 + E[U^T U] x^T x$   
 $= \|Ax - b\|_2^2 + x^T P x$   
2. hence, robust LS problem is equivalent to LS problem  
 $\minimize \quad \|Ax - b\|_2^2 + \|P^{1/2} x\|_2^2$   
3. for  $P = \delta I$ , get Tikhonov regularized problem  
 $\minimize \quad \|Ax - b\|_2^2 + \delta \|x\|_2^2$

随机鲁棒最小二乘  
图片给出了问题的目标函数, 问题的解以及其与Tikhonov问题的等价性证明  
Stochastic robust LS with  $A = A + U$ ,  $U$  random,  $EU = 0$ ,  $E U^T U = P$   
 $\minimize \quad E[\|A + U)x - b\|_2^2]$   
1. explicit expression for objective:  
 $E[\|Ax - b\|_2^2] = E[\|Ax - b + Ux\|_2^2]$   
 $= \|Ax - b\|_2^2 + E[U^T U] x^T x$   
 $= \|Ax - b\|_2^2 + x^T P x$   
2. hence, robust LS problem is equivalent to LS problem  
 $\minimize \quad \|Ax - b\|_2^2 + \|P^{1/2} x\|_2^2$   
3. for  $P = \delta I$ , get Tikhonov regularized problem  
 $\minimize \quad \|Ax - b\|_2^2 + \delta \|x\|_2^2$

随机鲁棒最小二乘  
图片给出了问题的目标函数, 问题的解以及其与Tikhonov问题的等价性证明  
Stochastic robust LS with  $A = A + U$ ,  $U$  random,  $EU = 0$ ,  $E U^T U = P$   
 $\minimize \quad E[\|A + U)x - b\|_2^2]$   
1. explicit expression for objective:  
 $E[\|Ax - b\|_2^2] = E[\|Ax - b + Ux\|_2^2]$   
 $= \|Ax - b\|_2^2 + E[U^T U] x^T x$   
 $= \|Ax - b\|_2^2 + x^T P x$   
2. hence, robust LS problem is equivalent to LS problem  
 $\minimize \quad \|Ax - b\|_2^2 + \|P^{1/2} x\|_2^2$   
3. for  $P = \delta I$ , get Tikhonov regularized problem  
 $\minimize \quad \|Ax - b\|_2^2 + \delta \|x\|_2^2$

随机鲁棒最小二乘  
图片给出了问题的目标函数, 问题的解以及其与Tikhonov问题的等价性证明  
Stochastic robust LS with  $A = A + U$ ,  $U$  random,  $EU = 0$ ,  $E U^T U = P$   
 $\minimize \quad E[\|A + U)x - b\|_2^2]$   
1. explicit expression for objective:  
 $E[\|Ax - b\|_2^2] = E[\|Ax - b + Ux\|_2^2]$   
 $= \|Ax - b\|_2^2 + E[U^T U] x^T x$   
 $= \|Ax - b\|_2^2 + x^T P x$   
2. hence, robust LS problem is equivalent to LS problem  
 $\minimize \quad \|Ax - b\|_2^2 + \|P^{1/2} x\|_2^2$   
3. for  $P = \delta I$ , get Tikhonov regularized problem  
 $\minimize \quad \|Ax - b\|_2^2 + \delta \|x\|_2^2$

随机鲁棒最小二乘  
图片给出了问题的目标函数, 问题的解以及其与Tikhonov问题的等价性证明  
Stochastic robust LS with  $A = A + U$ ,  $U$  random,  $EU = 0$ ,  $E U^T U = P$   
 $\minimize \quad E[\|A + U)x - b\|_2^2]$   
1. explicit expression for objective:  
 $E[\|Ax - b\|_2^2] = E[\|Ax - b + Ux\|_2^2]$   
 $= \|Ax - b\|_2^2 + E[U^T U] x^T x$   
 $= \|Ax - b\|_2^2 + x^T P x$   
2. hence, robust LS problem is equivalent to LS problem  
 $\minimize \quad \|Ax - b\|_2^2 + \|P^{1/2} x\|_2^2$   
3. for  $P = \delta I$ , get Tikhonov regularized problem  
 $\minimize \quad \|Ax - b\|_2^2 + \delta \|x\|_2^2$

随机鲁棒最小二乘  
图片给出了问题的目标函数, 问题的解以及其与Tikhonov问题的等价性证明  
Stochastic robust LS with  $A = A + U$ ,  $U$  random,  $EU = 0$ ,  $E U^T U = P$   
 $\minimize \quad E[\|A + U)x - b\|_2^2]$   
1. explicit expression for objective:  
 $E[\|Ax - b\|_2^2] = E[\|Ax - b + Ux\|_2^2]$   
 $= \|Ax - b\|_2^2 + E[U^T U] x^T x$   
 $= \|Ax - b\|_2^2 + x^T P x$   
2. hence, robust LS problem is equivalent to LS problem  
 $\minimize \quad \|Ax - b\|_2^2 + \|P^{1/2} x\|_2^2$   
3. for  $P = \delta I$ , get Tikhonov regularized problem  
 $\minimize \quad \|Ax - b\|_2^2 + \delta \|x\|_2^2$

随机鲁棒最小二乘  
图片给出了问题的目标函数, 问题的解以及其与Tikhonov问题的等价性证明  
Stochastic robust LS with  $A = A + U$ ,  $U$  random,  $EU = 0$ ,  $E U^T U = P$   
 $\minimize \quad E[\|A + U)x - b\|_2^2]$   
1. explicit expression for objective:  
 $E[\|Ax - b\|_2^2] = E[\|Ax - b + Ux\|_2^2]$   
 $= \|Ax - b\|_2^2 + E[U^T U] x^T x$   
 $= \|Ax - b\|_2^2 + x^T P x$   
2. hence, robust LS problem is equivalent to LS problem  
 $\minimize \quad \|Ax - b\|_2^2 + \|P^{1/2} x\|_2^2$   
3. for  $P = \delta I$ , get Tikhonov regularized problem  
 $\minimize \quad \|Ax - b\|_2^2 + \delta \|x\|_2^2$

随机鲁棒最小二乘  
图片给出了问题的目标函数, 问题的解以及其与Tikhonov问题的等价性证明  
Stochastic robust LS with  $A = A + U$ ,  $U$  random,  $EU = 0$ ,  $E U^T U = P$   
 $\minimize \quad E[\|A + U)x - b\|_2^2]$   
1. explicit expression for objective:  
 $E[\|Ax - b\|_2^2] = E[\|Ax - b + Ux\|_2^2]$   
 $= \|Ax - b\|_2^2 + E[U^T U] x^T x$   
 $= \|Ax - b\|_2^2 + x^T P x$   
2. hence, robust LS problem is equivalent to LS problem  
 $\minimize \quad \|Ax - b\|_2^2 + \|P^{1/2} x\|_2^2$   
3. for  $P = \delta I$ , get Tikhonov regularized problem  
 $\minimize \quad \|Ax - b\|_2^2 + \delta \|x\|_2^2$

随机鲁棒最小二乘  
图片给出了问题的目标函数, 问题的解以及其与Tikhonov问题的等价性证明  
Stochastic robust LS with  $A = A + U$ ,  $U$  random,  $EU = 0$ ,  $E U^T U = P$   
 $\minimize \quad E[\|A + U)x - b\|_2^2]$   
1. explicit expression for objective:  
 $E[\|Ax - b\|_2^2] = E[\|Ax - b + Ux\|_2^2]$   
 $= \|Ax - b\|_2^2 + E[U^T U] x^T x$   
 $= \|Ax - b\|_2^2 + x^T P x$   
2. hence, robust LS problem is equivalent to LS problem  
 $\minimize \quad \|Ax - b\|_2^2 + \|P^{1/2} x\|_2^2$   
3. for  $P = \delta I$ , get Tikhonov regularized problem  
 $\minimize \quad \|Ax - b\|_2^2 + \delta \|x\|_2^2$

随机鲁棒最小二乘  
图片给出了问题的目标函数, 问题的解以及其与Tikhonov问题的等价性证明  
Stochastic robust LS with  $A = A + U$ ,  $U$  random,  $EU = 0$ ,  $E U^T U = P$   
 $\minimize \quad E[\|A + U)x - b\|_2^2]$   
1. explicit expression for objective:  
 $E[\|Ax - b\|_2^2] = E[\|Ax - b + Ux\|_2^2]$   
 $= \|Ax - b\|_2^2 + E[U^T U] x^T x$   
 $= \|Ax - b\|_2^2 + x^T P x$   
2. hence, robust LS problem is equivalent to LS problem  
 $\minimize \quad \|Ax - b\|_2^2 + \|P^{1/2} x\|_2^2$   
3. for  $P = \delta I$ , get Tikhonov regularized problem  
 $\minimize \quad \|Ax - b\|_2^2 + \delta \|x\|_2^2$

随机鲁棒最小二乘  
图片给出了问题的目标函数, 问题的解以及其与Tikhonov问题的等价性证明  
Stochastic robust LS with  $A = A + U$ ,  $U$  random,  $EU = 0$ ,  $E U^T U = P$   
 $\minimize \quad E[\|A + U)x - b\|_2^2]$   
1. explicit expression for objective:  
 $E[\|Ax - b\|_2^2] = E[\|Ax - b + Ux\|_2^2]$   
 $= \|Ax - b\|_2^2 + E[U^T U] x^T x$   
 $= \|Ax - b\|_2^2 + x^T P x$   
2. hence, robust LS problem is equivalent to LS problem  
 $\minimize \quad \|Ax - b\|_2^2 + \|P^{1/2} x\|_2^2$   
3. for  $P = \delta I$ , get Tikhonov regularized problem  
 $\minimize \quad \|Ax - b\|_2^2 + \delta \|x\|_2^2$

随机鲁棒最小二乘  
图片给出了问题的目标函数, 问题的解以及其与Tikhonov问题的等价性证明  
Stochastic robust LS with  $A$