

模式识别

评估方法

PCA方法

张振宇

南京大学智科院

2025

评估方法简介

Introducing evaluation method

细化(refined)的框架

✓ 机器学习 $f: \mathcal{X} \mapsto \mathcal{Y}$

1. 与领域无关的特征变换和特征抽取


■ Normalization, PCA, FLD, ...

2. 针对不同数据特点的不同学习算法

■ SVM, Decision Tree, imbalanced learning, HMM, DTW, graphical model, deep learning, pLSA, ...

3. 机器学习方法常见分类、策略

✓ 针对不同问题的评价准则 (evaluation criterion)



评价准则—泛化和测试误差

✓ 暂时只考虑分类问题的评价

✓ 假设 $(\mathbf{x}, y) \sim p(\mathbf{x}, y)$

- 泛化误差generalization error: $E_{(\mathbf{x}, y) \sim p(\mathbf{x}, y)}[f(\mathbf{x}) \neq y]$

■ 通常无法实际计算

- 根本假设: 训练集 D_{train} 和测试集 D_{test} 都是服从真实数据分布 $p(\mathbf{x}, y)$ 的, 或者, 他们的样例是从 $p(\mathbf{x}, y)$ 中取样 (sample) 的

- 测试误差(testing error)

$$err = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(f(\mathbf{x}_i) \neq y_i), \quad \mathbf{x}_i \in D_{test}$$

- 准确率(accuracy): $acc = 1 - err$

一种常见的学习框架

✓ 代价最小化 cost minimization

- 错误是最常考虑的代价，所以现在我们可以说学习的目标是在训练集上获得最小的代价

✓ $\min_f \frac{1}{n} \sum_{i=1}^n \mathbb{I}(f(\mathbf{x}_i) \neq y_i), \mathbf{x}_i \in D_{train}$


- 难以优化 – 怎样求解?
- 一种方法是：把不连续的指示函数(indicator function)换成性质相似，但好优化的函数
- 如， $(f(\mathbf{x}_i) - y_i)^2$

✓ 学习这种思路：形式化、简化、优化

- Formalization, simplification, optimization

过拟合和欠拟合

✓ Overfitting & underfitting, 以回归(regression)为例



- 以一阶多项式拟合（直线）
- 学习模型的复杂性小于数据的复杂性
- 称为欠拟合
underfitting

正则化regularization

- ✓ 通常难以精确估计学习模型、数据的复杂性
 - 往往选用较复杂的学习模型
 - 训练集误差通常小于测试集误差(需要两者不相交)
- ✓ 那么如何降低overfitting的可能性呢？
 - 正则化regularization
- ✓ 进一步阅读：
 - 正则化如何能降低模型的复杂性？ PRML以及ESL(The Elements of Statistical Learning)

如果没有测试集

- ✓ 例如，总的数据量比较小（如医学图像）
 - 如何评估？
- ✓ 交叉验证cross validation
 1. 将训练集分为大小大致相等的 N 部分
 2. for $i = 1:N$
 1. 取第 i 部分的数据为测试集
 2. 取所有其余（一共 $N - 1$ 个部分）的数据为训练集
 3. 学习模型并评估/测试得到错误率为 err_i
 3. 交叉验证得到的错误率为 $\frac{1}{N} \sum_{i=1}^N err_i$
 - 称为 N 倍交叉验证 N -fold CV（常用 $N=5$ or 10 ）
- ✓ 可能需要进行多次试验（后面会讲）

数据、代价的不平衡性imbalance

- ✓ 例如，两类问题中，一类数据远比另一类数据多
 - 如，体检中阴性和阳性
 - 男女比例
 - 或在一类犯错的代价远高于另一类
- 不平衡学习(imbalance learning)
- 代价敏感学习(cost-sensitive learning)
- 进一步阅读：周志华教授主页和论文
<http://cs.nju.edu.cn/zhouzh/zhouzh.files/publication/publication.htm>

评价不平衡时的准则(1)


| | 预测为positive | 预测为negative |
|--------------|---------------------|---------------------|
| 真实值为positive | True positive (真阳性) | False negative(伪阴性) |
| 真实值为negative | False positive(伪阳性) | True negative(真阴性) |

- ✓ TP、TN、FP、FN： 标记四种情况的样例数目
- ✓ TOTAL： 总数 $TP+TN+FP+FN$
 - 正样本数目： $P = TP+FN$ ， 负样本数目： $N = FP+TN$
- ✓ False positive rate: $FPR = FP / N$
- ✓ False negative rate: $FNR = FN / P$
- ✓ True positive rate: $TPR = TP / P$
- ✓ Accuracy: $ACC = (TP+TN) / TOTAL$

评价不平衡时的准则(2)

✓ AUC-ROC (Area Under the ROC Curve)

- ROC – Receiver operating characteristic



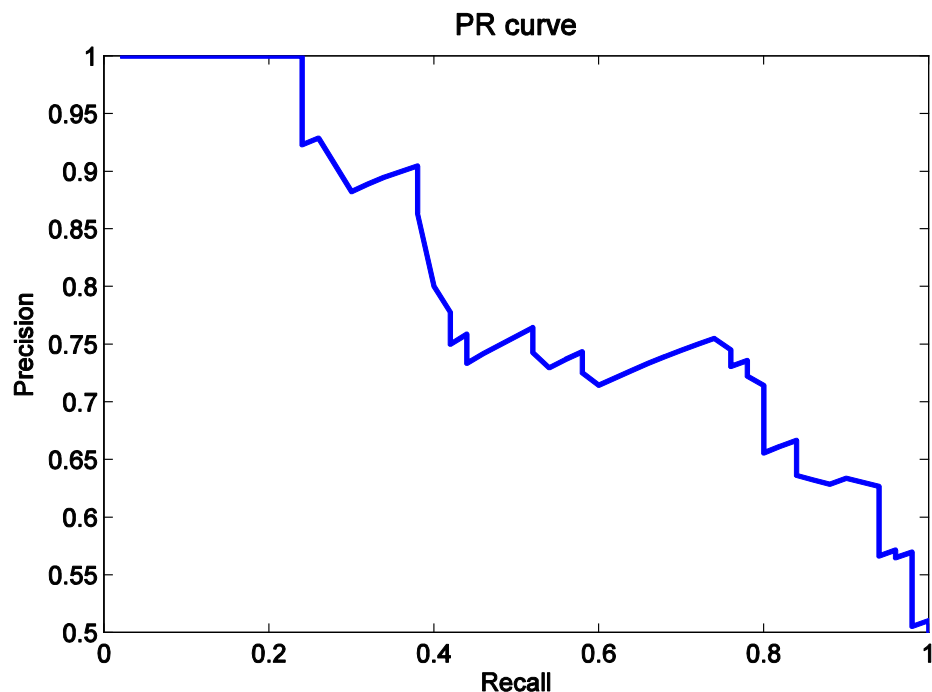
- Y轴：TPR
- X轴：FPR
- 其值为面积
- 为什么？
- 对角线是？
- 非减

评价不平衡时的准则(3)

- ✓ Precision（查准率）： $PRE = TP / (TP + FP)$
- ✓ Recall（查全率）： $REC = TP / P$ (和TPR一样)
- ✓ F1 score: Precision和Recall的调和平均(harmonic mean)
 - 调和平均： $\left(\frac{x^{-1} + y^{-1}}{2} \right)^{-1} = \frac{2xy}{x+y}$
 - $F1 = 2TP / (2TP + FP + FN)$
 - 为什么？

评价不平衡时的准则(4)

✓ AUC-PR (Area Under the Precision-Recall Curve)



- Y轴: Precision
- X轴: Recall
- 其值为面积
- 为什么?
- 单调吗?

进一步阅读: [The Relationship Between Precision-Recall and ROC Curves](#)

能100%准确吗:Bayes框架的回答(1)

✓ $f: \mathcal{X} \mapsto \mathcal{Y}$, 一个数据对(data pair): (\mathbf{x}, y)

- 假设注重于分类: $\mathcal{Y} = \{1, 2, \dots, m\}$
- 先验概率prior probability: $p(y = i)$
 - 在没有看到任何数据时, 怎么分类?
- 后验概率posterior probability: $p(y = i | \mathbf{x})$
 - 看到数据 \mathbf{x} 后, 得到更多的信息, 可以对分类有更好的估计
- 类条件概率class conditional probability: $p(\mathbf{x} | y = i)$
 - 数据的综合分布 $p(\mathbf{x})$ 和每个类别内部的分布 $p(\mathbf{x} | y = i)$ 不一样

✓ 贝叶斯定理Bayes' theorem

$$p(y = i | \mathbf{x}) = \frac{p(\mathbf{x} | y = i)p(y = i)}{p(\mathbf{x})} = \frac{\text{条件} \times \text{先验}}{\text{数据}}$$

代价矩阵

- ✓ 目前常见的为 $\begin{pmatrix} \lambda_{11} & \lambda_{12} \\ \lambda_{21} & \lambda_{22} \end{pmatrix} = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$
 - λ_{ij} : 当真实值为 i 、模型预测为 j 时付的代价
 - 0-1代价: 即分类正确代价为0, 分类错误代价为1
 - 但是, 根据实际情况, 可以给 λ_{ij} 设置任何值
 - 代价不平衡学习
- ✓ 对代价的计算: $E_{(x,y)}[\lambda_{y,f(x)}]$
 - 当使用0-1代价时, 和错误率一致

能100%准确吗:Bayes框架的回答(2)

✓ 贝叶斯决策规则Bayes decision rule:

- 选择代价最小的类别输出

$$\operatorname{argmin}_y E_{(x,y)} [\lambda_{y,f(x)}]$$

- 贝叶斯风险Bayes risk: 使用贝叶斯决策规则的风险
 - 其是理论上我们能得到的最好的结果, 记为 R^*
- ✓ 在使用0-1风险时, 风险和错误率等价
- 所以, R^* 是我们理论上能得到的最小误差
 - $1 - R^*$ 是理论上最高的准确率!
- ✓ 自学: DHS2.1 DHS2.2 (包括似然比规则likelihood ratio rule)

真实值Groundtruth

- ✓ 大多数时候，是手工标注的(manual annotation)
 - 或者人也不知道确切的答案
 - 有时候疲劳或其他因素会导致标注的错误
 - 很耗时、昂贵
- ✓ 真实值的形式
 - 分类：一个离散的类别
 - 回归regression：一个连续的值
 - 结构structured output：例如，输出一个句子的分词结果 “一个/句子/的/分词/结果”

错误从哪里来—以回归为例？

✓ 真实（但未知）的函数 $F(\mathbf{x})$

- 用由其产生的数据集 D 来学习，即 $y = F(\mathbf{x})$ 没有误差
- 回归的代价函数是欧几里得距离

✓ $E_D \left[(f(\mathbf{x}; D) - F(\mathbf{x}))^2 \right] = (E_D[f(\mathbf{x}; D)] - F(\mathbf{x}))^2 + E_D[(f(\mathbf{x}; D) - E_D[f(\mathbf{x}; D)])^2]$

- \mathbf{x} 和 $F(\mathbf{x})$ 不包含随机性，只有 D 出现时才取期望
- 简写为 $E[(f - F)^2] = (F - Ef)^2 + E[(f - Ef)^2]$
- DHS 376页的处理（或翻译）有问题

偏置-方差分解

✓ Bias-variance decomposition

- $E[(f - F)^2] = (F - Ef)^2 + E[(f - Ef)^2]$
- $E[F - Ef]$ -- 偏置bias
 - 当训练集取样有差异时，其值不变
- $E[(f - Ef)^2] = \text{Var}_D(f(\mathbf{x}; D))$ 方差
 - 当训练集取样有差异时，会带来预测的差异（误差不同）

✓ 误差=偏置²+方差

✓ 当考虑到 $y = F(\mathbf{x})$ 有误差是（白噪声）

- 误差=偏置²+方差+噪声
- 估计误差时，如没有测试集，需多次平均

✓ 进一步阅读：分类时候的分解(DHS9.3.2)

对分解的解读

- ✓ 偏置与数据无关，是由模型（的复杂度）决定的
 - 例如，线性分类器（1阶多项式）的偏置大
 - 但是，7阶多项式的复杂度高，偏置小
- ✓ 但是，方差 $\text{Var}_D(f(\mathbf{x}; D))$ 和抽样得到的训练集以及模型两者都有关系
 - 例如，高阶多项式的方差大
- ✓ 怎么减少误差？
 - 对于噪音，机器学习没有办法—高质量的数据获取！
 - 减少偏置和方差
 - 如集成方法(ensemble methods)

统计测试




- ✓ 可以决定我们对于评估的结果是否有信心
 - 自学教材第4.5节
 - 目标是理解统计测试的基本思想
 - 知识要点
 - 怎么理解置信度（第4.5.2节最后部分）
 - T检验的实际操作流程
 - 因假设“概率与数理统计”是前置课程,第4.5节只是一个简要回顾

目标

- ✓ 理解PCA的含义、目的、适用范围
- ✓ 熟记PCA的各个步骤，能实际应用PCA
- ✓ 了解PCA的各种相关解释，理解其含义
- ✓ 提高目标
 - 理解相关推导，能自主独立完成推导
 - 进一步能通过独立阅读理解更多PCA的含义、限制、解释等，并能应用到学习、研究中遇到的问题中去

PCA基础

你的数据是多少维的？



常见的数据特点

- ✓ 数据各维度之间不是互相独立的
 - 数据的内在维度(intrinsic dimensionality)通常远低于其表面维度
 - 因此，需要降低数据维度(dimensionality reduction)
 - PCA在降维方法中（可能）是最常用的一种



这是谁？

$$96 \times 108 = 10368?$$

Starting point: 零阶表示

- ✓ Zero-dimensional representation
- ✓ 不允许使用任何维度，如何最佳表示 \mathbf{x} ?
- ✓ 寻找某个固定(constant)的 \mathbf{m} ，使得

$$J_1(\mathbf{m}) = \min_{\mathbf{m}} \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2$$

- ✓ 最优解：(证明?)

$$\mathbf{m}^* = \operatorname{argmin}_{\mathbf{m}} \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2 = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

一维表示：数据维度间的线性关系

✓ 如同前面的例子

- 数据是 d 维
- 但是内在维度可能是 m 维的， $m < d$ 或者 $m \ll d$
- PCA用线性关系来降低维度



✓ $\mathbf{x} \in \mathbb{R}^d$: 原来的高维数据（随机变量）

- 训练样本： $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$

✓ 假设 $m = 1$, 用原数据的单个线性组合来表示

- $y_i = \mathbf{w}^T \mathbf{x}_i + b$
- y_1, y_2, \dots, y_n -- 新的数据/特征(features)
- 如何寻找最佳的 \mathbf{w} ? 如何找到最佳的 b ?

Idea: 选择什么方向？为什么？



✓ 什么方向最优？

形式化formalization：最大化方差

✓ 方差是衡量新特征包含信息多少的度量

- 有时也称为能量energy

✓ 优化目标函数 $J_2(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n \|\mathbf{w}^T (\mathbf{x}_i - \bar{\mathbf{x}})\|^2$

✓ 发现问题了吗？

- $J_2(\mathbf{w})$ 可以是无穷大或者无穷小！
- 最常用的解决办法：加上限制条件 $\|\mathbf{w}\|^2 = \mathbf{w}^T \mathbf{w} = 1$

$$\arg\max_{\mathbf{w}} \frac{1}{n} \sum_{i=1}^n \|(\mathbf{x}_i - \bar{\mathbf{x}})^T \mathbf{w}\|^2$$

$$\text{s.t.} \quad \mathbf{w}^T \mathbf{w} = 1$$

- s.t. —subject to, 表示约束条件constraint(s)

简化simplification 变换transformation

$$\begin{aligned}\|(\mathbf{x}_i - \bar{\mathbf{x}})^T \mathbf{w}\|^2 &= ((\mathbf{x}_i - \bar{\mathbf{x}})^T \mathbf{w})^T ((\mathbf{x}_i - \bar{\mathbf{x}})^T \mathbf{w}) \\ &= \mathbf{w}^T (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^T \mathbf{w}\end{aligned}$$

$$\begin{aligned}\frac{1}{n} \sum_{i=1}^n \|(\mathbf{x}_i - \bar{\mathbf{x}})^T \mathbf{w}\|^2 &= \mathbf{w}^T \sum_{i=1}^n \frac{1}{n} (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^T \mathbf{w} \\ &= \mathbf{w}^T \text{Cov}(\mathbf{x}) \mathbf{w}\end{aligned}$$

优化optimization

- ✓ 拉格朗日乘子法 **Lagrange** multipliers
 - 将有约束的优化问题转化为无约束的优化问题

- ✓ **Lagrangian** 拉格朗日函数

$$f(\mathbf{w}, \lambda) = \mathbf{w}^T \text{Cov}(\mathbf{x}) \mathbf{w} - \lambda(\mathbf{w}^T \mathbf{w} - 1)$$

- ✓ λ : 拉格朗日乘子 **Lagrange** multiplier

- ✓ 最优的**必要**条件: $\frac{\partial f}{\partial \mathbf{w}} = \mathbf{0}$, $\frac{\partial f}{\partial \lambda} = 0$

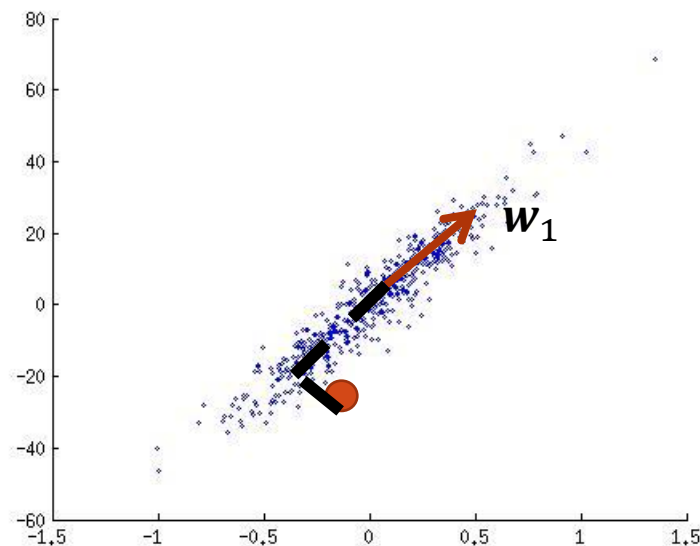
- ✓ $\frac{\partial f}{\partial \mathbf{w}} = 2\text{Cov}(\mathbf{x})\mathbf{w} - 2\lambda\mathbf{w} = \mathbf{0}$

- 我们这里的前提条件是什么?
- 应该想到用哪一个公式?

- ✓ **$\text{Cov}(\mathbf{x})\mathbf{w} = \lambda\mathbf{w}$** , **$\mathbf{w}^T \mathbf{w} = 1$!**

选哪个特征向量？

- ✓ $J_2(\mathbf{w}) = \mathbf{w}^T \text{Cov}(\mathbf{x}) \mathbf{w} = ?$
- ✓ $\text{Cov}(\mathbf{x})$ 是半正定的（如何证明？）
- ✓ 选取 λ_1 (即最大特征值) 对应的特征向量 ξ_1 为 \mathbf{w}_1
 - 为什么？约束条件满足了吗？
- ✓ 怎样用 \mathbf{w}_1 来近似 \mathbf{x} ?
 - 投影！
 - $\mathbf{x} \approx \bar{\mathbf{x}} + (\mathbf{w}_1^T (\mathbf{x} - \bar{\mathbf{x}})) \mathbf{w}_1$
 - 所以， $y_i = \mathbf{w}_1^T (\mathbf{x} - \bar{\mathbf{x}})$
 - 那么， $b = ?$



J_1 和 J_2 的等价关系

✓ 若干向量

- \mathbf{x}_i : 降维之前的向量
- $\mathbf{w}_1^T(\mathbf{x}_i - \bar{\mathbf{x}})\mathbf{w}_1 = y_i\mathbf{w}_1$: 降维之后的向量
- $\hat{\mathbf{x}}$: 在原空间中重建的向量
- 目前的重建关系: $\hat{\mathbf{x}}_i \approx \bar{\mathbf{x}} + y_i\mathbf{w}_1$

✓ J_1 的目的是使得 $\hat{\mathbf{x}}_i$ 和 \mathbf{x}_i 尽可能相差小($\bar{\mathbf{x}}$ 固定为均值)

- $J_1(\mathbf{w}, \mathbf{a}) = \sum_{i=1}^n \frac{1}{n} \|\mathbf{x}_i - (\bar{\mathbf{x}} + a_i\mathbf{w})\|^2$
- \mathbf{w} : 投影方向, a_i : 投影系数

✓ 最小化 J_1 得到的 a_i 和 \mathbf{w} 与 J_2 得到的结果完全一致!

- 试着去证明!

如果需要更多投影方向？

✓ What if we need $\mathbf{w}_2, \mathbf{w}_3, \dots$

- 新的投影方向需要继续保持“能量”
- 但是需要限制
- $\mathbf{w}_2 \perp \mathbf{w}_1, \mathbf{w}_3 \perp \mathbf{w}_2, \mathbf{w}_3 \perp \mathbf{w}_1, \dots$

✓ 在上述限制条件下

- $\mathbf{w}_2 = \boldsymbol{\xi}_2, \mathbf{w}_3 = \boldsymbol{\xi}_3, \dots$
- 重建系数: $\mathbf{w}_j^T (\mathbf{x} - \bar{\mathbf{x}})$

✓ 总之,

$$\mathbf{x} \approx \bar{\mathbf{x}} + (\mathbf{w}_1^T (\mathbf{x} - \bar{\mathbf{x}})) \mathbf{w}_1 + (\mathbf{w}_2^T (\mathbf{x} - \bar{\mathbf{x}})) \mathbf{w}_2 + \dots$$

重建和原数据的关系

- ✓ 假设 $n > d$ ，即数据比维数多
 - 进一步假设 $\text{Cov}(\mathbf{x})$ 可逆
 - 如果 $n < d$ ，那么情况如何、还能做PCA变换吗？
- ✓ $\text{Cov}(\mathbf{x})$ 是 $d \times d$ 矩阵，有 d 个互相垂直的特征向量 ξ_i
 - 重建会有 d 个互相垂直的投影方向 \mathbf{w}_i

$$\forall \mathbf{x}, \quad \mathbf{x} = \bar{\mathbf{x}} + \sum_{i=1}^d (\mathbf{w}_i^T (\mathbf{x} - \bar{\mathbf{x}})) \mathbf{w}_i$$

- 将 \mathbf{w}_i 拼成矩阵形式 $W = [\mathbf{w}_1 \ \mathbf{w}_2 \ \cdots \ \mathbf{w}_d]$ ($d \times d$)
- 投影系数是 $W^T (\mathbf{x} - \bar{\mathbf{x}})$ ，投影方向是 W
- $\mathbf{x} = \bar{\mathbf{x}} + WW^T (\mathbf{x} - \bar{\mathbf{x}})$ （为什么？）
- 重建是完全精确的（没有误差），为什么？

降维

✓ 很多时候，有些投影方向是噪声

- 需要扔掉一些方向
- 扔掉哪些？扔掉多少？

✓ 去掉特征值最小的那些

✓ 通常保持90%的能量

$$\frac{\lambda_1 + \lambda_2 + \cdots + \lambda_T}{\lambda_1 + \lambda_2 + \cdots + \lambda_d} > 0.9$$

- 寻找第一个 T ，使得上面的不等式成立

降维的损失

- ✓ 现在 $\hat{W} = [\mathbf{w}_1 \ \mathbf{w}_2 \ \cdots \mathbf{w}_T] \ (d \times T)$
- ✓ $\mathbf{x} - \hat{\mathbf{x}} = \sum_{j=T+1}^d (\mathbf{w}_j^T (\mathbf{x} - \bar{\mathbf{x}})) \mathbf{w}_j = \sum_{j=T+1}^d \mathbf{e}_j$
 - 这个误差多大?
 - $\mathbf{e}_j^T \mathbf{e}_k = 0$ 如果 $j \neq k$ (为什么?)
 - $E(\|\mathbf{x} - \hat{\mathbf{x}}\|^2) = \sum_{j=T+1}^d E(\|\mathbf{e}_j\|^2)$
 - $E(\|\mathbf{e}_j\|^2) = \lambda_j$
- ✓ 这样降维保证平均（期望）重建误差最小
 - 直接优化重建误差 J_1 得到同样的结果

小结：PCA变换的步骤

- ✓ 训练样本： $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$
- ✓ 计算得到 $\bar{\mathbf{x}}$ 和 $\text{Cov}(\mathbf{x})$
- ✓ 求得 $\text{Cov}(\mathbf{x})$ 的特征值和特征向量
 - Matlab, R, octave, ...
- ✓ 根据特征值选定 T
- ✓ 根据 T 的值确定矩阵 \hat{W}
- ✓ 对任何数据 \mathbf{x} ，其新的经过PCA变换得到的特征是
$$\mathbf{y} = \hat{W}^T (\mathbf{x} - \bar{\mathbf{x}})$$
重建则为 $\mathbf{x} \approx \hat{\mathbf{x}} = \bar{\mathbf{x}} + \hat{W} \mathbf{y}$


应用示例——3D人脸基底制作

01

模板构建

$$S = (X_1, Y_1, Z_1, X_2, \dots, Y_n, Z_n)^T \in \mathbb{R}^{3n}$$

$$T = (R_1, G_1, B_1, \bar{R}_2, \dots, G_n, B_n)^T \in \mathbb{R}^{3n}$$




02

数据集制作

$$S_{mod} = \sum_{i=1}^m a_i S_i, \quad T_{mod} = \sum_{i=1}^m b_i T_i, \quad \sum_{i=1}^m a_i = \sum_{i=1}^m b_i = 1.$$



采集数据



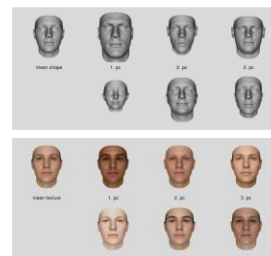
模板注册

03

基底制作

$$\Delta S_i = S_i - \bar{S} \text{ and } \Delta T_i = T_i - \bar{T}.$$

$$S_{model} = \bar{S} + \sum_{i=1}^{m-1} \alpha_i \Delta S_i, \quad T_{model} = \bar{T} + \sum_{i=1}^{m-1} \beta_i \Delta T_i$$




04

优化求解

$$\mathbf{I}_{model}(x, y) = (I_{r,model}(x, y), I_{g,model}(x, y), I_{b,model}(x, y))^T$$

$$E_I = \sum_{x,y} \|\mathbf{I}_{input}(x, y) - \mathbf{I}_{model}(x, y)\|^2.$$



几何系数 α
纹理系数 β
人脸姿态 r, t
光照 l

应用示例——3D人脸基底制作、求解

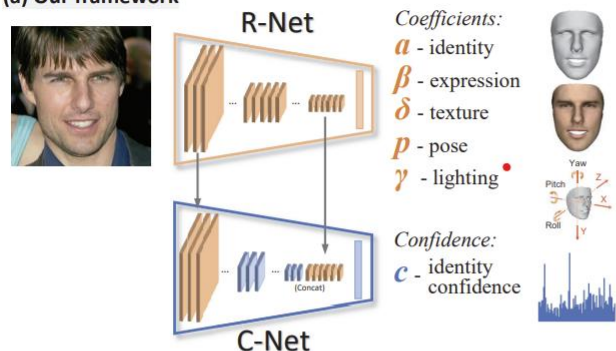
基于3DMM的人脸重建
本质都是求解基底系数



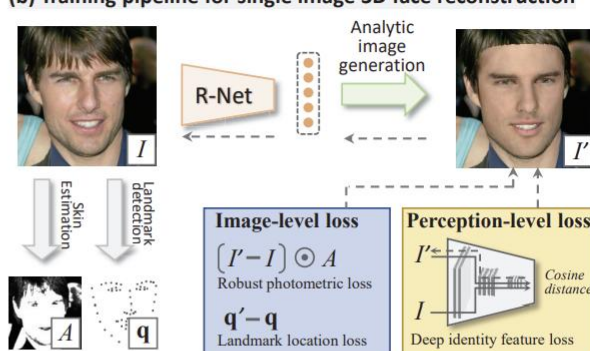
$$\Delta S_i = S_i - \bar{S} \text{ and } \Delta T_i = T_i - \bar{T}.$$

$$S_{model} = \bar{S} + \sum_{i=1}^{m-1} \alpha_i s_i, \quad T_{model} = \bar{T} + \sum_{i=1}^{m-1} \beta_i t_i$$


(a) Our framework



(b) Training pipeline for single image 3D face reconstruction



(c) Training pipeline for multi-image 3D face reconstruction with shape aggregation



- Deng Y, Yang J, Xu S, et al. Accurate 3d face reconstruction with weakly-supervised learning: From single image to image set[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition workshops. 2019: 0-0.