

《深度学习平台与应用》作业一

20251103

一、选择题

1. 基于数据驱动 (Data-Driven) 实现图像分类不包括: (D)
 - A. 收集图像和标签的数据集
 - B. 使用机器学习算法训练分类器
 - C. 使用分类器对新图像进行分类
 - D. 基于专业知识手动编写所有分类规则
2. 对于一个三层神经网络, 输入层输入维度4, 隐藏层包含5个神经元, 输出层包含2个神经元, 则网络中可训练参数的总数为 (请考虑所有层的权重和偏置项的数量) : (C)
 - A. 30
 - B. 31
 - C. 37
 - D. 43
3. 在深度学习模型训练中, 引入正则化 (Regularization) 的主要作用是: (B)
 - A. 增大模型容量, 使其在训练集上取得更高的准确率
 - B. 避免模型过拟合训练数据
 - C. 加快梯度下降的收敛速度
 - D. 提高模型的非线性表达能力, 使其能够拟合任意函数
4. 关于模型优化下列说法正确的是: (D)
 - A. 局部最优值处梯度为零并且随着网络参数量的增加, 局部最优值问题的影响会越来越大
 - B. 鞍点表现为Hessian矩阵全部为正或者全部为负
 - C. RMSProp会使沿着“陡峭”方向的优化变快
 - D. AdaGrad适合于解决凸优化问题
5. 在一个计算图中, 某个节点的“上游梯度”表示: (B)
 - A. 该节点对输入的影响
 - B. 损失函数对该节点输出的梯度
 - C. 该节点对损失函数的直接影响

- D. 该节点对参数的偏导数
6. 关于二阶优化方法中的拟牛顿法（如L-BFGS），以下说法正确的是：(C)
- A. 需要显式存储完整的 Hessian 矩阵
 - B. 计算复杂度为 $O(n^3)$
 - C. 通过维护近似的逆 Hessian 矩阵来避免直接求逆
 - D. 不适用于随机优化设置

二、填空题

1. 使用 Cosine 学习率调度，设初始学习率 $\alpha_0 = 0.1$ ，总迭代次数 $T = 100$ ，在第 $t = 50$ 次迭代时的学习率 $\alpha_{50} = \underline{\hspace{2cm}}(0.05)$ 。
2. 对于输入维度为256，输出维度为80的线性分类器
 $f(x, W) = Wx + b$ ，那么完成一次推理需要进行
 $256 \times 80 + 255 \times 80 + 80 = 40960$ 次运算（包括乘法和加法）
3. 给出L1距离和L2距离的公式($\sum_i |x_i - y_i|$ 和 $\sqrt{\sum_i (x_i - y_i)^2}$)

三、计算题：

1. 给定函数 $z = f(x, y) = \frac{1}{x^2 + 3xy + y^2}$
 - a) 画出该函数的计算图（画出计算图时，确保标明各个节点的计算过程，并清楚标出每一步的梯度计算）
 - b) 结合计算图，使用反向传播求出损失函数 $L = (z_{true} - z)^2$ 对 x 和 y 的梯度

2. 四分类的线性分类器 $f(x, w)$ 四个类别 $class_set = [1, 2, 3, 4]$ 的输出分数为 $[1.1, 0.7, -0.9, 2.2]$, 真实标签 $class = 1$, 请计算(给出计算过程):

a) 多类别svm loss(hinge loss): hinge loss = $\sum_{j \neq y} \max(0, s_j - s_y + 1)$
 $= 0.6 + 0 + 2.1 = 2.7$

b) Softmax loss:

$$L = -\log \left(\frac{e^{s_y}}{\sum e^{s_j}} \right) = -s_y + \log(\sum e^{s_j}) = 1.57$$

3. 给定一个线性分类器 $f(x, w) = w^T x + b$, 假设训练数据点集为 $D = (x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$, 其中 $x_i \in \mathbb{R}^d$ 为输入特征, $y_i \in \{1, -1\}$ 为标签。损失函数为:

$$L(w, b) = \frac{1}{n} \sum_{i=1}^n \max(0, 1 - y_i(w^T x_i + b)) + \lambda \|w\|_2^2$$

a) 计算该损失函数关于 w 和 b 的梯度。

$$\nabla_w L = \frac{1}{n} \sum_{i=1}^n [-\mathbb{I}(1 - y_i(w^T x_i + b) > 0) \cdot y_i x_i] + 2\lambda w$$

$$\nabla_b L = \frac{1}{n} \sum_{i=1}^n [-\mathbb{I}(1 - y_i(w^T x_i + b) > 0) \cdot y_i]$$

b) 讨论L2正则化的作用, 并解释如何通过正则化来防止过拟合。

- $\lambda \|w\|^2$ 项, 迫使权重向量 w 的分量尽可能小且分布均匀。避免模型过于复杂, 降低过拟合。

4. 给定二维训练集 (点与标签) :

- $x_1 = (1, 2)$, $y_1 = A$

- $x_2 = (2, 1)$, $y_2 = B$
- $x_3 = (4, 5)$, $y_3 = A$
- $x_4 = (7, 8)$, $y_4 = B$
- $x_5 = (1, 0)$, $y_5 = A$

测试点: $x_{\text{test}} = (2, 2.5)$ 。取 $k = 3$ 。

a) 计算 x_{test} 到每个训练点的 L1 距离和 L2 距离。

$$\begin{aligned}
 L_1(x, x_1) &= 1 + 0.5 = 1.5 & L_2(x, x_1) &= \sqrt{1 + (0.5)^2} = \frac{\sqrt{5}}{2} \\
 L_1(x, x_2) &= 0 + 1.5 = 1.5 & L_2(x, x_2) &= \sqrt{0 + (1.5)^2} = 1.5 \\
 L_1(x, x_3) &= 2 + 2.5 = 4.5 & L_2(x, x_3) &= \sqrt{2^2 + (2.5)^2} = \frac{\sqrt{41}}{2} \quad (1) \\
 L_1(x, x_4) &= 5 + 5.5 = 10.5 & L_2(x, x_4) &= \sqrt{5^2 + (5.5)^2} = \frac{\sqrt{221}}{2} \\
 L_1(x, x_5) &= 1 + 2.5 = 3.5 & L_2(x, x_5) &= \sqrt{1 + (2.5)^2} = \frac{\sqrt{29}}{2}
 \end{aligned}$$

b) 分别在 L1 与 L2 两种度量下, 找出 3 个最近邻的标签, 并给出最终预测。

L1: 最近的3个点: $x_1 (1.5, A)$, $x_2 (1.5, B)$, $x_5 (3.5, A)$ 。投票: 2票 A, 1票 B。预测: A。

L2: 最近的3个点: $x_1 (1.12, A)$, $x_2 (1.50, B)$, $x_5 (2.69, A)$ 。投票: 2票 A, 1票 B。预测: A。

5. 数据集大小 $N = 50000$, 批量大小 $B = 128$, 总训练 Epoch 为 $E = 100$ 。初始学习率 $\alpha_0 = 0.1$ 。

a) 计算每个 epoch 的迭代次数 (steps/epoch), 以及总迭代次数 (总 steps)

$$\text{epoch} = \lceil 50000 / 128 \rceil = 391$$

b) 按课件公式: $\alpha_t = \alpha_0 \cdot \frac{1+\cos(\pi t/T)}{2}$, 其中 t 为从 0 开始的全局迭代步数, T 为总迭代步数。计算在 $t = 0$, $t = T/2$, $t = T$ 时的学习率, 并解释为何 $t = T$ 时学习率降到 ≈ 0 。

$$t = 0: \alpha = 0.1 \cdot \frac{1+1}{2} = \mathbf{0.1}$$

$$t = T/2: \cos(\pi/2) = 0 \rightarrow \alpha = 0.1 \cdot 0.5 = \mathbf{0.05}$$

$$t = T: \cos(\pi) = -1 \rightarrow \alpha = 0.1 \cdot 0 = \mathbf{0}$$

学习率到0，这是为了在训练结束时让模型收敛到局部极小值的底部，不再跳动。

c) 假定加入线性 Warmup（前5000次迭代），Warmup期间学习率从0线性上升到 α_0 ，之后切换到Cosine调度（以 T 为总训练步数继续衰减）。写出Warmup阶段的学习率公式，并计算 $t=2500$ 、 $t=5000$ 时的学习率；切换到Cosine后，计算 $t=5000$ 与 $t=T$ 时的学习率（说明在 $t=5000$ 处两段是否相等，如果要保证连续性，cosine学习率策略该如何调整）。

$$\text{Warmup: } \alpha_t = \frac{t}{5000} \cdot \alpha_0 = \frac{t}{5000} \cdot 0.1.$$

- $t = 2500: \alpha = 0.5 \times 0.1 = 0.05.$
- $t = 5000: \alpha = 1.0 \times 0.1 = 0.1.$

Cosine ($t \geq 5000$):

- 要保证连续性，Cosine应该从warmup结束后的步数开始计数，即定义 $t' = t - 5000$ ，且分母为 $T_{remain} = T - 5000$ 。
- 修正公式： $\alpha_t = \alpha_0 \cdot \frac{1+\cos(\pi \frac{t-5000}{T-5000})}{2}$ 。
- $t = 5000$ 处： $\cos(0) = 1 \rightarrow \alpha = 0.1$ 。与Warmup结束时的值相等（连续）。
- $t = T$ 处： $\cos(\pi) = -1 \rightarrow \alpha = \mathbf{0}.$
- 调整策略说明：如果不调整（即直接代入全局 t 到原Cosine公式），在 $t = 5000$ 时 $\alpha \approx 0.1 \cdot \frac{1+\cos(5000\pi/39100)}{2} < 0.1$ ，会导致学习率突降。必须平移时间轴 $t \rightarrow t - T_{warmup}$ 并缩放周期。

6. 考虑同一个二分类模型的某一层参数向量，当前参数为：

$$w_0 = \begin{bmatrix} 0.50 \\ -0.30 \end{bmatrix}, \text{在当前 mini-batch 上，损失函数对该参数的梯度为:}$$

$$g_1 = \nabla_w L = \begin{bmatrix} 0.40 \\ -0.20 \end{bmatrix}, \text{现要求你分别用 (1) 普通 SGD、(2) 带动量的 SGD (Momentum)、(3) Adam 三种优化算法，计算“第 1 次更}$$

新”后得到的参数，并比较它们的差异。

给定超参数如下：

- SGD：学习率： $\alpha = 0.01$
- SGD + Momentum：学习率： $\alpha = 0.01$ ，动量系数： $\rho = 0.9$ ，初始动量： $v_0 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$
- Adam：学习率： $\alpha = 0.01$ ，一阶动量衰减： $\beta_1 = 0.9$ ，二阶动量衰减： $\beta_2 = 0.999$ ，数值稳定项： $\epsilon = 10^{-8}$ ，初始一阶动量： $m_0 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$ ，初始二阶动量： $v_0 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$

(1) 普通 SGD

$$w_1 = w_0 - \alpha g = \begin{bmatrix} 0.5 \\ -0.3 \end{bmatrix} - 0.01 \begin{bmatrix} 0.4 \\ -0.2 \end{bmatrix} = \begin{bmatrix} 0.5 - 0.004 \\ -0.3 + 0.002 \end{bmatrix} = \begin{bmatrix} 0.496 \\ -0.298 \end{bmatrix}$$

(2) SGD + Momentum

第一次迭代前 $v_0 = 0$ 。公式： $v_{t+1} = \rho v_t + g_t$, $w_{t+1} = w_t - \alpha v_{t+1}$

。

- $v_1 = 0.9 \times 0 + g = \begin{bmatrix} 0.4 \\ -0.2 \end{bmatrix}$
- $w_1 = w_0 - 0.01v_1 = \begin{bmatrix} 0.5 \\ -0.3 \end{bmatrix} - \begin{bmatrix} 0.004 \\ -0.002 \end{bmatrix} = \begin{bmatrix} 0.496 \\ -0.298 \end{bmatrix}$

(注：在第1步，由于没有历史动量积累，SGD 和 Momentum 更新结果相同)

(3) Adam

$t = 1$ 。

- 一阶动量 m_1 :

$$m_1 = \beta_1 m_0 + (1 - \beta_1)g = 0.9(0) + 0.1 \begin{bmatrix} 0.4 \\ -0.2 \end{bmatrix} = \begin{bmatrix} 0.04 \\ -0.02 \end{bmatrix}$$

- 二阶动量 v_1 (平方累积):

$$v_1 = \beta_2 v_0 + (1 - \beta_2)g^2 = 0.999(0) + 0.001 \begin{bmatrix} 0.4^2 \\ (-0.2)^2 \end{bmatrix} = \begin{bmatrix} 0.00016 \\ 0.00004 \end{bmatrix}$$

- 偏差修正:

$$\hat{m}_1 = m_1 / (1 - 0.9^1) = m_1 / 0.1 = \begin{bmatrix} 0.4 \\ -0.2 \end{bmatrix}$$

$$\hat{v}_1 = v_1 / (1 - 0.999^1) = v_1 / 0.001 = \begin{bmatrix} 0.16 \\ 0.04 \end{bmatrix}$$

- 参数更新:

$$\begin{aligned}\sqrt{\hat{v}_1} &= \begin{bmatrix} 0.4 \\ 0.2 \end{bmatrix} \text{ (忽略极小 } \epsilon\text{)} \\ Update &= \alpha \cdot \frac{\hat{m}_1}{\sqrt{\hat{v}_1}} = 0.01 \cdot \begin{bmatrix} 0.4/0.4 \\ -0.2/0.2 \end{bmatrix} = 0.01 \begin{bmatrix} 1 \\ -1 \end{bmatrix} \\ w_1 &= \begin{bmatrix} 0.5 \\ -0.3 \end{bmatrix} - \begin{bmatrix} 0.01 \\ -0.01 \end{bmatrix} = \begin{bmatrix} 0.49 \\ -0.29 \end{bmatrix}\end{aligned}$$