



矩阵计算与优化

(最优化--无约束优化)

授课人：陈硕



南京大学
NANJING UNIVERSITY



大纲

- 非线性优化基础
- 非线性无约束优化方法





非线性规划的基本概念

- 非线性规划问题
- 非线性规划数学模型
- 非线性规划的图解法
- 梯度、Hesse矩阵、Jacobi阵
- 凸函数和凸规划
- 解非线性规划方法概述





非线性规划是运筹学的重要分支之一。最近30多年来发展很快，不断提出各种算法，而其应用范围也越来越广泛。比如在各种预报、管理科学、最优设计、质量控制、系统控制等领域得到广泛且不短深入的应用。

一般来说，求解非线性规划问题比线性规划问题困难得多。而且，也不象线性规划那样有单纯形法这一通用的方法。非线性规划的各种算法大都有自己特定的使用范围，都有一定的局限性。到目前为止还没有**适合于各种问题的一般算法**，这是需要深入研究的一个领域。我们只是对一些模型及应用作简单介绍。





非线性规划问题举例

例1：选址问题

设有 n 个市场，第 j 个市场位置为 (p_j, q_j) ，它对某种货物的需要量为 $b_j (j = 1, 2, \dots, n)$ 。现计划建立 m 个仓库，第 i 个仓库的存储容量为 $a_i (i = 1, 2, \dots, m)$ 。试确定仓库的位置，使各仓库对各市场的运输量与路程乘积之和为最小。

设第 i 个仓库的位置为 $(x_i, y_i), i = 1, 2, \dots, m$ ，第 i 个仓库到第 j 个市场的货物供应量为 $z_{ij} (i = 1, 2, \dots, m, j = 1, 2, \dots, n)$ 。则第 i 个仓库到第 j 个市场的距离为

$$d_{ij} = \sqrt{(x_i - p_j)^2 + (y_i - q_j)^2},$$





矩阵计算与优化 (最优化--无约束优化)

目标函数为

$$\min \sum_{i=1}^m \sum_{j=1}^n z_{ij} d_{ij} = \sum_{i=1}^m \sum_{j=1}^n z_{ij} \sqrt{(x_i - p_j)^2 + (y_i - q_j)^2},$$

约束条件为

(1) 每个仓库向各市场提供的货物量之和不能超过它的存储容量。

$$\sum_{j=1}^n z_{ij} \leq a_i, \quad i = 1, 2, \dots, m$$

(2) 每个市场从各仓库得到的货物量之和应等于它的需要量。

$$\sum_{i=1}^m z_{ij} = b_j, \quad j = 1, 2, \dots, n$$

(3) 运输量不能为负数


$$z_{ij} \geq 0, \quad i = 1, 2, \dots, m, \quad j = 1, 2, \dots, n$$





例2. 木梁设计问题

把圆形木材加工成矩形横截面的木梁，要求木梁高度不超过 H ，横截面的惯性矩（高度的平方 $\times$ 宽度）不小于 W ，而且高度介于宽度与4倍宽度之间。问如何确定木梁尺寸可使木梁成本最小。



设矩形横截面的高度为 x_1 ，宽度为 x_2 ，则圆形木材的半径

$$r = \sqrt{\left(\frac{x_1}{2}\right)^2 + \left(\frac{x_2}{2}\right)^2}$$

而木梁长度无法改变，因此成本只与圆形木材的横截面积有关。





矩阵计算与优化 (最优化--无约束优化)

目标函数为

$$\min \quad s = \pi r^2 = \pi \left(\frac{x_1^2}{4} + \frac{x_2^2}{4} \right),$$

约束条件为

$$\begin{aligned} x_1 &\leq H && \text{(高度不小于 } H \text{)} \\ x_1^2 x_2 &\geq W && \text{(惯性矩不小于 } W \text{)} \\ x_1 &\geq x_2 && \text{(高度介于宽度与} \\ &&& \text{4倍宽度之间)} \\ x_1 &\leq 4x_2 && \\ x_1, x_2 &\geq 0. && \text{(高度与宽度非负)} \end{aligned}$$





非线性规划问题的数学模型

➤ (1) 数学规划模型的一般形式：

$$\begin{cases} \min & f(x) \\ \text{s.t.} & g_i(x) \leq 0, \quad i = 1, \dots, p \\ & h_j(x) = 0, \quad j = 1, \dots, q \end{cases}$$

其中, $x = (x_1, x_2, \dots, x_n)^T$, $f(x), g_i(x), h_j(x)$ 为 x 的实值函数,

简记为MP(Mathematical Programming)





矩阵计算与优化 (最优化--无约束优化)

➤ (2) 简记形式:

引入向量函数符号:

$$h(x) = (h_1(x), \dots, h_q(x))^T \quad g(x) = (g_1(x), \dots, g_p(x))^T$$

$$X = \left\{ x \in R^n \left| \begin{array}{l} g_i(x) \leq 0, i = 1, \dots, p \\ h_i(x) = 0, j = 1, \dots, q \end{array} \right. \right\}$$

$$\left\{ \begin{array}{l} \min f(x) \\ s.t. \quad g_i(x) \leq 0, \quad i = 1, \dots, p \\ \quad \quad h_i(x) = 0, \quad j = 1, \dots, q \end{array} \right. \quad \Rightarrow \quad \left\{ \begin{array}{l} \min f(x) \\ s.t. \quad g(x) \leq 0 \\ \quad \quad h(x) = 0 \end{array} \right.$$

$$\downarrow$$
$$\min_{x \in X} f(x)$$





矩阵计算与优化 (最优化--无约束优化)

➤ (3) 数学规划问题的分类:

$$\begin{cases} \min & f(x) \\ \text{s.t.} & g(x) \leq 0 \\ & h(x) = 0 \end{cases}$$

☺若 $f(x), g_i(x), h_j(x)$ 为线性函数, 即为**线性规划**(LP);

☺若 $f(x), g_i(x), h_j(x)$ 至少一个为非线性, 即为**非线性规划**(NLP);

☺对于非线性规划, 若没有 $g_i(x), h_j(x)$,即 $X=R^n$,称为

无约束非线性规划或无约束最优化问题;

否则称为**约束非线性规划或约束最优化问题。**





矩阵计算与优化 (最优化--无约束优化)

$$\begin{cases} \min & f(x) \\ s.t. & g_i(x) \leq 0, \quad i = 1, \dots, p \\ & h_i(x) = 0, \quad j = 1, \dots, q \end{cases}$$

➤ (4) 可行域和可行解:

称
$$X = \left\{ x \in R^n \left| \begin{array}{l} g_i(x) \leq 0, i = 1, \dots, p \\ h_i(x) = 0, j = 1, \dots, q \end{array} \right. \right\}$$

为MP问题的约束集或可行域。

若 x 在 X 内, 称 x 为MP的可行解或者可行点。





矩阵计算与优化（最优化--无约束优化）

➤ （5）最优解和极小点

定义： 对于非线性规划（MP），若 $x^* \in X$ ，并且有

$$f(x^*) \leq f(x), \quad \forall x \in X$$

则称 x^* 是（MP）的整体最优解或整体极小点，
称 $f(x^*)$ 是（MP）的整体最优值或整体极小值。

如果有 $f(x^*) < f(x), \quad \forall x \in X, x \neq x^*$

称 x^* 是（MP）的严格整体最优解或严格整体极小点，

称 $f(x^*)$ 是（MP）的严格整体最优值或严格整体极小值。



矩阵计算与优化 (最优化--无约束优化)

定义 对于非线性规划 (MP), 若 $x^* \in X$, 并且存在 x^* 的邻域

$$N_\delta(x^*) = \{x \in R^n \mid \|x - x^*\| < \delta\}$$

$$f(x^*) \leq f(x), \quad \forall x \in N_\delta(x^*) \cap X$$

则称 x^* 是(MP)的局部最优解或局部极小解,

称 $f(x^*)$ 是 (MP) 的局部最优值或局部极小值

如果有

$$f(x^*) < f(x), \quad \forall x \in N_\delta(x^*) \cap X, x \neq x^*$$

称 x^* 是 (MP) 的严格局部最优解或严格局部极小点

$f(x^*)$ 是 (MP) 的严格局部最优值或严格局部极小值。






非线性规划问题的图解法

对二维最优化问题，总可以用图解法求解，而对三维或高维问题，已不便在平面上作图，此法失效。

例1：用图解法求解

$$\begin{aligned} \min \quad & f(x) = (x_1 - 2)^2 + (x_2 - 2)^2 \\ \text{s.t.} \quad & h(x) = x_1 + x_2 - 6 = 0 \end{aligned}$$






非线性规划问题的图解法

例2: 用图解法求解

$$\begin{aligned} \min \quad & f(x) = (x_1 - 2)^2 + (x_2 - 2)^2 \\ \text{s.t.} \quad & h(x) = x_1 + x_2 - 6 \leq 0 \end{aligned}$$






非线性规划问题的图解法

$$\min f(x) = (x_1 - 2)^2 + (x_2 - 1)^2$$

$$s.t \begin{cases} x_1 + x_2^2 - 5x_2 = 0 \\ x_1 + x_2 - 5 \geq 0 \\ x_1, x_2 \geq 0 \end{cases}$$



- 解：①先画出等式约束曲线 $x_1 + x_2^2 - 5x_2 = 0$ 的图形——抛物线，
②再画出不等式约束区域，
③最后画出目标函数等值线，

所以 最优解 $x^* = (4, 1)$, 最优值 $\min f(x) = 4$.





梯度、Hesse矩阵、Jacobi阵

► 二次函数

一般形式:
$$f(x_1, x_2, \dots, x_n) = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n g_{ij} x_i x_j + \sum_{i=1}^n b_i x_i + c$$

矩阵形式:
$$f(x) = \frac{1}{2} x^T A x + b^T x + c \quad \text{其中 } A = A^T.$$

二次型:
$$f(x) = \frac{1}{2} x^T A x$$

矩阵 A 的正定性: 正定、半正定、负定、不定。

二次型的正定性: 正定、半正定、负定、不定。





梯度

定义： $f(x)$ 是定义在 E_n 上的可微函数。 $f(x)$ 的 n 个偏导数为分量的向量称为 $f(x)$ 的**梯度**。

$$\nabla f(x) = \left[\frac{\partial f(x)}{\partial x_1}, \frac{\partial f(x)}{\partial x_2}, \dots, \frac{\partial f(x)}{\partial x_n} \right]^T$$

性质： 设 $f(x)$ 在定义域内有连续偏导数，即有连续梯度，则梯度有以下两个重要性质：

性质一 函数在某点的梯度不为零，则该梯度方向必与过该点的等值面垂直；

性质二 梯度方向是函数具有最大变化率的方向（负梯度方向也叫**最速下降方向**）。





矩阵计算与优化 (最优化--无约束优化)

例：试求目标函数 $f(x_1, x_2) = 3x_1^2 - 4x_1x_2 + x_2^2$ 在点 $x = [0, 1]^T$ 处的最速下降方向，并求沿这个方向移动一个单位长度后新点的目标函数值。

解：由于 $\frac{\partial f}{\partial x_1} = 6x_1 - 4x_2, \quad \frac{\partial f}{\partial x_2} = -4x_1 + 2x_2$

则函数在 $x = [0, 1]^T$ 处的最速下降方向是

$$P = -\nabla f(x) = \begin{bmatrix} -\frac{\partial f}{\partial x_1} \\ -\frac{\partial f}{\partial x_2} \end{bmatrix}_{\substack{x_1=0 \\ x_2=1}} = \begin{bmatrix} -6x_1 + 4x_2 \\ 4x_1 + 2x_2 \end{bmatrix}_{\substack{x_1=0 \\ x_2=1}} = \begin{bmatrix} +4 \\ -2 \end{bmatrix}$$

这个方向上的单位向量是：

$$e = \frac{-\nabla f(x)}{\|-\nabla f(x)\|} = \frac{\begin{bmatrix} +4 \\ -2 \end{bmatrix}}{\sqrt{(+4)^2 + (-2)^2}} = \begin{bmatrix} +\frac{2}{5}\sqrt{5} \\ -\frac{1}{5}\sqrt{5} \end{bmatrix}$$





矩阵计算与优化 (最优化--无约束优化)

例：试求目标函数 $f(x_1, x_2) = 3x_1^2 - 4x_1x_2 + x_2^2$ 在点 $x = [0, 1]^T$ 处的最速下降方向，并求沿这个方向移动一个单位长度后新点的目标函数值。

解：由于

$$e = \frac{-\nabla f(x)}{\|-\nabla f(x)\|} = \frac{\begin{bmatrix} +4 \\ -2 \end{bmatrix}}{\sqrt{(+4)^2 + (-2)^2}} = \begin{bmatrix} +\frac{2}{5}\sqrt{5} \\ -\frac{1}{5}\sqrt{5} \end{bmatrix}$$

新点是：

$$x^1 = x + e = \begin{bmatrix} 0 \\ 1 \end{bmatrix} + \begin{bmatrix} +\frac{2}{5}\sqrt{5} \\ -\frac{1}{5}\sqrt{5} \end{bmatrix} = \begin{bmatrix} +\frac{2}{5}\sqrt{5} \\ 1 - \frac{1}{5}\sqrt{5} \end{bmatrix}$$

函数值：

$$f(x^1) = 3x_1^2 - 4x_1x_2 + x_2^2 \big|_{x^1} = \frac{26}{5} - 2\sqrt{5}$$





矩阵计算与优化 (最优化--无约束优化)

几个常用的梯度公式:

- (1). $f(x) = C$ (常数), 则 $\nabla f(x) = 0$. 即 $\nabla C = 0$
- (2). $f(x) = b^T x$ 则 $\nabla f(x) = b$.
- (3). $f(x) = x^T x$ 则 $\nabla f(x) = 2x$.
- (4). A 对称矩阵。 $f(x) = x^T A x$ 则 $\nabla f(x) = 2Ax$





矩阵计算与优化 (最优化--无约束优化)

Hesse矩阵

多元函数 $f(x)$ 关于 x 的二阶导数, 称为 $f(x)$ 的Hesse矩阵.

$$\nabla^2 f(x) = \nabla(\nabla f(x)) = \begin{bmatrix} \frac{\partial^2 f(x)}{\partial x_1^2} & \frac{\partial^2 f(x)}{\partial x_2 \partial x_1} \dots & \frac{\partial^2 f(x)}{\partial x_n \partial x_1} \\ \frac{\partial^2 f(x)}{\partial x_1 x_2} & \frac{\partial^2 f(x)}{\partial x_2^2} \dots & \frac{\partial^2 f(x)}{\partial x_n \partial x_2} \\ \vdots & \vdots & \vdots \\ \frac{\partial^2 f(x)}{\partial x_1 x_n} & \frac{\partial^2 f(x)}{\partial x_2 x_n} \dots & \frac{\partial^2 f(x)}{\partial x_n^2} \end{bmatrix}$$

当 $f(x)$ 的所有二阶偏导数连续时, 即 $\frac{\partial^2 f(x)}{\partial x_i \partial x_j} = \frac{\partial^2 f(x)}{\partial x_j \partial x_i}$ 时, Hesse矩阵是对称的.





几个常用Hessian公式:

$$f(x) = b^T x \Rightarrow \nabla f(x) = b, \nabla^2 f(x) = 0;$$

$$f(x) = \frac{1}{2} x^T x \Rightarrow \nabla f(x) = x, \nabla^2 f(x) = I (\text{单位阵});$$

$$f(x) = \frac{1}{2} x^T A x, A \text{ 对称} \Rightarrow \nabla f(x) = A x, \nabla^2 f(x) = A.$$





矩阵计算与优化 (最优化--无约束优化)

Jacobi矩阵

- 向量变量值函数: $g(x) = (g_1(x), g_2(x), \dots, g_n(x))^T$

$$x = (x_1, x_2, \dots, x_n)^T$$

- 向量变量值函数的导数:

$$\nabla g(x_0) = \begin{bmatrix} \frac{\partial g_1(x_0)}{\partial x_1} & \frac{\partial g_1(x_0)}{\partial x_2} \dots & \frac{\partial g_1(x_0)}{\partial x_n} \\ \frac{\partial g_2(x_0)}{\partial x_1} & \frac{\partial g_2(x_0)}{\partial x_2} \dots & \frac{\partial g_2(x_0)}{\partial x_n} \\ \vdots & \vdots & \vdots \\ \frac{\partial g_m(x_0)}{\partial x_1} & \frac{\partial g_m(x_0)}{\partial x_2} \dots & \frac{\partial g_m(x_0)}{\partial x_n} \end{bmatrix}$$

向量值函数 $g(x)$ 在点 x_0 处的Jacobi矩阵





凸函数和凸规划

(1)凸函数:

定义 设 $S \subset R^n$ 是非空凸集, $f: S \rightarrow R^1$, 若对 $\forall \alpha \in (0,1)$ 有

$$f(\alpha x^1 + (1-\alpha)x^2) \leq \alpha f(x^1) + (1-\alpha)f(x^2), \forall x^1, x^2 \in S$$

则称 f 是 S 上的凸函数, 或 f 在 S 上是凸的。

若 $f(\alpha x^1 + (1-\alpha)x^2) < \alpha f(x^1) + (1-\alpha)f(x^2), \forall x^1, x^2 \in S$

则称 f 是 S 上的严格凸函数, 或 f 在 S 上是严格凸的。

若 $-f$ 是 S 上的(严格)凸函数, 称 f 是 S 上的(严格)凹函数, 或 f 在 S 上是(严格)凹的。





例 $f(x)=\|x\|$ 其中 $x \in R^n$ 是凸函数

例 $f(x)=\alpha^T x + \beta$, 其中 $\alpha, x \in R^n, \beta \in R^1$ 即是凸的也是凹的。

例：正定二次函数 $f(x) = \frac{1}{2} x^T A x + b^T x + c$,

其中 A 是正定矩阵, $f(x)$ 是凸函数。





➤ (2) 凸函数的性质

性质1: 设 $S \subset R^n$ 是非空凸集

(1)若 f 是 S 上的凸函数, $\alpha \geq 0$, 则 αf 是 S 上的凸函数;

(2)若 f_1, f_2 是 S 上的凸函数, $f_1 + f_2$ 是 S 上的凸函数。

性质2: 设 $S \subset R^n$ 是非空凸集, f 是凸函数, $c \in R^1$, 则集合

$$H_S(f, c) = \{x \in S \mid f(x) \leq c\} \text{ 是凸集。}$$





矩阵计算与优化 (最优化--无约束优化)

➤ (3) 凸函数的判定

定理1: (一阶条件)

设 $S \subset R^n$ 是非空开凸集, $f: S \rightarrow R^1$ 可微, 则

① f 是 S 上的凸函数 $\Leftrightarrow$

$$\nabla f(x^1)^T (x^2 - x^1) \leq f(x^2) - f(x^1), \forall x^1, x^2 \in S$$

其中 $\nabla f(x^1) = (\frac{\partial f(x^1)}{\partial x_1}, \dots, \frac{\partial f(x^1)}{\partial x_n})^T$ 是函数在点 x^1 处的梯度。

② f 是 S 上的严格凸函数 $\Leftrightarrow$

$$\nabla f(x^1)^T (x^2 - x^1) < f(x^2) - f(x^1), \forall x^1, x^2 \in S, x^1 \neq x^2$$

$n=1$ 时几何意义: 可微函数是凸的等价于切线不在函数图像上方。





矩阵计算与优化 (最优化--无约束优化)

定理2: (二阶条件)

设 $S \subset R^n$ 是非空开凸集, $f: S \rightarrow R^1$ 二阶连续可导,
则 f 是 S 上的凸函数 $\Leftrightarrow$

$\nabla^2 f(x)$ 在 S 上是半正定的。

当 $\nabla^2 f(x)$ 在 S 上是正定矩阵时 $\Rightarrow$

f 是 S 上的严格凸函数 (此时, 逆命题不成立)

其中 $\nabla^2 f(x)$ 为 Hesse 矩阵,

$$\nabla^2 f(x) = \begin{bmatrix} \frac{\partial^2 f(x)}{\partial x_1 \partial x_1} & \cdots & \frac{\partial^2 f(x)}{\partial x_1 \partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f(x)}{\partial x_n \partial x_1} & \cdots & \frac{\partial^2 f(x)}{\partial x_n \partial x_n} \end{bmatrix}$$





矩阵计算与优化 (最优化--无约束优化)

➤ (4) 凸规划的定义及其性质:

凸规划定义:

$$\begin{cases} \min & f(x) \\ \text{s.t.} & g_i(x) \leq 0 \quad i=1, \dots, p \\ & h_j(x) = 0 \quad j=1, \dots, q \end{cases}$$

$$X = \left\{ x \in R^n \left| \begin{array}{ll} g_i(x) \leq 0 & i=1, \dots, p \\ h_j(x) = 0 & j=1, \dots, q \end{array} \right. \right\}$$

若 X 是凸集, f 是 S 上的凸函数, 称(MP)为非线性凸规划, 简称凸规划。





矩阵计算与优化 (最优化--无约束优化)

凸规划性质:

定理 对于非线性规划 (MP),

$$\begin{cases} \min & f(x) \\ \text{s.t.} & g_i(x) \leq 0 \quad i=1, \dots, p \\ & h_j(x) = 0 \quad j=1, \dots, q \end{cases}$$

凸函数

线性函数

若 $g_i(x)$ 皆为 R^n 上的凸函数, $h_j(x)$ 皆为线性函数,
并且 f 是 X 上的凸函数, 则 (MP)是凸规划。

定理 凸规划的任一局部最优解都是它的整体最优解。

☺凸规划是以后重点讨论的一类非线性规划





非线性规划方法概述

➤（1）微分学方法的局限性：


- ⊖实际的问题中，函数可能是不连续或者不可微的。
- ⊖需要解复杂的方程组，而方程组到目前仍没有有效的算法。
- ⊖实际的问题可能含有不等式约束，微分学方法不易处理。





矩阵计算与优化（最优化--无约束优化）


➤（2）数值方法的基本思路：迭代





矩阵计算与优化（最优化--无约束优化）

➤ 迭代格式



$$\Delta x^k = t_k p^k$$

$$x^{k+1} = x^k + \Delta x^k$$

称 p^k 为第 k 轮**搜索方向**， t_k 为第 k 轮沿 p^k 方向的**步长**。

产生 t_k 和 p^k 的不同方法，形成了不同的算法。





矩阵计算与优化 (最优化--无约束优化)


定义：特殊搜索方向——下降方向

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}^1, \bar{x} \in \mathbb{R}^n, p \in \mathbb{R}^n, p \neq 0$, 若存在 $\delta > 0$, 使

$$f(\bar{x} + tp) < f(\bar{x}), \quad \forall t \in (0, \delta)$$

则称向量 p 是函数 $f(x)$
在点 $\bar{x}$ 处的下降方向。

若 $f(x)$ 在 $\bar{x}$ 可导, 则 $-\nabla f(\bar{x})$ 就是
 $f(x)$ 在 $\bar{x}$ 处下降最快的方向。





矩阵计算与优化 (最优化--无约束优化)

定义：特殊搜索方向——**可行下降方向**


设 $X \subset R^n, \bar{x} \in X, p \in R^n, p \neq 0$, 若存在 $t > 0$, 使得

$$\bar{x} + tp \in X$$

则称向量 p 是点 $\bar{x}$ 处
关于 X 的可行方向。

解非线性规划问题，关键在于找到某个方向，使得在此方向上，目标函数得到下降，同时还是可行方向。

这样的方向称为**可行下降方向**。





矩阵计算与优化 (最优化--无约束优化)

定义：算法收敛、下降迭代算法


集合S上的迭代算法：

(1) 初始点 x^0 ；

(2) 按照某种搜索方向 p^k 产生下一个迭代点 $x^{k+1} = x^k + \lambda_k p^k$.

(i) 如果点列 $\{x^k\}$ 收敛于最优解 x^* ，则称此算法收敛。

(ii) 如果 $f(x^0) > f(x^1) > \dots > f(x^k) > \dots$ ，则称此算法为下降迭代算法。





矩阵计算与优化 (最优化--无约束优化)

➤ (3) 下降迭代算法步骤

- (1) 给出初始点 x^0 , 令 $k = 0$;
- (2) 按照某种规则确定下降搜索方向 d^k ;
- (3) 按照某种规则确定搜索步长 λ_k , 使得
$$f(x^k + \lambda_k d^k) < f(x^k) ;$$
- (4) 令 $x^{k+1} = x^k + \lambda_k d^k$ $k := k + 1$;
- (5) 判断 x^k 是否满足**停止条件**。是则停止, 否则转第2步。

搜索步长确定方法:

$$f(x^k + \lambda_k d^k) = \min_{\lambda} f(x^k + \lambda d^k)$$

称 λ_k 为**最优步长**, 且有对 λ_k 的梯度

$$\nabla f(x^k + \lambda_k d^k)^T d^k = 0$$





矩阵计算与优化 (最优化--无约束优化)

➤ (4) 终止条件

$$\textcircled{1} \quad \left\| \mathbf{x}^{k+1} - \mathbf{x}^k \right\| < \varepsilon_1$$

$$\textcircled{2} \quad \left| f(\mathbf{x}^{k+1}) - f(\mathbf{x}^k) \right| < \varepsilon_2$$

$$\textcircled{3} \quad \frac{\left\| \mathbf{x}^{k+1} - \mathbf{x}^k \right\|}{\left\| \mathbf{x}^k \right\|} < \varepsilon_3 \quad (\left\| \mathbf{x}^k \right\| > \varepsilon)$$

$$\textcircled{4} \quad \frac{\left| f(\mathbf{x}^{k+1}) - f(\mathbf{x}^k) \right|}{\left| f(\mathbf{x}^k) \right|} < \varepsilon_4 \quad (|f(\mathbf{x}^k)| > \varepsilon)$$





(5) 常用的收敛性判别准则:

点收敛准则: $\|x^{(k)} - x^{(k-1)}\| \leq \varepsilon$ ($\|\bullet\|$ 可取 $\mathbf{R}^n$ 中任一种模)。

目标函数值准则: $|f(x^{(k)}) - f(x^{(k-1)})| \leq \varepsilon$ (绝对差)。

目标函数值准则: $\frac{f(x^{(k)}) - f(x^{(k-1)})}{f(x^{(k)})} \leq \varepsilon$ (相对差)。

取其中之一,也可同时取(1)与(2);(1)与(3);或(1),(2)和(3)等。





矩阵计算与优化（最优化--无约束优化）

➤ (6) 算法的收敛速度

设算法所得的点列为 $\{x^k\}$ ，如果

$$\frac{\|x^{k+1} - x^*\|}{\|x^k - x^*\|^\alpha} < \lambda, \quad \lambda, \alpha > 0. \quad (*)$$

则称 $\{x^k\}$ 的收敛阶为 α 。

1. 线性收敛（当 k 充分大时）：
$$\frac{\|x^{(k+1)} - x^*\|}{\|x^{(k)} - x^*\|} < 1$$

2. 超线性收敛：
$$\lim_{k \rightarrow \infty} \frac{\|x^{(k+1)} - x^*\|}{\|x^{(k)} - x^*\|} = 0$$

3. 二阶收敛：(*) 式中 $\alpha=2$ 时成立。





大纲

- 非线性优化基础
- **非线性无约束优化方法**





单变量(一维)最优化

- 一维最优化问题
- 进退法
- 黄金分割法
- 抛物线搜索法
- 三次插值法






矩阵计算与优化 (最优化--无约束优化)

一维最优化问题

下降迭代算法中最优步长的确定 $f(x^k + \lambda_k d^k) = \min_{\lambda} f(x^k + \lambda d^k)$



一维最优化问题: $\min f(x)$
 $s.t. \quad x \in R$

解析的方法 (极值点的必要条件) $f'(x) = 0$





矩阵计算与优化 (最优化--无约束优化)


1. 单峰函数

定义： 设 $f(x)$ 是区间 $[a, b]$ 上的一元函数， $\bar{x}$ 是 $f(x)$ 在 $[a, b]$ 上的极小点，且对任意的 $x_1, x_2 \in [a, b], x_1 < x_2$ ， 有

(a) 当 $x_2 \leq \bar{x}$ 时， $f(x_1) > f(x_2)$;

(b) 当 $x_1 \geq \bar{x}$ 时， $f(x_1) < f(x_2)$.

则称 $f(x)$ 是单峰函数。






矩阵计算与优化 (最优化--无约束优化)

性质: 通过计算区间 $[a, b]$ 内两个不同点的函数值, 就可以确定一个包含极小点的子区间。

定理 设 $f(x)$ 是区间 $[a, b]$ 上的一元函数, $\bar{x}$ 是 $f(x)$ 在 $[a, b]$ 上的极小点。任取点 $c < d \in [a, b]$, 则有

- (1) 如果 $f(c) > f(d)$, 则 $\bar{x} \in [c, b]$;
- (2) 如果 $f(c) \leq f(d)$, 则 $\bar{x} \in [a, d]$ 。





2 搜索法求解:

$$\min_{x \geq 0} \varphi(x) \quad \text{或} \quad \min_{0 \leq x \leq x_{\max}} \varphi(x)$$

基本过程:

- ☺ 给出 $[a, b]$, 使得 x^* 在 $[a, b]$ 中。 $[a, b]$ 称为 **搜索区间**。
- ☺ 迭代缩短 $[a, b]$ 的长度。
- ☺ 当 $[a, b]$ 的长度小于某个预设的值, 或者导数的绝对值小于某个预设的正数, 则迭代终止。





矩阵计算与优化 (最优化--无约束优化)

进退法

如何确定包含极小点的一个区间？

思想 从一点出发,按一定的步长, 试图确定出函数值呈现“高 - 低 - 高”的三点。一个方向不成功, 就退回来, 再沿相反方向寻找。

进退法的计算步骤

1. 给定初始点 $x^{(0)} \in R$, 初始步长 $h_0 > 0$, 令 $h = h_0$, $x^{(1)} = x^{(0)}$, 计算 $f(x^{(1)})$, 并令 $k = 0$.
2. 令 $x^{(4)} = x^{(1)} + h$, 计算 $f(x^{(4)})$, 令 $k := k + 1$.
3. 若 $f(x^{(4)}) < f(x^{(1)})$, 则转 4, 否则, 转 5.
4. 令 $x^{(2)} = x^{(1)}$, $x^{(1)} = x^{(4)}$, $f(x^{(2)}) = f(x^{(1)})$, $f(x^{(1)}) = f(x^{(4)})$, 令 $h := 2h$, 转 2.
5. 若 $k = 1$, 则转 6; 否则, 转 7.






矩阵计算与优化 (最优化--无约束优化)

6. 令 $h := -h$, $x^{(2)} = x^{(4)}$, $f(x^{(2)}) = f(x^{(4)})$, 转 2.


7. 令 $x^{(3)} = x^{(2)}$, $x^{(2)} = x^{(1)}$, $x^{(1)} = x^{(4)}$, 停止计算。

区间 $[x^{(1)}, x^{(3)}]$ 或 $[x^{(3)}, x^{(1)}]$ 即为包含极小点的区间。

例:



极小点区间: $[x^{(3)}, x^{(1)}]$



极小点区间: $[x^{(1)}, x^{(3)}]$






矩阵计算与优化 (最优化--无约束优化)


黄金分割法 (0.618法)

假定：已经确定了单峰区间 $[a,b]$

$$\left. \begin{array}{l} \min_{x \geq 0} \varphi(x) \\ \min_{0 \leq x \leq x_{\max}} \varphi(x) \end{array} \right\} \Rightarrow \min_{a \leq x \leq b} \varphi(x)$$



新搜索区间为 $[a, x_2]$




新搜索区间为 $[x_1, b]$





矩阵计算与优化（最优化--无约束优化）

➤ 区间缩小比例的确定：



区间缩短比例为 $(x_2 - a)/(b - a)$

缩短比例为 $(b - x_1)/(b - a)$

缩短比例 满足：

☺ 每次插入搜索点使得两个区间 $[a, x_2]$ 和 $[x_1, b]$ 相等；

☺ 每次迭代都以相等的比例缩小区间。

$$\text{缩短比例 } \omega = \frac{\sqrt{5}-1}{2} \approx 0.618 \quad \dots \quad 0.618 \text{法}$$





矩阵计算与优化 (最优化--无约束优化)

黄金分割法的计算公式的推导:

设 $f(x)$ 在 $[a_1, b_1]$ 上单峰, 极小点 $\bar{x} \in [a_1, b_1]$. 假设进行第 k 次迭代前 $\bar{x} \in [a_k, b_k]$, 取 $\lambda_k, \mu_k \in [a_k, b_k]$, 规定 $\lambda_k < \mu_k$.

计算 $f(\lambda_k)$ 和 $f(\mu_k)$, 分两种情况:

1. 若 $f(\lambda_k) > f(\mu_k)$, 则令 $a_{k+1} = \lambda_k, b_{k+1} = b_k$;
2. 若 $f(\lambda_k) \leq f(\mu_k)$, 则令 $a_{k+1} = a_k, b_{k+1} = \mu_k$.

如何确定 λ_k 与 μ_k ?






矩阵计算与优化 (最优化--无约束优化)

要求其满足以下两个条件:

$$1. \quad b_k - \lambda_k = \mu_k - a_k \quad (1)$$



2. 每次迭代区间长度缩短 比率相同, 即

$$b_{k+1} - a_{k+1} = \alpha(b_k - a_k) \quad (\alpha > 0) \quad (2)$$

由式 (1) 与 (2) 可得:

$$\begin{cases} \lambda_k = a_k + (1 - \alpha)(b_k - a_k) \end{cases} \quad (3)$$

$$\begin{cases} \mu_k = a_k + \alpha(b_k - a_k) \end{cases} \quad (4)$$





矩阵计算与优化 (最优化--无约束优化)

α 取值的确定?

通过确定 α 的取值, 使上一次迭代剩余的迭代点恰与下一次迭代的一个迭代点重合, 从而减少算法的计算量。

(1) 设在第 k 次迭代时有 $f(\lambda_k) \leq f(u_k)$, 则有

$$[a_{k+1}, b_{k+1}] = [a_k, u_k]。$$

在第 $k+1$ 次迭代时选取 λ_{k+1}, u_{k+1} , 则由 (4) 有

$$\begin{aligned} u_{k+1} &= a_{k+1} + \alpha(b_{k+1} - a_{k+1}) \\ &= a_k + \alpha^2(b_k - a_k) \end{aligned}$$

如果令 $\alpha^2 = 1 - \alpha$, 则 $u_{k+1} = \lambda_k$, 因此 u_{k+1} 不必重新计算。

$$\alpha^2 = 1 - \alpha \Rightarrow \alpha = \frac{\sqrt{5} - 1}{2} \approx 0.618$$

(2) 若在第 k 次迭代时有 $f(\lambda_k) > f(u_k)$ 。 同理可得。





矩阵计算与优化 (最优化--无约束优化)

0.618法的算法步骤:

1. 给定初始区间 $[a_1, b_1]$, 精度要求 $\varepsilon > 0$.

令 $\lambda_1 = a_1 + 0.382(b_1 - a_1)$, $\mu_1 = a_1 + 0.618(b_1 - a_1)$,

并计算 $f(\lambda_1)$ 与 $f(\mu_1)$. 令 $k := 1$.

2. 若 $b_k - a_k < \varepsilon$, 停止, 且 $\bar{x} = \frac{b_k + a_k}{2}$. 否则,

当 $f(\lambda_k) > f(\mu_k)$ 时, 转 3; 当 $f(\lambda_k) \leq f(\mu_k)$ 时, 转 4.

3. 令 $a_{k+1} = \lambda_k$, $b_{k+1} = b_k$, $\lambda_{k+1} = \mu_k$,

$\mu_{k+1} = a_{k+1} + 0.618(b_{k+1} - a_{k+1})$, 计算 $f(\mu_{k+1})$, 令 $k := k + 1$, 转 2.

4. 令 $a_{k+1} = a_k$, $b_{k+1} = \mu_k$, $\mu_{k+1} = \lambda_k$,


$\lambda_{k+1} = a_{k+1} + 0.382(b_{k+1} - a_{k+1})$, 计算 $f(\lambda_{k+1})$, 令 $k := k + 1$, 转 2.





矩阵计算与优化（最优化--无约束优化）

0.618法的算法框图：





矩阵计算与优化（最优化--无约束优化）

黄金分割法的迭代效果：

第 k 次后迭代后所得区间长度为初始区间长度的 $(\frac{\sqrt{5}-1}{2})^k$ 倍。

其它的试探点算法：Fibonacci算法。





矩阵计算与优化 (最优化--无约束优化)

➤例：求解 $\min_{t \geq 0} \varphi(t) = t^3 - 2t + 1$

其中单谷区间 $[0,3]$,精度0.5

解：


1、第一轮：

$$t_1 = 1.146, t_2 = 1.854$$

$$\varphi(t_1) = 0.2131,$$

$$\varphi(t_2) = 3.6648$$

$$t_2 - 0 > 0.5$$





矩阵计算与优化 (最优化--无约束优化)

2、第二轮:

$$t_2=1.146, t_1=0.708$$

$$\varphi(t_1)=-0.0611$$

$$\varphi(t_2)=0.2131$$

$$t_2 - 0 = 1.146 > 0.5$$



3、第三轮:

$$t_1=0.438, t_2=0.708$$

$$\varphi(t_2)=-0.0611$$

$$\varphi(t_1)=0.2082$$

$$b - t_1 = 1.146 - 0.438 > 0.5$$





矩阵计算与优化（最优化--无约束优化）


4、第四轮：

$$t_2 = 0.876 = (1.146 - 0.438), t_1 = 0.708$$

$$\varphi(t_1) = -0.0611$$

$$\varphi(t_2) = -0.0798$$

$$b - t_1 = 1.146 - 0.708 < 0.5$$



输出： $t^* = t_2 = 0.876$ 为最优解，最优值为-0.0798





Fibonacci法

此法类似于0.618法，也是用于单峰函数。其计算过程也与0.618类似，第1次迭代计算两个试探点，以后每次迭代只需新加一点，另一试探点取自上次的迭代点。此法与0.618法的主要差别为：区间长度的缩短比率不是常数，而是由Fibonacci数确定；给出精度后，迭代次数可预先确定；适合于参数只能取整数值的情况。

定义 称满足条件

(i) $F_0 = F_1 = 1$;

(ii) $F_n = F_{n-1} + F_{n-2}, n = 1, 2, \dots$

的数列 $\{F_n\}$ 为Fibonacci数列。





矩阵计算与优化 (最优化--无约束优化)

由定义推知Fibonacci数列的前10项为1,1,2,3,5,8,13,21,34,55,89。
通过求解递推关系可求得该数列的通项为

$$F_n = \frac{1}{\sqrt{5}} \left[\left(\frac{1+\sqrt{5}}{2} \right)^{n+1} - \left(\frac{1-\sqrt{5}}{2} \right)^{n+1} \right] \quad (2.3)$$

由 (2.3) 式可求得 $\frac{F_{n-1}}{F_n} \approx 0.618$ 。利用Fibonacci数的这一特点，用 $\frac{F_{n-1}}{F_n}$ 代替0.618法中的0.618，再稍加改进，便是Fibonacci法。

在Fibonacci法中，第 n 次迭代的搜索区间的长度（记为 L_n ）是上一次区间长度的 $\frac{F_{n-1}}{F_n}$ 倍





矩阵计算与优化 (最优化--无约束优化)

即有

$$L_n = \frac{F_{n-1}}{F_n} L_{n-1} = \frac{F_{n-1}}{F_n} \left(\frac{F_{n-2}}{F_{n-1}} L_{n-2} \right) = \frac{F_{n-2}}{F_n} L_{n-2} = \cdots = \frac{F_0}{F_n} L_0 = \frac{1}{F_n} L_0$$

所以要使在第 n 次迭代时搜索区间的长度不超过 ε , 只需

$$\frac{1}{F_n} L_0 \leq \varepsilon \quad (2.4)$$

即可。因 F_n, L_0 是已知值, 所以给出精度 ε 后利用 (2.4) 式可求得迭代次数。

Fibonacci法在迭代中计算试探点的公式为

$$\begin{aligned} \lambda_k &= a_k + \frac{F_{n-k-1}}{F_{n-k+1}} (b_k - a_k), \quad k = 1, 2, \dots, n-1. \\ \mu_k &= a_k + \frac{F_{n-k}}{F_{n-k+1}} (b_k - a_k), \quad k = 1, 2, \dots, n-1. \end{aligned}$$





Fibonacci法

(1) 对初始区间 $[a_1, b_1]$ 和精度 $\varepsilon > 0$, 求目标函数值的计算次数 n , 使 $F_n \geq (b_1 - a_1) / \varepsilon$

置辨别常数 $\delta > 0$ 。计算试探点 λ_1 和 μ_1

$$\lambda_1 = a_1 + \frac{F_{n-2}}{F_n}(b_1 - a_1), \quad \mu_1 = a_1 + \frac{F_{n-1}}{F_n}(b_1 - a_1),$$

计算函数值和 $f(\lambda_1)$ 和 $f(\mu_1)$ 。置 $k=1$ 。

(2) 若 $f(\lambda_k) > f(\mu_k)$, 则转 (3) ;
若 $f(\lambda_k) \leq f(\mu_k)$, 则转 (4) 。





矩阵计算与优化 (最优化--无约束优化)

(3) 令 $a_{k+1} = \lambda_k, b_{k+1} = b_k, \lambda_{k+1} = \mu_k$, 计算试探点:

$$\mu_{k+1} = a_{k+1} + (b_{k+1} - a_{k+1}) \quad (2.7)$$

若 $k = n-2$, 则转(6); 否则, 计算函数值 $f(\mu_{k+1})$, 转(5)

(4) 令 $a_{k+1} = a_k, b_{k+1} = \mu_k, \mu_{k+1} = \lambda_k$, 计算 λ_{k+1} :

$$\lambda_{k+1} = a_{k+1} + (b_{k+1} - a_{k+1}) \quad (2.8)$$

若 $k = n-2$, 则转(6); 否则, 计算函数值 $f(\lambda_{k+1})$, 转(5)

(5) 置 $k := k+1$, 转 (2) 。

(6) 令 $\lambda_n = \lambda_{n-1}, \mu_n = \mu_{n-1} + \delta$, 计算函数值 $f(\lambda_n)$ 和 $f(\mu_n)$,

若 $f(\lambda_n) > f(\mu_n)$, 则令 $a_n = \lambda_n, b_n = b_{n-1}$;

若 $f(\lambda_n) \leq f(\mu_n)$, 则令 $a_n = a_{n-1}, b_n = \lambda_n$.

停止计算, 极小点含于 $[a_n, b_n]$, 且 $[a_n, b_n]$ 的长度不超过 ε .






矩阵计算与优化（最优化--无约束优化）

抛物线（二次）插值

思想 在极小点附近，用二次三项式 $\varphi(x)$ 逼近目标函数 $f(x)$ ，
令 $\varphi(x)$ 与 $f(x)$ 在三点 $x^{(1)} < x^{(2)} < x^{(3)}$ 处有相同的函数值，
并假设 $f(x^{(1)}) > f(x^{(2)})$, $f(x^{(2)}) > f(x^{(3)})$.





矩阵计算与优化 (最优化--无约束优化)

如何计算函数 $\varphi(x)$?

设 $\varphi(x) = a + bx + cx^2,$
令 $\varphi(x^{(1)}) = a + bx^{(1)} + cx^{(1)2} = f(x^{(1)})$

$$\varphi(x^{(2)}) = a + bx^{(2)} + cx^{(2)2} = f(x^{(2)})$$

$$\varphi(x^{(3)}) = a + bx^{(3)} + cx^{(3)2} = f(x^{(3)})$$

解上述方程组, 可得逼近函数 $\varphi(x)$ 的系数 b 和 c .

再求函数 $\varphi(x)$ 的极小点, 令

$$\varphi'(x) = b + 2cx = 0,$$

解得 $\bar{x} = -\frac{b}{2c}$

$$= \frac{(x^{(2)2} - x^{(3)2})f(x^{(1)}) + (x^{(3)2} - x^{(1)2})f(x^{(2)}) + (x^{(1)2} - x^{(2)2})f(x^{(3)})}{2[(x^{(2)} - x^{(3)})f(x^{(1)}) + (x^{(3)} - x^{(1)})f(x^{(2)}) + (x^{(1)} - x^{(2)})f(x^{(3)})]}$$

以 $\bar{x}$ 作为 $f(x)$ 的极小点的估计值。





矩阵计算与优化 (最优化--无约束优化)

抛物线插值算法步骤:

(1) 给定初始区间 $[x^{(1)}, x^{(3)}]$, 设 $f(x^{(1)}) > f(x^{(2)})$, $f(x^{(2)}) > f(x^{(3)})$.

令 $k := 1$. $\bar{x}^{(0)} = x^{(1)}$. 给定精度 ε .

(2) 设 $\varphi(x) = a + bx + cx^2$. 令 $\varphi(x^{(i)}) = f(x^{(i)})$, $i = 1, 2, 3$. 解出

系数 a, b, c . 解出 $\varphi(x)$ 的极小点 $\bar{x}^{(k)} = -\frac{b}{2c}$.

若 $|f(\bar{x}^{(k)}) - f(\bar{x}^{(k-1)})| < \varepsilon$, 则算法停止, 否则转 (3).

(3) 从 $x^{(1)}, x^{(2)}, x^{(3)}$ 和 $\bar{x}^{(k)}$ 中选择 $f(x)$ 的函数值最小的三个点 及其左、右两点, 重新标记为 $x^{(1)}, x^{(2)}, x^{(3)}$. 令 $k := k + 1$. 转 (2).






矩阵计算与优化 (最优化--无约束优化)

三次插值法

思路： 已知 $f(x)$ 在点 $x^{(1)}$ 、 $x^{(2)}$ ($x^{(1)} < x^{(2)}$) 的函数值，且有 $f'(x^{(1)}) < 0$ ， $f'(x^{(2)}) > 0$ 。则区间 $(x^{(1)}, x^{(2)})$ 内存在 $f(x)$ 的极小点。利用这两点的函数值和导数构造一个三次多项式 $\varphi(x)$ ，使它与 $f(x)$ 在这两点有相同的函数值和导数，用 $\varphi(x)$ 逼近 $f(x)$ ，并用 $\varphi(x)$ 的极小点近似 $f(x)$ 的极小点。





矩阵计算与优化 (最优化--无约束优化)

确定函数 $\varphi(x)$ 的方法:

$$\text{设 } \varphi(x) = a(x - x^{(1)})^3 + b(x - x^{(1)})^2 + c(x - x^{(1)}) + d \quad (1)$$

$$\text{令 } \begin{cases} \varphi(x^{(1)}) = f(x^{(1)}) \\ \varphi(x^{(2)}) = f(x^{(2)}) \\ \varphi'(x^{(1)}) = f'(x^{(1)}) \\ \varphi'(x^{(2)}) = f'(x^{(2)}) \end{cases}$$

则有

$$\begin{cases} d = f(x^{(1)}) \\ a(x^{(2)} - x^{(1)})^3 + b(x^{(2)} - x^{(1)})^2 + c(x^{(2)} - x^{(1)}) + d = f(x^{(2)}) \\ c = f'(x^{(1)}) \\ 3a(x^{(2)} - x^{(1)})^2 + 2b(x^{(2)} - x^{(1)}) + c = f'(x^{(2)}) \end{cases} \quad (2)$$

求解方程组得出系数 a, b, c, d 的值, 从而确定函数 $\varphi(x)$ 。





矩阵计算与优化 (最优化--无约束优化)

求解满足 $\begin{cases} \varphi'(x) = 0 \\ \varphi''(x) > 0 \end{cases}$ 的极小点 $\bar{x}$ 。

$$\text{令 } \varphi'(x) = 3a(x - x^{(1)})^2 + 2b(x - x^{(1)}) + c = 0 \quad (3)$$

$$\text{而 } \varphi''(x) = 6a(x - x^{(1)}) + 2b。$$

解方程 (3)，有两种情况：

1. 当 $a = 0$ 时，解得

$$\bar{x} - x^{(1)} = -\frac{c}{2b} \quad (4)$$

由 (2) 可知

$$c = f'(x^{(1)}) < 0, f'(x^{(2)}) > 0, x^{(2)} > x^{(1)}。$$

所以 $b > 0$ 。

因此 $\varphi''(\bar{x}) = 2b > 0$ ，即 $\bar{x}$ 是 $\varphi(x)$ 的极小点。





矩阵计算与优化 (最优化--无约束优化)

2. 当 $a \neq 0$ 时, 解得

$$\bar{x} - x^{(1)} = \frac{-b \pm \sqrt{b^2 - 3ac}}{3a} \quad (5)$$

此时有

$$\begin{aligned} \varphi''(\bar{x}) &= 6a \cdot \frac{-b \pm \sqrt{b^2 - 3ac}}{3a} + 2b \\ &= \pm 2\sqrt{b^2 - 3ac} \end{aligned}$$

为使 $\varphi''(\bar{x}) > 0$, 则在(5)式中应取

$$\begin{aligned} \bar{x} - x^{(1)} &= \frac{-b + \sqrt{b^2 - 3ac}}{3a} \\ &= \frac{-c}{b + \sqrt{b^2 - 3ac}} \end{aligned} \quad (6)$$

而当 $a = 0$ 时, 由(6)式可知 $\bar{x} - x^{(1)} = -\frac{c}{2b}$, 所以(6)式

是1、2两种情况下极小点的统一表达式。





矩阵计算与优化（最优化--无约束优化）

极小点的计算公式：

$$\text{令 } s = \frac{3[f(x^{(2)}) - f(x^{(1)})]}{x^{(2)} - x^{(1)}} \quad (7)$$

$$t = s - f'(x^{(1)}) - f'(x^{(2)}) \quad (8)$$

$$w^2 = t^2 - f'(x^{(1)})f'(x^{(2)}) \quad (9)$$

$$\text{则有 } \bar{x} = x^{(1)} + (x^{(2)} - x^{(1)})\left(1 - \frac{f'(x^{(2)}) + t + w}{f'(x^{(2)}) - f'(x^{(1)}) + 2w}\right) \quad (10)$$





矩阵计算与优化 (最优化--无约束优化)

算法步骤:

1. 给定初始点 $x^{(1)}, x^{(2)}$, 计算 $f(x^{(1)}), f(x^{(2)}), f'(x^{(1)}), f'(x^{(2)})$, 要求满足条件: $x^{(2)} > x^{(1)}, f'(x^{(1)}) < 0, f'(x^{(2)}) > 0$ 。

给定允许误差 $\delta > 0, \varepsilon > 0$ 。

2. 按照公式(7)、(8)、(9)、(10)计算 s 、 t 、 w 和 $\bar{x}$ 。

3. 若 $|x^{(2)} - x^{(1)}| < \delta$, 则停止计算, 得到点 $\bar{x}$; 否则, 转4。

4. 计算 $f(\bar{x}), f'(\bar{x})$ 。若 $|f'(\bar{x})| < \varepsilon$, 停止计算, 得到点 $\bar{x}$ 。

若 $f'(\bar{x}) < 0$, 则令 $x^{(1)} = \bar{x}, f(x^{(1)}) = f(\bar{x}), f'(x^{(1)}) = f'(\bar{x})$ 。转2。

若 $f'(\bar{x}) > 0$, 则令 $x^{(2)} = \bar{x}, f(x^{(2)}) = f(\bar{x}), f'(x^{(2)}) = f'(\bar{x})$ 。转2。





矩阵计算与优化 (最优化--无约束优化)

例 用三次插值算法求解下述问题:

$$\min \quad f(x) = x^3 - 3x + 1$$

$$s.t. \quad 0 \leq x \leq 2$$

解: 取初始点 $x^{(1)} = 0, x^{(2)} = 2$ 。则有

$$x^{(2)} - x^{(1)} = 2, \quad f(x^{(1)}) = 1, \quad f(x^{(2)}) = 3,$$

$$\text{由} \quad f'(x) = 3x^2 - 3, \text{得} \quad f'(x^{(1)}) = -3, \quad f'(x^{(2)}) = 9。$$

$$\text{所以} \quad s = \frac{3[f(x^{(2)}) - f(x^{(1)})]}{x^{(2)} - x^{(1)}} = 3,$$

$$t = s - f'(x^{(1)}) - f'(x^{(2)}) = -3,$$

$$w^2 = t^2 - f'(x^{(1)})f'(x^{(2)}) = 6 \Rightarrow w = \sqrt{6}。$$

$$\text{则} \quad \bar{x} = 0 + 2 \times \left(1 - \frac{9 - 3 + \sqrt{6}}{9 + 3 + 2\sqrt{6}}\right) = 1。$$

而 $f'(\bar{x}) = 0$, 所以 $\bar{x} = 1$ 是极小点。





矩阵计算与优化 (最优化--无约束优化)

MATLAB

► 单变量函数求最小值的标准形式为

$$\begin{array}{ll} \min_x & f(x) \\ \text{s.t} & x_1 < x < x_2 \end{array}$$

函数 **fminbnd**

格式 `x = fminbnd(fun,x1,x2)` %返回自变量x在区间

上函数fun取最小值时x值，fun为目标函数的表达式字符串或MATLAB自定义函数的函数柄。

函数fminbnd的算法基于黄金分割法和二次插值法，它要求目标函数必须是连续函数，并可能只给出局部最优解。





矩阵计算与优化（最优化--无约束优化）

- ▶ `x = fminbnd(fun,x1,x2,options)` % options为指定优化参数选项
- ▶ `[x,fval] = fminbnd(...)` % fval为目标函数的最小值
- ▶ `[x,fval,exitflag] = fminbnd(...)` % exitflag为终止迭代的条件
- ▶ `[x,fval,exitflag,output] = fminbnd(...)` % output为优化信息
- ▶ 说明 若参数`exitflag>0`，表示函数收敛于x，若`exitflag=0`，表示超过函数估计值或迭代的最大数字，`exitflag<0`表示函数不收敛于x；若参数`output=iterations`表示迭代次数，`output=funccount`表示函数赋值次数，`output=algorithm`表示所使用的算法。





矩阵计算与优化 (最优化--无约束优化)

例1 计算下面函数在区间(0, 1)内的最小值。

$$f(x) = \frac{x^3 + \cos x + x \log x}{e^x}$$

```
解: [x,fval,exitflag,output]
    =fminbnd('(x^3+cos(x)+x*log(x))/exp(x)',0,1)
x =
    0.5223
fval =
    0.3974
exitflag =
     1
output =
    iterations: 9
    funcCount: 9
    algorithm: 'golden section search, parabolic interpolation'
```





矩阵计算与优化 (最优化--无约束优化)

例 2 求 $e^{-x} \sin x$ 在 $0 < x < 8$ 中的最小值与最大值.

主程序为ex2.m:

```
f='2*exp(-x).*sin(x)';  
fplot(f,[0,8]);           %作图语句  
[xmin,ymin]=fminbnd(f,0,8)  
f1='-2*exp(-x).*sin(x)';  
[xmax,ymax]=fminbnd(f1,0,8)
```

运行结果:

xmin = 3.9270	ymin = -0.0279
xmax = 0.7854	ymax = 0.6448





多维无约束最优化

- 梯度法（最速下降法）
- 牛顿法与拟牛顿法
- 变尺度法 (DFP法)





矩阵计算与优化（最优化--无约束优化）

$$\begin{array}{ll} \text{无约束最优化问题} & \min \quad f(x) \\ & s.t. \quad x \in R^n \end{array} \quad (UMP)$$

其中 $f(x)$ 有一阶连续偏导数。

解析方法：利用函数的解析性质——驻点，得到最优解。

数值方法：利用函数的解析性质构造迭代公式使之收敛到最优解。

$$x^{k+1} = x^k + \lambda_k d^k$$

$$f(x^k + \lambda_k d^k) = \min_{\lambda} f(x^k + \lambda d^k)$$





无约束问题的最优性条件

定理1 设 $f: R^n \rightarrow R$ 在点 $\bar{x} \in R^n$ 处可微, 若存在 $p \in R^n$, 使

$$\nabla f(\bar{x})^T p < 0$$

则向量 p 是 f 在点 $\bar{x}$ 处的下降方向

定理2 设 f 在点 $x^* \in R^n$ 可微, 若 x^* 是 $\min f(x)$ 的局部最优解

$$\text{则 } g^* = \nabla f(x^*) = 0$$

注: ☺ 梯度为0的点称为函数的**驻点**。

☺ 驻点可能是极小点, 也可能是极大点, 也可能即不是极大也不是极小, 这时称为函数的**鞍点**。

☺ 定理2说明: UMP问题的局部最优解必是目标函数的驻点





定理3 设 f 在点 $x^* \in R^n \dots$ 处的Hesse矩阵 $\nabla^2 f(x^*)$ 存在,

若 $\nabla f(x^*)=0$, 并且 $\nabla^2 f(x^*)$ 正定

则 x^* 是 $\min f(x)$ 的严格局部最优解

定理4 设 $f: R^n \rightarrow R^1, x^* \in R^n, f$ 是 R^n 上的可微凸函数

若 $\nabla f(x^*)=0$, 则

则 x^* 是 $\min f(x)$ 的整体最优解






梯度法 (最速下降法)

迭代公式: $x^{k+1} = x^k + \lambda_k d^k$

如何选择下降最快的方向?





矩阵计算与优化 (最优化--无约束优化)

一、梯度法 (最速下降法) :

1. 搜索方向: $d^k = -\nabla f(x^k)$, 也称为最速下降方向;
2. 搜索步长: λ_k 取最优步长, 即满足

$$f(x^k + \lambda_k d^k) = \min_{\lambda} f(x^k + \lambda d^k)。$$

二、梯度法算法步骤:

1. 给定初始点 $x^1 \in R^n$, 允许误差 $\varepsilon > 0$, 令 $k = 1$ 。
2. 计算搜索方向 $d^k = -\nabla f(x^k)$;
3. 若 $\|d^k\| \leq \varepsilon$, 则停止计算, x^k 为所求极值点; 否则, 求最优步长 λ_k

$$\text{使得 } f(x^k + \lambda_k d^k) = \min_{\lambda} f(x^k + \lambda d^k)。$$

4. 令 $x^{k+1} = x^k + \lambda_k d^k$, 令 $k := k + 1$, 转2。





矩阵计算与优化 (最优化--无约束优化)

例 1 用最速下降法求解： $\min f(x) = x_1^2 + 3x_2^2$, 设初始点为 $x^1 = (2, 1)^T$,
求迭代一次后的迭代点 x^2 。

解： $\because \nabla f(x) = (2x_1, 6x_2)^T$,

$$\therefore d^1 = -\nabla f(x^1) = (-4, -6)^T.$$

$$\therefore x^1 + \lambda d^1 = (2 - 4\lambda, 1 - 6\lambda)^T.$$

$$\text{令 } \varphi(\lambda) = f(x^1 + \lambda d^1) = (2 - 4\lambda)^2 + 3(1 - 6\lambda)^2,$$

$$\text{求解 } \min_{\lambda} \varphi(\lambda)$$

$$\text{令 } \varphi'(\lambda) = -8(2 - 4\lambda) - 36(1 - 6\lambda) = 0 \Rightarrow \lambda_1 = \frac{13}{62}$$

$$\therefore x^2 = x^1 + \lambda_1 d^1 = \left(\frac{36}{31}, \frac{-8}{31}\right)^T$$





矩阵计算与优化 (最优化--无约束优化)

最速下降法的特点

1.性质. 设 $f(x)$ 有一阶连续偏导数, 若步长 λ_k 满足

$$f(x^k + \lambda_k d^k) = \min_{\lambda} f(x^k + \lambda d^k)$$

则有 $\nabla f(x^k + \lambda_k d^k)^T d^k = 0$ 。

证明: 令 $\varphi(\lambda) = f(x^k + \lambda d^k)$, 所以

$$\varphi'(\lambda) = \nabla f(x^k + \lambda d^k)^T d^k.$$

$$\because f(x^k + \lambda_k d^k) = \min_{\lambda} f(x^k + \lambda d^k)$$

$$\therefore \varphi'(\lambda_k) = \nabla f(x^k + \lambda_k d^k)^T d^k = 0.$$

注: 因为梯度法的搜索方向 $d^{k+1} = -\nabla f(x^k + \lambda_k d^k)$, 所以

$$(d^{k+1})^T d^k = 0 \Rightarrow d^{k+1} \perp d^k.$$






矩阵计算与优化（最优化--无约束优化）

最速下降法的锯齿现象

在极小点附近，目标函数可以用二次函数近似，其等值面近似椭球面。





矩阵计算与优化（最优化--无约束优化）

特点：线性收敛，易产生扭摆现象而造成早停。

（当 $x^{(k)}$ 距最优点较远时，速度快，而接近最优点时，速度下降）

原因：

$$f(x) = f(x^{(k)}) + \nabla f(x^{(k)})^T (x - x^{(k)}) + o\|(x - x^{(k)})^2\|$$

当 $x^{(k)}$ 接近极小点时 $\nabla f(x^{(k)}) \rightarrow 0$ ，于是高阶项 $o\|(x - x^{(k)})\|$ 的影响可能超过 $\nabla f(x^{(k)})^T (x - x^{(k)})$ 。

如果用 $f(x)$ 的Taylor展开近似计算？—— 牛顿法





Newton 法

问题

$$\min_{x \in R^n} f(x)$$

$f(x)$ 是 R^n 上二次连续可微函数

$$\text{即 } f(x) \in C^2(R^n)$$

用 $f(x)$ 的 Taylor 展开近似计算





矩阵计算与优化 (最优化--无约束优化)

算法思想

$$\mathbf{x}^0 \rightarrow \mathbf{x}^1 \rightarrow \cdots \rightarrow \mathbf{x}^k \rightarrow \mathbf{x}^{k+1} \rightarrow \cdots$$

为了由 $\mathbf{x}^k$ 产生 $\mathbf{x}^{k+1}$, 用二次函数 $Q(\mathbf{x})$ 近似 $f(\mathbf{x})$ 。

$$f(\mathbf{x}) \approx Q(\mathbf{x}) = f(\mathbf{x}^k) + \nabla f(\mathbf{x}^k)^T (\mathbf{x} - \mathbf{x}^k) +$$

$$+ \frac{1}{2} (\mathbf{x} - \mathbf{x}^k)^T \nabla^2 f(\mathbf{x}^k) (\mathbf{x} - \mathbf{x}^k)$$

$$Q(\mathbf{x}) = f(\mathbf{x}^k) + \mathbf{g}_k^T \cdot (\mathbf{x} - \mathbf{x}^k) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^k)^T \mathbf{G}_k (\mathbf{x} - \mathbf{x}^k)$$

其中 $\mathbf{g}_k = \nabla f(\mathbf{x}^k)^T$, $\mathbf{G}_k = \nabla^2 f(\mathbf{x}^k)$ 。

两边对 $\mathbf{x}$ 求导, 则: $\nabla Q(\mathbf{x}) = \mathbf{g}_k + \mathbf{G}_k (\mathbf{x} - \mathbf{x}^k) = \mathbf{0}$





矩阵计算与优化 (最优化--无约束优化)

$$\nabla Q(x) = g_k + G_k(x - x^k) = 0$$

若Hesse矩阵 G_k 正定, 即 $G_k > 0$,

则 $G_k^{-1} > 0$, 此时有

$$x^{k+1} = x^k - G_k^{-1} g_k$$

这就是Newton迭代公式。

比较迭代公式 $x^{k+1} = x^k + \lambda_k d^k$, 有

$$d^k = -G_k^{-1} g_k, \quad \text{而} \quad \lambda_k = 1。$$





矩阵计算与优化 (最优化--无约束优化)

算法步骤

step1. 给定初始点 x^0 , 精度 $\varepsilon > 0, k := 0$

step2. 计算 $g_k = \nabla f(x^k)$ 和 $G_k = \nabla^2 f(x^k)$

当 G_k 可逆时, $x^{k+1} = x^k - G_k^{-1} g_k$ 。

step3. 由方程组 $\nabla Q(x) = g_k + G_k(x - x^k) = 0$ 解出 x^{k+1}

step4. 若 $\|\nabla f(x^{k+1})\| < \varepsilon$, 停止, $x^* = x^{k+1}$;


否则, 令 $k := k + 1$, 转 step 2。





矩阵计算与优化 (最优化--无约束优化)

➤ 算法框图





矩阵计算与优化 (最优化--无约束优化)

例1: 求解 $\min f(x) = \int_0^x \arctan t dt$

解: 取 $x^0=1$, 计算:

$$\nabla f(x) = f'(x) = \arctan x, \nabla^2 f(x) = f''(x) = \frac{1}{1+x^2}$$

迭代过程如下表:

$$\text{计算 } x^{k+1} = x^k - \frac{\nabla f(x^k)}{\nabla^2 f(x^k)}$$

k	x^k	$f'(x^k)$	$f''(x^k)$
0	1	0.7854	0.5000
1	-0.5708	-0.5178	1.3258
2	0.1169	0.1163	1.137
3	-0.001061		





矩阵计算与优化 (最优化--无约束优化)

例 2: 用 Newton 法求解, $\min f(x) = x_1^4 + 25x_2^4 + x_1^2x_2^2$, 选取 $x^0 = (2,2)^T$,

$\varepsilon = 10^{-6}$ 。

$$\nabla f(x) = [4x_1^3 + 2x_1x_2^2 \quad 100x_2^3 + 2x_1^2x_2]^T, \nabla^2 f = \begin{bmatrix} 12x_1^2 + 2x_2^2 & 4x_1x_2 \\ 4x_1x_2 & 300x_2^2 + 4x_1^2 \end{bmatrix}$$

(ii) 编写M文件nwfun.m如下:

```
function [f,df,d2f]=nwfun(x);  
f=x(1)^4+25*x(2)^4+x(1)^2*x(2)^2;  
df(1)=4*x(1)^3+2*x(1)*x(2)^2;  
df(2)=100*x(2)^3+2*x(1)^2*x(2);  
d2f(1,1)=12*x(1)^2+2*x(2)^2;  
d2f(1,2)=4*x(1)*x(2);  
d2f(2,1)=d2f(1,2);  
d2f(2,2)=300*x(2)^2+4*x(1)^2;
```

编写M文件nwfun2.m:

```
x=[2;2];  
[f0,g1,g2]=nwfun(x)  
while norm(g1)>0.00001  
    i=1:3  
    p=-inv(g2)*g1',p=p/norm(p)  
    t=1.0,f=detaf(x+t*p)  
    while f>f0  
        t=t/2,f=detaf(x+t*p), %步长减半  
    end  
    x=x+t*p  
    [f0,g1,g2]=nwfun(x)  
end
```





矩阵计算与优化 (最优化--无约束优化)

4. 算法特点

$$\frac{\|x^{k+1} - x^*\|}{\|x^k - x^*\|^2} < \lambda, \quad \lambda > 0.$$

- 收敛速度快，为二阶收敛。
- 初始点要选在最优点附近。

$$x^{k+1} = x^k - G_k^{-1} g_k$$

5. 存在缺点及修正

- (1) $f(x^{k+1}) < f(x^k)$?
- (2) 初始点的选取困难，甚至无法实施。
- (3) G_k^{-1} 的存在性和计算量问题。





问题一：如何使得 $f(x^{k+1}) < f(x^k)$?

在Newton法中，有

$$x^{k+1} = x^k - G_k^{-1} g_k = x^k + d^k$$

当 $G_k > 0$ 时, 有 $\nabla f(x^k)^T d^k = -\nabla f(x^k)^T G_k^{-1} g_k = -g_k^T G_k^{-1} g_k < 0$,

$\therefore$ 当 $G_k > 0$ 时, d^k 是下降方向。

如果对Newton法稍作修正:

$$x^{k+1} = x^k + \lambda_k d^k$$

$$t_k : f(x^k + \lambda_k d^k) = \min_t f(x^k + \lambda d^k)$$

则有: $f(x^{k+1}) < f(x^k)$ 。





问题二：如何克服初始点问题和二阶偏导矩阵可逆问题

拟牛顿法(变尺度法)

一、拟牛顿法的思想

1. 先考虑Newton迭代公式： $x^{k+1} = x^k - G_k^{-1} \nabla f(x^k)$

在Newton迭代公式中，如果我们用正定矩阵 H_k 替代 G_k^{-1} ，则有：

$$x^{k+1} = x^k - H_k \nabla f(x^k)$$

2. 考虑更一般的形式： $x^{k+1} = x^k - \lambda_k H_k \nabla f(x^k)$





矩阵计算与优化 (最优化--无约束优化)

$$x^{k+1} = x^k - \lambda_k H_k \nabla f(x^k)$$

$H_k \equiv I$ 时 $\Rightarrow$ 梯度法,

最速下降方向 $d^k = -\nabla f(x^k)$, 度量为 $\|x\| = \sqrt{x^T I x}$

$H_k = G_k^{-1}$ 时 $\Rightarrow$ Newton法

最速下降方向 $d^k = -G_k^{-1} \nabla f(x^k)$, 度量为 $\|x\| = \sqrt{x^T G_k^{-1} x}$

也称拟Newton法为变尺度算法。





3. 如何对 H_k 附加某些条件使得:

(1) 迭代公式具有下降性质 $\leftrightarrow H_k > 0$

(2) H_k 的计算量要小 $\leftrightarrow H_{k+1} = H_k + \Delta H_k$
($\Delta H_k = H_{k+1} - H_k$)

(3) 收敛速度要快 $\leftrightarrow H_k \approx G_k^{-1}$

如何保证 $H_k > 0$ 和 $H_k \approx G_k^{-1}$?

如何确定 ΔH_k ?





矩阵计算与优化 (最优化--无约束优化)

拟Newton条件 $\leftrightarrow H_k \approx G_k^{-1}$

分析 G_k^{-1} 需满足的条件, 并利用此条件确定 H_k 。

记 $g(x) = \nabla f(x)$, $g_k = \nabla f(x^k)$ $G_k = \nabla^2 f(x^k)$, 则因为

$$\begin{aligned} f(x) &\approx f(x^{k+1}) + \nabla f(x^{k+1})^T (x - x^{k+1}) \\ &\quad + \frac{1}{2} (x - x^{k+1})^T \nabla^2 f(x^{k+1}) (x - x^{k+1}) \end{aligned}$$

$$g(x) \approx g(x^{k+1}) + \nabla^2 f(x^{k+1}) (x - x^{k+1})$$

$$g_k \approx g_{k+1} + G_{k+1} (x^k - x^{k+1})$$

$G_{k+1}^{-1} (g_{k+1} - g_k) = x^{k+1} - x^k$, 这样我们想到

$$H_{k+1} (g_{k+1} - g_k) = x^{k+1} - x^k$$





记 $\Delta g_k = g_{k+1} - g_k$, $\Delta x_k = x^{k+1} - x^k$, 则有

拟Newton条件或拟Newton方程: $H_{k+1} \Delta g_k = \Delta x^k$.

二、拟Newton算法(变尺度法)的一般步骤:

Step 1. 给定初始点 x^0 , 正定矩阵 H_0 , 精度 $\varepsilon > 0$, $k := 0$

Step 2. 计算搜索方向 $d^k = -H_k \nabla f(x^k)$;

Step 3. 令 $x^{k+1} = x^k + \lambda_k d^k$,

其中 $t_k : f(x^k + \lambda_k d^k) = \min_{\lambda} f(x^k + \lambda d^k)$ 。





矩阵计算与优化 (最优化--无约束优化)

Step 4. 判断 x^{k+1} 是否满足终止准则:

yes: 计算 stop, 则 $x^* := x^{k+1}$

No : 转 step 5 .

Step 5. 令 $g_{k+1} = \nabla f(x^{k+1})$, $g_k = \nabla f(x^k)$,

$$\Delta g_k = \nabla f(x^{k+1}) - \nabla f(x^k) = g_{k+1} - g_k, \Delta x_k = x^{k+1} - x^k .$$

按照校正公式 $H_{k+1} = H_k + \Delta H_k$,

计算 H_{k+1} 使得 H_{k+1} 满足 拟Newton 条件

或拟Newton方程: $H_{k+1} \Delta g_k = \Delta x_k$.

令 $k =: k + 1$, 转 step 2.

问题: 如何确定一个合适的 H_k ?





DFP算法

一、DFP法的提出

- (1) 1959年Davidon首次提出
- (2) 1963年Fletcher和Powell做了改进
- (3) 多变量无约束优化问题的一个重要工作

二. 如何确定 H_k ? – 秩2校正法

$$\begin{aligned} H_{k+1} &= H_k + \Delta H_k \\ &= H_k + \alpha_k u_k u_k^T + \beta_k v_k v_k^T \end{aligned}$$

待定: $\alpha_k, \beta_k \in R, u_k, v_k \in R^n$





矩阵计算与优化 (最优化--无约束优化)

根据 拟Newton条件: $H_{k+1}\Delta g_k = \Delta x_k$, 我们有

$$(H_k + \alpha_k u_k u_k^T + \beta_k v_k v_k^T) \Delta g_k = \Delta x_k$$

$$\text{即: } \alpha_k u_k u_k^T \Delta g_k + \beta_k v_k v_k^T \Delta g_k = \Delta x_k - H_k \Delta g_k$$

满足上述方程的解很多, 我们可以如下确定一组解:

$$\alpha_k u_k u_k^T \Delta g_k = \Delta x_k$$

$$\beta_k v_k v_k^T \Delta g_k = -H_k \Delta g_k$$

这样, 我们可以取:

$$u_k = \Delta x_k, \quad \alpha_k u_k^T \Delta g_k = 1,$$

$$v_k = H_k \Delta g_k, \quad \beta_k v_k^T \Delta g_k = -1。$$





矩阵计算与优化 (最优化--无约束优化)

即: $u_k = \Delta x_k, \quad \alpha_k = \frac{1}{\Delta x_k^T \Delta g_k},$

$$v_k = H_k \Delta g_k, \quad \beta_k = -\frac{1}{\Delta g_k^T H_k \Delta g_k}.$$

根据上述推导, 我们能够得到 H_k 的DFP的校正公式:

$$H_{k+1} = H_k + \frac{\Delta x_k^T \Delta x_k}{\Delta x_k^T \Delta g_k} - \frac{H_k \Delta g_k \Delta g_k^T H_k}{\Delta g_k^T H_k \Delta g_k} \quad \text{-- DFP校正公式}$$

性质: $H_0 > 0 \Rightarrow H_k > 0.$





三、DFP算法的步骤

将拟牛顿法的第 5 步：

按照校正公式 $H_{k+1} = H_k + \Delta H_k$,

计算 H_{k+1} 使得 H_{k+1} 满足 拟Newton 条件

或拟Newton 方程: $H_{k+1} \Delta g_k = \Delta x_k$ 。

令 $k := k + 1$, 转 step 2.

改为：

Step 5. 按照 DFP 的校正公式：

$$H_{k+1} = H_k + \frac{\Delta x_k^T \Delta x_k}{\Delta x_k^T \Delta g_k} - \frac{H_k \Delta g_k \Delta g_k^T H_k}{\Delta g_k^T H_k \Delta g_k}$$


计算 H_k , $k := k + 1$, 转 step 2.





矩阵计算与优化（最优化--无约束优化）

四、变尺度法算法框图：





矩阵计算与优化 (最优化--无约束优化)

五 变尺度算法的校正公式

一般的变尺度算法主要是Huang族公式:

$$H_{k+1} = H_k + \Delta x_k u_k^T + H_k \Delta g_k v_k^T$$

其中:

$$u_k = a_k \Delta x_k + b_k H_k^T \Delta g_k$$

$$v_k = c_k \Delta x_k + d_k H_k^T \Delta g_k$$

且满足:

$$u_k^T \Delta g_k = \omega$$

$$v_k^T \Delta g_k = -1$$

这个公式含有5个参数

$$(a_k, b_k, c_k, d_k, \omega)$$





矩阵计算与优化 (最优化--无约束优化)

但有2个关系式，故有3个独立参数
较重要的三种公式是：

- (i) 令 $\omega = 1$, $c_k = b_k = 0$, 即DFP公式。
- (ii) 令 $\omega = 1$, $b_k = c_k$, 即Broyden族公式。
- (iii) 令 $\omega = 1$, $b_k = c_k$, $d_k = 0$, 即得重要的
BFGS公式：

$$H_{k+1} = H_k + \frac{\beta_k \Delta x_k \Delta x_k^T - H_k \Delta g_k \Delta x_k^T - \Delta x_k \Delta g_k^T H_k}{\Delta x_k^T \Delta g_k}$$

$$\beta_k = 1 + \frac{\Delta g_k^T H_k \Delta g_k}{\Delta x_k^T \Delta g_k}$$

它是当前变度量方法中数值稳定性最好的。





矩阵计算与优化 (最优化--无约束优化)

例 用DFP算法求解 $\min f(x) = x_1^2 + 4x_2^2$, 初始点 $x^0 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$.

解 取 $H_0 = I$, $\nabla f(x) = \begin{pmatrix} 2x_1 \\ 8x_2 \end{pmatrix}$.

第一步DFP算法与梯度法相同: 因为 $x^0 - \lambda \nabla f(x^0) = \begin{pmatrix} 1-2t \\ 1-8t \end{pmatrix}$,

$$f(x^0 - t_0 \nabla f(x^0)) = \min f(x^0 - \lambda \nabla f(x^0)) = (1-2t)^2 + 4(1-8t)^2$$

解得 $\lambda_0 = 0.13$, 所以 $x^1 = \begin{pmatrix} 0.73846 \\ -0.04616 \end{pmatrix}$.

$$\therefore \Delta x_0 = x^1 - x^0 = \begin{pmatrix} -0.26154 \\ -1.04616 \end{pmatrix},$$





矩阵计算与优化（最优化--无约束优化）

$$\Delta g_0 = \nabla f(x^1) - \nabla f(x^0) = g_1 - g_0 = \begin{pmatrix} -0.52308 \\ -8.36923 \end{pmatrix}。$$

按照DFP的校正公式：

$$H_1 = H_0 + \frac{\Delta x_0^T \Delta x_0}{\Delta x_0^T \Delta g_0} - \frac{H_0 \Delta g_0 \Delta g_0^T H_0}{\Delta g_0^T H_0 \Delta g_0} = \begin{pmatrix} 1.00380 & -0.03149 \\ -0.03149 & 0.12697 \end{pmatrix}。$$

$$\therefore \text{搜索方向 } d^1 = -H_1 \nabla f(x^1) = \begin{pmatrix} -1.49416 \\ 0.09340 \end{pmatrix}。$$

$$x^2 = x^1 + \lambda_1 d^1 = x^1 + 0.49423 d^1 = \begin{pmatrix} 0.0000 \\ 0.0000 \end{pmatrix}。$$

因为 $\nabla f(x^2) = 0$ ，所以 x^2 是极小点。





感谢聆听!