



# 矩阵计算与优化

(最优化--随机与多目标优化)

授课人：陈硕



南京大學  
NANJING UNIVERSITY



## 大纲

- 随机优化
- 多目标优化





## 梯度下降法

梯度下降方法基于以下的观察：如果实值函数 $F(\mathbf{x})$ 在点 $\mathbf{a}$ 处可微且有定义，那么函数 $F(\mathbf{x})$ 在 $\mathbf{a}$ 点沿着梯度相反的方向 $-\nabla F(\mathbf{a})$ 下降最多。

因而，如果

$$\mathbf{b} = \mathbf{a} - \gamma \nabla F(\mathbf{a})$$


对于一个足够小数值 $\gamma > 0$ 时成立，那么 $F(\mathbf{a}) \geq F(\mathbf{b})$ 。

考虑到这一点，我们可以从函数 $F$ 的局部极小值的初始估计 $\mathbf{x}_0$ 出发，并考虑如下序列 $\mathbf{x}_0, \mathbf{x}_1, \mathbf{x}_2, \dots$ 使得

$$\mathbf{x}_{n+1} = \mathbf{x}_n - \gamma_n \nabla F(\mathbf{x}_n), \quad n \geq 0.$$

因此可得到

$$F(\mathbf{x}_0) \geq F(\mathbf{x}_1) \geq F(\mathbf{x}_2) \geq \dots,$$






## 梯度下降法

梯度下降法处理一些复杂的非线性函数会出现问题，例如Rosenbrock函数

$$f(x, y) = (1 - x)^2 + 100(y - x^2)^2.$$

其最小值在 $(x, y) = (1, 1)$ 处，数值为 $f(x, y) = 0$ 。但是此函数具有狭窄弯曲的山谷，最小值 $(x, y) = (1, 1)$ 就在这些山谷之中，并且谷底很平。优化过程是之字形的向极小值点靠近，速度非常缓慢。



(c) 2006 P. A. Simionescu

不依赖初始点，理想情况下收敛速度： $O(1/N)$





### 梯度下降法 理论收敛性

#### 梯度法在凸函数上的收敛性

假设  $f(x)$  为凸函数，是梯度L利普西茨连续，最优值  $f^* = \inf_x f(x)$  可达，且步长  $\alpha \in (0, \frac{1}{L})$

，则梯度下降法得到的点列  $\{x^k\}$  的函数值列

$\{f_k\}$  收敛到  $f^*$ ，且收敛速度为  $O(\frac{1}{k})$





## 梯度下降法 收敛前提 (梯度Lipschitz连续的二次有界性)

条件:  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  梯度  $L$ -Lipschitz

$$\|\nabla f(\mathbf{u}) - \nabla f(\mathbf{v})\| \leq L\|\mathbf{u} - \mathbf{v}\|$$

求证:

$$f(\mathbf{y}) \leq f(\mathbf{x}) + \nabla f(\mathbf{x})^\top (\mathbf{y} - \mathbf{x}) + \frac{L}{2} \|\mathbf{y} - \mathbf{x}\|^2$$

证明

令  $\mathbf{d} = \mathbf{y} - \mathbf{x}$ , 设  $\varphi(t) = f(\mathbf{x} + t\mathbf{d})$ ,  $t \in [0, 1]$ , 则

$$\varphi'(t) = \nabla f(\mathbf{x} + t\mathbf{d})^\top \mathbf{d}$$

由微积分基本定理:

$$f(\mathbf{y}) - f(\mathbf{x}) = \int_0^1 \nabla f(\mathbf{x} + t\mathbf{d})^\top \mathbf{d} dt$$

变形:

$$f(\mathbf{y}) - f(\mathbf{x}) - \nabla f(\mathbf{x})^\top \mathbf{d} = \int_0^1 [\nabla f(\mathbf{x} + t\mathbf{d}) - \nabla f(\mathbf{x})]^\top \mathbf{d} dt$$

结合柯西不等式与Lipschitz 条件:

$$\begin{aligned} [\nabla f(\mathbf{x} + t\mathbf{d}) - \nabla f(\mathbf{x})]^\top \mathbf{d} &\leq \|\nabla f(\mathbf{x} + t\mathbf{d}) - \nabla f(\mathbf{x})\| \cdot \|\mathbf{d}\| \\ &\leq Lt\|\mathbf{d}\|^2 \end{aligned}$$

积分放缩:

$$f(\mathbf{y}) - f(\mathbf{x}) - \nabla f(\mathbf{x})^\top \mathbf{d} \leq \int_0^1 Lt\|\mathbf{d}\|^2 dt = \frac{L}{2} \|\mathbf{d}\|^2$$

代入  $\mathbf{d} = \mathbf{y} - \mathbf{x}$ , 得

$$f(\mathbf{y}) \leq f(\mathbf{x}) + \nabla f(\mathbf{x})^\top (\mathbf{y} - \mathbf{x}) + \frac{L}{2} \|\mathbf{y} - \mathbf{x}\|^2$$



## 梯度下降法 理论收敛性（convex case）

由梯度Lipschitz连续性的二次有界性

$$\begin{aligned} f_{k+1} &= f(x_k - \alpha \nabla f(x_k)) \\ &\leq f(x_k) - \alpha \|\nabla f(x_k)\|^2 + \frac{L\alpha^2}{2} \|\nabla f(x_k)\|^2 \\ &= f(x_k) - \alpha \left(1 - \frac{\alpha L}{2}\right) \|\nabla f(x_k)\|^2 \end{aligned}$$

由alpha范围和凸函数的梯度性质

$$\begin{aligned} f_{k+1} &\leq f(x_k) - \frac{\alpha}{2} \|\nabla f(x_k)\|^2 \\ &\leq f^* + \nabla f(x_k)^\top (x_k - x^*) - \frac{\alpha}{2} \|\nabla f(x_k)\|^2 \\ &= f^* + \frac{1}{2\alpha} (\|x_k - x^*\|^2 - \|x_k - x^* - \alpha \nabla f(x_k)\|^2) \\ &= f^* + \frac{1}{2\alpha} (\|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2) \end{aligned}$$

首尾连通、多次累加求和

$$f_{k+1} - f^* \leq \frac{1}{2\alpha} (\|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2)$$


$$\begin{aligned} \sum_{k=0}^n (f_{k+1} - f^*) &\leq \frac{1}{2\alpha} (\|x_0 - x^*\|^2 - \|x_{n+1} - x^*\|^2) \\ &= \frac{1}{2\alpha} \|x_0 - x^*\|^2 \end{aligned}$$

$$f_{n+1} - f^* \leq \frac{1}{n+1} \sum_{k=0}^n (f_{k+1} - f^*) \leq \frac{1}{2(n+1)\alpha} \|x_0 - x^*\|^2$$





## 梯度下降法（步长的重要性）





### 最速梯度下降法（增加一维搜索）

第 1 步 选取初始点  $x^0$ ，给定终止误差  $\varepsilon > 0$ ，令  $k := 0$ ；

第 2 步 计算  $\nabla f(x^k)$ ，若  $\|\nabla f(x^k)\| \leq \varepsilon$ ，停止迭代.输出  $x^k$ . 否则进行第三步；

第 3 步 取  $p^k = -\nabla f(x^k)$ ；

第 4 步 进行一维搜索，求  $t_k$ ，使得

$$f(x^k + t_k p^k) = \min_{t \geq 0} f(x^k + t p^k)$$

令  $x^{k+1} = x^k + t_k p^k$ ， $k := k + 1$ ，转第 2 步。





### 最速梯度下降法（增加一维搜索）

方法一：采用任一种一维寻优法 *例如黄金分割搜索法*

此时的  $f(x^k - t\nabla f(x^k))$  已成为步长  $t$  的一元函数，故可用任何一种一维寻优法求出  $t_k$ ，即

$$f(x^{k+1}) = f(x^k - t_k \nabla f(x^k)) = \min_t f(x^k - t \nabla f(x^k))$$

方法二：微分法

因为

$$\varphi(t) = f(x^k - t \nabla f(x^k))$$

所以，一些简单情况下，可令

$$\varphi'(t) = 0$$

以解出近似最优步长  $t_k$  的值。



## 最速梯度下降法 (一维搜索的闭解案例)

例 1  $\min f(x) = x_1 - x_2 + 2x_1^2 + 2x_1x_2 + x_2^2$  给定初始点  $X^{(1)} = (0,0)^T$

解: 目标函数  $f(x)$  的梯度  $\nabla f(x) = \begin{bmatrix} \frac{\partial f(x)}{\partial x_1} \\ \frac{\partial f(x)}{\partial x_2} \end{bmatrix} = \begin{bmatrix} 1 + 4x_1 + 2x_2 \\ -1 + 2x_1 + 2x_2 \end{bmatrix}$

$\nabla f(X^{(1)}) = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$  令搜索方向  $d^{(1)} = -\nabla f(X^{(1)}) = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$  再从  $X^{(1)}$  出发, 沿  $d^{(1)}$  方向作一维寻优, 令

步长变量为  $\lambda$ , 最优步长为  $\lambda_1$ , 则有  $X^{(1)} + \lambda d^{(1)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} + \lambda \begin{bmatrix} -1 \\ 1 \end{bmatrix} = \begin{bmatrix} -\lambda \\ \lambda \end{bmatrix}$

故  $f(x) = f(X^{(1)} + \lambda d^{(1)}) = (-\lambda) - \lambda + 2(-\lambda)^2 + 2(-\lambda)\lambda + \lambda^2 = \lambda^2 - 2\lambda = \phi_1(\lambda)$

令  $\phi_1'(\lambda) = 2\lambda - 2 = 0$  可得  $\lambda_1 = 1$   $X^{(2)} = X^{(1)} + \lambda_1 d^{(1)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} + \begin{bmatrix} -1 \\ 1 \end{bmatrix} = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$  求出  $X^{(2)}$  点之后, 与

上类似地, 进行第二次迭代:  $\nabla f(X^{(2)}) = \begin{bmatrix} -1 \\ -1 \end{bmatrix}$  令  $d^{(2)} = -\nabla f(X^{(2)}) = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$





### 优化算法智能化的初步递进

- **梯度下降 → 随机梯度下降**





### 梯度下降 → 随机梯度下降

**随机梯度下降**（通常缩写为SGD）是一种迭代方法，用于优化具有适当平滑性质（例如可微分或次可微分）的目标函数。它可以被视为**梯度下降优化的随机近似**，因为它用实际梯度（根据整个数据集计算）的估计值（根据**随机选择的数据子集计算**）代替了实际梯度。尤其是在高维优化问题中，这可以减轻非常高的计算负担，并以**较低的收敛速度实现更快的迭代速度**。





### SGD的重要历史

1951 年，赫伯特·罗宾斯 (Herbert Robbins)和萨顿·蒙罗 (Sutton Monro)提出了最早的随机近似方法，早于随机梯度下降。一年后，在此基础上，杰克·基弗 (Jack Kiefer)和雅各布·沃尔福威茨 (Jacob Wolfowitz)发表了一种非常接近随机梯度下降的优化算法，使用中心差分作为梯度的近似值。后来在 20 世纪 50 年代，弗兰克·罗森布拉特 (Frank Rosenblatt)使用 SGD 来优化他的感知器模型，证实了随机梯度下降首次适用于神经网络。

反向传播算法最早于1986年被提出，当时随机梯度下降法被用于高效优化具有多个隐藏层的神经网络的参数。不久之后，另一项改进方法被开发出来：小批量梯度下降法，用小批量数据代替单个样本。1997 年，人们首次探索了使用此类小批量数据实现矢量化所带来的实际性能优势，为机器学习中的高效优化铺平了道路。截至 2023 年，这种小批量方法仍然是神经网络训练的标准，它平衡了随机梯度下降法和梯度下降法的优势。





### SGD的重要历史

到了 20 世纪 80 年代，动量已被引入，并于 1986 年被添加到 SGD 优化技术中。然而，这些优化技术假设超参数为常数，即固定的学习率和动量参数。在 2010 年代，应用每个参数都指定学习率的 SGD 的自适应方法相继出现，包括 2011 年的 AdaGrad（“自适应梯度”）和 2012 年的 RMSprop（“均方根传播”）。**2014 年，Adam（“自适应矩估计”）发布**，将 RMSprop 的自适应方法应用于动量；随后，Adam 的许多改进和分支被开发出来，例如 Adadelta、Adagrad、AdamW 和 Adamax。TensorFlow 和 PyTorch 是迄今为止最受欢迎的机器学习库，截至 2023 年，它们基本上只包含 Adam 衍生的优化器，以及 Adam 的前身，例如 RMSprop 和经典的 SGD。





### 梯度下降 → 随机梯度下降

待求解问题：

$$Q(w) = \frac{1}{n} \sum_{i=1}^n Q_i(w),$$

传统标准梯度下降（GD）：

$$w := w - \eta \nabla Q(w) = w - \frac{\eta}{n} \sum_{i=1}^n \nabla Q_i(w).$$

随机梯度下降（SGD）：


$$w := w - \eta \nabla Q_i(w).$$





### 梯度下降 → 随机梯度下降

- 选择参数的初始向量 $w$ 和学习率 $\eta$ 。
- 重复直到获得近似最小值：
  - 随机打乱训练集中的样本。
  - 为了 $i = 1, 2, \dots, n$ ，做：
    - $w := w - \eta \nabla Q_i(w)$ .



**注意：再小的步长也不一定能带来目标函数的严格下降！**





# 梯度下降 → 随机梯度下降

### 问题设定

- **任务**：二分类问题，预测患病概率。
- **模型**：逻辑回归（含偏置项）： $\hat{y} = \sigma(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$ ,

其中  $\sigma(z) = \frac{1}{1+e^{-z}}$  是 Sigmoid 函数。

- **损失函数**：交叉熵 + L2 正则化： $L = -\frac{1}{m} \sum_{i=1}^m [y_i \ln \hat{y}_i + (1 - y_i) \ln(1 - \hat{y}_i)] + \frac{\lambda}{2}(\theta_1^2 + \theta_2^2)$ 。

- **数据集**：3 个样本，每个样本 2 个特征： $X = \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 2 & 1 \end{bmatrix}, y = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$ 。

- **参数**：初始  $\theta_0 = 0, \theta_1 = 0, \theta_2 = 0$ ，学习率  $\eta = 0.01$ ，正则化系数  $\lambda = 0.1$ 。





### 梯度下降（具体计算）

#### 梯度推导（关键公式）

对  $\theta_0$  的梯度:  $\frac{\partial L}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i)$

对  $\theta_j$  ( $j = 1, 2$ ) 的梯度:  $\frac{\partial L}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i) x_{i,j} + \lambda \theta_j$





# 矩阵计算与优化 (最优化--随机与多目标优化)

## 第1次迭代

### 1. 计算所有样本的预测值:

- 样本 1:  $z_1 = 0 + 0 \times 1 + 0 \times 2 = 0, \hat{y}_1 = \sigma(0) = 0.5$
- 样本 2:  $z_2 = 0 + 0 \times 3 + 0 \times 4 = 0, \hat{y}_2 = 0.5$
- 样本 3:  $z_3 = 0 + 0 \times 2 + 0 \times 1 = 0, \hat{y}_3 = 0.5$

### 2. 计算梯度:

- $\frac{\partial L}{\partial \theta_0} = \frac{1}{3} [(0.5 - 1) + (0.5 - 0) + (0.5 - 1)] = \frac{1}{3} (-0.5 + 0.5 - 0.5) = -\frac{0.5}{3} \approx -0.1667$
- $\frac{\partial L}{\partial \theta_1} = \frac{1}{3} [(0.5 - 1) \times 1 + (0.5 - 0) \times 3 + (0.5 - 1) \times 2] + 0.1 \times 0 = \frac{1}{3} (-1 + 1.5 - 1) = -\frac{0.5}{3} \approx -0.1667$
- $\frac{\partial L}{\partial \theta_2} = \frac{1}{3} [(0.5 - 1) \times 2 + (0.5 - 0) \times 4 + (0.5 - 1) \times 1] + 0.1 \times 0 = \frac{1}{3} (-1 + 2 - 0.5) = \frac{0.5}{3} \approx 0.1667$

$$\theta_0 = 0 - 0.01 \times (-0.1667) \approx 0.0017,$$

### 3. 参数更新: $\theta_1 = 0 - 0.01 \times (-0.1667) \approx 0.0017,$

$$\theta_2 = 0 - 0.01 \times (0.1667) \approx -0.0017.$$





### 梯度下降（具体计算）

#### 第 $n$ 次迭代（理论趋势）

- **梯度稳定性**：每次梯度是所有样本的精确平均，方向稳定，无随机噪声。
- **收敛性**：若学习率合适（此处  $\eta = 0.01$  较小），参数会单调收敛至最优解，无 SGD 的震荡现象。
- **计算量**：每次迭代需计算所有样本的梯度，时间复杂度为  $O(m)$ ，本例中  $m = 3$  可忽略，但大数据集下计算成本高。





# 同问题，使用随机梯度下降

### 问题设定

- **任务**：二分类问题，预测患病概率。
- **模型**：逻辑回归（含偏置项）： $\hat{y} = \sigma(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$ ,

其中  $\sigma(z) = \frac{1}{1+e^{-z}}$  是 Sigmoid 函数。

- **损失函数**：交叉熵 + L2 正则化： $L = -\frac{1}{m} \sum_{i=1}^m [y_i \ln \hat{y}_i + (1 - y_i) \ln(1 - \hat{y}_i)] + \frac{\lambda}{2}(\theta_1^2 + \theta_2^2)$ 。

- **数据集**：3 个样本，每个样本 2 个特征： $X = \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 2 & 1 \end{bmatrix}, y = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$ 。

- **参数**：初始  $\theta_0 = 0, \theta_1 = 0, \theta_2 = 0$ ，学习率  $\eta = 0.01$ ，正则化系数  $\lambda = 0.1$ 。





## 随机梯度下降（具体计算）

第1次迭代：选择样本1 ( $x_1=1, x_2=2, y=1$ )

1. 预测值计算：  $z = 0 + 0 \times 1 + 0 \times 2 = 0, \hat{y} = \sigma(0) = 0.5$ 。

2. 梯度计算：

◦ 交叉熵梯度：  $\frac{\partial L}{\partial \theta_0} = \frac{1}{m}(\hat{y} - y) = \frac{1}{3}(0.5 - 1) = -0.1667$ ,

$$\frac{\partial L}{\partial \theta_1} = \frac{1}{m}(\hat{y} - y)x_1 + \lambda\theta_1 = \frac{1}{3}(-0.5) \times 1 + 0.1 \times 0 = -0.1667,$$

$$\frac{\partial L}{\partial \theta_2} = \frac{1}{m}(\hat{y} - y)x_2 + \lambda\theta_2 = \frac{1}{3}(-0.5) \times 2 + 0 = -0.3333。$$

◦ 正则化项梯度：  $\frac{\partial L}{\partial \theta_1}$ （正则化）  $= \lambda\theta_1 = 0$ ,  $\frac{\partial L}{\partial \theta_2}$ （正则化）  $= \lambda\theta_2 = 0$ 。

3. 参数更新：  $\theta_0 = 0 - 0.01 \times (-0.1667) = 0.0017$ ,  $\theta_1 = 0 - 0.01 \times (-0.1667) = 0.0017$ ,

$$\theta_2 = 0 - 0.01 \times (-0.3333) = 0.0033。$$





### 随机梯度下降（具体计算）

第 2 次迭代：选择样本 3 ( $x_1=2, x_2=1, y=1$ )

1. 预测值计算： $z = 0.0017 + 0.0017 \times 2 + 0.0033 \times 1 \approx 0.0084$ ,  $\hat{y} = \sigma(0.0084) \approx 0.5021$ 。

2. 梯度计算：

◦ 交叉熵梯度： $\frac{\partial L}{\partial \theta_0} = \frac{1}{3}(0.5021 - 1) \approx -0.1659$ ,

$$\frac{\partial L}{\partial \theta_1} = \frac{1}{3}(-0.4979) \times 2 + 0.1 \times 0.0017 \approx -0.3319 + 0.0002 = -0.3317,$$

$$\frac{\partial L}{\partial \theta_2} = \frac{1}{3}(-0.4979) \times 1 + 0.1 \times 0.0033 \approx -0.1659 + 0.0003 = -0.1656.$$

3. 参数更新： $\theta_0 \approx 0.0017 - 0.01 \times (-0.1659) \approx 0.0033$ ,

$$\theta_1 \approx 0.0017 - 0.01 \times (-0.3317) \approx 0.0050, \theta_2 \approx 0.0033 - 0.01 \times (-0.1656) \approx 0.0049.$$





### 随机梯度下降（具体计算）

第 3 次迭代：选择样本 2 ( $x_1=3, x_2=4, y=0$ )

1. 预测值计算：  $z = 0.0033 + 0.0050 \times 3 + 0.0049 \times 4 \approx 0.0033 + 0.015 + 0.0196 = 0.0379$ ,

$$\hat{y} = \sigma(0.0379) \approx 0.5095.$$

2. 梯度计算：

◦ 交叉熵梯度：  $\frac{\partial L}{\partial \theta_0} = \frac{1}{3}(0.5095 - 0) \approx 0.1698$ ,

$$\frac{\partial L}{\partial \theta_1} = \frac{1}{3}(0.5095) \times 3 + 0.1 \times 0.0050 \approx 0.5095 + 0.0005 = 0.5100,$$

$$\frac{\partial L}{\partial \theta_2} = \frac{1}{3}(0.5095) \times 4 + 0.1 \times 0.0049 \approx 0.6793 + 0.0005 = 0.6798.$$

3. 参数更新：  $\theta_0 \approx 0.0033 - 0.01 \times 0.1698 \approx 0.0016$ ,  $\theta_1 \approx 0.0050 - 0.01 \times 0.5100 \approx -0.0001$ ,

$$\theta_2 \approx 0.0049 - 0.01 \times 0.6798 \approx -0.0019.$$





### 梯度下降 → 随机梯度下降 (理论收敛性)

**Theorem 2.** We assume that function  $\mathcal{F}(\varphi)$  has a  $\delta$ -bounded gradient ( $\|\nabla \mathcal{F}(\varphi)\|_2 < \delta$ ) and let  $\eta = \sqrt{2(\mathcal{F}(\varphi^{(0)}) - \mathcal{F}(\varphi^*)) / (S\delta^2 T)}$ , and then for iteration points in Algorithm 1 we have  $\min_{0 \leq t \leq T} \mathbb{E}[\|\nabla \mathcal{F}(\varphi^{(t)})\|_2] \leq \sqrt{2S\Delta\mathcal{F}/T}\delta$ , where  $\Delta\mathcal{F} = \mathcal{F}(\varphi^{(0)}) - \mathcal{F}(\varphi^*)$  and  $S > 0$  is a Lipschitz constant such that  $\|\nabla \mathcal{F}(\varphi) - \nabla \mathcal{F}(\varphi')\|_2 \leq S\|\varphi - \varphi'\|_2$ .

$\sqrt{1/T}$  的收敛速率!

S. Chen, et al., Robust Similarity Learning with Difference Alignment Regularization, ICLR 2024

S. J Reddi, et al., Stochastic variance reduction for nonconvex optimization, ICML 2016





## 梯度下降 → 随机梯度下降（理论收敛性）

*Proof.* Firstly, by using the Lipschitz continuity of  $\mathcal{F}(\varphi)$  we have that

$$\begin{aligned}
 & \mathbb{E}[\mathcal{F}(\varphi^{(t+1)})] - \mathbb{E}[\mathcal{F}(\varphi^{(t)})] && \text{二次有界性} \\
 & \leq \mathbb{E}[\|\nabla \mathcal{F}(\varphi^{(t+1)}) - (\varphi^{(t+1)} - \varphi^{(t)})\|_2^2 + S/2\|\varphi^{(t+1)} - \varphi^{(t)}\|_2^2] \\
 & \leq -\eta_t \mathbb{E}[\|\nabla \mathcal{F}(\varphi^{(t)})\|_2^2] + (S\eta_t^2/2)\mathbb{E}[\|\nabla \mathcal{F}_{b_i}(\varphi^{(t)})\|_2^2] \\
 & \leq -\eta_t \mathbb{E}[\|\nabla \mathcal{F}(\varphi^{(t)})\|_2^2] + (S\eta_t^2/2)\delta^2, && \text{梯度有界性}
 \end{aligned} \tag{19}$$

where the second inequality follows from the fact that  $\varphi^{(t+1)}$  is updated by Algorithm 1. Then, we have that

$$\mathbb{E}[\|\nabla \mathcal{F}(\varphi^{(t+1)})\|_2^2] \leq (1/\eta_t)\mathbb{E}[\mathcal{F}(\varphi^{(t)}) - \mathcal{F}(\varphi^{(t+1)})] + (L\eta_t/2)\delta^2, \tag{20}$$

and thus

$$\begin{cases} \mathbb{E}[\|\nabla \mathcal{F}(\varphi^{(0)})\|_2^2] \leq (1/\eta_0)\mathbb{E}[\mathcal{F}(\varphi^{(0)}) - \mathcal{F}(\varphi^{(1)})] + (S\eta_0/2)\delta^2, \\ \mathbb{E}[\|\nabla \mathcal{F}(\varphi^{(1)})\|_2^2] \leq (1/\eta_1)\mathbb{E}[\mathcal{F}(\varphi^{(1)}) - \mathcal{F}(\varphi^{(2)})] + (S\eta_1/2)\delta^2, \\ \dots \\ \mathbb{E}[\|\nabla \mathcal{F}(\varphi^{(T-1)})\|_2^2] \leq (1/\eta_{T-1})\mathbb{E}[\mathcal{F}(\varphi^{(T-1)}) - \mathcal{F}(\varphi^{(T)})] + (S\eta_{T-1}/2)\delta^2. \end{cases} \tag{21}$$





## 梯度下降 → 随机梯度下降 (理论收敛性)

Finally, we combine all inequalities in the above Eq. (21) by letting  $\eta_0 = \eta_1 = \dots = \eta_{T-1} = \eta$ . Then we have

$$\begin{aligned}
 & \min_{0 \leq t \leq T-1} \mathbb{E}[\|\nabla \mathcal{F}(\varphi^{(t)})\|_2] \\
 & \leq \frac{1}{T} \sum_{t=0}^{T-1} \mathbb{E}[\|\nabla \mathcal{F}(\varphi^{(t)})\|_2] + (S\eta/2)\delta^2 \\
 & \leq \frac{1}{T\eta} \mathbb{E}[\mathcal{F}(\varphi^{(0)}) - \mathcal{F}(\varphi^{(t)})] + (S\eta/2)\delta^2 \\
 & \leq \frac{1}{T\eta} (\mathcal{F}(\varphi^{(0)}) - \mathcal{F}(\varphi^*)) + (S\eta/2)\delta^2 \\
 & \leq \frac{1}{\sqrt{T}} ((\mathcal{F}(\varphi^{(0)}) - \mathcal{F}(\varphi^*)) / c + (Sc/2)\delta^2),
 \end{aligned} \tag{22}$$

where  $c = \eta\sqrt{T}$ . We set  $c = \sqrt{2(\mathcal{F}(\varphi^{(0)}) - \mathcal{F}(\varphi^*)) / (S\delta^2)}$ , and we have

$$\min_{0 \leq t \leq T-1} \mathbb{E}[\|\nabla \mathcal{F}(\varphi^{(t)})\|_2] \leq \sqrt{2S(\mathcal{F}(\varphi^{(0)}) - \mathcal{F}(\varphi^*)) / T} \delta, \tag{23}$$

which completes the proof. □





## 梯度下降 → 随机梯度下降

| 特性     | 梯度下降 (GD)               | 随机梯度下降 (SGD)              |
|--------|-------------------------|---------------------------|
| 梯度计算   | 所有样本的平均梯度               | 单个样本的梯度                   |
| 参数更新方向 | 稳定 (基于全局平均信息)           | 随机 (基于单个样本噪声)             |
| 迭代路径   | 平滑, 无震荡                 | 波动大, 可能出现 震荡              |
| 收敛速度   | 初期可能较慢 (需计算全梯度), 后期稳定收敛 | 初期快 (单个样本更新灵活), 后期因噪声收敛变慢 |
| 适用场景   | 小数据集或内存可容纳全数据           | 大规模数据集 (每次计算量小)           |
| 正则化影响  | 梯度含全局平均正则化项             | 梯度含单个样本正则化项 (噪声更大)        |



## 大纲

- 随机优化
- 多目标优化





## 矩阵计算与优化 (最优化--随机与多目标优化)

多目标规划是数学规划的一个分支。

研究**多于一个的目标函数**在**给定区域**上的最优化。又称多目标最优化。  
通常记为

MOP(multi-objective programming)。

在很多实际问题中，例如经济、管理、军事、科学和工程设计等领域，衡量一个方案的好坏往往难以用一个指标来判断，而需要用多个目标来比较，而这些目标有时不甚协调，甚至是矛盾的。因此有许多学者致力于这方面的研究。

1896年法国**经济学家 V. 帕雷托**最早研究不可比较目标的优化问题，之后，J.冯·诺伊曼、H.W.库恩、A.W.塔克、A.M.日夫里翁等**数学家**做了深入的探讨，但是**尚未有一个完全令人满意的定义**。





# 多目标决策简介

## 一、多目标决策问题实例

- 干部评估—德、才兼备
- 教师晋升—教学、科研、论文等
- 购买冰箱—价格、质量、耗电、品牌等
- 球员选择—技术、体能、经验、心理
- 找对象—容貌、学历、气质、家庭状况





## 多目标决策简介

### 二、多目标决策与多目标规划





## 多目标决策简介

### 三、多目标决策与单目标决策区别

- 点评价与向量评价

单目标: 方案 $d_j \leftarrow$ 评价值 $f(d_j)$

多目标: 方案 $d_j \leftarrow$ 评价向量 $(f_1(d_j), f_2(d_j), \dots, f_p(d_j))$

- 全序与半序: 方案 $d_i$ 与 $d_j$ 之间

单目标问题:  $d_i < d_j$ ;  $d_i = d_j$ ;  $d_i > d_j$

多目标问题: 除了这三种情况之外,还有一种情况是不可比较大小

- 决策者偏好: 多目标决策过程中, 反映决策者对目标的偏好。





## • 解概念区别

**单目标**决策的解只有一种（绝对）最优解；

**多目标**决策的解有下面三种情况：

### ➤ 绝对最优解

|       | 数学 | 外语 | 专业 | 解的类型  |
|-------|----|----|----|-------|
| $d_1$ | 80 | 75 | 88 |       |
| $d_2$ | 75 | 81 | 85 |       |
| $d_3$ | 76 | 78 | 89 |       |
| $d_4$ | 85 | 82 | 92 | 绝对最优解 |
| $d_5$ | 78 | 74 | 86 |       |





### • 解概念区别

**单目标**决策的解只有一种（绝对）最优解；

**多目标**决策的解有下面三种情况：

- 绝对最优解
- 劣解（如 $d_4$ 劣于 $d_1$ ）
- 有效解(pareto解)——非劣解

|       | 数学 | 外语 | 专业 | 解的类型 |
|-------|----|----|----|------|
| $d_1$ | 80 | 75 | 88 | 有效解  |
| $d_2$ | 75 | 81 | 85 | 有效解  |
| $d_3$ | 76 | 78 | 89 | 有效解  |
| $d_4$ | 78 | 74 | 86 | 劣解   |





## 多目标规划模型及其解的概念

### 一、多目标规划举例

**例1：【喜糖问题】** 设市场上有甲级糖及乙级糖，单价分别为4元/斤及2元/斤。今要筹办一桩喜事。“筹备小组”计划总花费不超过40元，糖的总斤数不少于10斤，甲级糖不少于5斤。问如何确定最佳的采购方案。

**决策变量：** 甲级糖数量为 $x_1$ ，乙级糖数量为 $x_2$

**约束条件：**

$$\begin{cases} 4x_1 + 2x_2 \leq 40 \\ x_1 + x_2 \geq 10 \\ x_1 \geq 5 \\ x_1 \geq 0, x_2 \geq 0 \end{cases}$$






### 多目标规划模型及其解的概念

**目标函数：**何为最佳？

(1) 总花费最小：  $\min f_1(x_1, x_2) = 4x_1 + 2x_2$

(2) 糖的总数量最大：  $\max f_2(x_1, x_2) = x_1 + x_2$

(3) 甲级糖的数量最大：  $\max f_3(x_1, x_2) = x_1$



**多目标规划问题**





### 多目标规划模型及其解的概念

**例2【投资决策问题】** 某投资开发公司拥有总资金 $A$ 万元，今有 $n(\geq 2)$ 个项目可供选择。设投资第 $i$  ( $i=1, \dots, n$ ) 个项目要用资金 $a_i$ 万元，预计可得到收益 $b_i$ 万元。问应如何使用总资金 $A$ 万元，才能得到最佳的经济效益？

解：令

$$x_i = \begin{cases} 1, & \text{投资第} i \text{个项目} \\ 0, & \text{不投资第} i \text{个项目} \end{cases}$$

约束条件：

$$\begin{cases} \sum_{i=1}^n a_i x_i \leq A \\ x_i = 0 \text{ 或 } 1 (i = 1, \dots, n) \end{cases}$$





### 多目标规划模型及其解的概念


**目标函数：**何为最佳的经济效益？

(1) 收益最大：

$$\max f_1(x_1, \dots, x_n) = \sum_{i=1}^n b_i x_i$$

(2) 投资最少：

$$\min f_2(x_1, \dots, x_n) = \sum_{i=1}^n a_i x_i$$



**多目标0-1规划问题**





## 多目标规划模型及其解的概念

### 二、多目标规划的模型

决策变量:  $x_1, \dots, x_n$

目标函数:  $\min f_1(x_1, \dots, x_n)$

$$\dots$$
$$\min f_p(x_1, \dots, x_n)$$

约束条件: 
$$\begin{cases} g_1(x_1, \dots, x_n) \geq 0 \\ \dots \\ g_m(x_1, \dots, x_n) \geq 0 \end{cases}$$





## 多目标规划模型及其解的概念

### 多目标规划模型的向量表达形式

记:  $X = (x_1, \dots, x_n)^T$

$$F(X) = (f_1(X), \dots, f_p(X))^T$$

$$R = \{X \mid g_i(X) \geq 0, \quad i = 1, \dots, m\}$$

则模型为:

$$(VMP) \begin{cases} \min (f_1(X), \dots, f_p(X)) \\ g_i(X) \geq 0, \quad i = 1, \dots, m \end{cases}$$

或

$$(VMP) \begin{cases} \min F(X) \\ X \in R \end{cases}$$

向量数学规划  
(Vector  
Mathematical  
Programming)





## 多目标规划模型及其解的概念

- 一、多目标规划举例
- 二、多目标规划的模型
- 三、多目标规划解的概念





## 多目标规划模型及其解的概念

### 三、多目标规划解的概念

先引进一些记号, 记

$$F^1 = (f_1^1, \dots, f_p^1) \in E_p$$

$$F^2 = (f_1^2, \dots, f_p^2) \in E_p$$

(1) " $<$ ":  $F^1 < F^2$  意味着向量  $F^1$  的每个分量都要严格的小于向量  $F^2$  对应的分量。即对于  $i = 1, \dots, p$ , 均有  $f_i^1 < f_i^2$ 。

(2) " $\leq$ ":  $F^1 \leq F^2$  意味着向量  $F^1$  的每个分量都要小于或等于向量  $F^2$  对应的分量。即对于  $i = 1, \dots, p$ , 均有  $f_i^1 \leq f_i^2$ 。

(3) " $\leq$ ":  $F^1 \leq F^2$  意味着向量  $F^1$  的每个分量都要小于或等于向量  $F^2$  对应的分量, 并且存在  $F^1$  的某一个分量要严格的小于向量  $F^2$  对应的分量。即对于  $i = 1, \dots, p$ , 均有  $f_i^1 \leq f_i^2$ , 并且要至少存在某个  $i_0 (1 \leq i_0 \leq p)$ , 有  $f_{i_0}^1 < f_{i_0}^2$ 。


可见, " $F^1 \leq F^2$ " 等价于 " $F^1 \leq F^2$ " 且 " $F^1 \neq F^2$ "。





## 多目标规划模型及其解的概念

**定义1** 设 $X^* \in R$ ，若对任意 $X \in R$ ，均有 $F(X^*) \leq F(X)$ ，则称 $X^*$ 为问题（VMP）的**绝对最优解**。其全体记为 $R^*_{ab}$ 。



绝对最优解示意图

**注：**绝对最优解往往不存在！






### 多目标规划模型及其解的概念

**定义2** 设  $X^0 \in R$ , 若存在另一个可行解  $X^1 \in R$ , 有  $F(X^1) \leq F(X^0)$ , 则称可行解  $X^0$  相对于  $X^1$  来说是**劣解**。

**注:** 决策中, 劣解不会被考虑!

**定义3** 设  $\bar{X} \in R$ , 若不存在  $X \in R$ , 使  $F(X) \leq F(\bar{X})$ , 则称  $\bar{X}$  为问题的**非劣解**, 又称**有效解**, 或**Pareto解**。其全体记为  $R_{pa}^*$ 。






## 多目标规划模型及其解的概念

**定义4** 设  $\bar{X} \in R$ , 若不存在  $X \in R$ , 使  $F(X) < F(\bar{X})$ , 则称  $\bar{X}$  为问题的**弱有效解**。其全体记为  $R_{wp}^*$ 。


**注：**有效解必是弱有效解。





## 多目标规划模型及其解的概念

两个目标的最大化问题：



劣解与有效解






## 多目标规划模型及其解的概念

### 多目标规划——解的关系

**定理1**  $R_{ab}^* = \bigcap_{i=1}^p R_i^*$ , 其中  $R_i^*$  为单目标  $f_i(X)$  上最优解集合。

**定理2**  $R_{ab}^* \subseteq R_{pa}^* \subseteq R_{wp}^* \subset R$





### 多目标规划模型及其解的概念

#### 多目标规划——解的关系

定理3  $R_i^* \subseteq R_{wp}^*$

定理4 若  $R_{ab}^* \neq \phi$ , 则

$$(1) R_{pa}^* = R_{ab}^* = \bigcap_{i=1}^p R_i^*; \quad (2) R_{wp}^* = \bigcup_{i=1}^p R_i^*$$






## 多目标规划模型及其解的概念

### 多目标规划——解的关系

例1 下图中， $R_1^* = \{x_1\}$ ， $R_2^* = \{x_2\}$ ，


$$R_{pa}^* = R_{wp}^* = [x_1, x_2]$$






## 多目标规划模型及其解的概念

### 多目标规划——解的关系



$$p=3 \quad R_{ab}^* = \varnothing$$



$$p=3 \quad R_{ab}^* \neq \varnothing$$





## 多目标规划

§ 1 多目标决策简介

§ 2 多目标规划模型及其解的概念

§ 3 多目标规划的解法





### 多目标规划的解法

- 求：有效解或弱有效解
- 方法分类
  - 评价函数法
  - 目标排序法
- 准备工作：目标函数规范化

$$f_i(X) = \frac{\bar{f}_i(X)}{\bar{f}_i}, \text{ 其中 } \bar{f}_i = \left| \max_{X \in R} \bar{f}_i(X) \right|$$





## 多目标规划的解法

### 一、评价函数法:

评价函数法就是利用一个复合函数:

$$h(F) = h(f_1, \dots, f_p)$$

把多目标问题(VMP)转化为单目标问题:

$$(P) \quad \min_{X \in R} h[F(X)]$$

然后来求解, 而单目标问题的解法我们是熟知的。问题是, 用评价函数 $h(F)$ 得到的 $(P)$ 的最优解 $\bar{X}$ 是否为原问题(VMP)的有效解或弱有效解? 因为若连弱有效解都不是, 那显然是不足取的。





### 多目标规划的解法

下面我们将指出，当评价函数 $h(F)$ 具有某种“单调性时”，是可以保证 $\bar{X} \in R_{pa}^*$ （或 $\bar{X} \in R_{wp}^*$ ）的。为此，先给出两个定义：

定义4 设 $h(F)$ 是定义在 $E_p$ 上的函数，若对于任意满足 $F^1 \leq F^2$ 的 $F^1 \in E_p$ ， $F^2 \in E_p$ ，均有：

$$h(F^1) < h(F^2)$$

则称 $h(F)$ 为严格单调函数。

定义5 设 $h(F)$ 是定义在 $E_p$ 上的函数，若对于任意满足 $F^1 < F^2$ 的 $F^1 \in E_p$ ， $F^2 \in E_p$ ，均有：

$$h(F^1) < h(F^2)$$

则称 $h(F)$ 为单调函数。





## 多目标规划的解法

定理6 若 $h(F)$ 为定义在 $E_p$ 上的严格单调函数, $\bar{X}$ 为规划问题

$$(p) \min_{X \in R} h[F(X)]$$

的最优解, 则 $\bar{X} \in R_{pa}^*$ 。

证: 用反证法。若 $\bar{X} \notin R_{pa}^*$ , 则存在 $Y \in R$ , 有 $F(Y) \leq F(\bar{X})$ , 由 $h(F)$ 的严格单调性, 有

$$h[F(Y)] < h[F(\bar{X})]$$

这与 $\bar{X}$ 为问题 $(p)$ 的最优解矛盾, 故 $\bar{X} \in R_{pa}^*$ 。

定理7 若 $h(F)$ 为定义在 $E_p$ 上的单调函数, $\bar{X}$ 为规划问题

$$(p) \min_{X \in R} h[F(X)]$$

的最优解, 则 $\bar{X} \in R_{wp}^*$ 。

证明方法与定理6雷同。





## 多目标规划的解法

### 一、评价函数法

#### 1. 线性加权和法

#### 2. 理想点法

#### 3. 目标规划法

### 二、目标排序法





### 多目标规划的解法

#### 1、线性加权和法

该方法就是取评价函数为各目标函数的线性加权和，

即

$$h(F) = \lambda_1 f_1 + \dots + \lambda_p f_p$$

其中 $\lambda_1, \dots, \lambda_p$ 为相应目标的权系数。

线性加权和法的步骤如下：

(1) 依目标的重要程度给出一组权系数 $\lambda_1, \dots, \lambda_p$ ,

其中 $\lambda_i \geq 0, i = 1, \dots, p, \sum_{i=1}^p \lambda_i = 1$ 。





## 多目标规划的解法

(2)将(VMP)转化为单目标问题

$$(P_\lambda) \quad \min_{X \in R} \sum_{i=1}^p \lambda_i f_i(X)$$

求解 $(P_\lambda)$ 得最优解 $\bar{X}$ 。

(3)可以证明, $\bar{X}$ 是(VMP)的弱有效解, 即 $\bar{X} \in R_{wp}^*$ 。进一步, 若所有权系数均为正, 即 $\lambda_i > 0, i = 1, \dots, p$ , 则 $\bar{X} \in R_{pa}^*$ 。

事实上, 当 $\lambda_i > 0, i = 1, \dots, p$ 时,  $h(F)$ 为严格单调函数, 故 $\bar{X} \in R_{pa}^*$ ; 而当 $\lambda_i \geq 0, i = 1, \dots, p$ 时,  $h(F)$ 为单调函数, 故 $\bar{X} \in R_{wp}^*$ 。





### 多目标规划的解法

- 确定权系数常用方法：特尔菲法、层次分析法、 $\alpha$ -法
- $\alpha$ -法的步骤（以两个目标为例）：

$$U[F(X)] = \alpha_1 f_1(X) + \alpha_2 f_2(X)$$

#### (1) 求解单目标优化问题

$$(\text{问题一}) \quad \min_{X \in R} f_1(X) = f_1(X^1) \quad , \quad \text{记}$$

$$f_1^1 = f_1(X^1), f_2^1 = f_2(X^1)$$

$$(\text{问题二}) \quad \min_{X \in R} f_2(X) = f_2(X^2) \quad , \quad \text{记}$$

$$f_2^2 = f_2(X^2), f_1^2 = f_1(X^2)$$





## 多目标规划的解法

(2)  $\alpha$ -方法的出发点:  $U[F(X^1)] = U[F(X^2)]$



$$\begin{cases} \alpha_1 f_1^1 + \alpha_2 f_2^1 = \alpha_1 f_1^2 + \alpha_2 f_2^2 \\ \alpha_1 + \alpha_2 = 1 \end{cases}$$



$$\alpha_1 = \frac{f_2^2 - f_2^1}{f_2^2 - f_2^1 + f_1^1 - f_1^2}; \quad \alpha_2 = \frac{f_1^1 - f_1^2}{f_2^2 - f_2^1 + f_1^1 - f_1^2}$$

(3) 求解  $\min_{X \in R} U[F(X)] = \min_{X \in R} [\alpha_1 f_1(X) + \alpha_2 f_2(X)]$

得  $X^*$






## 多目标规划的解法

$\alpha$ -方法的几何意义:

$X^1 \rightarrow (f_1^1, f_2^1): A$ 点;       $X^2 \rightarrow (f_1^2, f_2^2): B$ 点



(1) 平行直线簇

$$\alpha_1 f_1 + \alpha_2 f_2 = c;$$

(2) 同一条直线上 $X^1$ 与 $X^2$ 有相同的评价值, 即有

$$U[F(X^1)] = U[F(X^2)].$$





## 矩阵计算与优化 (最优化--随机与多目标优化)

例 设  $f_1(X) = 4x_1 + x_2 \rightarrow \min, f_2(X) = -3x_1 - 2x_2 \rightarrow \min$

有  $R = \{X \mid 2x_1 + x_2 \leq 4, x_1 + x_2 \leq 3, x_1, x_2 \geq 0, X \in R^2\}$

试用 $\alpha$ -法求解。

解：求解单目标优化问题，得  $X^1 = (0,0)^T, X^2 = (1,2)^T$

$$f_1^1 = f_1(X^1) = 0, f_2^1 = f_2(X^1) = 0$$

$$f_1^2 = f_1(X^2) = 6, f_2^2 = f_2(X^2) = -7$$

$$\alpha_1 = \frac{f_2^2 - f_2^1}{f_2^2 - f_2^1 + f_1^1 - f_1^2} = \frac{7}{13}, \quad \alpha_2 = \frac{6}{13}$$

$$U(X) = \frac{7}{13} f_1(X) + \frac{6}{13} f_2(X) = \frac{10}{13} x_1 - \frac{5}{13} x_2$$

求解LP

$$\min_{X \in R} U(X) = U(0,3) = -\frac{15}{13}$$





## 多目标规划的解法

### 一、评价函数法

1. 线性加权和法（ $\alpha$ -法确定权系数）

2. 理想点法

3. 目标规划法

### 二、目标排序法






## 2. 理想点法

**基本思想：**  $X$  的评价向量  $F(X) = (f_1(X), f_2(X), \dots, f_p(X))$  越接近理想点越好。

**理想点：** 一般指由各单目标最优值组成的  $p$  维点

$$F^* = (f_1^*, \dots, f_p^*)$$





### 理想点法的步骤：

- (1) 求理想点。求解 $p$ 个单目标最优化问题

$$\min_{X \in R} f_i(X) = f_i(X^i) = f_i^* \quad i = 1, 2, \dots, p$$

得理想点：  $F^* = (f_1^*, \dots, f_p^*)$

- (2) 检验理想点。绝对最优点，则输出绝对最优解，

$X^* = X^i$ ，求解完毕。否则，转（3）。





### 理想点法的步骤：

(3) 作评价函数。

$$U[F(X)] = \|F(X) - F^*\| = \left[ \sum_{i=1}^p (f_i(X) - f_i^*)^q \right]^{\frac{1}{q}}$$

(4) 求解  $\min_{X \in R} U[F(X)] \rightarrow \bar{X}$

**Note:** 上述评价函数是严格增函数，故按其求得的解是(VMP)的有效解。





## 矩阵计算与优化 (最优化--随机与多目标优化)

**例：** 设 $f_1(X)=-3x_1+2x_2$ ,  $f_2(X)=4x_1+3x_2$ 都要求实现最大, 约束集为 $R = \{X|2x_1+3x_2 \leq 18, 2x_1+x_2 \leq 10, x_1, x_2 \geq 0, X \in R^2\}$ , 试用理想点法求解。

**解：** 先分别求解两个单目标问题  $\max_{X \in R^2} f_i(X) \quad i=1,2$


$$X^{(1)}=(0,6), f_1^*=12; \quad X^{(2)}=(3,4), \quad f_2^*=24$$

$$\text{理想点 } F^*=(f_1^*, f_2^*)=(12,24)$$

$$\text{评价函数 } \min_{X \in R} [(f_1(X) - f_1^*)^2 + (f_2(X) - f_2^*)^2]^{\frac{1}{2}}$$

$$X^*=(0.53,5.65), \quad f_1^*=9.72, f_2^*=19.06。$$





## § 3 多目标规划的解法

### 一、评价函数法

1. 线性加权和法（ $\alpha$ -法确定权系数）
2. 理想点法
3. 目标规划法

### 二、目标排序法





### 3 目标规划法 (Goal Programming)

#### (一) 目标规划的思想

是求解多目标规划的一种常用方法。

该方法不考虑对各个目标进行极小化或极大化，而是希望在约束条件的限制下，每一目标尽可能地接近于事先给定的目的值。





## 矩阵计算与优化 (最优化--随机与多目标优化)

**例：**某工厂生产**I**、**II**两种产品，有关数据如下表：

|     | <b>I</b> | <b>II</b> | 资源量       |
|-----|----------|-----------|-----------|
| 原材料 | <b>2</b> | <b>1</b>  | <b>11</b> |
| 设备  | <b>1</b> | <b>2</b>  | <b>10</b> |
| 利润  | <b>8</b> | <b>10</b> |           |

决策者在原材料供应受严格限制的基础上，考虑尽量满足如下条件：

- (1) 首先，产品**II**的产量不低于产品**I** 的产量；
- (2) 其次，充分利用设备有效台时，不加班；
- (3) 再次，利润额不小于**56**元。





## (二) 目标规划的数学模型


分析:

(1) 在每个目标 $f_i(X)$ 上预先确定一个希望达到的目标值, 得一目标值向量

$$F = (f_1^0, f_2^0, \dots, f_p^0)$$

(2) 构造评价函数

$$\sum_{i=1}^p |f_i(X) - f_i^0|$$

(3) 多目标决策问题  单目标问题

$$\min_{x \in R} \sum_{i=1}^p |f_i(X) - f_i^0|$$

(其中 $R$ 为问题的可行域)





## 矩阵计算与优化 (最优化--随机与多目标优化)

(4) 为了求解(3), 引入类偏差变量

$$\min_{x \in R} \sum_{i=1}^p |f_i(X) - f_i^0|$$

正偏差  $d_i^+ = \begin{cases} f_i(X) - f_i^0, & f_i(X) > f_i^0 \\ 0 & f_i(X) \leq f_i^0 \end{cases} \quad i = 1, 2, \dots, p$

负偏差  $d_i^- = \begin{cases} 0 & f_i(X) \geq f_i^0 \\ f_i^0 - f_i(X) & f_i(X) < f_i^0 \end{cases}, \quad i = 1, 2, \dots, p$

可以证明 (3) 等价于

$$\min \sum_{i=1}^p (d_i^+ + d_i^-)$$

$$\begin{cases} f_i(X) - d_i^+ + d_i^- = f_i^0 \\ X \in R \\ d_i^+ \geq 0, d_i^- \geq 0 \end{cases} \quad i = 1, 2, \dots, p$$

目标约束  
(软约束)

绝对约束  
(硬约束)





实际问题中:

- ①各目标可赋予不同的优先因子 $P_j$  ;
- ②相同优先因子的两个目标的差别, 可分别赋予它们不同的权系数 $\omega_{ij}$

于是得到目标规划模型:

$$\begin{aligned} \min & \sum_{j=1}^l P_j \left( \sum_{i=1}^p \omega_{ji}^- d_i^- + \sum_{i=1}^p \omega_{ji}^+ d_i^+ \right) \\ & \begin{cases} f_i(X) - d_i^+ + d_i^- = f_i^0 \\ X \in R \\ d_i^+ \geq 0, d_i^- \geq 0 \quad (i = 1, 2, \dots, p) \end{cases} \end{aligned}$$





$$\begin{aligned} \min & \sum_{j=1}^l P_j \left( \sum_{i=1}^p \omega_{ji}^- d_i^- + \sum_{i=1}^p \omega_{ji}^+ d_i^+ \right) \\ & \begin{cases} f_i(X) - d_i^+ + d_i^- = f_i^0 \\ X \in R \\ d_i^+ \geq 0, d_i^- \geq 0 \quad (i = 1, 2, \dots, p) \end{cases} \end{aligned}$$

目标规划模型的特点:

- (1) 目标函数都是最小化, 只有偏差变量和优先因子 (不含一般决策变量);
- (2) 约束条件中既可包含目标约束, 还可包含绝对约束;
- (3) 目标约束均为等式; 且一般在一个约束中同时含有正、负偏差变量;





另外，根据决策者的不同要求，目标函数有三种基本形式：

（1）要求恰好达到目标值，评价函数为

$$\min \sum_{i=1}^p (d_i^+ + d_i^-)$$

（2）要求超过目标值，评价函数为

$$\min \sum_{i=1}^p d_i^-$$

（3）要求不超过目标值，评价函数为

$$\min \sum_{i=1}^p d_i^+$$





### (三) 目标规划建模举例

**例1:** 某工厂生产**I**、**II**两种产品，有关数据如下表：

|     | <b>I</b> | <b>II</b> | 资源量       |
|-----|----------|-----------|-----------|
| 原材料 | <b>2</b> | <b>1</b>  | <b>11</b> |
| 设备  | <b>1</b> | <b>2</b>  | <b>10</b> |
| 利润  | <b>8</b> | <b>10</b> |           |

决策者在原材料供应受严格限制的基础上，考虑尽量满足如下条件：

- (1) 首先，产品**II**的产量不低于产品**I** 的产量；
- (2) 其次，充分利用设备有效台时，不加班；
- (3) 再次，利润额不小于**56**元。





例1：某工厂生产**I**、**II**两种产品，有关数据如下表：

|     | <b>I</b> | <b>II</b> | 资源量       |
|-----|----------|-----------|-----------|
| 原材料 | <b>2</b> | <b>1</b>  | <b>11</b> |
| 设备  | <b>1</b> | <b>2</b>  | <b>10</b> |
| 利润  | <b>8</b> | <b>10</b> |           |

决策者在原材料供应受严格限制的基础上考虑：

- (1) 首先，产品**II**的产量不低于产品**I**的产量；
- (2) 其次，充分利用设备有效台时，不加班；
- (3) 再次，利润额不小于**56**元。

$$\begin{cases} \min [P_1 d_1^+ + P_2 (d_2^- + d_2^+) + P_3 d_3^-] \\ 2x_1 + x_2 \leq 11 \\ x_1 - x_2 + d_1^- - d_1^+ = 0 \\ x_1 + 2x_2 + d_2^- - d_2^+ = 10 \\ 8x_1 + 10x_2 + d_3^- - d_3^+ = 56 \\ x_1, x_2, d_i^+, d_i^- \geq 0 \quad (i=1, 2, 3) \end{cases}$$





## 矩阵计算与优化 (最优化--随机与多目标优化)

有一纺织厂生产尼龙布和棉布，平均生产能力都是1km/h，工厂生产能力为每周80h。根据市场预测，下周最大销售量为：尼龙布为70km，棉布45km。尼龙布利润为2.5元/m，棉布利润为1.5元/m。工厂领导的管理目标如下： $P_1$ ：保证职工正常上班，避免开工不足； $P_2$ ：尽量达到最大销售量； $P_3$ ：尽量减少加班时间，限制加班时间不得超过10h。

解：设决策变量 $x_1$ 、 $x_2$ 分别表示尼龙布和棉布的下周计划产量

$$\min [P_1 d_1^- + P_2 (5d_2^- + 3d_3^-) + P_3 d_1^+]$$

$$\begin{cases} x_1 + x_2 + d_1^- - d_1^+ = 80 \\ x_1 + d_2^- - d_2^+ = 70 \\ x_2 + d_3^- - d_3^+ = 45 \\ d_1^+ \leq 10 \\ x_1, x_2, d_i^+, d_i^- \geq 0 \quad (i = 1, 2, 3) \end{cases}$$





## (四) 目标规划的求解

### (1) 图解法

先考虑绝对约束；再考虑目标约束，并令目标约束中的偏差变量为0，作直线。

Step1 P1  $\rightarrow \triangle OBC$


Step2 P2  $\rightarrow$  线段ED

Step3 P3  $\rightarrow$  目标规划的解：线段GD. 其中，  
G(2,4), D(10/3,10/3)

注：该例求得最优解，且  $Z^*=0$ . 但大多问题可能无法满足所有约束，此时求满意解。


$$\min [P_1 d_1^+ + P_2 (d_2^- + d_2^+) + P_3 d_3^-]$$

$$\begin{cases} 2x_1 + x_2 \leq 11 \\ x_1 - x_2 + d_1^- - d_1^+ = 0 \quad \textcircled{1} \\ x_1 + 2x_2 + d_2^- - d_2^+ = 10 \quad \textcircled{2} \\ 8x_1 + 10x_2 + d_3^- - d_3^+ = 56 \quad \textcircled{3} \\ x_1, x_2, d_i^+, d_i^- \geq 0 \quad (i=1, 2, 3) \end{cases}$$





# 矩阵计算与优化 (最优化--随机与多目标优化)



$$\begin{aligned} \min \quad & P_1 d_1^- + P_2 d_2^+ + P_3 (2d_3^- + d_4^-) \\ \begin{cases} x_1 + x_2 + d_1^- - d_1^+ = 40 & \textcircled{1} \\ x_1 + x_2 + d_2^- - d_2^+ = 50 & \textcircled{2} \\ x_1 + d_3^- - d_3^+ = 24 & \textcircled{3} \\ x_2 + d_4^- - d_4^+ = 30 & \textcircled{4} \\ x_1, x_2, d_i^-, d_i^+ \geq 0, i=1, \dots, 4 \end{cases} \end{aligned}$$

分析: 1) 目标P1,P2 → 四边形ABCD;

2)  $d_3^-$ 的权系数大于 $d_4^-$ , 故优先考虑  $\min d_3^- \rightarrow$  四边形ABEF;

3) 四边形ABEF无法满足 $d_4^-=0$ , 故选取E为满意解, 使 $d_4^-$ 尽量小。





### （2）目标规划的单纯形法

与一般单纯形法的区别：

- （1）最优性准则：所有检验数  $\geq 0$ ；
- （2）检验数的正负，优先取决于P1的系数，其次P2……。
- （3）确定进基变量时，其在所有更高级目标函数下的检验数为0，使低级目标上的进基不影响所有高级目标上已获目标值。





### （2）目标规划的单纯形法

- 步骤：** 1) 建立初始单纯形表，在表中将检验数行按优先因子个数列成 $K$ 行，置 $k=1$ 。
- 2) 检查该行是否存在负数，且对应的前 $k-1$ 行的系数是0。若有负数，取最小者对应的变量为进基变量，转3)。若无负数，转（5）。
- 3) 按最小比值规则确定出基变量，当存在两个及以上相同的最小比值时，选取优先级较高的为出基变量。
- 4) 按单纯形法进行基变换运算，得新表，转（2）。
- 5) 当 $k=K$ 时，算法结束，得满意解。否则置 $k=k+1$ ,转（2）。





## 多目标规划的解法

### 一、评价函数法

1. 线性加权和法（ $\alpha$ -法确定权系数）
2. 理想点法
3. 目标规划法

### 二、目标排序法





## 多目标规划的解法

### 二、目标排序法（简介）

➤ **思想：**把目标按其重要性排序，设给出的重要性序列为 $f_1(X), f_2(X), \dots, f_p(X)$ ，然后按这种排序逐步进行一系列单目标优化，最后求出满意解。


➤ **方法**  **序列最优化法**  
**宽容意义下的序列优化方法**






## 1. 序列最优化法

$$\min_{X \in R} f_1(X) = f_1^*(X_1)$$



最优解集 $R_1$


$$\min_{X \in R_1 \subset R} f_2(X) = f_2^*(X_2)$$



最优解集 $R_2$


...

$$\min_{X \in R_{p-2} \subseteq R_{p-3}} f_{p-1}(X) = f_{p-1}^*(X_{p-1})$$



最优解集 $R_{p-1}$

$$\min_{X \in R_{p-1} \subseteq R_{p-2}} f_p(X) = f_p^*(X_p)$$



最优解 $X_p$

**缺点：** 由于某一步最优解唯一时，以后的目标的优化就不能进行下去了。





## 2. 宽容意义下的序列优化方法

预先给定  $\varepsilon_1 > 0, \varepsilon_2 > 0, \dots, \varepsilon_{p-1} > 0$  作为宽容值

$$\min_{X \in R} f_1(X) = f_1^*(X_1)$$

$$\min_{X \in R_1} f_2(X) = f_2^*, R_1 = \{X \mid f_1(X) < f_1^* + \varepsilon_1, X \in R\}$$

⋮

$$\min_{X \in R_{p-1}} f_p(X) = f_p^*(X_p), R_{p-1} = \{X \mid f_{p-1}(X) < f_{p-1}^* + \varepsilon_{p-1}, X \in R_{p-2}\}$$

则  $X_p$  为多目标问题的最优解。





## 矩阵计算与优化（最优化--随机与多目标优化）

### 多目标规划的Matlab求解

用目标达到法求解多目标规划的计算过程，可以通过调用Matlab软件系统优化工具箱中的fgoalattain函数实现。该函数的使用方法，如下：

**$X = \text{FGOALATTAIN}(\text{FUN}, X_0, \text{GOAL}, \text{WEIGHT})$**

**$X = \text{FGOALATTAIN}(\text{FUN}, X_0, \text{GOAL}, \text{WEIGHT}, A, B, A_{\text{eq}}, B_{\text{eq}}, LB, UB)$**

**$[X, FVAL, \text{ATTAINFACTOR}, \text{EXITFLAG}, \text{OUTPUT}] = \text{FGOALATTAIN}(\text{FUN}, X_0, \dots)$**





## 矩阵计算与优化（最优化--随机与多目标优化）

在MATLAB中，多目标问题的标准形式为：

$\gamma$  为一个松弛因子标量；  
 $F(x)$  为多目标规划中的目标函数向量。

$$\begin{aligned} \min_{x, \gamma} \quad & \gamma \\ \text{s.t.} \quad & F(x) - \text{weight} \cdot \gamma \leq \text{goal} \\ & C(x) \leq 0 \\ & \text{Ceq}(x) = 0 \\ & A \cdot x \leq b \\ & \text{Aeq} \cdot x = \text{beq} \\ & lb \leq x \leq ub \end{aligned}$$

其中： $x$ 、 $b$ 、 $\text{beq}$ 、 $lb$ 、 $ub$ 是向量；

$A$ 、 $\text{Aeq}$ 为矩阵； $C(x)$ 、 $\text{Ceq}(x)$ 和 $F(x)$ 是返回向量的函数；

$F(x)$ 、 $C(x)$ 、 $\text{Ceq}(x)$ 可以是非线性函数；

$\text{weight}$ 为权值系数向量，用于控制对应的目标函数与用户定义的目标函数值的接近程度；

$\text{goal}$ 为用户设计的与目标函数相应的目标函数值向量；





## 矩阵计算与优化 (最优化--随机与多目标优化)

例：某工厂因生产需要，欲采购一种原料，市场上这种原材料有两个等级，甲级单价2元/kg,乙级单价1元/kg，现要求总费用不超过200元，购得原料总量不少于100kg,其中甲级原料不少于50kg，问如何确定最好的采购方案。

分析:列出方程

$$x_1 \geq 50; 2x_1 + x_2 \leq 200; x_1 + x_2 \geq 100; x_1, x_2 \geq 0$$

化为标准形

$$\min f_1 = 2x_1 + x_2$$

$$\min f_2 = -x_1 - x_2$$

$$\min f_3 = -x_1$$

s.t :

$$2x_1 + x_2 \leq 200$$

$$-x_1 - x_2 \leq -100$$

$$-x_1 \leq -50$$

$$x_1, x_2 \geq 0$$





## 矩阵计算与优化 (最优化--随机与多目标优化)

化为标准形

$$\min f_1 = 2x_1 + x_2$$

$$\min f_2 = -x_1 - x_2$$

$$\min f_3 = -x_1$$

s.t :

$$2x_1 + x_2 \leq 200$$

$$-x_1 - x_2 \leq -100$$

$$-x_1 \leq -50$$

$$x_1, x_2 \geq 0$$

matlab程序

```
fun='[2*x(1)+x(2),-x(1)-x(2),-x(1)]';
```

```
a=[2 1;-1 -1;-1 0];
```

```
b=[200 -100 -20]';
```

```
goal=[200,-100,-50];
```

```
weight=goal;
```

```
x0=[55, 55];
```

```
lb=[0,0]';
```

```
[X,FVAL,ATTAINFACTOR,EXITFLAG,OUTPUT,LAMBDA]=fgoalattain(fun,x0,  
goal,weight,a,b,[],[],lb,[])
```





## 矩阵计算与优化 (最优化--随机与多目标优化)

Optimization terminated: Search direction less than 2\*options.TolX  
and maximum constraint violation is less than options.TolCon.

Active inequalities (to within options.TolCon = 1e-006):

| lower | upper | ineqlin | ineqnonlin |
|-------|-------|---------|------------|
|       |       | 2       | 2          |
|       |       |         | 3          |

x = 50.0000 50.0000

fval = 150.0000 -100.0000 -50.0000

attainfactor = -1.4476e-024

exitflag = 4





感谢聆听!